


GPT-5.5 기술동향 리포트

1. GPT-5.5 모델 라인업

별도 평가 대상



2. 에이전트 실행 능력

유의미한 성능 개선 확인

3. 벤치마크 결과 해석

항목별 선두 상이



4. Hallucination 완화 **추론**

개선되었으나 완전 해소 아님
별도 검증 필요



5. 비용 산정 주의사항 **주의**

토큰 단가가 아닌 작업 단위 총비용
xhigh 설정 오해 금지



6. 도입 전 거버넌스 권장

기록·검증·도구 범위·승인
통제 체계 선행 구축 필수




핵심 요약 (Executive Takeaways)



Fact

GPT-5.5 출시 확정

Thinking 2026-04-23 / Instant 2026-05-05 공식 출시



Fact

3종 모델은 별개 평가 대상

Thinking·Pro·Instant를 같은 증거로 비교 금지



Inference

이전트 실행 능력 개선

코드·도구 사용·긴 문맥 처리에서 가장 선택력 있는 증거



Inference

벤치마크 선두는 측정 대상에 따라 다름

SWE-Bench Pro-MCP Atlas에서는 Claude-Gemini가 앞섬



Caution

사실성 일부 개선 — 완전 해소 아님

허위 주장 감소 확인, 그러나 내부 평가 기준임



Caution

불확실 시 답변 보류 능력 별도 검증 필요

AA-Omniscience: Hallucination 86% — 내부 검증 필수


계열 모델 구분 (Variant Map)

GPT-5.5 제품군 주요 모델 및 특성 비교 분석



GPT-5.5 Thinking

- ☐ 복잡한 다단계 작업 전담
- ☐ 코드 작성 및 터미널 실행
- ☐ 웹 탐색 및 긴 문서 조사 수행



GPT-5.5 Pro

- ☐ 동일 기반 모델에 parallel test-time compute 증가 설정
- ☐ 더 긴 추론 시간으로 높은 신뢰성 확보



GPT-5.5 Instant

- ☐ ChatGPT 기반 모델 교체
- ☐ 기존 모델: GPT-5.3 Instant
- ☐ GPT-5.4 Instant 공식명 없음


추론 강도 (Inference Intensity): Low → Medium(기본) → High → xhigh(비동기 평가)

[Caution (Red)] xhigh 환경 점수 ≠ 실제 배포 성능 (연구 환경 vs production 설정 차이 구분 필수)

[Inference (Blue)] 세 모델은 별도 평가 객체 (같은 표 기재되나 동일 증거로 결론 도출 금지)

출시 타임라인 (Release Timeline)

GPT-5.5 기술동향 리포트



벤치마크 전체 표면 (Benchmark Surface)

벤치마크 성능 비교표

벤치마크	GPT-5.5 (연구/최적화)	GPT-5.4	Claude Opus 4.7 (경쟁사)
Terminal-Bench 2.0	82.7% 초록 #2E7D32, 인라인 라운드 필	75.1%	69.4%
MRCR 512K-1M	74.0% 파랑 #1565C0, 인라인 라운드 필	36.6%	32.2%
FrontierMath Tier 4	35.4% Fact badge	데이터 없음	22.9%
MCP Atlas (에이전트)	58.6%	데이터 없음	79.1% Inference
SWE-Bench Pro (에이전트)	58.6%	데이터 없음	64.3% Inference

설정 최적화 및 성능 상한선

Fact badge

- BrowseComp Pro 설정 시 90.1% 달성
- 기본 설정 84.4% 대비 성능 한계치 확장

기술 환경 및 운영 시 주의사항

Caution

- 발표 수치는 xhigh 연구 환경 기준 Fact badge
- production 환경 기본값은 medium, 실제 운영 성능과 상이함
- 발표 수치를 그대로 운영 성능으로 해석 금지


핵심 메시지 / Key Takeaways



코드 작업과 에이전트형 실행 / Code Tasks and Agent-like Execution

벤치마크별 성능 비교 및 고려사항 / Benchmark Performance Comparison & Considerations

터미널 벤치마크



[Fact: Green]
Terminal-Bench 2.0 리더
(Fact: Green badge)

- GPT-5.5 82.7% 달성 (선두)
- GPT-5.4(75.1%), Opus 4.7(69.4%) 대비 확고한 우위

출처: 내부 벤치마크 데이터

GitHub 이슈 벤치마크



[Fact: Green]
SWE-Bench Pro 최강
(Fact: Green badge)

- Claude Opus 4.7 선두 (64.3%)
- GPT-5.5 58.6% 기록 — 측정 대상 및 최적화 차이

출처: 내부 벤치마크 데이터

전문 평가 및 실행 지침



- Expert-SWE 내부 평가 (73.1% 기록)
Inference: Blue Caution
- 연구 환경 vs 실배포 설정 Caution
- xhigh 수치는 기본 medium과 차이 존재
- 작업 유형별 최적 모델 선택 Inference
- 용도별 검증 권장 Inference

출처: 내부 연구 데이터

7. 도구 사용과 컴퓨터 조작 | Tool Use and Computer Operation

GPT-5.5 기술동향 리포트

BrowseComp 성능

BrowseComp: 웹 검색 에이전트 성능

Fact



• Gemini 3.1 Pro(85.9%)에 근소 차이

MCP Atlas 성능

MCP Atlas: 외부 도구 사용 평가


Fact



OSWorld 성능

OSWorld: 컴퓨터 조작 실행

Fact




도구 설계 영향

Impact of Tool Design

Fact

checklist 항목
질문: 도구 선택, 파라미터, 순서 오류가 주요 실패 원인



OSWorld 성능

OSWorld Performance
OSWorld: 컴퓨터 조작 실행

Fact



도구 설계 영향

Impact of Tool Design
도구 설계가 결과에 미치는 영향

Caution


checklist



평가 vs 배포 차이

Evaluation vs Deployment
평가 환경과 실제 배포의 차이

Caution




핵심 판단

Inference

Fact

checklist 항목
질문: 도구 사용 선택은 벤치마크 및 실행에 따라 다름




질문: X, A, O의 성능 차이?

8. 긴 문맥 처리 (Long-Context Handling)

백만 토큰 문맥 지원 및 RAG 필수성

벤치마크 성능 비교 (Performance Comparison)

MRCR 512K~1M 성능 (Captions 11px)



주의 균일하지 않은 성능 분포에 유의. Graphwalks parents 1M 벤치마크에서는 Claude Opus 4.6 (72.0%) 선전.

현황 및 핵심 고려사항

문맥 창 크기 현황

- Thinking 유료 플랜 256K 지원
- Pro 플랜 400K 지원

추론) 큰 문맥 창이 정확한 인용을 자동으로 보장하지 않음.

RAG 설계 핵심 원칙

☐ 문서 조각 출처 기록 및 메타데이터 관리

☒ 인용 검증 및 출처 대조 체계 구축

출처: GPT-5.5 기술 리포트 (추정)

비용, 지연 시간, 추론 강도

GPT-5.5 기술동향 리포트

성능 및 비용 최적화 (TCO) 전략

모델별 API 운영 비용

■ Fact gpt-5.5 (표준):

- 입력: \$5.00 / 1M 토큰
- 출력: \$30.00 / 1M 토큰

■ Fact gpt-5.5-pro:

- 입력: \$30.00 / 1M 토큰
- 출력: \$180.00 / 1M 토큰

(비고: 고정확도 비동기 전용)



토큰 효율성 및 추론 강도 관리

■ Fact xhigh 강도 기준:

- 출력 토큰 약 40% 감소 확인
(비용 상쇄)

■ Inference 작업 난이도별 추론 강도 (4단계) 선택 기준:

- low→medium→high→xhigh



TCO 계산 및 단계적 도입 전략


■ Caution 실제 TCO 공식 적용 필수:

- 단가 × 토큰 수 + 재시도 + 검토
+ 지연 시간 손실



■ Fact 단계적 전환 권장 (A/B 평가):

- 작업별 비용·성능 검증 후
전사 확대



Hallucination 평가 방법론 / Hallucination Evaluation Methodology

평가 다각화 및 단일 지표 오남용 경계

Hallucination 평가 체계 및 주요 지표 비교

평가 방식 1: 내부 high-stakes 평가



GPT-5.3 Instant
(baseline)



GPT-5.5
(52.5% 허위 주장
감소)

[Fact] 선별 질문 묶음 기준
GPT-5.5 사실성 개선 핵심 지표

평가 방식 2: 사용자 신고 기반 평가



GPT-5.5
(37.3% 부정확 주장
감소)

[Inference] 사용자 피드백 분석 결과
과거 사실 오류 개선 정도 측정

평가 방식 3: AA-Omniscience 외부 평가



Claude 4.7 (참고):
36% Hallucination
비율



GPT-5.5:
86% Hallucination
비율

[Fact] AA-Omniscience 외부 벤치마크
GPT-5.5 Hallucination 문제점 부각



세 평가는 교환 불가능한 별개 측정값
질문 묶음 방법·조건이 상이하여 단일 운영 지표로 산출



answer-when-uncertain 능력 별도 검증 필요
신도용지대 답변 부류 여부는 사실성 개선 수치와 분리 평가



[Caution] 내부 개선 수치 ≠ 전체 트래픽 대표값
선별 질문 묶음 결과를 실제 운영 성능으로 확대 해석 금

사실성 vs 불확실성 표시

지식량과 답변 보류 능력을 기반으로 하는 2×2 분석 프레임워크

2×2 Analysis Framework Based on Knowledge and Deferral Ability

		지식 상태 / Knowledge State	
		알고 있음 / Know	모르고 있음 / Don't Know
답변 유형 / Answer Type	답변함 Answer	✓ 알고 → 답함 (이상적) GPT-5.5 지식량 증대로 이 영역 확장 확인	⚠ 모르면서 → 답함 위험 Ⓟ primary Ⓢ Caution Hallucination 핵심 위험 구간, 별도 내부 검증 필수
	보류함 Defer	⚠ 알지만 → 불충분 설명 Inference 근거·출처 누락 시 발생, 인용 정책으로 완화 가능	✓ 모르면 → 보류 (이상적) answer-when-uncertain 능력은 아직 미해결 과제



이상적 시나리오 ((✓)) Fact

지식량 증대로 정확한 답변 영역 확대 및
적절한 보류 능력 확보 목표



위험 시나리오 (⚠) Caution

지식 오류 및 근거 누락 등 Hallucination과
불충분 설명 방지 대책 마련 필요



평가팀 실용 가이드

오류 유형 세분화·도구 조건별·보류 허용 설계 권장

안전성과 사이버 능력 / Safety and Cyber Capability

AI 모델의 사이버 위험 평가 및 통제 체계

리스크 평가



사이버 영역 'High Capability' 판정

OpenAI 시스템 카드: 사이버보안·생물·화학 영역
고위험 능력 분류



UK AISI 외부 평가 결과 공식 확인


역공학 및 사이버 훈련장 end-to-end
작업 수행 사례



Instant 모델도 고위험군 분류

GPT-5.5 Instant, 'xhigh' 기준 첫 고위험 분류 모델

통제 및 대응



장기 자율성의 이중성

추론·코드 능력 향상이 악용 위험도 함께 높임

6단계 운영 통제 체계



방어적 활용과 위험의 균형

보안 분석·취약점 탐지 등 방어적 활용과 위험 통제 필요

[출처: OpenAI System Card, UK AISI Report]

활용 사례 매트릭스 (Use-Case Map)

최적의 GPT-5.5 모델 선택 및 제언



Fact=초록 #2E7D32

일상 보조 → GPT-5.5 Instant 권장
기본값 추론, 개인화·메모리 출처 통제 적용



Caution=빨강 #B71C1C

고위험 도메인은 RAG + 전문가 검토
사실성 개선 ≠ 의료·법률·금융 통제 해소



Caution=빨강 #B71C1C

코드 에이전트 처리 및 검토 필수
medium/high 추론, 격리 환경·diff 검토·
디플리기 경고 필수




Inference=파랑 #1565C0

대량 처리는 소형 모델 고려
GPT-5.5 강점이 과한 비용으로 나타날 수 있음



Inference=파랑 #1565C0

고난도 기술 검토는 xhigh 비동기
추적 로그·도구 예산·사람 확인 3중 통제



Caution=빨강 #B71C1C

xhigh 성능 != 운영 Baseline
production 기본값은 medium, 별도 검증 필요

배치 전 점검표 (Pre-Deployment Checklist)

안전하고 신뢰할 수 있는 GPT-5.5 배포를 위한 최종 필수 점검 목록

모델 및 시스템 구성

☐ 모델 유형·추론 강도 기록

Variant와 Effort 설정을 배포 기록에 남긴다

☐ 도구 권한·부작용 범위 사전 설정

도구 접근 범위와 부작용을 미리 제한한다

☐ 답변 보류(abstention) 허용

모를 때 멈추는 응답을 허용하고 보상한다

데이터 신뢰 및 운영 검토

☐ 사실 주장에 인용·출처 요구

모든 사실 주장에 출처 첨부을 의무화한다

☐ 운영 트래픽과 평가 차이 추적

오프라인 평가와 실제 운영 결과를 비교한다

☐ 고위험 도메인 사람 검토 유지

의료·법률·금융·보안은 반드시 전문가가 확인한다

경영진용 한 장 요약 / Executive Summary

핵심 요약 및 권고 사항 / Key Insights and Recommendations

무엇이 바뀌었나



Thinking, 에이전트·도구·긴 문맥 개선



Instant: 기본 모델 교체 / Pro: 고정확도 설정



먼저 시험해볼 항목

- ✓ Instant: 저위험 일상 보조
- ✓ Thinking: 코드·조사
- ✓ Pro: 고가치 비동기 작업

벤치마크 선두 비교

측정 대상에 따라 상이함.

터미널 작업: GPT-5.5 약점

코드 이해 해결: Claude Opus 4.7 약점



과대 해석 금지 사항



xhigh 점수를 production 기본값으로 제시 금지
Pro를 별도 아키텍처로 설명 금지

사실성 vs Hallucination **Caution**

사실성 개선 ≠ Hallucination 해소 **Fact**

불확실할 때 답변 보류 능력은 별도 내부 검증 필요

핵심 결론

'더 높은 권한 전에 기록·근거 검증·도구 범위·
사람 승인·되돌리기 경로를 먼저 갖출 것'