LECTURE NOTE ARCHIVE · 2026.10

퀀텀 머신러닝: 데이터, 학습과 양자 우위의 조건

수학의 기초에서 최신 연구의 주장까지
직접 계산하며 읽는 독립 학습 시리즈

CMU 17-620의 공개 실라버스에서 출발해 수학 준비편, 한영 용어 144항목, 80분 강의 18개와 풀이 72문제, 실습 5개, 최종 프로젝트 3개를 한 권으로 묶었다. 원강의 녹취·공식 교재·강사 승인 자료가 아니다.

책임 편집 김현중 · AI 보조 OpenAI Codex
근거 기준일 2026-10-20 · 판본 2.0
직접 실행 범위: CPU 기반 고전 시뮬레이션

퀀텀 머신러닝: 데이터, 학습과 양자 우위의 조건

CMU 17-620의 공개 실라버스에서 출발해 독립 집필한 **한국어 자율학습서 2.0**이다. 원 수업을 들을 수 없는 독자가 정의를 이해하고, 식을 유도하고, 작은 실험을 실행하며 최신 논문의 주장을 읽도록 구성했다. 원강의 녹취·공식 교재·강사 승인 자료가 아니다.

책임 편집: 김현중 · AI 보조: OpenAI Codex · 근거 기준일: **2026-10-20** · 판본: **2.0**

- 처음 시작하기: 학습 시간·14주 계획·통과 기준
- 수학 준비편: 복소수·선형대수·확률·최적화와 준비도 8문제
- 한영 용어집: 정의·기호·예·혼동 주의 144항목
- 원 강좌의 실라버스와 우리 시리즈 대응
- 브라우저용 전체 노트·용어 검색
- 통합 PDF
- 자율학습 기록지·풀이 작성 예·논문 읽기 양식
- 실행 가능한 실습과 실제 실행 결과
- 최종 프로젝트 3종
- 출처 목록과 확인 범위

시간에 맞춘 학습 설계

원 강좌는 강의 7회와 실습 5회, 각 80분으로 총 16시간이다. 우리의 독립 강의는 **18×80분=24시간**이며, 원 수업의 분량으로 표시하지 않는다. 각 강의에는 선수 지식, 확인 가능한 목표, 한영 핵심 용어, 시간별 순서, 단계별 유도, 계산 예제와 반례, **문제 4개와 힌트·완전 풀이**, 출구 점검, 원문에서 확인할 위치와 조건을 넣었다. 강의 문제는 총 **72개**이며 수학 준비도 8문제와 프로젝트는 별도다.

80분에는 핵심 유도와 선택 문제 1-2개를 다룬다. 나머지 문제·유도 재작성·오답 수정에는 각 강의 후 60-90분을 따로 쓴다. 사전 읽기, 수학 보충, 실습, 프로젝트 하나까지 포함한 전체 제안은 **74-100시간**이다. 이 시간은 학습 계획용 추정이며 독자 실험으로 측정한 값이 아니다. 세부 합계와 수준별 경로는 학습 안내에 있다.

내용을 읽었다는 이유만으로 다음 강으로 넘어가지 않는다. 핵심 용어 5개를 한영으로 설명하고, 유도 하나를 빈 종이에 재작성하고, 수치를 바꾼 예제와 반례를 설명하고, 문제 4개 중 3개를 해설 없이 푼 뒤 나머지 오류를 수정하는 기준을 제안한다. 이 기준은 학습을 돕는 자체 점검이며 공식 자격 평가가 아니다.

18개 강의

강	내용	직접 확인할 질문
01	학습 문제와 양자 우위의 주장	무엇을 같은 조건으로 비교하는가?
02	큐비트·게이트·측정	진폭·위상·shot 오차는 어떻게 연결되는가?
03	텐서곱·얽힘·회로	얽힘과 고전 모사의 어려움은 같은가?

강	내용	직접 확인할 질문
04	인코딩과 데이터 적재	로그 큐비트에 넣으면서 어떤 정보·비용을 잃는가?
05	거리와 양자 k-means	Fidelity 군집은 원래 k-means와 같은가?
06	QNN·재업로드·표현력	접근 가능한 Fourier 주파수와 학습 자유도는 어떻게 다른가?
07	Parameter shift와 훈련	정확한 미분식에도 왜 측정 비용이 드는가?
08	커널·SVM·특징공간	계산하기 어려운 커널이 학습에도 좋은가?
09	학습 가능성과 barren plateaus	작은 기울기의 원인과 예외는 무엇인가?
10	일반화·벤치마크	정확도와 자원 사용을 어떻게 공정하게 비교하는가?
11	QPU·하드웨어·자원	큐비트 수 외에 무엇을 세어야 하는가?
12	잡음·완화·정정	오류 완화는 언제 bias를 줄이고 비용을 늘리는가?
13	양자 데이터·classical shadows	역채널과 shadow norm은 무엇을 보장하는가?
14	우위와 탈양자화	시간·표본·메모리 우위는 어떻게 다른가?
15	Born machine·생성 학습	샘플링의 난도가 좋은 생성 모델을 보장하는가?
16	대칭·과학 학습	불변성·등변성과 물리적 라벨은 어떻게 연결되는가?
17	내결함성 QML	Block encoding·성공확률·논리 자원은 어떻게 연결되는가?
18	2025-2026 연구 읽기	최신 결과의 가정·실행 수준·미검증 범위는?

01과 13-18강은 원 실라버스 밖의 확장이다. 02-12강은 공개 주제를 보충하며 각 강의의 설명·유도·예제·문제와 해설은 독립 작성했다. 원강좌의 비공개 과제·영상·슬라이드는 사용하지 않았다.

실습과 최신 연구의 확인 범위

실습은 Bell 상태·미분, 인코딩·군집, 커널/VQC와 고전 기준선, 자원·샷 장부, 잡음·완화의 다섯 주제다. NumPy 참조 코드는 작은 상태벡터와 확률 모형을 계산한다. PennyLane 교차검증은 별도 설치 경로로 제공한다. 정확한 명령·의존성·실행 수치는 실습 안내를 기준으로 한다.

직접 실행한 것은 **CPU 기반 교육용 고전 시뮬레이션**이다. 실제 QPU 실행·대규모 논문 재현·실용적 양자 우위 입증을 수행하지 않았다. 작은 실습의 점수는 해당 데이터·분할·모델·seed의 결과이며 일반 성능 순위가 아니다.

2025-2026년의 광학 양자 학습, 학습 가능성과 고전 모사성, 잡음이 있는 학습, 양자 메모리를 쓰는 대규모 고전 데이터 처리, 생성 학습, quantum uploading을 다룬다. 출판·최초 공개·수정일을 구별하고 사전공개 연구는 상태를 표시한다. 작은 예의 자체 증명, 출처의 조건부 정리, 저자가 보고한 장치 실험, 향후 프로젝트를 구별했다. 기준일의 모든 논문을 망라한

체계적 문헌조사는 아니다.

보존·재생성

`lectures/`와 루트의 학습 문서는 편집 가능한 정본, `labs/`는 재현 코드·환경·결과, `dist/`는 최종 공개 HTML·수식·승인 코드, `output/pdf/`는 통합 PDF다. `research/`의 작업 메모와 `tmp/`의 QA 화면은 배포하지 않는다. 수집 원문·접속 정보·개인 메일·내부 경로도 배포물에서 제외한다.

HTML은 `artifacts/build_notes.mjs`, PDF와 반응형 QA는 `artifacts/print_notes.mjs`로 생성한다. `artifacts/README.md`에 도구 버전과 순서를 기록한다. 완성본에는 개인 환경 경로를 기록하지 않는다. 표지는 판본과 범위를 식별하는 텍스트 조판이며 기존 리뷰 표지를 교체하지 않았다.

판본과 작성·검증 공개

1.0판은 18강·54문제·실습 5개의 초기 아카이브다. 2.0판은 사용자의 "강의 시간에 맞는 학술적 깊이, 수강 없이 가능한 자율학습, 명확한 terminology" 요청에 따라 18강을 전면 확장하고, 수학 준비편·용어 144항목·문제 72개·학습 기록지를 추가했다. 동일 아카이브 ID에서 최신 판을 제공하며 첫 판 PDF는 내부 판본 기록으로 보존한다.

입력은 공개 게시물·공식 실라버스·원 논문·공식 교육 및 SDK 문서다. OpenAI Codex의 **root**가 통합 편집·수학 준비편·용어집·HTML/PDF·아카이브를, **revise_foundations**가 01-06강·학습 안내·기록지를, **revise_learning**이 07-12강을, **revise_research**가 13-18강과 관련 문헌 확인을 맡았다. 초기 실습·프로젝트는 **qml_labs**가 작성·실행했다. 정확한 실행 모델 식별자는 별도로 보존되지 않아 추정하지 않는다. 적용 하네스는 AI Tech Review Editorial Harness 2026.08이다.

수학 검토는 작성 역할을 바꿔 수행했다. root가 01-06강을, revise_research가 07-12강을, revise_learning이 13-18강을 검토했고, revise_foundations가 수학 준비편·용어집을 검토했다. 정의의 복소 내적 관례, 재업로드와 주파수의 구별, 군의 공리를 이 과정에서 수정했다. 작은 계산을 독립 재계산하고 문헌의 가정을 대조했지만 원 논문 전체 증명·대규모 데이터·실제 장치 결과를 독립 검증하지는 않았다. 사람은 주제와 개정 방향을 요청했으며 문장·문제별 사람 심사를 마쳤다고 주장하지 않는다. 오류나 후속 결과가 확인되면 판본과 근거 시점을 함께 갱신한다.

CMU 17-620 공개 실라버스와 독립 학습 시리즈의 대응

책임 편집: 김현중 · AI 보조: OpenAI Codex · 확인일: 2026-10-20 · 작성·검증 원칙

어떤 강좌인가

사용자가 제공한 LinkedIn 단축 링크는 Daniel Justice의 강좌 소개 게시물로 연결된다. 게시물 안의 강좌 링크를 따라 The Quantum Turtle의 공식 강좌 홈페이지와 세션별 공개 개요 12개를 확인했다. 검색 결과에 함께 나오는 11-860 및 과거 연도 강좌는 이번 수업과 구별했다.

항목	공개 페이지에서 확인한 내용
강좌	Carnegie Mellon University, 17-620: Quantum Machine Learning
담당	Daniel Justice, Rita Singh
학기	Fall 2026, Mini-2
기간	2026-10-20–2026-12-03
수업	화·목 08:00–09:20 미국 동부 현지시간, 대면
분량	6 units, 강의 7회·실습 5회, 각 80분으로 총 16시간
핵심 도구	PennyLane; 공개 개요에 Qiskit·Cirq·TensorFlow Quantum·Braket도 언급
목표	양자 학습 모델의 구현, 인코딩·군집·분류, 실제 장치 비교, 잡음과 완화의 효과·한계
공개 범위	홈페이지의 시간표와 각 세션의 주제 개요. 과제·추가 공지는 Canvas로 안내

미국 동부는 이 기간 중 서머타임이 바뀐다. 한국 시각은 10월 수업 21:00–22:20, 11월 5일 이후 수업 22:00–23:20에 해당한다. 이것은 시간대 변환 설명이며 원격 수강 가능 여부를 확인했다는 뜻이 아니다. 공개 Zoom·Canvas·Piazza 주소와 접속 정보는 이 배포본에 옮기지 않았다.

페이지의 마지막 갱신 표시는 2026-10-19다. 다음 표는 2026-10-20에 확인한 계획이며 실제 진행·향후 변경을 보증하지 않는다. 강의 영상·슬라이드·비공개 과제에 접근하거나 수업을 청강하지 않았다. 성적 배점과 공식 선수 과목은 확보한 페이지에서 확인하지 못해 만들지 않았다.

원 강좌의 세션별 계획

아래 내용은 공개 항목을 간결하게 한국어로 요약한 것이다. 상세 유도·연습·코드는 원 수업을 복제하지 않고 이 시리즈에서 새로 작성했다. 기존 URL slug가 화면 제목과 다른 경우에는 현재 화면의 제목·날짜를 우선했다.

날짜	구분·공개 세션	확인한 주제의 요약	우리 노트
10-20	Lecture 1: Foundations 1	큐비트·Bloch 구·게이트·측정	02
10-22	Lab 1: PennyLane Fundamentals	환경·회로·미분·Bell 실험	02-03, 07, 실습 1
10-27	Lecture 2: Foundations 2	얽힘·보편 게이트·복제 불가·SDK	03
10-29	Lecture 3: Encoding and k-means	인코딩·적재 비용·군집 복잡도	04-05
11-03	휴강	Democracy Day	—
11-05	Lecture 4: Perceptrons, MLPs, QNNs	고전 신경망·하이브리드·재업로드·표현력	06-07
11-10	Lab 2: Encoding and k-means	작은 군집 실험·고전 비교	실습 2
11-12	Lab 3: Hardware and Benchmarking	QPU 실행·샷·대기·시간·에너지	10-11, 실습 4
11-17	Lecture 5: Linear and Variational Classifiers	분류·최적화·커널·학습 가능성	07-10
11-19	Lab 4: VQC in PennyLane	변분 모델·자동미분·MLP 비교	실습 3
11-24	Lecture 6: Hardware 1	큐비트 구현·프로세서 비교·에너지	11
11-26	휴강	Thanksgiving	—
12-01	Lab 5: Noise and Mitigation	잡음·깊이·샷·ZNE·측정 보정	12, 실습 5
12-03	Lecture 7: Hardware 2	오류·완화와 정정·장치 지표	11-12

원강좌 Lab 3은 IBM Quantum·IonQ·Rigetti 및 Braket 경로를 언급한다. 해당 플랫폼 이용권·과금·현재 connector 지원을 우리가 확보했다는 뜻은 아니다. 원강좌 Lab 4는 PyTorch 또는 JAX와의 결합 및 MLP 비교를 제안한다. 우리의 필수 실습은 설치 부담이 적은 NumPy 참조 구현과 고전 RBF·삼각 특징 기준선을 사용하므로 공식 Lab 4의 과제를 동일하게 수행한 것이 아니다.

우리가 추가한 내용

원 계획의 세션을 그대로 18회라고 늘려 부르지 않는다. 공개 주제를 02-12강에서 더 작은 개념 단위로 풀고, 준비 강의 01과 연구 확장 13-18을 붙였다. 그 결과는 다음과 같은 독립 커리큘럼이다.

부분	범위	원 계획과의 관계
준비	01: 학습 문제·입출력·우위의 자원 정의	우리 추가
기초와 모델	02-06: 상태·얽힘·인코딩·군집·QNN	원 강의 1-4를 보충

부분	범위	원 계획과의 관계
훈련과 검증	07-12: 미분·커널·plateau·일반화·장치·잡음	원 강의 5-7을 보충
연구 확장	13-18: 양자 데이터·우위·생성·대칭·내결함성·최신 논문	원 실라버스 밖의 우리 추가
실습·연구	자체 실습 5개와 프로젝트 3개	원 실습 주제를 참고한 별도 설계

원 페이지가 소개하는 도서명은 *Practical Quantum Machine Learning and Quantum Optimization*, *Machine Learning with Quantum Computers*, *A Gentle Introduction to Quantum Computing*이다. 공개 페이지의 도서 표기와 모든 연결 파일의 서지 일치까지 검증한 것은 아니며, 강의별 핵심 주장은 별도로 확인한 원 논문·공식 문서를 인용한다.

보존과 갱신

원강좌의 변경 이력과 우리 노트의 개정을 별도로 기록한다. 새 주제를 추가할 때에는 논문의 최초 공개일·채택본·수정일을 구별하고, 근거 기준일 뒤의 결과를 이번 판에 섞지 않는다. 이 문서의 원 페이지 대조는 Codex가 수행했으며 사람의 문장 단위 검토는 아직 받지 않았다.

혼자 따라가는 학습 안내: 학습 시간, 선수 관계와 이해도 점검

> 독립 학습 시리즈 2.0 · 근거 기준일 2026-10-20. 원 수업에 참석하거나 비공개 강의 자료를 확인한 결과가 아니다. 아래 시간과 진도 판정은 이 자료를 공부하기 위한 제안이며, 실제 수강 기록이나 검증된 교육 효과 측정값이 아니다.

이 시리즈의 목표는 실라버스의 제목을 아는 데서 그치지 않고, 핵심 식을 유도하고, 숫자를 바꾸어 계산하고, 주장의 가정을 찾아내는 것이다. 각 강의는 정의·유도·완전 예제·반례·문제와 풀이를 포함한다. 외부 교재는 심화 학습용이다. 본문의 기본 계산을 따라가기 위해 별도의 유료 교재나 원강좌 수강을 요구하지 않는다. 다만 연구 논문의 모든 정리와 부록 증명을 이 노트가 대체하지는 않는다.

처음에는 수학 보충편, 용어를 찾을 때는 한영 용어집, 실제 공부 기록에는 자율학습 워크북을 사용한다. 본문 길이나 PDF 쪽수보다 직접 남긴 계산과 설명으로 이해도를 판단한다.

원강좌 시간과 독립 학습 시간을 구별한다

공개 실라버스의 CMU 원강좌는 7개 lecture와 5개 lab을 각각 80분으로 안내한다. 총 12세션, 960분, 16시간이다. 실라버스 정리는 그 공개 범위를 기록한다. 이 시리즈는 범위를 확장한 **이론 18강 × 80분 = 24시간**의 자체 구성이다. 원강좌의 7강이 실제로 18강으로 진행되었다는 뜻이 아니다.

80분은 용어 확인, 식 전개, 예제 재계산, 선택 문제와 회상을 포함한 한 세션이다. 장마다 문제 네 개를 수록했지만, 첫 세션에는 핵심 1-2개를 먼저 풀고 나머지와 오답 수정은 복습에 배정한다. 자세한 시간표는 각 강의의 “80분 학습 순서”를 따른다. 처음 보는 수학 때문에 더 오래 걸리면 시간을 늘리고, 이해가 부족한 채 시계에 맞춰 다음 강의로 넘어가지 않는다.

학습 활동	제안 배정	합계의 의미
수학 보충편 P1-P8	4-8시간	예제·준비도 문제 재계산
강의 전 준비	18 × 20분 = 6시간	선수 개념과 용어 미리 확인
이론 첫 세션	18 × 80분 = 24시간	강의별 활동 시간표
강의별 복습	18 × 60-90분 = 18-27시간	네 문제 완전 풀이·유도 회상·오답 수정
필수 실습 5개	합계 10-15시간	실행·조건 변경·결과 해석 포함
최종 프로젝트 1개	12-20시간	세 제안 중 하나를 선택
전체	**74-100시간**	원문 전문 독해를 무제한 포함한 시간이 아님

합계는 하한 4+6+24+18+10+12=74시간, 상한 8+6+24+27+15+20=100시간이다. 실험 실패, 기초 보충, 논문 증명 독해, 실제 QPU 이용에는 추가 시간이 들 수 있다. 연구 경험이 있는 독자는 준비 부분을 진단으로 대체할 수 있지만, 생략한 내용을 이해한 것으로 자동 처리하지 않는다.

출발 준비도와 학습 환경

수학 보충편의 준비 문제 8개를 풀이를 가리고 시도한다. **6개 이상 독립적으로 해결하고, 틀린 문제를 해당 절로 돌아가 다시 푸는 것**을 시작의 권장 기준으로 삼는다. 이 기준은 표준화된 시험이나 교육적으로 검증된 합격선이 아니다. 총점보다 켤레 내적·부분 trace·평균의 분산·chain rule 중 무엇이 막히는지 찾는 데 쓴다. 한 문제라도 계산 과정을 설명할 수 없으면 그 절을 표시한다.

막히는 계산	먼저 돌아갈 준비 절	바로 연결할 강의
복소수·전역 위상·켤레	P1, P2	02
고유값·PSD·역행렬	P3	02, 05, 08, 17
여러 큐비트·부분계	P4, P5	03, 13
shots·bias·신뢰구간	P6	02, 07, 10, 12
손실 미분·경사하강	P7	06-07
데이터 분할·복잡도 표기	P8	01, 10-11, 14, 17

실습은 실습 안내의 고정 환경을 따른다. CPU에서 실행하는 NumPy 경로가 기본이며 PennyLane은 별도의 교차검증 경로다. QPU 계정이나 유료 API 없이 핵심 계산과 다섯 실습을 진행할 수 있다. 실제 장치에 제출하지 않은 결과를 QPU 측정으로 기록하지 않는다. 설치·실행 로그와 관측값은 워크북에 버전·seed·실행 수준과 함께 남긴다.

한 강의를 혼자 공부하는 절차

사전 20분에는 제목과 학습 목표를 읽고 선수 강의의 식 하나를 빈 종이에 다시 쓴다. 처음 보는 영어 용어는 최대 다섯 개를 골라 한영 이름, 정의, 기호를 미리 적는다. 모든 정의를 외우고 시작하려고 하지 않는다. 80분 세션에는 각 식의 왼쪽과 오른쪽이 같은 종류의 대상인지 확인하고, 완전 예제의 숫자를 직접 재계산한다. 답을 읽기 전에 다음 줄을 예측해 본다.

복습 60-90분에는 본문을 덮고 유도 하나를 다시 만든다. 이어 네 문제를 모두 시도하고, 어떤 문제에서 정의·기술·가정이 부족했는지 표시한다. 힌트나 풀이를 본 문제는 해결했다고 끝내지 않고, 나중에 숫자나 조건을 바꾸어 다시 푼다. 유도에서 생략했던 중간 행렬곱, 분산의 독립성, 최적화 상계의 부등호 방향을 채운다.

원문 읽기는 본문의 모든 계산을 처음부터 외부 논문으로 대체하는 활동이 아니다. 강의 끝에서 지정한 공개 절을 읽고 “노트의 식과 같은 규약인가”, “정리 조건은 무엇인가”, “여기서 직접 확인한 범위는 어디까지인가”를 기록한다. 읽지 않은 증명을 읽었다고 표시하거나 초록의 주장을 전체 증명 검증으로 옮기지 않는다.

모르는 영어 용어가 세 개 이상 겹칠 때

한 문장에 낯선 용어가 세 개 이상 있으면 문장 전체를 번역해 암기하기보다 동작을 나눈다. 우선 무엇이 입력이고 무엇이 출력인지 적고, 명사에는 대상, 동사에는 연산, 부사·형용사에는 조건이라는 표시를 붙인다. 용어집에서 가장 핵심인 하나를 찾아 식으로 연결한 뒤 원문으로 돌아간다. 여전히 설명할 수 없는 두 단어를 다음으로 확인한다.

예를 들어 *efficient coherent state preparation with sample-and-query access*를 만나면 efficient의 입력 크기·오차 변수를, coherent의 중첩 보존 의미를, state preparation의 실제 출력 상태를 따로 적는다. sample-and-query가 고전 접근 가정인지 문맥을 확인한다. 같은 SQ가 statistical query도 뜻할 수 있으므로 약자만 보고 같은 모형이라고 결론 내리지 않는다.

용어 카드에는 한국어·영어 이름, 한 문장 정의, 식 하나, 닮았지만 다른 말 하나를 적는다. “fidelity = 충실도”만 쓰는 것은 정의를 아는 증거가 아니다. 순수 상태에서 절댓값 제곱이라는 식과 내적 부호를 잃는 반례까지 쓰면 다음 읽기에 사용할 수 있다. 다음날에는 영어 이름을 보고 식을, 그 다음에는 식을 보고 의미를 회상한다.

강의별 선수 관계와 남길 결과

표의 선수 관계는 자체 학습 설계다. 번호는 원강좌 lecture 번호가 아니라 이 시리즈의 번호다. 앞 강의 전체를 완벽히 외워야 한다는 뜻이 아니라, 해당 계산과 정의를 다시 만들 수 있어야 한다는 뜻이다.

강의	먼저 확인할 내용	완료 때 남길 한 가지 결과
01 문제와 주장	P2·P6·P8	위험의 세 원인과 shots를 포함한 비용 장부
02 큐비트와 측정	P1-P3·P5-P6, 01	같은 Z 통계의 중첩·혼합을 구별하는 계산
03 얽힘과 회로	02, P4	Bell 부분 trace와 추가 기저의 상관
04 인코딩과 적재	02-03	norm·부호 손실 반례와 product 커널 유도
05 군집과 거리	04, P3	유클리드 평균과 projective 중심 갱신 비교
06 QNN과 표현력	02·04, P7	회로 출력의 Fourier 전개와 관측 불가 파라미터
07 미분과 훈련	06, P6-P7	공유 파라미터의 올바른 미분·측정 분산
08 커널과 SVM	01·04, P3·P7	Gram 행렬과 예측·정규화의 식
09 학습 가능성	06-07, P6	기울기 분산 감소의 가정과 반례
10 일반화와 비교	01·08-09, P8	누수 없는 평가 분할과 불확실성 설명
11 하드웨어와 자원	03·07, P8	게이트·회로·샷·시간 단위를 분리한 장부
12 잡음과 완화	02·07·11, P6	완화 전후 bias·variance·MSE 비교
13 양자 데이터와 shadows	02-03·12	국소 Pauli 추정자와 관측량별 비용
14 우위와 탈양자화	01·04-05·10-11	입력 접근·출력·정밀도를 맞춘 비교 계약
15 생성형 모델	06-07·10·13	생성 손실과 놓치는 고차 상관의 반례
16 대칭과 과학 학습	03·06·10	불변·등변 출력과 틀린 대칭 가정의 반례
17 내결함성 QML	04·11-12·14, P3	선형계의 조건수·해 상태·출력 비용 계산
18 2025-2026 연구	09-17의 관련 주제, 특히 10·14	최근 논문 두 편의 가정·증거·미검증 범위

14주 권장 배치

74-100시간을 14주에 배분하면 평균 약 주 5-7시간이다. 이는 각 주의 작업량이 같다는 뜻은 아니다. 두 강의와 실습이 겹치는 주는 더 길 수 있으므로 다음 주의 복습 시간을 함께 사용한다. 추가 수학 보충이 필요하면 주 수를 늘린다.

주	이론·실습	주말까지 남길 결과
1	수학 보충편·01	준비도 진단과 위험·비용 장부
2	02-03·Lab 1	Born 확률·Bell 상관·측정 분산의 손계산과 실행 비교
3	04-05·Lab 2	인코딩 충돌과 서로 다른 군집 목적함수의 해석
4	06-07	재업로드의 계수 제한·공유 파라미터 미분
5	08-09·Lab 3 시작	커널·VQC·고전 기준선의 비교 조건
6	10·Lab 3 분석	seed·데이터 분할·불확실성을 반영한 결과표
7	11-12·Lab 4	자원 장부와 잡음에 따른 신호 변화
8	12 복습·Lab 5	bias 감소와 분산 증가를 함께 설명하는 분석
9	13-14	양자 데이터 접근과 탈양자화의 비교 계약
10	15-16	생성 분포 평가·대칭 가정의 반례
11	17	조건수·논리 자원·최종 출력의 수치 예제
12	18	기준일까지의 논문 두 편을 읽은 기록과 프로젝트 질문
13	프로젝트 설계·구현	질문·가정·비교 기준·실행 가능한 코드
14	프로젝트 검증·집필	결과·실패 분석·재현 명세

다음 강의로 넘어갈 때의 자기평가

다음 네 가지를 강의마다 워크북에 남긴다. 권장 기준이며 객관식 시험의 검증된 합격선이 아니다.

- 핵심 용어 다섯 개를 한국어·영어 이름과 함께 정의하고, 닮은 용어와 차이를 설명한다.
- 핵심 유도 하나를 중간 단계를 생략하지 않고 다시 쓴다. 기호의 뜻과 독립성·정규화 등 가정을 표시한다.
- 예제의 숫자나 조건을 바꾸어 새 계산을 하나 하고, 주장이 깨지는 반례를 하나 든다.
- 네 문제 중 세 개 이상을 답·힌트를 보지 않고 풀고, 남은 문제는 해설 확인 뒤 스스로 다시 풀어 오답을 수정한다.

용어만 막히면 용어집과 해당 강의 “핵심 용어”로 돌아간다. 행렬곱·미분이 막히면 수학 준비 절로, 왜 그 식을 쓰는지 설명이 막히면 위 선수 관계 표의 앞 강의로 돌아간다. 숫자는 맞지만 가정을 말하지 못하면 그 문제를 완료로 표시하지 않는다. 예를 들어 fidelity를 유클리드 거리로 바꾼 오류는 계산기를 더 사용하는 대신 04-05강의 정보 손실과 거리 정의를 다시 공부한다.

실습과 프로젝트에서 학습을 확인한다

실습마다 변경 전의 예상값, 실제 출력, 차이의 원인, 실행 수준을 적는다. seed 변경으로 달라지는 값과 닫힌 식으로 고정되는 값을 구별한다. 표준편차·신뢰구간·평균 bias를 혼용하지 않고, 상태벡터의 정확 기대값과 finite-shot 추정을 따로 기록한다. 오류가 없다는 로그 하나보다 조건을 바꾸어 예측한 현상이 나타났는지가 이해의 증거다.

최종 프로젝트는 세 제안 중 하나를 택한다. 질문 하나, 강한 비교 기준 하나, 실패할 수 있는 조건 하나를 정한 뒤 실험 범위를 고정한다. 전체 데이터와 모든 최신 논문을 한 프로젝트에 담으려고 하지 않는다. 최종 보고서에는 재현한 것, 저자가 보고한 것을 인용한 것, 자신의 해석과 후속 제안을 분리한다. 근거 기준일 이후 논문을 추가하면 새 자료의 날짜·판본과 변경 범위를 따로 기록한다.

최종 점검에서는 다음을 각각 반례나 식과 함께 답한다. 같은 계산 기저 분포인데 다른 상태가 가능한가? 로그 큐비트 표현은 왜 공짜 적재가 아닌가? 큰 상태공간은 왜 좋은 커널을 보장하지 않는가? shots를 늘려도 남는 오류는 무엇인가? 양자 데이터의 표본 우위와 고전 표 데이터의 실용 우위는 어떻게 다른가? 답이 막히면 각각 02-03, 04, 08-09, 12, 13-14강으로 돌아간다.

수학 보충편: 식을 읽고 직접 계산하기 위한 준비

이 보충편은 양자역학을 미리 배웠다고 가정하지 않는다. 복소수, 선형대수, 확률과 미분에서 본문에 실제로 쓰는 계산을 정리한다. 원 강좌의 공식 선수 과목이나 수업 자료가 아니라, 독립 학습 시리즈 2.0판을 위해 작성한 준비 과정이다. 개념별 정확한 뜻은 용어집에서 다시 찾을 수 있다.

처음 공부한다면 P1-P4에 2-4시간, P5-P8에 2-4시간을 배정한다. 이것은 제안 시간이며 숙련도를 측정한 결과가 아니다. 식을 눈으로 읽고 넘어가기보다 각 예제를 종이에 재계산한다. 마지막 준비도 문제에서 막히면 표시된 절로 돌아온다. 외부 교재는 추가 학습용이며 이 보충편의 예제를 푸는 필수 조건은 아니다.

P1. 복소수와 진폭: 확률과 같은 수가 아니다

복소수는 $z = a + ib$, $i^2 = -1$로 쓴다. a와 b는 실수다. 켤레는 $z^* = a - ib$, 절댓값은 $|z| = \sqrt{a^2 + b^2}$다. 따라서 $z^* z = a^2 + b^2$는 음수가 아니다. 양자 상태의 성분은 확률이 아니라 복소 진폭(amplitude)이며, 측정 확률에는 진폭의 절댓값 제곱을 쓴다.

예를 들어 $z = (1 + i)/2$라면

$$z^* z = \frac{(1 - i)(1 + i)}{4} = \frac{1 - i^2}{4} = \frac{1}{2}.$$

반면 $z^2 = i/2$는 복소수이며 확률로 사용할 수 없다. 제곱과 절댓값 제곱을 구별하는 것이 첫 번째 준비다.

복소수는 $z = re^{i\phi}$로도 나타낸다. Euler 관계 $e^{i\phi} = \cos\phi + i\sin\phi$에서 r는 크기, ϕ는 위상이다. 위상각의 단위는 라디안이며 $180^\circ = \pi$다. 각도 인코딩에 원래 데이터의 물리 단위를 넣을 때에는 라디안으로 보내는 무차원 변환이 필요하다.

간섭을 계산하는 예. 진폭 a, b를 합친 뒤 확률을 구하면

$$|a + b|^2 = |a|^2 + |b|^2 + 2\,\mathrm{Re}(a^* b).$$

마지막 항은 간섭항이다. $a = b = 1/2$이면 합친 확률은 1이며, $a = 1/2, b = -1/2$이면 0이다. 두 경우에 개별 크기의 제곱은 모두 1/4이다. 어떤 회로의 경로 진폭을 더하는 상황인지 먼저 정해야 하며, 서로 구별되는 고전적 사건의 확률을 임의로 진폭처럼 더하지 않는다.

준비 확인. $(1 + i)/\sqrt{2}$의 절댓값은 1이다. 절댓값 제곱이 2라고 계산했다면 분모도 제곱해야 한다는 점을 다시 확인한다. 02강에서 위상을 측정 결과로 바꾸는 회로를 다룬다.

P2. 벡터·내적·행렬: shape부터 확인한다

d차원 복소 열벡터 v는 $d \times 1$ 배열이다. 전치 v^T는 행과 열만 바꾸고, 켤레전치 $v^\dagger$는 성분을 켤레 처리한 뒤 전치한다. 복소 내적은 $\langle u, v \rangle = u^\dagger v$로 정의한다. 이 노트는 첫 번째 인자에 켤레가 들어가는 물리학 관례를 사용한다.

$$u = \frac{1}{\sqrt{2}}\begin{pmatrix}1\\ i\end{pmatrix}, \qquad v = \frac{1}{\sqrt{2}}\begin{pmatrix}1\\ -i\end{pmatrix}, \qquad u^\dagger v = \frac{1 + (-i)(-i)}{2} = 0.$$

이 두 벡터는 직교한다. 켤레를 빼고 $u^T v$를 계산하면 1이 나와 잘못된 판정을 한다. 벡터 노름은 $\|v\|_2 = \sqrt{v^\dagger v}$이며, $v \neq 0$일 때 $v/\|v\|_2$로 정규화한다. 정규화는 방향을 남기고 전체 크기를 없애므로 원 데이터의 크기가 필요한 학습 문제에서는 추가 정보가 필요하다.

행렬 $A \in \mathbb{C}^{m\times d}$는 d차원 벡터를 m차원으로 보낸다. AB가 정의되려면 A의 열 수와 B의 행 수가 같아야 한다. 오른쪽 행렬이 먼저 작용한다. 행렬 곱은 일반적으로 교환하지 않는다. Pauli X와 Z로 직접 보면

$$XZ = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}, \qquad ZX = \begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix}, \qquad XZ = -ZX.$$

내적 $u^\dagger v$는 스칼라인 반면 외적 $uv^\dagger$는 행렬이다. u와 v의 길이가 각각 m, d라면 외적의 shape는 $m \times d$다. 이 차이가 상태벡터와 밀도행렬의 차이로 이어진다.

손계산. $w = (1, 2)^T$일 때 $ww^T = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}$, $w^T w = 5$다. 정규화한 $\widehat{w} = w/\sqrt{5}$의 projector는 $\widehat{w}\widehat{w}^T = ww^T/5$이며 trace가 1이다. 04강에서는 이 표현이 원래 벡터의 norm을 잃는다는 점을 사용한다.

P3. 고유값·양의 준정부호·trace: 상태와 커널을 판정한다

$Av = \lambda v$, $v \neq 0$이면 λ가 고유값이다. 행렬이 에르미트이면 $A = A^\dagger$이며 고유값은 실수이고 서로 직교하는 고유벡터를 선택할 수 있다. 유한차원에서

$$A = \sum_j \lambda_j |v_j\rangle\langle v_j|$$

로 쓴다. 이 식은 spectral decomposition이다. 이 노트의 $|v\rangle$는 열벡터를 쓰는 Dirac 표기일 뿐 별도의 새로운 연산은 아니다.

양의 준정부호(positive semidefinite, PSD)란 모든 z에 대해 $z^\dagger A z \geq 0$인 에르미트 행렬이다. 이는 고유값이 모두 0 이상인 것과 동치다. 양의 정부호는 0이 아닌 모든 z에서 엄격히 양수인 경우다. $\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$의 고유값은 2와 0이라 PSD지만 가역이 아니다. 반면 $\begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$의 고유값은 3과 -1이므로 PSD가 아니다. 대각 원소가 양수라고 PSD인 것은 아니다.

Trace는 대각 원소의 합이다. 두 행렬의 곱이 정의되고 trace를 취할 수 있으면 $\mathrm{Tr}(AB) = \mathrm{Tr}(BA)$다. 인덱스로 쓰면 $\sum_{ij} A_{ij}B_{ji} = \sum_{ji} B_{ji}A_{ij}$라서 성립한다. 그러나 ABC에서 임의의 두 행렬을 바꿀 수 있다는 뜻은 아니다. 허용되는 것은 $ABC \to BCA \to CAB$라는 순환 이동이다.

행렬에도 서로 다른 노름이 있다. 특잇값을 s_j라 할 때 연산자 노름은 $\|A\| = \max_j s_j$, trace norm은 $\|A\|_1 = \sum_j s_j = \mathrm{Tr}\sqrt{A^\dagger A}$, Hilbert-Schmidt norm은 $\|A\|_{\mathrm{HS}} = \sqrt{\sum_j s_j^2} = \sqrt{\mathrm{Tr}(A^\dagger A)}$다. 에르미트 행렬에서는 특잇값이 고유값의 절댓값이다. 예를 들어 $A = \mathrm{diag}(3, -4)$의 세 노름은 각각 4, 7, 5다. 상태 구별에 쓰는 trace distance $\|\rho - \sigma\|_1/2$와 커널에서 쓰는 Hilbert-Schmidt 거리를 구별한다.

유니터리 U는 $U^\dagger U = I$를 만족하며, $\|Uv\|^2 = v^\dagger U^\dagger U v = \|v\|^2$로 노름을 보존한다. 에르미트와 유니터리는 다른 조건이다. Pauli 행렬은 둘 다 만족하지만 일반 회전 게이트는 에르미트가 아니다. 관측량과 게이트를 무조건 같은 종류의 행렬로 취급하면 안 된다.

행렬 지수. 에르미트 생성자 H로 $U(\theta) = e^{-i\theta H}$를 만들면 고유값별로 위상이 붙으므로 유니터리다. $P^2 = I$이면 지수의 짝수·홀수 항을 묶어

$$e^{-i\theta P/2} = I\cos(\theta/2) - iP\sin(\theta/2)$$

를 얻는다. 이것이 회전 게이트와 07강의 미분식을 계산하는 출발점이다.

P4. 텐서곱과 부분계: 인덱스를 지우는 일이 아니다

두 독립 벡터 공간을 합치면 벡터의 성분 수는 곱해진다. $a = (a_0, a_1)^T$, $b = (b_0, b_1)^T$에 대해

$$a \otimes b = (a_0 b_0, a_0 b_1, a_1 b_0, a_1 b_1)^T.$$

기저는 $|00\rangle, |01\rangle, |10\rangle, |11\rangle$ 순서로 고정한다. $A \otimes B$는 A의 각 원소에 B를 곱한 block 행렬이다. 행렬이 작아도 크기가 빨리 커지므로, $(A \otimes B)(a \otimes b) = (Aa) \otimes (Bb)$ 같은 구조를 이용해 계산한다.

Bell 상태 $|\Phi^+\rangle = (|00\rangle + |11\rangle)/\sqrt{2}$의 밀도행렬을 직접 만들면

$$\rho_{AB} = \frac{1}{2}\begin{pmatrix} 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 \end{pmatrix}.$$

첫 계의 reduced state는 둘째 계 인덱스를 **합산**해 얻는다.

$$(\rho_A)_{a,a'} = \sum_{b=0}^{1} (\rho_{AB})_{ab,a'b}.$$

따라서 $(\rho_A)_{00} = 1/2 + 0$, $(\rho_A)_{11} = 0 + 1/2$, 비대각 원소는 0이다. 결과는 $\rho_A = I/2$다. 4×4 행렬에서 왼쪽 위 2×2 block만 떼는 것과 다르다. 실제로 그 block의 trace는 1/2여서 정규화된 상태조차 아니다.

이 계산은 전체 순수 상태의 부분계가 혼합 상태일 수 있음을 보여준다. 혼합 상태를 "실제로는 하나의 순수 상태인데 우리가 몰라서 그런 것"으로만 이해하면 얽힘의 부분계를 설명하지 못한다. 본문에서는 측정 가능한 예측을 주는 밀도행렬을 상태의 수학적 표현으로 사용한다. 03강에서 얽힘·Schmidt 분해와 연결한다.

P5. 밀도행렬과 측정: 양성·정규화를 함께 점검한다

유한차원 양자 상태 ρ는 PSD이며 trace가 1이다. 순수 상태는 $\rho = |\psi\rangle\langle\psi|$, $\langle\psi|\psi\rangle = 1$로 쓴다. 한 큐비트에서는

$$\rho = \frac{I + r_x X + r_y Y + r_z Z}{2} = \frac{1}{2}\begin{pmatrix} 1 + r_z & r_x - i r_y \\ r_x + i r_y & 1 - r_z \end{pmatrix}.$$

이 행렬의 고유값은 $(1 \pm \|r\|)/2$이므로 $\|r\| \le 1$이어야 PSD다. 순수 상태는 $\|r\| = 1$, 중심 $r = 0$은 $I/2$다. Bloch 구의 점은 공간에 있는 작은 구슬의 위치가 아니라 세 Pauli 기대값을 요약한 좌표다.

유한 결과 측정의 POVM은 PSD 행렬들 E_a가 $\sum_a E_a = I$를 만족하는 집합이다. 결과 확률은

$$p(a) = \mathrm{Tr}(E_a \rho), \qquad \sum_a p(a) = \mathrm{Tr}\left[\left(\sum_a E_a\right)\rho\right] = 1.$$

양성 때문에 각 확률도 음수가 아니다. POVM은 결과 확률을 지정하며, 측정 뒤 상태까지 유일하게 지정하지는 않는다. 후자의 설명에는 측정 연산자나 instrument가 더 필요하다. Projective measurement에서는 E_a들이 서로 직교하는 projector다.

관측량 $O = \sum_a o_a \Pi_a$를 projective하게 측정하면 결과 숫자는 고유값 o_a, 평균은 $\mathrm{Tr}(O\rho)$다. Z 측정의 결과 숫자는 ±1이다. 출력 비트 0/1과 물리적 관측값 ±1을 코드에서 같은 배열로 섞지 않는다.

완전 예제. $\rho = \mathrm{diag}(0.7, 0.3)$이면 Z의 평균은 $0.7 - 0.3 = 0.4$, 분산은 $1 - 0.4^2 = 0.84$다. X의 평균은 0이다. 대각 원소만으로 모든 기저의 상태를 판정할 수 없다는 점은 02강에서 다시 확인한다.

P6. 표본 평균과 불확실성: 어떤 양의 오차인가

연속변수의 평균. 각도 θ가 $[a,b]$에서 균등하면 확률밀도는 $1/(b-a)$이고 $\mathbb{E}[h(\theta)] = (b-a)^{-1}\int_a^b h(\theta)\,d\theta$다. 적분은 작은 구간의 함수값에 구간 길이를 곱해 합한 값의 극한이며, 정규화한 넓이가 평균이 된다. $[0,2\pi]$에서 0이 아닌 정수 k에 대해 $\int_0^{2\pi}\cos(k\theta)\,d\theta = [\sin(k\theta)/k]_0^{2\pi} = 0$이고 사인도 평균 0이다. $\sin^2\theta = (1-\cos 2\theta)/2$, $\cos^2\theta = (1+\cos 2\theta)/2$이므로 두 제곱의 평균은 각각 1/2다. 곱을 합으로 바꾸는 삼각 항등식으로 서로 다른 정수 주파수의 직교성도 얻는다. 이것이 06강의 Fourier 오차 하한과 09강의 초기화 분산 계산에 필요한 적분이다.

기댓값은 분포에 대한 평균이다. 유한한 측정 평균과 같다고 가정하지 않는다. 독립 동일분포(i.i.d.)인 $Z_s \in \{-1,+1\}$의 평균을 μ라 하고, $\widehat{\mu} = S^{-1}\sum_s Z_s$로 추정하자. 선형성으로 불편성 $\mathbb{E}\widehat{\mu} = \mu$를 얻고, 독립성이 공분산 항을 지우므로

$$\mathrm{Var}(\widehat{\mu}) = \frac{1-\mu^2}{S}, \qquad \mathrm{SE}(\widehat{\mu}) = \sqrt{\frac{1-\mu^2}{S}}.$$

평균에 대한 표준오차(SE)는 개별 측정값의 표준편차(SD)를 $\sqrt{S}$로 나눈 것이다. $\mu = 0.4, S = 400$이면 SD는 약 0.9165, SE는 약 0.0458이다. 값의 흔들림과 평균 추정의 흔들림을 구별한다.

Bernoulli 비트 $B \in \{0,1\}$는 분산이 $p(1-p)$다. 같은 실험에서 $Z = 1-2B$이면 $\mu = 1-2p$, 평균의 분산도 4배다. 결과의 숫자 규약을 바꾸면서 예전 분산 식을 그대로 쓰면 틀린다.

확률 보장과 근사 구간. Hoeffding 부등식을 ±1 결과에 적용하면

$$\Pr(|\widehat{\mu}-\mu| \ge \epsilon) \le 2e^{-S\epsilon^2/2}.$$

실패 확률을 δ 이하로 만들기 위한 충분조건은 $S \ge 2\log(2/\delta)/\epsilon^2$다. $\epsilon = 0.05, \delta = 0.05$이면 약 2,952샷이 필요하다. 이는 평균값을 몰라도 쓸 수 있는 보수적인 상한이며 최소 샷 수의 정확한 값이 아니다. 0/1 Bernoulli 평균에는 구간 길이가 1이어서 지수 상수가 다르다.

흔히 쓰는 $\widehat{\mu} \pm 1.96\,\widehat{\mathrm{SE}}$는 큰 표본의 정규 근사에 의존한다. 경계 확률·소표본에서는 정확하지 않을 수 있다. 빈도주의 95% 신뢰구간은 같은 절차를 반복했을 때 참 값을 포함하는 비율에 관한 말이다. 관측한 구간에 대해 고정된 참 값이 95% 확률로 들어간다는 Bayesian 해석과 같지 않다.

Bias와 RMSE의 유도. 참 값 θ, 추정량 T, 평균 $m = \mathbb{E}T$에 대해

$$\mathbb{E}[(T-\theta)^2] = \mathbb{E}[(T-m+m-\theta)^2] = \mathrm{Var}(T) + (m-\theta)^2.$$

가운데 교차항은 $\mathbb{E}(T-m) = 0$이라 사라진다. RMSE는 이 MSE의 제곱근이다. 장치 bias가 0.1로 남아 있으면 샷을 무한히 늘려도 RMSE는 0으로 가지 않는다. 12강에서 완화의 bias 감소와 분산 증가를 같이 계산한다.

P7. 미분·경사하강·정규화: 무엇을 최소화하는가

손실 $L(\theta)$가 미분 가능할 때 작은 변화의 일차 근사는 $L(\theta+\Delta) \approx L(\theta) + \nabla L(\theta)^T\Delta$다. 그래서 $\Delta = -\eta\nabla L$, $\eta > 0$를 선택한다. 하지만 고차항이 남으므로 임의의 큰 학습률에서 감소를 보장하지 않는다.

예를 들어 $L(\theta) = \theta^2$이면 갱신은 $\theta_{t+1} = (1-2\eta)\theta_t$다. $0 < \eta < 1$일 때 크기가 줄고, $\eta = 1$이면 부호만 바뀌고, $\eta > 1$이면 일반적으로 커진다. 영 기울기가 나오는 점을 찾는 것과 전역 최소를 찾는 것도 비볼록 손실에서는 다른 문제다.

양자 기대값 뒤의 고전 손실에는 chain rule이 필요하다. $f(\theta) = \cos\theta$, $L = (f-y)^2$라면

$$\frac{dL}{d\theta} = 2(f-y)\frac{df}{d\theta} = -2(\cos\theta - y)\sin\theta.$$

회로의 미분만 구하고 앞의 $2(f-y)$를 빼먹으면 다른 목적을 최적화한다. 역전파·parameter shift·유한차분은 같은 미분을 구하려는 다른 방법이며 적용 조건과 실행 비용이 다르다.

선형 회귀에서는 $X \in \mathbb{R}^{N\times d}$, $y \in \mathbb{R}^N$, $\beta \in \mathbb{R}^d$를 쓰자. 다음 규약의 ridge 목적함수는

$$L(\beta) = \|X\beta - y\|_2^2 + \lambda\|\beta\|_2^2, \qquad \lambda > 0$$

이며 미분해 $(X^TX + \lambda I)\beta = X^Ty$를 얻는다. 손실 앞에 $1/N$을 넣었다면 같은 λ 기호라도 정상방정식은 $X^TX + N\lambda I$가 된다. 논문과 코드의 정규화 규약을 먼저 맞춘다. 역행렬을 실제로 만들기보다 선형 방정식 solver를 사용하는 편이 일반적으로 적절하다.

조건수 $\kappa_2(A) = \sigma_{\max}(A)/\sigma_{\min}(A)$는 가역 행렬의 입력 오차가 얼마나 증폭될 수 있는지와 관련한다. $A = \mathrm{diag}(1, 0.01)$이면 조건수는 100이다. 작은 고유값의 역수를 키우는 계산은 오차에 민감할 수 있으며, 정규화는 안정성과 추정 bias 사이의 절충을 만든다. 17강의 해 상태·QSVT를 읽기 전 이 예제를 다시 계산한다.

P8. 학습 이론·복잡도의 기호를 읽는 최소 준비

입력과 label의 분포를 $\mathcal{D}$, 모델을 f, 손실을 ℓ라 쓰면 모집단 위험은 $R(f) = \mathbb{E}_{\mathcal{D}}\ell(f(x), y)$, 경험 위험은 $\widehat{R}_D(f) = N^{-1}\sum_i \ell(f(x_i), y_i)$다. 일반화 차이는 같은 모델의 두 위험 사이 차이다. 테스트 정확도는 그 중 일부를 추정하는 통계이지 정리의 결론 자체가 아니다.

모델을 선택한 데이터와 성능을 평가할 데이터를 나눈다. Train은 파라미터 갱신에, validation은 모델·설정 선택에, test는 선택이 끝난 뒤의 평가에 쓴다. 표준화의 평균·분산도 train에서 계산한다. 같은 환자·분자·시간 구간의 가까운 자료가 두 분할에 섞이면 형식적으로 다른 행이라도 독립 표본 가정이 깨질 수 있다.

$O(g(n))$는 충분히 큰 n에서 어떤 상수배 g로 상한을 잡는 표기다. Ω는 하한, Θ는 양쪽이 같은 규모, $\widetilde{O}$는 보통 로그 인자를 숨기지만 정확한 관례는 논문을 따른다. 예를 들어 $100n$과 n^2 중 작은 n에서는 전자가 느릴 수 있다. 점근 표기만으로 실제 실행 순서를 판단하지 않는다.

복잡도 식에는 입력 크기뿐 아니라 정밀도 ϵ, 실패 확률 δ, 조건수 κ, 데이터 접근 비용이 들어갈 수 있다. $O(\log d)$큐비트로 표현한다고 임의의 d차원 데이터를 $O(\log d)$시간에 준비할 수 있는 것은 아니다. Oracle query 한 번이라는 추상 비용과 실제 게이트·메모리·파일 읽기의 비용을 구별한다. 14강이 이 구별을 중심으로 구성된다.

준비도 문제: 힌트 뒤에 계산을 가리고 푼다

준비 문제 1. 켤레와 정규화

$v = (1, i, 1, -i)^T/2$의 norm과 $|v_1|^2$를 계산하라. **힌트:** 인덱스는 0부터 쓰되 모든 성분의 절댓값은 1/2다. **풀이:** 네 성분의 제곱 크기가 각각 1/4이므로 norm 제곱은 1, norm은 1이다. 인덱스 1 성분은 i/2이고 확률은 1/4다. 복소 성분을 그냥 제곱해 -1/4로 보고하면 틀리다. 틀렸다면 P1-P2로 돌아간다.

준비 문제 2. 상태 조건

$A = \begin{pmatrix} 0.5 & 0.6 \\ 0.6 & 0.5 \end{pmatrix}$는 상태인가? **힌트:** 대칭 벡터와 반대칭 벡터에 작용시킨다. **풀이:** 고유값은 1.1과 -0.1이다. 에르미트이고 trace는 1이지만 양성이 깨져 밀도행렬이 아니다. 모든 상태 조건을 함께 점검해야 한다. P3·P5를 복습한다.

준비 문제 3. 부분 trace

$|\psi\rangle = \sqrt{3/4}|00\rangle + \sqrt{1/4}|11\rangle$에서 첫 계 상태와 purity를 구하라. **힌트:** 둘째 계 기저가 다른 교차항은 부분 trace에서 사라진다. **풀이:** $\rho_A = \mathrm{diag}(3/4, 1/4)$. purity는 $\mathrm{Tr}(\rho_A^2) = 9/16 + 1/16 = 5/8$로 1보다 작다. 전체 순수성과 부분계 순수성을 구별하지 못했다면 P4로 돌아간다.

준비 문제 4. 평균과 bias

실험 평균의 기대값은 참 값보다 0.03 크고 분산은 0.0016이다. MSE와 RMSE는? **힌트:** 제곱근은 합을 끝낸 뒤 취한다. **풀이:** MSE는 $0.0016 + 0.03^2 = 0.0025$, RMSE는 0.05다. 분산의 제곱근 0.04만 보고 전체 오차라고 하면 bias가 빠진다. P6을 복습한다.

준비 문제 5. 샷과 표준오차

같은 i.i.d. 측정의 표준오차가 2,000샷에서 0.02였다. 8,000샷에서는? **힌트:** 표본 수 비율의 제곱근을 쓴다. **풀이:** $0.02\sqrt{2000/8000} = 0.01$. 독립성·정상성이 깨지거나 systematic bias를 보고 있다면 이 비례를 적용할 수 없다. P6을 복습한다.

준비 문제 6. Chain rule

$f(\theta) = \sin\theta$, $L = (f-1)^2$에서 $\theta = 0$의 기울기와 학습률 0.1의 다음 값은? **풀이:** $L' = 2(\sin\theta - 1)\cos\theta$라서 -2다. 새 각도는 $0 - 0.1(-2) = 0.2$. f의 미분만 구해 +1을 사용하면 반대 방향으로 간다. P7을 복습한다.

준비 문제 7. 정규화 규약

$X = (1, 1)^T, y = (1, 3)^T$, 즉 표본 두 개·특징 하나이며 $\lambda = 2$다. $\|X\beta - y\|^2 + \lambda\beta^2$의 해는? **풀이:** $X^TX = 2$, $X^Ty = 4$이므로 $(2+2)\beta = 4$, $\beta = 1$이다. 손실을 N으로 나누는 다른 규약에서는 같은 λ 숫자가 다른 문제를 정의한다. P7을 복습한다.

준비 문제 8. 복잡도 주장

알고리즘이 상태 준비 oracle을 $O(\log d)$번 호출한다. 이 정보만으로 저장된 일반 벡터에 대한 전체 실행이 polylog(d)라고 결론낼 수 있는가? **풀이:** oracle을 구현하는 비용과 준비 횟수별 재사용, 출력·정밀도 비용이 없다. 따라서 query 상한만 알 수 있다. P8과 04강을 다시 읽는다.

여덟 문제 중 여섯 개 이상을 해설 없이 설명하고, 틀린 문제를 다시 계산하면 본문을 시작할 준비가 된 것으로 **이 학습 안내에서** 제안한다. 이는 검증된 능력 평가나 공식 수강 요건이 아니다. 정답 숫자만 맞히지 말고 사용한 가정을 한 문장씩 적는다.

추가 읽기와 출처

위 작은 예제와 유도는 독립 교육용 구성이다. 표준 수학 정의의 심화 자료는 다음과 같다.

- John Watrous, The Theory of Quantum Information, Ch. 1 *Mathematical preliminaries*, Ch. 2 *Basic notions of quantum information*, Ch. 3 *Similarity and distance among states and channels*. 저자가 제공하는 개인 열람용 원고로 연결하며 파일을 이 아카이브에 재배포하지 않는다. 정확한 페이지는 판형에 따라 다르다.
- IBM Quantum Learning, Density matrix basics와 Multiple systems and reduced states: 상태와 부분계의 공식 교육 자료. 이 보충편은 자체 예제로 설명한다.
- IBM Quantum Learning, Mathematical formulations of measurements: projective measurement와 일반 측정의 구별을 더 읽을 수 있다.

한영 용어집: 정의, 사용 예와 혼동하기 쉬운 말

2.0판의 용어집이다. 한국어 번역 하나를 외우기보다 **대상을 나타내는 말인지, 계산 방법인지, 오차나 자원을 나타내는 말인지** 먼저 확인한다. 영어 원어·약어를 함께 실어 논문에서도 찾을 수 있게 했다. 같은 기호가 문헌마다 달라질 수 있으며, 아래 정의와 각 강의의 명시적인 규약을 우선한다. 식의 계산이 막히면 수학 보충편으로 돌아간다.

144개 항목은 해당 용어를 처음 이해하기 위한 설명이다. 모든 용례를 포괄하는 사전이나 새로운 연구 결과의 주장은 아니다. 각 묶음 끝의 강의에서 정의를 사용해 직접 계산한다. 특정 알고리즘의 효율·일반화·우위는 정의만으로 따라오지 않는다.

A. 복소수와 선형대수

G001. 스칼라·벡터 — scalar, vector

스칼라는 수 하나, 벡터는 정해진 기저에서 여러 성분을 갖는 대상이다. 예를 들어 $x \in \mathbb{R}^d$는 d개 실수 특징을 모은다. 벡터의 차원 d와 데이터 표본 수 N은 다른 축이다.

G002. 복소수·켤레 — complex number, complex conjugate

$z = a + ib$, $i^2 = -1$이고 켤레는 $z^* = a - ib$다. $|z|^2 = z^* z$는 음수가 아닌 실수다. z^2와 $|z|^2$는 다르며 양자 확률에는 후자를 사용한다.

G003. 내적 — inner product

두 복소 열벡터의 내적은 $u^\dagger v$다. 방향의 겹침을 수로 나타내며 0이면 직교한다. 첫 인자의 켤레를 빠뜨리는 단순 전치 곱은 복소 공간의 내적이 아니다.

G004. 노름·정규화 — norm, normalization

$\|v\|_2 = \sqrt{v^\dagger v}$는 벡터 크기다. 영벡터가 아니면 $v/\|v\|_2$로 단위 길이를 만든다. 정규화는 크기를 지우므로 원 데이터의 norm이 정답을 결정한다면 별도 보존이 필요하다.

G005. 외적 — outer product

$uv^\dagger$는 행렬이며 내적처럼 스칼라가 아니다. 정규화한 v의 $vv^\dagger$는 그 방향으로의 projector다. 두 벡터를 단순 이어 붙인 배열과도 다르다.

G006. 텐서곱 — tensor product

복합계를 나타내는 곱이다. 길이 m과 d의 벡터는 길이 md의 $u \otimes v$가 된다. 차원을 더하는 직합이나 성분별 곱과 구별한다. 모든 복합 상태가 단일 텐서곱으로 분리되지는 않는다.

G007. 기저·직교정규 — basis, orthonormality

기저는 공간의 모든 벡터를 표현하는 독립 방향들의 집합이다. 각 길이가 1이고 서로 내적이 0이면 직교정규다. 기저를 바꿔도 물리 상태는 같을 수 있지만 측정의 의미는 함께 변환해야 한다.

G008. 켤레전치·adjoint — conjugate transpose

$A^\dagger = (A^*)^T$는 성분을 켤레 처리하고 행·열을 바꾼다. 행렬의 adjoint가 항상 역행렬인 것은 아니다. 유니터리일 때에만 $U^{-1} = U^\dagger$다.

G009. 에르미트 — Hermitian

$A = A^\dagger$인 행렬이다. 고유값은 실수이며 관측량을 나타낸다. 실수 대칭 행렬은 특수한 예다. 에르미트라는 조건만으로 PSD이거나 게이트의 유니터리 조건을 만족하지는 않는다.

G010. 유니터리 — unitary

$U^\dagger U = I$여서 내적과 norm을 보존하는 정사각 행렬이다. 닫힌 계의 가역 게이트가 이에 해당한다. 측정이나 환경을 버리는 잡음 채널 전체를 같은 크기의 유니터리 하나로 표현할 수는 없다.

G011. 양의 준정부호 — positive semidefinite, PSD

에르미트 A에서 모든 z에 대해 $z^\dagger A z \geq 0$인 조건이다. 고유값은 모두 0 이상이다. 대각이 양수인 것만으로 충분하지 않으며, PSD 행렬도 0 고유값 때문에 역행렬이 없을 수 있다.

G012. 고유분해·trace·교환자 — eigendecomposition, trace, commutator

에르미트 행렬은 고유값과 projector의 합으로 분해한다. trace는 대각합이며 고유값의 합과 같다. $[A, B] = AB - BA$는 연산 순서의 차이다. trace의 순환성은 임의의 두 행렬을 교환해도 된다는 뜻이 아니다.

사용: 수학 P1-P4, 02강, 03강.

B. 양자 상태와 측정

G013. Ket·bra — Dirac notation

$|\psi\rangle$는 열벡터, $\langle\psi|$는 그 켤레전치다. $\langle\phi|\psi\rangle$는 내적, $|\psi\rangle\langle\phi|$는 외적이다. 꺾쇠의 방향은 장식이 아니라 행렬의 shape를 알려준다.

G014. 진폭·Born 규칙 — amplitude, Born rule

순수 상태의 기저 성분이 진폭이며, 해당 기저 측정의 확률은 그 절댓값 제곱이다. 진폭은 음수·복소수일 수 있지만 확률은 그럴 수 없다. 측정 한 번으로 진폭 전체를 읽지는 못한다.

G015. 전역 위상·상대 위상 — global phase, relative phase

전체 상태에 같은 $e^{i\gamma}$를 곱한 전역 위상은 관측 확률을 바꾸지 않는다. 성분 사이 상대 위상은 간섭을 바꿀 수 있다. v와 -v가 같은 양자 상태여도 두 원 데이터가 같은 label을 갖는 것은 아니다.

G016. 중첩·코히런스 — superposition, coherence

중첩은 기저벡터의 선형결합이다. 특정 기저에서 밀도행렬의 비대각 성분은 coherence를 나타낸다. 코히런스는 선택한 기저와 관련하며, 확률적으로 두 상태를 섞는 고전적 혼합과 다르다.

G017. 밀도행렬·순수·혼합 — density matrix, pure state, mixed state

상태 ρ는 PSD이고 trace 1이다. 순수하면 $\rho = |\psi\rangle\langle\psi|$, 혼합이면 rank가 더 클 수 있다. 같은 ρ를 만드는 순수 상태의 확률적 분해는 유일하지 않다.

G018. Bloch 벡터 — Bloch vector

한 큐비트의 $\rho = (I + r_x X + r_y Y + r_z Z)/2$에서 r은 세 Pauli 평균이다. 물리 상태는 $\|r\| \le 1$, 순수 상태는 경계에 있다. 구의 좌표를 실제 입자의 공간 위치로 해석하지 않는다.

G019. 축소 상태·부분 trace — reduced state, partial trace

복합 상태에서 일부 계만의 예측을 주는 상태다. $(\rho_A)_{aa'} = \sum_b \rho_{ab,a'b}$처럼 버리는 계 인덱스를 합한다. 큰 행렬의 특정 block만 자르는 연산이 아니다.

G020. 얽힘·Schmidt rank — entanglement, Schmidt rank

순수 복합 상태가 하나의 곱 상태로 쓰이지 않으면 얽혔다. Schmidt 분해의 양의 계수 개수가 2 이상이면 순수 상태의 얽힘이 있다. 혼합 상태에서는 곱 상태들의 확률적 혼합으로 표현 가능한지도 보아야 한다.

G021. 관측량·기댓값 — observable, expectation value

관측량 O는 측정 결과 숫자의 규칙이며 평균은 $\mathrm{Tr}(O\rho)$다. 평균은 단일 측정 결과와 다를 수 있다. Z 평균 0은 결과가 0이었다는 뜻이 아니라 ±1 결과가 평균적으로 상쇄된다는 뜻이다.

G022. 사영 측정·POVM — projective measurement, positive operator-valued measure

사영 측정은 서로 직교하는 projector들로, 일반 POVM은 양의 effect들 E_a와 $\sum_a E_a = I$로 정의한다. $p(a) = \mathrm{Tr}(E_a\rho)$다. POVM 효과만으로 측정 후 상태까지 유일하게 정해지지는 않는다.

G023. 충실도·순도·trace distance — fidelity, purity, trace distance

순수 두 상태의 fidelity는 내적 절댓값 제곱이다. 일반 상태의 squared fidelity 규약은 $(\mathrm{Tr}\sqrt{\sqrt{\rho}\sigma\sqrt{\rho}})^2$다. purity는 $\mathrm{Tr}\,\rho^2$, trace distance는 $\|\rho - \sigma\|_1/2$다. 서로 다른 양이며 문헌의 fidelity 제곱 관례도 확인한다.

G024. 계산 기저·wire 순서 — computational basis, wire order

계산 기저는 비트열로 붙인 직교정규 기저다. 본 노트 두 큐비트는 00,01,10,11 순서다. SDK의 bitstring 표시·endianness는 다를 수 있어, 회로 그림의 wire와 배열 인덱스를 먼저 대응시킨다.

사용: 02강, 03강, 13강.

C. 확률·통계와 실험 오차

G025. 확률변수 — random variable

무작위 결과에 숫자를 대응시킨 대상이다. 비트 B를 0/1로 세는 것과 $Z = 1 - 2B$로 ±1을 세는 것은 같은 사건을 다른 숫자로 코딩한 것이다. 평균·분산도 이 변환에 맞춰 바뀐다.

G026. 독립 동일분포 — independent and identically distributed, i.i.d.

표본들이 서로 독립이고 같은 분포를 따르는 가정이다. 시간에 따른 calibration drift가 있으면 어긋날 수 있다. 행이 여러 개라는 사실만으로 독립 표본이라고 할 수는 없다.

G027. 추정량·실현값 — estimator, estimate

추정량은 데이터에 적용하는 통계적 규칙으로 무작위변수다. 관측 후 얻은 구체적인 숫자는 그 실현값이다. 하나의 결과가 참 값에 가깝다는 사실만으로 추정량이 불편하다고 결론내리지 않는다.

G028. 편향 — bias

추정량 T의 bias는 $\mathbb{E}T - \theta$다. 표본 수를 늘리면 사라지는 경우도 있지만 장치·모형 불일치 때문에 남을 수도 있다. 통계적 bias와 사회적 편향, 모델의 inductive bias는 같은 개념이 아니다.

G029. 분산 — variance

$\mathrm{Var}(T) = \mathbb{E}(T - \mathbb{E}T)^2$는 평균 주위의 흔들림이다. 평균이 참 값과 얼마나 떨어져 있는지는 직접 말하지 않는다. 분산이 작은데도 bias가 큰 추정량이 가능하다.

G030. 표준편차·표준오차 — standard deviation, standard error

SD는 분포의 분산 제곱근, SE는 추정량의 SD다. i.i.d. 평균의 SE는 개별 결과 SD를 $\sqrt{S}$로 나눈 값이다. seed 사이 SD를 그대로 95% 신뢰구간이라고 표시하면 안 된다.

G031. 신뢰구간 — confidence interval, CI

정해진 반복 표집 절차에서 참 값을 포함하는 비율을 제어하는 구간이다. 보통의 $\hat{\theta} \pm 1.96\,SE$는 정규 근사가 필요하다. 소표본·경계 확률이나 상관 표본에서는 별도 처리가 필요하다.

G032. 농축 부등식 — concentration inequality

표본 평균 등이 기대값에서 멀어질 확률을 제한한다. Hoeffding은 독립 bounded 변수에 적용되는 예다. 데이터 상관이나 관측값 범위 조건을 뺀 채 샷 수 보장만 가져오지 않는다.

G033. MSE·RMSE — mean squared error, root mean squared error

참 값 대비 제곱 오차의 평균과 그 제곱근이다. $MSE = variance + bias^2$다. 오류 완화의 성능을 분산만으로 판단하면 bias 감소의 효과를 놓칠 수 있고, 평균만 보면 분산 비용을 놓친다.

G034. 공분산 — covariance

$\mathrm{Cov}(A, B) = \mathbb{E}[(A - \mathbb{E}A)(B - \mathbb{E}B)]$는 두 추정량의 공동 변동이다. 같은 샷·같은 calibration을 재사용하면 생길 수 있다. 합의 분산을 계산할 때 독립성을 확인하지 않고 이 항을 버리면 안 된다.

G035. Bootstrap — 재표집 불확실성 추정

관측 자료를 다시 뽑아 통계량의 변동을 근사하는 방법군이다. 무엇을 단위로 재표집하는지가 중요하다. shots만 다시 뽑으면 고정한 calibration의 불확실성이나 환자 간 변동을 포함하지 못한다.

G036. 짝지은 비교 — paired comparison

같은 테스트 표본에 대한 두 모델 결과의 차이를 분석한다. 각 표본에서 정오가 함께 변하므로 두 독립 비율의 오차식보다 공분산을 포함하는 접근이 적절할 수 있다. 차이를 본 뒤 유리한 검정만 고르지 않는다.

사용: 수학 P6, 07강, 10강, 12강.

D. 머신러닝의 문제 정의

G037. 특징·정답 — feature, label, target

특징 x는 모델에 주는 입력 표현이고, y는 학습 목표다. Label은 주로 분류 범주를 뜻하며 target은 회귀값 등도 포함한다. 사람이 만든 전처리 특징과 모델이 학습한 내부 특징도 구별한다.

G038. 표본·분포 이동 — sample, distribution shift

표본은 관측한 개별 데이터이고 분포는 데이터를 만드는 규칙이다. 훈련과 배포의 분포가 다르면 distribution shift다. 같은 벤치마크 테스트 점수가 새로운 실험실·장치·모집단에 그대로 적용되지는 않는다.

G039. 가설 공간·모델 — hypothesis class, model

학습기가 선택할 수 있는 함수들의 집합과 그 중 특정 함수다. 같은 파라미터 수여도 함수 집합은 다를 수 있다. 회로가 표현 가능한 함수와 최적화기가 실제로 찾는 함수도 구별한다.

G040. 손실·위험 — loss, risk

손실은 한 예측을 평가하는 규칙, 위험은 그 손실의 분포 평균이다. 정확도와 cross-entropy는 다른 평가량이다. 낮은 한 종류 손실이 모든 지표의 개선을 보장하지 않는다.

G041. 경험 위험 최소화 — empirical risk minimization, ERM

관측한 훈련 표본의 평균 손실을 최소화하는 원리다. 수치 최적화는 근사해만 찾을 수 있다. 경험 위험이 작아졌다고 새 표본의 모집단 위험도 작다는 결론은 자동으로 나오지 않는다.

G042. 일반화 차이 — generalization gap

같은 모델의 모집단 위험과 경험 위험 차이다. 작은 gap은 작은 훈련 손실이나 우수한 절대 성능을 뜻하지 않는다. 훈련·모집단 모두 나쁜 상수 모델도 gap은 작을 수 있다.

G043. 근사·추정·최적화 오차 — approximation, estimation, optimization error

선택한 함수 집합의 한계, 유한 데이터의 한계, 탐색의 한계를 나눈다. 엄밀한 분해·상계의 형태는 정리에 따라 다르다. 여기에 측정 샷 오차와 장치 bias도 구별해 기록한다.

G044. 훈련·검증·시험 — train, validation, test

파라미터 학습, 설정 선택, 선택 이후 평가에 각각 사용한다. Test를 반복 조회해 설정을 바꾸면 사실상 validation으로 사용한 것이다. 데이터가 적을 때는 적절한 교차검증 설계를 따로 정한다.

G045. 데이터 누수 — data leakage

평가 때만 알아야 할 정보가 학습·모델 선택으로 들어오는 일이다. 전체 자료로 scaling을 맞춘 뒤 나누는 것도 사례다. 환자·분자·시간 등 상관 단위의 누수도 확인한다.

G046. 규제·정규화 — regularization

학습 목적이나 함수 공간에 제약·penalty를 넣는 방법이다. Ridge의 $\lambda\|w\|^2$가 예다. 벡터 길이를 1로 만드는 normalization과 한국어 번역이 겹칠 수 있어 영어와 식을 확인한다.

G047. 하이퍼파라미터 — hyperparameter

학습률·층 수·kernel 폭처럼 바깥 절차에서 고르는 설정이다. 학습 변수 θ와 같은 방식으로 취급하지 않을 수 있다. 탐색 횟수와 데이터 조회 비용도 비교 예산에 넣는다.

G048. 귀납 편향 — inductive bias

관측하지 않은 입력에서 어떤 함수를 선호할지 정하는 구조적 가정이다. 국소성·대칭·주파수 제한이 예다. 가정이 문제와 맞으면 유리하지만 잘못 맞추면 정답을 표현하지 못할 수 있다.

사용: 01강, 10강.

E. 인코딩과 커널 방법

G049. 기저 인코딩 — basis encoding

고전 비트열 b를 $|b\rangle$로 준비한다. 실수에는 precision·부호 표현을 정해야 한다. 무한 정밀도 숫자 하나를 큐비트 하나에 고전적으로 그대로 읽을 수 있는 방식이 아니다.

G050. 각도 인코딩 — angle encoding

특징값을 회전 게이트의 각도로 보낸다. 예를 들어 $R_y(x_j)$를 쓴다. 주기적 중첩과 scaling이 geometry를 바꾸므로 원 데이터의 유클리드 거리와 같다고 가정하지 않는다.

G051. 진폭 인코딩 — amplitude encoding

정규화한 벡터 성분을 상태의 진폭으로 쓴다. d차원 표현에는 $\lceil \log_2 d \rceil$ 큐비트가 충분할 수 있다. 일반 입력의 준비 비용, norm과 전역 부호 손실을 별도로 다뤄야 한다.

G052. 상태 준비·qRAM — state preparation, quantum random access memory

원하는 입력 상태를 만드는 물리·논리 과정과 coherent 주소 접근 메모리 개념이다. Python 배열 생성이나 classical RAM 조회와 같은 기능이 아니다. 초기 적재·업데이트·오류 비용을 명시한다.

G053. 특징 사상 — feature map

입력 x를 다른 표현 $\phi(x)$로 보내는 규칙이다. 양자에서는 상태나 density operator를 특징으로 삼는다. 특징 공간이 크다는 사실만으로 좋은 label 구조나 계산 우위가 생기지는 않는다.

G054. 커널·Gram 행렬 — kernel, Gram matrix

커널은 입력 쌍의 유사도를 주는 함수다. 표본들에 대해 $K_{ij} = k(x_i, x_j)$를 모은 것이 Gram 행렬이다. 머신러닝의 PSD kernel과 운영체제 kernel은 다른 용어다.

G055. PSD 커널 — positive semidefinite kernel

어떤 유한 표본 집합에서도 Gram 행렬이 PSD인 커널이다. 내적 $k(x, z) = \langle \phi(x), \phi(z) \rangle$으로 구성하면 이 성질을 갖는다. 유한 샷으로 원소별 추정한 행렬까지 항상 PSD인 것은 아니다.

G056. 재생 커널 Hilbert 공간 — reproducing kernel Hilbert space, RKHS

함수값 평가가 커널 내적으로 표현되는 함수 공간이다. 첫 인자에 켤레를 취하는 이 노트의 내적 관례에서는 평가 원소 k_x에 대해 $f(x) = \langle k_x, f \rangle$라는 재생 성질을 가진다. 커널을 $k(x, z) = \langle k_x, k_z \rangle$로 쓰면 함수로서 $k_x(t) = k(t, x)$다. 양자 상태 Hilbert 공간과 관련시킬 수 있지만 같은 대상이라고 무조건 동일시하지 않는다.

G057. RBF 커널 — radial basis function kernel

대표적으로 $e^{-\gamma \|x - z\|^2}$를 쓴다. γ는 유사도가 줄어드는 길이 척도를 정한다. γ가 너무 크면 거의 단위행렬, 너무 작으면 거의 상수 행렬이 되어 학습의 성질이 달라진다.

G058. SVM·마진 — support vector machine, margin

분류 경계와 표본 사이의 여유를 제어하는 학습법이다. Soft-margin은 일부 위반을 penalty와 절충한다. Feature map이 복잡해도 고전 최적화 문제가 볼록일 수 있으며 kernel 추정 비용은 별도로 남는다.

G059. Hinge loss·쌍대 문제 — hinge loss, dual problem

이진 label ±1에서 hinge는 $\max(0, 1 - y f(x))$다. SVM 쌍대는 표본 계수와 Gram 행렬로 최적화를 쓴다. 쌍대식의 C·손실 정규화 규약을 코드와 맞춘다.

G060. Kernel ridge·PSD projection — kernel ridge regression, PSD projection

Kernel ridge는 제곱 손실과 규제를 사용하며 SVM과 다르다. 추정 Gram의 음의 고유값을 잘라 PSD로 만드는 처리는 학습 규칙을 바꾼다. 보정이 수치적으로 유용해도 원래 추정량의 불편성을 그대로 보존하지는 않는다.

사용: 04강, 05강, 08강.

F. 변분 모델과 최적화

G061. Ansatz·매개변수화 회로 — ansatz, parameterized quantum circuit, PQC

탐색할 상태·연산의 구조를 미리 정하고 연속 파라미터를 넣은 회로다. Ansatz는 검증된 정답이라는 뜻이 아니라 선택한 함수 집합이다. 관측량에 보이지 않는 파라미터가 있을 수도 있다.

G062. QNN·VQC — quantum neural network, variational quantum classifier

QNN은 양자 학습 모델의 넓은 이름이고 VQC는 변분 회로를 쓰는 분류기다. 고전 신경망의 모든 neuron·활성함수와 일대일 대응하지 않는다. 실제 함수·측정·고전 head를 식으로 적는다.

G063. 하이브리드 모델 — hybrid quantum-classical model

양자 처리와 고전 처리를 함께 쓰는 모델이다. 양자 기대값 뒤의 logistic head와 고전 optimizer가 예다. 데이터 변환·loss·측정·업데이트 전체가 모델과 비용의 일부다.

G064. 데이터 재업로드 — data re-uploading

학습 게이트 사이에 데이터를 여러 번 넣는다. 접근 주파수 집합이 커질 수 있으며 같은 축의 $R_y(x)$도 L번 반복하면 $R_y(Lx)$가 된다. 입력 업로드를 추가하지 않고 같은 축의 학습 게이트만 더하면 합각으로 축약되어 독립 학습 자유도가 늘지 않을 수 있다.

G065. 표현력·학습 가능성 — expressivity, trainability

표현력은 담을 수 있는 함수·상태 범위, 학습 가능성은 정해진 자료·측정·최적화 예산에서 적절한 해를 찾을 수 있는 성질이다. 보편 근사 정리가 효율적인 학습 알고리즘을 자동 제공하지는 않는다.

G066. 식별 가능성 — identifiability

서로 다른 파라미터가 서로 다른 관측 예측을 만드는지에 관한 성질이다. 동일 예측을 내는 θ들이 있으면 데이터만으로 구별하기 어렵다. 파라미터 수와 유효 자유도가 항상 같지는 않다.

G067. 연쇄 법칙 — chain rule

합성 함수의 미분을 연결하는 규칙이다. $L = \ell(f_\theta)$에서 $\nabla L = \ell'(f)\nabla f$다. 양자 회로의 기울기만 계산한 뒤 고전 loss 미분을 빼먹으면 다른 갱신이 된다.

G068. Parameter-shift rule — 매개변수 이동 규칙

특정 생성자 스펙트럼에서 shifted 회로들의 기대값으로 미분을 정확히 표현한다. Pauli 회전 한 번이면 ±π/2의 두 항이 대표적이다. 공유 변수가 여러 게이트에 나타나면 단순 동시 이동이 일반적으로 성립하지 않는다.

G069. 유한차분·역전파 — finite differences, backpropagation

유한차분은 작은 변화의 함수 차이로 미분을 근사하고, 역전파는 계산 그래프의 chain rule을 역방향으로 계산한다. 시뮬레이터의 역전파가 물리 QPU에서 동일한 비용으로 가능한 것은 아니다.

G070. SGD·Adam·SPSA — stochastic optimization

SGD는 잡음 있는 기울기를 쓰고 Adam은 모멘트 추정을 이용한다. SPSA는 두 함수 평가로 무작위 방향을 추정한다. 평가 두 번이라는 사실이 모든 좌표의 정확한 미분을 동시에 얻는다는 뜻은 아니다.

G071. 양자 자연 기울기·QFI — quantum natural gradient, quantum Fisher information

파라미터 좌표보다 상태의 구별 가능성에 맞춘 계량을 사용한다. 순수 상태에서는 Fubini-Study 계량과 QFI가 관례에 따른 상수배 관계를 가진다. 계량 추정·정규화·선형계 비용도 든다.

G072. Barren plateau·2-design — 기울기 집중과 무작위 회로 조건

정해진 회로·초기화 분포에서 기울기 분산이 크기에 따라 매우 작아지는 현상이다. 2-design은 Haar 분포의 특정 2차 모멘트를 재현하는 앙상블이다. 단일 정상점의 영 기울기나 모든 깊은 회로를 같은 현상으로 부르지 않는다.

사용: 06강, 07강, 09강.

G. 장치와 자원

G073. CPU·GPU·TPU·QPU — processing units

CPU는 범용 제어, GPU·TPU는 특정 고전 병렬·행렬 계산, QPU는 양자 연산·측정에 사용된다. 하나의 QML workflow에 여러 장치가 참여할 수 있다. 같은 입력과 출력·정확도 없이 칩 이름만으로 비교하지 않는다.

G074. 물리·논리 큐비트 — physical qubit, logical qubit

물리 큐비트는 실제 정보 단위이고 논리 큐비트는 오류정정 코드에 보호된 정보 단위다. 하나의 논리 큐비트에 필요한 물리 자원은 코드·오류율·목표 실패 확률에 따라 달라진다.

G075. Native gate·컴파일 — native gate, compilation/transpilation

Native gate는 장치가 직접 제공하는 연산 집합이다. 컴파일은 추상 회로를 이를 사용한 실행 회로로 바꾼다. 논리 게이트 하나가 물리 연산 하나라는 보장은 없으며 변환의 정확성과 잡음 효과도 별개다.

G076. 배치·routing — qubit placement, routing

논리 wire를 물리 위치에 놓고 연결 제약에 맞추는 과정이다. 먼 두 큐비트의 연산에 SWAP이 추가될 수 있다. 같은 모델도 배치·컴파일 seed·장치 topology에 따라 실행 자원이 다르다.

G077. 폭·깊이·게이트 수 — circuit width, depth, gate count

폭은 사용 wire 수, 깊이는 병렬 실행을 고려한 순차 층 수, gate count는 연산 총수다. 깊이의 layer 정의가 서로 다를 수 있다. 세 숫자 중 하나만으로 회로 비용을 대신하지 않는다.

G078. 샷 — shot

정해진 회로를 준비·실행·측정해 얻는 한 표본이다. 회로 설정 수와 shots는 다르다. 미분·입력·측정 그룹별 회로에 샷을 배정하면 총수는 여러 축의 곱으로 커진다.

G079. 측정 그룹 — measurement group

같은 설정에서 함께 얻을 수 있는 관측량을 묶은 것이다. 가환성만으로 모든 장치의 측정 비용이 동일해지는 것은 아니다. 추가 basis rotation·연결·공분산을 확인한다.

G080. 보정 — calibration

게이트·측정 등의 장치 파라미터를 추정·조정하는 과정이다. 한 번 추정한 보정값을 재사용하면 그 불확실성이 여러 결과에 공유된다. 실제 실행 사이 장치 drift도 기록한다.

G081. 판독 오류 — readout error

준비한 상태 또는 측정 결과가 다른 고전 bit로 보고되는 오류를 뜻한다. Assignment 행렬의 행·열 규약을 명시한다. 읽기 오류와 게이트 이전의 상태 준비 오류를 모든 실험에서 분리할 수 있는 것은 아니다.

G082. QV·CLOPS·RB — quantum volume, circuit-layer throughput, randomized benchmarking

각각 정해진 회로 품질, 처리량, 무작위 시퀀스 오류 특성을 평가하는 protocol이다. 정의·버전·가정을 같이 읽는다. 이 지표가 특정 QML task의 정확도나 실용 우위를 직접 보증하지는 않는다.

G083. 전체 경과 시간 — end-to-end wall-clock time

사용자가 작업을 시작해 결과를 얻을 때까지 걸린 시간이다. 적재·컴파일·대기·실행·고전 후처리를 포함할 수 있다. QPU의 순수 gate time만 보고 전체 시간이라고 하지 않는다.

G084. 전력·에너지 — power, energy

전력은 순간 소비율, 에너지는 전력의 시간 적분이다. W와 J 또는 Wh를 구별한다. 냉각·제어·고전 계산을 포함한 시스템 경계를 정하지 않고 서로 다른 장치의 에너지를 비교하지 않는다.

사용: 11강, 실습 4.

H. 잡음·완화·오류정정

G085. 양자 채널·Kraus·CPTP — quantum channel, Kraus representation, completely positive trace preserving

물리 상태를 상태로 보내는 선형 map은 보조계와 결합해도 양성을 보존하고 trace를 보존해야 한다. $\mathcal{E}(\rho) = \sum_k K_k \rho K_k^\dagger$, $\sum_k K_k^\dagger K_k = I$가 Kraus 표현이다.

G086. 유니탈 — unital

채널이 $\mathcal{E}(I) = I$를 만족하는 성질이다. 같은 입력·출력 차원에서는 완전 혼합 상태를 보존한다. 모든 CPTP 채널이 유니탈인 것은 아니며, amplitude damping이 대표적인 반례다.

G087. Depolarizing 잡음 — depolarizing channel

본 노트 한 큐비트 규약은 $\mathcal{D}_p(\rho) = (1-p)\rho + pI/2$다. Bloch 벡터가 $1-p$배로 줄어든다. Pauli 오류 확률로 정의한 다른 p와 수치가 다를 수 있다.

G088. 위상 감쇠 — dephasing

특정 기저의 population보다 coherence를 감소시키는 잡음이다. 이 노트에서 식을 지정한 기저·확률 규약을 확인한다. 모든 coherence 감소가 같은 물리 채널이나 같은 T2 원인을 뜻하는 것은 아니다.

G089. 진폭 감쇠 — amplitude damping

여기서 보통 $|1\rangle$에서 $|0\rangle$로 이완하는 채널을 뜻한다. Population과 coherence를 함께 바꿀 수 있고 유니탈이 아니다. 단순 depolarizing 수축과 같은 식으로 대체하지 않는다.

G090. 결맞는 오류·확률 오류 — coherent error, stochastic error

잘못된 회전각처럼 일관된 unitary 오차와 무작위 오류 사건 모형을 구별한다. 같은 평균 gate infidelity라도 회로 반복에 따른 누적은 다를 수 있다. 오류율 숫자 하나로 최종 예측 bias를 결정하지 않는다.

G091. 오류 완화·판독 보정 — error mitigation, readout mitigation

추가 실험·가정·후처리로 관측량 bias를 줄이는 방법군이다. 판독 행렬 역산은 한 예다. 보정이 분산을 키울 수 있고 결과가 물리 확률 범위 밖으로 나올 수도 있다. 오류정정 코드로 보호했다는 뜻은 아니다.

G092. ZNE·Richardson 외삽 — zero-noise extrapolation, Richardson extrapolation

여러 잡음 scale의 값을 결합해 0잡음 값을 추정한다. 가중치가 낮은 차수 항을 소거하도록 정한다. 잡음 확대의 물리적 타당성·높은 차수 잔여항·가중치 분산 비용을 확인한다.

G093. PEC — probabilistic error cancellation

이상 연산을 구현 가능한 noisy 연산들의 부호 있는 결합으로 나타내 추정한다. 확률 혼합과 달리 음의 계수가 가능해 샘플 오버헤드가 생긴다. 정확한 잡음 모형과 sampling 규약이 필요하다.

G094. QEC·syndrome — quantum error correction, error syndrome

코드 공간에 정보를 부호화하고 오류 관련 parity 정보를 측정해 복구하는 방법이다. Syndrome은 논리 상태의 모든 진폭을 읽는 값이 아니다. 오류 채널·코드·decoder의 가정을 함께 지정한다.

G095. 코드 거리·문턱값 — code distance, error threshold

코드 거리는 구별·정정 가능한 오류 구조와 관련한 코드 성질이다. Threshold는 특정 fault model과 반복 구조에서 규모를 키워 논리 오류를 줄일 수 있는 조건이다. 모든 장치에 공통인 하나의 상수가 아니다.

G096. Magic state — 매직 상태

일부 오류정정 scheme에서 비Clifford 연산을 구현하는 데 공급하는 특수 자원 상태다. 생산·증류·주입 비용이 전체 자원에서 클 수 있다. 논리 큐비트 수만 세면 이 비용을 놓칠 수 있다.

사용: 12강, 17강.

I. 계산 모형과 우위 주장

G097. Oracle·query — 접근 oracle, 질의

허용한 입력 접근이나 함수를 추상적으로 제공하는 장치와 그 호출이다. Query 한 번이 물리 gate 하나나 파일 읽기 한 번이라는 뜻은 아니다. 실제 구현 비용과 접근의 강도를 따로 기술한다.

G098. 표본 복잡도 — sample complexity

정해진 오차·성공 확률을 얻는 데 필요한 독립 자료·상태 준비 횟수다. 측정 설정·장치 시간과 같지 않을 수 있다. 복사본 하나를 여러 샷에 무제한 재사용한다고 가정하지 않는다.

G099. 시간·공간 복잡도 — time complexity, space complexity

연산 시간과 계산 중 유지하는 메모리의 입력 크기 의존성이다. 고전 bit, 정밀도 고정 register, 논리 qubit을 명시한다. 메모리 우위를 곧바로 시간 우위로 바꾸어 말하지 않는다.

G100. 점근 표기 — asymptotic notation

O는 상한, Ω는 하한, Θ는 같은 차수의 양쪽 경계를 나타낸다. 숨긴 상수·로그·정밀도 의존성이 실용 비용을 좌우할 수 있다. 작은 실험의 시간 순위와 정리의 점근 차이는 별개다.

G101. 정밀도·실패 확률 — accuracy/tolerance, failure probability

보통 ε는 허용 오차, δ는 그 보장을 벗어날 확률이다. 가산·상대 오차나 분포 거리 중 무엇인지 정해야 한다. 같은 정확도라는 말이 분류 accuracy와 수치 precision을 동시에 뜻하지 않는다.

G102. 양자 우위 — quantum advantage

같은 과제·입출력·오차·허용 자원에서 명시한 고전 비교보다 어떤 자원을 줄인 주장이다. 정리·제한된 알고리즘군 대비 결과·장치 proof of concept·실용 이득을 구별한다.

G103. 탈양자화 — dequantization

양자 알고리즘의 이점을 비슷한 고전 접근 자원에서 재검토해 효율적 고전 알고리즘을 찾는 일이다. 모든 QML의 불가능성 정리가 아니다. 입력 접근이 정말 동등한지도 다시 확인해야 한다.

G104. Sample-and-query access — 표본·원소 조회 접근

벡터의 원소·norm 조회와 길이제곱에 비례한 인덱스 sampling 등을 허용하는 고전 접근 모형이다. 허용 동작·비용을 정해야 한다. 아래 statistical-query learning과 약자 SQ만 같고 개념은 다르다.

G105. Statistical query — 통계 질의

학습 분포에 대한 특정 함수 평균을 허용 오차 안에서 묻는 접근 모형이다. 표본 각각을 전부 직접 받는 모형과 구별된다. Correlational SQ는 다시 제한된 질의 종류다.

G106. Quantum example·QSQ — 양자 예제 상태, quantum statistical query

분포·label 정보를 coherent하게 담은 상태나 그에 대한 기대값 질의를 허용하는 학습 모형이다. 저장된 고전 데이터가 무료로 이 접근을 제공하지는 않는다. 준비·정밀도·질의의 범위를 논문에서 확인한다.

G107. 고전 surrogate — classical surrogate

원래 회로의 손실·예측을 대신 계산하는 고전 표현이다. 필요한 초기 특징을 QPU에서 얻었다면 양자 자료 획득을 포함하는 방법이다. 완전히 고전 입력만 쓰는 모델과 구별한다.

G108. 비교 기준선·절제 실험 — baseline, ablation

경쟁 방법과 특정 구성 요소를 제거해 원인을 조사하는 실험이다. 얽힘 gate를 뺀 모델이나 같은 Fourier feature를 쓰는 고전 모델이 예다. 파라미터 수만 같게 맞추는 것이 항상 공정한 비교는 아니다.

사용: 01강, 14강, 18강.

J. 양자 데이터와 측정 재사용

G109. 양자 데이터·복사본 — quantum data, copy

아직 측정하지 않은 상태·과정에 접근하는 자료다. 여러 copy는 미지 상태 하나를 복제했다는 뜻이 아니라 같은 준비 과정을 반복한 독립 표본이다. 고전 기록처럼 무제한 복제 가능하다고 가정하지 않는다.

G110. 집단 측정 — collective/joint measurement

여러 계나 상태 복사본에 공동 연산 후 측정하는 방법이다. 각 복사본을 따로 측정하는 방법보다 많은 정보를 얻을 수 있는 과제가 있다. 허용한 메모리·접근이 결과의 조건이다.

G111. Classical shadow — 고전 그림자 기록

무작위 측정 설정·결과를 저장해 여러 관측량을 나중에 추정하는 방법이다. 기록 하나가 전체 상태를 정확히 복원한 것은 아니다. 선택한 측정 앙상블과 예측할 관측량이 비용을 정한다.

G112. 측정 채널·역채널 — measurement channel, inverse map

측정으로 평균적으로 어떤 정보를 남기는지 나타내는 선형 map과 그 통계적 역변환이다. Shadow의 역변환은 개별 추정자를 비물리적인 행렬로 만들 수 있다. 실제 장치에서 잡음을 역으로 되돌린다는 뜻이 아니다.

G113. Shadow norm — 관측량별 측정 비용 척도

선택한 shadow 측정 방식에서 관측량 추정의 분산을 제어하는 양이다. 관측량 개수의 log 의존성만 보아서는 안 된다. 비국소 관측량에서 이 norm이 커지면 샷 비용이 커질 수 있다.

G114. Pauli 문자열·무게 — Pauli string, Pauli weight

I,X,Y,Z의 텐서곱과 항등이 아닌 인자 수다. 예를 들어 $X \otimes I \otimes Z$는 무게 2다. 큐비트 총수와 같지 않을 수 있고 국소 잡음·shadow 분산의 의존성을 정한다.

G115. 토모그래피 — quantum state tomography

여러 측정에서 상태 자체를 복원하는 작업이다. 일반 n큐비트 상태의 자유도는 $4^n - 1$이다. 일부 국소 기대값을 예측하는 더 제한된 과제와 전체 상태 복원을 혼동하지 않는다.

G116. 선형·비선형 상태 함수 — linear/nonlinear state functional

$\mathrm{Tr}(O\rho)$는 ρ에 선형이지만 $\mathrm{Tr}\,\rho^2$는 아니다. 불편한 상태 추정자를 얻었다고 그 제곱을 대입한 추정도 자동 불편한 것은 아니다. 독립 copy 또는 교차항 처리가 필요할 수 있다.

G117. 상태·채널 학습 — state learning, channel learning

준비된 상태의 성질을 배우는 문제와 입력을 출력으로 보내는 미지 과정을 배우는 문제다. 후자는 어떤 probe·입력·보조계 사용이 허용되는지 정해야 한다. 두 과제의 샘플 수를 같은 단위로 비교하지 않는다.

G118. 양자 메모리 — quantum memory

측정 전 상태를 보관해 나중에 공동 처리할 수 있는 자원이다. 저장 시간·잡음·접근·정정 비용이 든다. 고전 bitstring을 RAM에 저장하는 것과 같은 가정이 아니다.

G119. Bell 측정·SWAP test — Bell measurement, SWAP test

전자는 얽힌 Bell 기저에서 측정하는 절차, 후자는 상태 겹침과 관련한 확률을 읽는 절차다. 서로 다른 회로다. SWAP test는 보통 내적의 복소 위상이나 부호를 직접 제공하지 않는다.

G120. 복제 불가능 정리 — no-cloning theorem

미지의 임의 상태 모두를 완벽하게 복제하는 하나의 물리적 보편 연산은 없다. 알려진 준비 회로를 반복하는 것은 가능하다. 직교 상태의 복사와 임의 비직교 상태의 보편 복제를 구별한다.

사용: 03강, 05강, 13강.

K. 생성 학습과 대칭

G121. Born machine·QCBM — quantum circuit Born machine

$p_\theta(z) = |\langle z|U_\theta|0\rangle|^2$로 분포를 정의해 측정 샘플을 생성하는 모델이다. 샘플 생성이 쉬워도 특정 bitstring의 확률을 효율적으로 계산하는 것은 별도 문제다.

G122. KL divergence·총변동 거리 — Kullback-Leibler divergence, total variation distance

KL은 분포 비율의 log 평균이며 방향이 있고, TV는 확률 차이 절댓값 합의 절반이다. q가 0인 곳에 p가 양수이면 $D_{KL}(p\|q)$는 무한대다. 둘 다 fidelity와 같은 양이 아니다.

G123. MMD — maximum mean discrepancy

커널 특징 평균의 차이를 비교하는 분포 discrepancy다. 샘플 쌍의 커널 평균으로 추정할 수 있다. 좋은 학습 신호·전체 분포 구별 능력은 커널 선택에 달려 있다.

G124. U-statistic·V-statistic — 표본 쌍 평균의 두 규약

MMD 추정 등에서 자기 자신과의 쌍을 제외하는지 포함하는지 구별한다. 불편한 제곱 MMD 추정값은 유한 표본에서 음수가 나올 수도 있다. 그 사실만으로 계산 오류라고 하지 않는다.

G125. Characteristic kernel — 분포 구별성이 있는 커널

확률분포의 평균 임베딩이 서로 다른 분포를 구별하는 커널이다. 고정 특징 몇 개만 보는 kernel은 이 성질이 없을 수 있다. 표현상 구별 가능해도 유한 샷에서 쉽게 학습된다는 뜻은 아니다.

G126. 지지집합·mode collapse — support, mode collapse

지지집합은 확률이 놓이는 영역이고 mode collapse는 생성기가 일부 양상만 내는 현상을 가리킨다. 모든 낮은 차수 주변분포가 맞아도 전역 분포의 일부를 놓칠 수 있다.

G127. Parity·고차 상관 — parity, higher-order correlation

여러 비트의 합을 mod 2로 본 parity는 전역 구조의 작은 예다. 세 비트 짝수·홀수 분포는 1·2차 주변분포가 같아도 3차 상관이 다르다. 국소 평가량만으로 전체 분포를 인증할 수 없는 반례다.

G128. 군·표현 — group, representation

군은 닫힌 합성 연산·결합법칙·항등원·역원을 갖는 집합이고, 표현은 그 합성 구조를 행렬·연산으로 실현한다. 물리적 입력 변환과 encoding 후의 표현이 어떻게 대응하는지 먼저 정해야 한다.

G129. 불변성 — invariance

변환해도 출력이 같은 성질이다. 분자 에너지는 적절한 전체 공간 회전에 불변일 수 있다. 상태의 물리적 대칭, 라벨의 대칭, 회로의 대칭은 각각 확인해야 한다.

G130. 등변성 — equivariance

입력을 변환하면 출력도 정해진 법칙으로 변하는 성질이다. 힘 벡터는 회전하면 함께 회전해야 한다. 불변 스칼라 출력과 같은 제약을 쓰면 필요한 정보를 잃을 수 있다.

G131. Twirling — 군 평균

상태·관측량·채널을 군의 작용에 대해 평균해 대칭 성분을 추출한다. 두 wire 교환에 대한 Z_1의 평균은 $(Z_1 + Z_2)/2$다. 평균은 방향 정보도 지울 수 있고 구현 비용도 있다.

G132. 대칭 부문 — symmetry sector

보존량·대칭 표현 등에 따라 나뉜 부분공간이다. 대칭 보존 회로는 초기 부문을 벗어나지 못할 수 있다. 정답이 다른 부문에 있으면 최적화기를 바꾸는 것만으로 해결되지 않는다.

사용: 15강, 16강.

L. 과학 계산과 내결함성 QML

G133. Neural quantum state — 신경망 양자 상태, NQS

구성 s에 대한 파동함수 진폭 $\psi_\theta(s)$를 고전 신경망으로 표현한다. 학습 대상이 양자 상태라는 뜻이며 계산 장치가 반드시 QPU라는 뜻은 아니다.

G134. VMC·local energy — variational Monte Carlo, 국소 에너지

$|\psi|^2$에 비례해 구성을 뽑아 $E_{loc}(s) = \sum_{s'} H_{ss'}\psi(s')/\psi(s)$를 평균한다. Local이라는 이름이 반드시 작은 공간 영역의 에너지만 뜻하지는 않는다. 샘플링 혼합·해밀토니안 희소성도 중요하다.

G135. Block encoding — 블록 부호화

더 큰 유니터리의 특정 보조계 block에 A/α를 넣는 표현이다. 보조 wire 수·정규화 α·구현 오차를 명시한다. 큰 행렬이 주어졌다는 사실만으로 이 유니터리를 무료로 구현할 수는 없다.

G136. QSVT — quantum singular value transformation

Block encoding과 phase 연산을 조합해 행렬의 특잇값에 다항식 변환을 구현하는 틀이다. 역수·필터 등의 근사는 구간·차수·오차 조건이 필요하다. 임의의 함수를 한 번에 적용하는 기능은 아니다.

G137. HHL·해 상태 — quantum linear systems algorithm, solution state

선형계의 해 방향을 양자 상태로 만드는 알고리즘 계열의 출발점이다. 해 벡터의 모든 계수를 고전 숫자로 출력하는 작업과 다르다. 입력 접근·조건수·정밀도·출력 목적이 비용의 일부다.

G138. 특잇값·조건수 — singular value, condition number

특잇값은 $A^\dagger A$ 고유값의 제곱근이다. 가역 A에서 2-norm 조건수는 최대/최소 특잇값 비다. 정규방정식은 조건수를 제곱할 수 있어 표현 선택이 중요하다.

G139. 진폭 추정 — amplitude estimation

적절한 coherent oracle 접근에서 성공 확률 같은 양을 추정하는 양자 절차다. 이상적인 query 차수 개선에는 oracle·역연산·긴 일관된 연산 조건이 붙는다. 일반 finite-shot 평균과 같은 비용 모형이 아니다.

G140. 내결함성 — fault tolerance

허용한 물리 오류 아래에서도 논리 계산을 목표 실패 확률로 수행하도록 설계하는 성질이다. 보호된 처리기가 외부에서 들어오는 미지의 데이터를 자동으로 무잡음으로 바꾸지는 않는다.

G141. Quantum uploading — 양자 자료의 보호 메모리 부호화

이 노트에서는 2026년 연구가 다룬 외부 실험 상태의 즉시 보호 부호화 맥락으로 사용한다. 상태 준비·고전 파일 업로드와 다른 개념이다. 비교 전략·잡음·부호화 시점이 결과의 조건이다.

G142. 논리 자원 추정 — logical resource estimate

알고리즘의 논리 wire·gate·비Clifford 공급·목표 오류 등을 계산한 추정이다. 물리 큐비트 수와 시간으로 바꾸려면 코드·오류·하드웨어 가정이 더 필요하다. 장치 실험 결과로 표시하지 않는다.

G143. 사전공개·출판본 — preprint, version of record

심사·출판 상태와 문헌 판본을 나타낸다. arXiv 최초일·수정일·학술지 온라인 공개일·권 연도는 다를 수 있다. 제목이 같아도 어느 판의 정리·실험을 읽었는지 기록한다.

G144. 재현·독립 검증 — reproduction, independent verification

같은 코드·자료·조건을 실행해 결과를 대조하는 것과 별도 계산·증명·실험으로 확인하는 범위를 구별한다. 논문의 서지나 작은 교육 예제를 검산한 일을 전체 장치 결과의 독립 재현으로 부르지 않는다.

사용: 16강, 17강, 18강.

혼동을 줄이는 사용법

논문에서 새로운 용어를 만날 때 “무엇의 정의인가”, “식의 입력·출력은 무엇인가”, “어떤 유사한 말과 다른가”, “어느 조건에서 쓰는가”를 적는다. 예를 들어 *efficient*는 실제 초 단위로 빠르다는 말일 수도, 입력 크기의 다항 시간이라는 이론 용어일 수도 있다. 정리를 읽을 때는 후자의 변수·접근 모형을 먼저 확인한다.

약자 SQ는 **sample-and-query access**와 **statistical query**를 모두 가리킬 수 있다. Fidelity는 제곱 관례가 다를 수 있고, depolarizing p도 정의가 다르며, regularization과 normalization은 모두 정규화로 번역되기도 한다. 이 네 가지는 영어 원어와 식을 함께 메모한다.

이 용어집의 표준 수학·양자정보 정의에 대한 추가 읽기는 Watrous의 저자 제공 교재 안내와 IBM Quantum Learning다. 원문 파일은 재배포하지 않는다. QML의 특정 정리·최신 용례는 각 강의의 원 논문과 출처 확인 범위를 따른다. 단어의 정의와 그 단어를 포함한 우위 주장의 검증은 별개다.

01. 머신러닝 문제를 양자 계산의 언어로 바꾸기

> 독립 집필한 80분 학습 단원 · 근거 기준일 2026-10-20. CMU 공식 강의록이 아니다. 원강좌의 7강·5실습과 별개로 구성한 자체 시리즈의 첫 강의다.

시작하기 전에

이 강의의 질문은 “양자컴퓨터를 넣으면 정확도가 오르는가?”보다 먼저 “무엇을 학습하며 무엇을 비용으로 셀 것인가?”다. 벡터의 내적, 평균, 분산을 알고 있으면 시작할 수 있다. 식의 합 기호와 기댓값이 낯설면 수학 준비 노트를 먼저 읽는다. 양자 상태를 아직 몰라도 괜찮다. 여기서 **양자 상태**는 장치가 준비하는 입력, 관측량은 장치에서 읽을 수 있는 수량으로 이해하고, 2-3강에서 정확한 정의를 배운다.

학습 후에는 데이터와 출력의 종류를 명시하고, 경험 위험과 모집단 위험을 계산하며, 학습 오차의 원인을 세 가지로 분리하고, shot을 포함한 훈련 비용을 직접 산출할 수 있어야 한다. 외부 논문의 속도 향상 주장에는 입력 접근·출력·오차·자원이라는 네 조건을 붙일 수 있어야 한다.

80분 학습 순서

시간	수행할 활동	남길 결과
0-10분	용어를 읽고 자신이 관심 있는 학습 문제를 한 문장으로 정의	입력·정답·출력 명세
10-25분	위험과 오차 분해를 종이에 유도	세 항이 생기는 이유
25-45분	평균 예측기 예제와 shot 비용 예제 계산	수치와 단위가 있는 장부
45-60분	동일하지 않은 비교를 찾아 비교 조건을 수정	공정한 비교표
60-75분	문제 1·3을 먼저 풀고 선택한 문제의 해설만 대조	틀린 이유 두 문장
75-80분	본문을 덮고 완료 점검에 답함	다음 강의 진행 여부

80분은 읽는 데 걸리는 시간을 보증하는 수치가 아니다. 계산과 회상을 포함한 첫 학습 세션이다. 네 문제를 모두 독립적으로 풀고 원문까지 읽는 일에는 별도의 복습 시간이 필요하다.

강의 후 **60-90분**에는 남은 문제를 해설 없이 풀고, 유도 하나를 재작성하고, 오답을 수정한다. 원문 전문 독해와 코딩 실습은 별도 시간이다.

핵심 용어

한국어·영어	정의·기호·구별할 것
표본·sample	분포에서 관측한 한 사례 (x_i, y_i). 샷 한 번과 훈련 사례 하나는 다른 단위다.

한국어·영어	정의·기호·구별할 것
가설 집합·hypothesis class	선택 가능한 예측 함수들의 집합 $\mathcal{F}$. 회로 구조와 고전 후처리까지 포함한다.
손실·loss	한 예측을 평가하는 수 $\ell(f(x), y)$. 분류 정확도와 미분 가능한 훈련 손실은 다를 수 있다.
경험 위험·empirical risk	관측 데이터의 평균 손실 $\widehat{R}_D(f)$. 훈련 데이터에만 대한 성적이다.
모집단 위험·population risk	새 사례 분포의 평균 손실 $R(f)$. 실전 목표이며 보통 정확히 알 수 없다.
경험 위험 최소화·ERM	$\widehat{R}_D$를 줄여 모델을 선택하는 원리. 일반화나 최적화 성공을 자동 보장하지 않는다.
근사 오차·approximation error	허용한 모델 집합으로 최선의 목표 함수에 얼마나 가까이 갈 수 있는가의 한계.
추정 오차·estimation error	유한한 훈련 표본으로 모델을 선택하면서 생기는 차이. 측정 shot 오차와 구분한다.
최적화 오차·optimization error	정한 훈련 목적함수의 최솟값에 실제 알고리즘이 도달하지 못한 정도.
샷·shot	상태 준비부터 측정까지 한 번 실행하여 결과 하나를 얻는 반복 단위.
접근 모형·access model	데이터에 어떤 연산을 얼마의 비용으로 허용하는지 정한 계산 규칙.
종단간 비용·end-to-end cost	입력 준비부터 최종 산출물까지 포함한 비용. 회로 실행 시간만으로 대체하지 않는다.

용어의 영문 표기와 다른 강의의 사용례는 통합 용어집을 따른다. “위험”은 안전상의 위험이라는 뜻이 아니라 통계학의 평균 손실이다.

무엇을 예측하는지부터 적는다

지도학습의 데이터셋을 $D = \{(x_i, y_i)\}_{i=1}^{N}$라 쓰자. N은 사례 수이고, $x_i \in \mathbb{R}^d$는 d개 특징, y_i는 정답이다. 회귀는 실수 정답을, 분류는 범주 정답을 예측한다. 비지도학습은 정답 없이 밀도나 군집 같은 구조를 찾는다. 같은 데이터라도 분류, 군집, 생성은 서로 다른 과제이며 출력의 크기도 다르다.

검사표에서 질병을 예측하는 문제의 입력은 이미 고전 메모리에 저장된 숫자다. 이를 QPU에 올리는 비용이 든다. 반면 양자 센서가 생성한 미지의 상태를 분류하는 문제는 측정하기 전의 상태를 입력으로 허용할 수 있다. 상태를 먼저 개별 측정한 고전 기록과, 여러 상태를 함께 처리하는 양자 접근은 같은 정보를 제공하지 않는다. 어떤 접근이 허용되는지가 연구 질문의 일부다.

입력·접근	학습 절차	먼저 비교할 대상
고전 표 데이터	CPU/GPU 학습	강한 고전 기준선과 튜닝 예산
같은 표 데이터	데이터 준비 후 양자 회로	준비·측정·고전 처리를 합한 비용
양자 상태를 개별 측정한 기록	고전 통계 학습	어떤 측정과 몇 개 상태를 사용했는가

입력·접근	학습 절차	먼저 비교할 대상
미지의 양자 상태에 직접 접근	양자 메모리·집단 처리	메모리·게이트와 상태 사본 수

양자 장치를 고전 머신러닝으로 제어하는 연구도 중요하지만, 그것이 곧 머신러닝을 양자 계산으로 가속했다는 뜻은 아니다. 논문 제목의 QML이라는 이름만으로 입력과 계산 방향을 추정하지 않는다.

유도 1: 훈련 성적과 실전 성적의 차이

제곱 손실 $\ell(\hat{y}, y) = (\hat{y} - y)^2$라면 경험 위험과 모집단 위험은 각각

$$\widehat{R}_D(f) = \frac{1}{N}\sum_{i=1}^{N}(f(x_i) - y_i)^2, \qquad R(f) = \mathbb{E}_{(x,y)\sim\mathcal{D}}(f(x) - y)^2$$

다. 여기서 $\mathcal{D}$는 새 사례를 만드는 미지의 분포다. 첫 식은 실제로 계산할 수 있지만 두 번째 식은 대체로 독립 테스트 표본으로 추정해야 한다. 두 분포가 같다는 가정도 필요하다. 훈련 때와 배포 때 장치나 데이터 생성 조건이 달라지면 이 가정부터 확인한다.

모집단에서 가장 좋은 모델을 $f^*_{\mathcal{F}} \in \arg\min_{f\in\mathcal{F}} R(f)$, 훈련 데이터를 가장 잘 맞춘 모델을 $\hat{f} \in \arg\min_{f\in\mathcal{F}} \widehat{R}_D(f)$라 쓰자. 실제 학습 결과 $\tilde{f}$가 정확한 최솟값에 도달하지 못하고

$$\widehat{R}_D(\tilde{f}) - \widehat{R}_D(\hat{f}) \le \epsilon_{\text{opt}}$$

를 만족한다고 하자. 또한 모든 허용 모델에서 훈련·실전 차이가 $|R(f) - \widehat{R}_D(f)| \le \delta$라고 가정하자. 그러면 항을 더하고 빼서

$$\begin{aligned} R(\tilde{f}) - R(f^*_{\mathcal{F}}) &= [R(\tilde{f}) - \widehat{R}_D(\tilde{f})] + [\widehat{R}_D(\tilde{f}) - \widehat{R}_D(\hat{f})] \\ &\quad + [\widehat{R}_D(\hat{f}) - \widehat{R}_D(f^*_{\mathcal{F}})] + [\widehat{R}_D(f^*_{\mathcal{F}}) - R(f^*_{\mathcal{F}})] \\ &\le 2\delta + \epsilon_{\text{opt}}. \end{aligned}$$

세 번째 대괄호가 0 이하인 이유는 $\hat{f}$가 경험 위험의 최소화자이기 때문이다. 모든 가능한 예측 함수의 최적 위험을 R^*라 하면 최종 초과 위험에는

$$R(\tilde{f}) - R^* \le \underbrace{R(f^*_{\mathcal{F}}) - R^*}_{A} + \underbrace{2\delta}_{B} + \underbrace{\epsilon_{\text{opt}}}_{C}$$

가 성립한다. A는 근사 오차, B는 유한 표본으로 생기는 차이의 상계, C는 최적화 오차다. 이는 조건을 가정한 교육용 부등식이며, 모든 QML 회로에 작은 δ를 보장한 정리는 아니다. 데이터가 적어서 생긴 문제와 회로가 목표 함수를 표현하지 못해서 생긴 문제를 구별하는 용도로 쓴다. 실제 finite-shot 목적함수는 추가 확률오차를 가지며, 장치 잡음은 평균 자체를 바꿀 수 있다.

완전 예제 1: 단순한 상수 예측기도 배울 것이 있다

입력과 관계없이 $f_a(x) = a$를 출력하고 정답이 1, 2, 3이라고 하자. 훈련 위험은

$$\widehat{R}(a) = \frac{(a-1)^2 + (a-2)^2 + (a-3)^2}{3} = (a-2)^2 + \frac{2}{3}.$$

따라서 최적 상수는 2이고 최소 훈련 위험은 $2/3$이다. 전개 없이 미분해도 $\partial_a \widehat{R} = 2a - 4 = 0$을 얻는다. 모델이 단순해서 정답 세 개를 모두 맞출 수 없다는 것이 근사 능력의 제한이다.

이제 실제 정답이 0과 4를 같은 확률로 만든다고 가정하면 모집단 위험은 $R(a) = [a^2 + (a-4)^2]/2 = (a-2)^2 + 4$다. 최적 상수는 여전히 2지만 위험은 4다. 훈련 위험 $2/3$을 실전 위험으로 보고하면 틀린다. 이 예제의 훈련 정답과 모집단은 의도적으로 다르게 정했다. 데이터 분포가 바뀌면 작은 훈련 오차만으로 평가할 수 없다는 반례다.

유도 2와 완전 예제 2: 양자 예측은 측정 예산을 가진다

대표적인 양자 예측기를

$$f_\theta(x) = \mathrm{Tr}[O\, U_\theta \rho(x) U_\theta^\dagger]$$

라 쓰자. $\rho(x)$는 입력 상태, U_θ는 학습 회로, O는 관측량이다. Tr는 행렬의 대각 원소 합인 trace다. 관측값이 ±1이면 한 번의 결과 Z_s의 평균은 f이고 제곱은 언제나 1이다. 따라서 $\mathrm{Var}(Z_s) = 1 - f^2$이며, 독립 S회 평균의 분산은 $(1-f^2)/S$다. 정확한 기댓값을 즉시 반환하는 시뮬레이터는 이 통계 비용을 지불하지 않는다.

20개 파라미터를 각각 두 shifted 회로로 미분하고, minibatch 32개, 회로당 1,000 shots를 쓴다고 하자. 한 단계에는 $2 \times 20 \times 32 = 1{,}280$개 입력·회로 조합, $1{,}280{,}000$개 shots가 필요하다. 100단계면 $128{,}000{,}000$회다. 가상의 실행 장치가 한 shot에 10마이크로초를 쓴다면 직렬 순수 측정 시간만 1,280초다. 이 수는 장치 성능 보고가 아니라 단위 계산 예제다. 순방향 손실, 검증, 다중 관측량, 보정과 대기는 아직 빠져 있다.

전체 시간은 교육용으로

$$T_{\mathrm{end}} = T_{\mathrm{prep}} + T_{\mathrm{compile}} + T_{\mathrm{queue}} + N_{\mathrm{circuits}} S\, t_{\mathrm{shot}} + T_{\mathrm{classical}} + T_{\mathrm{output}}$$

처럼 기록할 수 있다. 실제 배치·병렬 실행에서는 항들이 겹칠 수 있으므로 이 식을 하드웨어의 정밀 모형으로 쓰지 않는다. 표본 수, 회로 수, 벽시계 시간과 메모리는 서로 다른 자원이다.

활동: 우위 주장에 비교 조건을 붙인다

“100만 차원 벡터를 20큐비트에 저장하므로 입력이 20단계다”는 문장을 고쳐 보자. 20큐비트는 진폭을 표현하는 공간의 크기를 말한다. 일반 벡터를 준비하는 게이트 수와 데이터 파일을 읽는 시간은 별개다. “20큐비트로 상태를 표현한다. 준비 oracle을 가정한 회로 질의 수를 비교했으며 일반 데이터 적재 시간은 포함하지 않았다”라고 쓰면 검증 가능한 주장이 된다.

또 다른 반례는 전체 해 벡터를 반환하는 고전 알고리즘과, 해 상태의 단일 기댓값만 반환하는 양자 알고리즘을 비교하는 것이다. 출력을 하나의 기댓값으로 맞추거나 양자 쪽에도 전체 읽기 비용을 넣어야 한다. 정확도와 성공 확률도 같아야 한다. 이 네 조건을 못 쓰면 “빠르다”라는 결론을 보류하고 무엇을 줄였는지만 기록한다.

연습문제와 풀이

문제 1. 경험 위험을 직접 최소화하기

정답 0, 0, 3을 상수 모델 a로 예측한다. 제곱 손실의 최솟값과 최적 a를 구하라. **힌트:** 제곱을 전개하고 완전제곱식으로 묶는다.

풀이: $\widehat{R}(a) = [a^2 + a^2 + (a-3)^2]/3 = a^2 - 2a + 3 = (a-1)^2 + 2$다. 따라서 $a = 1$, 최솟값 2다. 평균을 쓰는 이유는 외운 규칙 때문이 아니라 제곱 손실의 대수적 성질 때문이다. 절댓값 손실이면 중앙값이 최적이며 여기서는 0이 된다. 손실을 바꾸면 학습 목표도 달라진다.

문제 2. 작은 훈련 손실의 의미

모델 A는 훈련 위험 0, 테스트 위험 0.25이고 모델 B는 각각 0.1, 0.12다. 어느 모델을 배포할지 판단하고 더 필요한 정보를 적어라. **힌트:** 테스트 점수의 불확실성과 선택에 사용한 데이터 여부를 생각한다.

풀이: 현재 수치만 보면 B가 새 사례에서 낫지만 즉시 확정할 수 없다. 동일한 독립 테스트셋에서 평가했는지, 표본 수와 신뢰구간, 반복 seed, 비용을 확인한다. A의 훈련 성적만으로 근사 능력이 유용했다고 결론 내릴 수 없다. 테스트셋을 여러 번 보고 B를 선택했다면 그 집합은 사실상 검증셋이 되었으므로 새 최종 평가가 필요하다.

문제 3. 측정 예산 계산

파라미터 12개, batch 8개, 두 회로 미분, 500 shots, 200단계라면 총 shots는? 표준오차를 절반으로 줄이면 얼마가 되는가? **힌트:** 단계당 비용을 구한 뒤 반복 수를 곱한다.

풀이: 단계당 $2 \times 12 \times 8 \times 500 = 96{,}000$회, 총 19,200,000회다. 독립 반복의 표준오차는 $S^{-1/2}$에 비례하므로 절반으로 줄이려면 회로당 2,000 shots가 필요하다. 새 총량은 76,800,000회다. 장치의 systematic bias는 이 증가로 사라지지 않는다. 정확도 개선과 측정 예산을 별도로 보고해야 한다.

문제 4. 입력과 출력을 맞추기

양자 알고리즘은 공짜 상태 준비 후 평균 하나를 오차 0.1로 출력하고, 고전 알고리즘은 파일을 읽어 모든 예측을 오차 0.001로 출력한다. 실행 시간만 비교해 우위를 주장할 수 있는가? **힌트:** 비교 계약을 네 문장으로 고쳐라.

풀이: 현재는 같은 과제가 아니다. 두 방법에 같은 데이터 접근을 주고, 목표 출력을 같은 평균으로 정하며, 허용 오차와 성공 확률을 동일하게 맞춘다. 상태 준비·파일 적재·반복 측정·고전 후처리를 포함한 자원을 다시 센다. 그 뒤에도 차이가 남으면 그 구체적 자원의 우위를 주장할 수 있다. 이 수정은 양자 결과를 무효화하는 것이 아니라 어떤 접근 모형에서 성립하는지 분명하게 만든다.

학습 완료 점검

- 경험 위험과 모집단 위험의 식을 보고 각각의 평균이 무엇에 대해 계산되는지 설명한다. N개 관측 표본과 미지의 분포를 명시하면 통과다. 실패하면 “유도 1”로 돌아간다.
- 근사·추정·최적화 오차마다 서로 다른 개선책을 하나씩 든다. 모델 집합 변경·새 데이터·최적화 개선을 연결하면 통과다. shots 증가를 세 항의 공통 해법으로 답하면 다시 읽는다.
- 두 shifted 회로 비용에서 파라미터·batch·shots·step의 네 인자를 빠짐없이 곱한다. 단위를 shots로 쓰면 통과다.
- 양자 우위 주장의 조건 네 가지를 입력 접근·출력·오차/성공률·자원으로 적는다. 하나라도 빠지면 활동을 반복한다.

원문 읽기

- CMU 17-620 공개 강좌 페이지: 원강좌의 세션 범위만 확인한다. 자체 18강의 강의 시간과 내용을 원 수업의 실제 운영으로 읽지 않는다.
- Huang et al., Power of data in quantum machine learning (2021): 본문의 학습 문제 설정과 Discussion을 읽고 “상태 계산이 어렵다”와 “데이터에서 학습하기 어렵다”의 차이를 표시한다. 논문 전체 증명과 실험을 독립 재현한 것은 아니다.
- Cerezo et al., Challenges and opportunities in quantum machine learning (2022): 연구자의 전망과 난제 분류를 읽는 선택 자료다. 본 강의의 위험 부등식과 수치 예제는 직접 만든 교육용 계산이다.

02. 큐비트, 위상, 게이트와 측정

> 독립 집필한 80분 학습 단원 · 2026-10-20 기준. 원강좌 Lecture 1의 공개 주제를 출발점으로 확장했으며 실제 수업 필기가 아니다.

시작하기 전에

양자 학습 모델이 숫자를 예측하는 과정을 이해하려면 상태, 연산, 측정을 구별해야 한다. 1강의 평균과 분산을 복습한다. 복소수의 절댓값, 켤레전치, 행렬곱이 낯설면 수학 준비 노트를 함께 편다. 이 강의에서는 벡터의 원소를 계산하고, 밀도행렬이 올바른 상태인지 판정하고, 한 측정 설정으로 알 수 없는 정보를 찾아내며, 측정 평균의 불확실성을 계산한다.

이상적 단일 큐비트를 먼저 다룬다. 실제 장치의 누설, 상태 준비 오류, 상관된 잡음은 이 모형에 모두 포함되어 있지 않다. 이상 모형과 측정 데이터의 불일치를 곧바로 양자역학의 실패로 해석하지 않는다.

80분 학습 순서

시간	수행할 활동	남길 결과
0-10분	용어와 복소수 내적 확인	정규화 계산 한 개
10-25분	위상과 H 게이트 예제 계산	두 상태의 Z·X 통계
25-45분	밀도행렬·Bloch 벡터·POVM 유도	상태 판정과 확률
45-60분	측정 분산 예제를 손으로 재계산	표준오차와 가정
60-75분	문제 1·3부터 풀고 선택한 문제의 해설만 대조	오개념 수정 기록
75-80분	답을 보지 않고 완료 점검	진도 판단

계산을 멈추고 직접 식을 쓰는 시간이 포함되어 있다. 네 문제 전체와 선택 원문은 복습 시간에 마친다.

강의 후 **60-90분**에는 남은 문제를 해설 없이 풀고, 유도 하나를 재작성하고, 오답을 수정한다. 원문 전문 독해와 코딩 실습은 별도 시간이다.

핵심 용어

한국어·영어	정의와 직관
큐비트·qubit	상태공간이 $\mathbb{C}^2$인 두 수준 양자계의 정보 단위. 측정 결과는 연속 벡터 전체가 아니다.
켓과 브라·ket/bra	열벡터 $\lvert\psi\rangle$와 그 켤레전치 $\langle\psi\rvert$. 내적은 bra와 ket의 곱이다.
진폭·amplitude	기저벡터의 복소 계수 α, β. 확률은 계수 자체가 아니라 절댓값 제곱이다.

한국어·영어	정의와 직관
상대 위상·relative phase	두 진폭 사이의 위상차. 간섭 측정으로 구별될 수 있다.
전역 위상·global phase	모든 진폭에 같은 $e^{i\gamma}$를 곱하는 변화. 고립된 상태의 측정 확률을 바꾸지 않는다.
유니터리·unitary	$U^\dagger U = I$인 선형 연산. 닫힌 계의 가역 진화를 나타낸다.
관측량·observable	에르미트 행렬 $O = O^\dagger$. 고유값이 가능한 측정 수치다.
밀도행렬·density matrix	$\rho \succeq 0, \operatorname{Tr}\rho = 1$인 행렬. 순수 상태와 혼합 상태를 함께 표현한다.
Bloch 벡터·Bloch vector	$\rho = (I + \mathbf{r}\cdot\boldsymbol{\sigma})/2$의 실수 벡터 $\mathbf{r}$. 길이는 1 이하이다.
일반화 측정·POVM	양의 준정부호 효과 E_m들이 $\sum_m E_m = I$를 만족하는 측정 명세. 확률은 $\operatorname{Tr}(\rho E_m)$다.
순도·purity	$\operatorname{Tr}(\rho^2)$. 큐비트에서 순수 상태는 1, 완전 혼합은 1/2다.
표준오차·standard error	추정량의 표준편차. 한 번 측정한 결과의 표준편차와 다르다.

통합 용어집에서 발음이나 다른 용례를 확인할 수 있다. 여기서 “순수”는 오염이나 장치 품질에 대한 일상적 표현이 아니라 수학적 상태 분류다.

유도 1: 진폭, 위상과 측정 기저

계산 기저를 $|0\rangle = (1,0)^T$, $|1\rangle = (0,1)^T$로 고정하면 순수 상태는

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \qquad |\alpha|^2 + |\beta|^2 = 1$$

이다. 예를 들어 $\alpha = 1/\sqrt{2}, \beta = i/\sqrt{2}$이면 내적은 $\langle\psi|\psi\rangle = (1/2) + (-i)i/2 = 1$이다. 켤레를 빠뜨리면 0이 되어 잘못된 정규화 판정을 한다. Born 규칙은 계산 기저 측정의 확률을 $p(0) = |\alpha|^2$, $p(1) = |\beta|^2$로 준다.

기저를 바꾸면 위상을 확률로 바꿀 수 있다. Hadamard 게이트

$$H = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$$

를 작용시키면 $H|\psi\rangle = [(\alpha+\beta)|0\rangle + (\alpha-\beta)|1\rangle]/\sqrt{2}$다. 따라서 H 후에 0이 나올 확률은 $|\alpha+\beta|^2/2$이며, 전개하면 $[1 + 2\,\mathrm{Re}(\alpha^*\beta)]/2$다. 교차항이 간섭이다. 확률 두 개 $|\alpha|^2, |\beta|^2$만으로 이 항을 복구할 수 없다.

반면 모든 진폭에 같은 위상을 곱하면 $|e^{i\gamma}\alpha + e^{i\gamma}\beta|^2 = |\alpha+\beta|^2$다. 다른 모든 측정에서도 같은 상쇄가 일어난다. 전역 위상과 상대 위상을 구별해야 하는 이유다.

완전 예제 1과 반례: 같은 Z 분포는 같은 상태가 아니다

$|+\rangle = (|0\rangle + |1\rangle)/\sqrt{2}$와 $|-\rangle = (|0\rangle - |1\rangle)/\sqrt{2}$를 보자. Z 측정에서는 둘 다 0과 1을 반반 출력한다. H를 곱하면 각각 $|0\rangle$와 $|1\rangle$가 되므로 H 뒤 Z 측정으로 완전히 구별된다. 이는 X 기저 측정과 같다.

그렇다면 동전을 던져 절반은 $|0\rangle$, 절반은 $|1\rangle$를 준비하면 $|+\rangle$인가? 아니다. 동전 혼합의 밀도행렬은 $\rho_{\text{mix}} = I/2$이고 $|+\rangle\langle+| = \frac{1}{2}\begin{pmatrix}1 & 1\\ 1 & 1\end{pmatrix}$다. 두 행렬은 대각 원소가 같지만 비대각 원소가 다르다. H 뒤 Z 측정에서 혼합은 계속 반반, $|+\rangle$는 0만 출력한다. 중첩을 "모르는 고전 비트"로 대체하면 이 실험을 설명할 수 없다.

게이트와 행렬곱의 순서

Pauli 행렬은

$$X = \begin{pmatrix}0 & 1\\ 1 & 0\end{pmatrix}, \quad Y = \begin{pmatrix}0 & -i\\ i & 0\end{pmatrix}, \quad Z = \begin{pmatrix}1 & 0\\ 0 & -1\end{pmatrix}$$

이고, $R_y(\theta) = e^{-i\theta Y/2}$는

$$R_y(\theta) = \begin{pmatrix}\cos(\theta/2) & -\sin(\theta/2)\\ \sin(\theta/2) & \cos(\theta/2)\end{pmatrix}$$

다. $Y^2 = I$를 이용하여 지수함수의 짝수·홀수 거듭제곱을 모으면 이 식을 얻는다. 행렬곱은 오른쪽부터 작용한다. 회로에서 "먼저 H, 다음 Z"라고 썼으면 수식은 $ZH|0\rangle$다. 소프트웨어 명령 순서와 행렬식을 같은 방향으로 읽지 않는다.

게이트를 모든 상태에 똑같이 적용하면 상태 간 내적은 보존된다. 실제 측정은 이 유니터리 진화와 별개의 과정이며, 결과를 무시한 측정은 coherence를 없앨 수 있다. 잡음까지 하나의 상태벡터로 다루려 하지 말고 밀도행렬로 넘어간다.

유도 2: 밀도행렬에서 Bloch 구와 측정으로

상태를 확률 q_j로 골라 준비하면 $\rho = \sum_j q_j |\psi_j\rangle\langle\psi_j|$다. 모든 벡터 v에 대해 $v^\dagger \rho v = \sum_j q_j |\langle\psi_j|v\rangle|^2 \geq 0$이므로 양의 준정부호다. trace는 $\sum_j q_j = 1$이다. 같은 밀도행렬은 여러 서로 다른 혼합 방식으로 만들 수 있으므로 혼합의 준비 이력이 상태 자체에서 유일하게 읽히지는 않는다.

trace 1인 에르미트 2×2 행렬은

$$\rho = \frac{1}{2}\begin{pmatrix}1 + r_z & r_x - i r_y\\ r_x + i r_y & 1 - r_z\end{pmatrix} = \frac{1}{2}(I + r_x X + r_y Y + r_z Z)$$

로 쓸 수 있다. 고유값은 $(1 \pm \|\mathbf{r}\|)/2$다. 따라서 양의 준정부호 조건은 $\|\mathbf{r}\| \leq 1$과 같다. 또한 Pauli 행렬의 trace 관계를 이용하면 $\mathrm{Tr}(\rho X) = r_x$이고 Y, Z도 같다. 즉 Bloch 좌표는 서로 다른 세 측정의 평균이다. 구의 표면은 순수 상태, 내부는 혼합 상태를 나타내며 실제 공간의 작은 공이라는 뜻은 아니다.

예를 들어 $\rho = \mathrm{diag}(3/4, 1/4)$이면 $\mathbf{r} = (0, 0, 1/2)$, 순도는 $(3/4)^2 + (1/4)^2 = 5/8$다. 일반식 $\mathrm{Tr}(\rho^2) = (1 + \|\mathbf{r}\|^2)/2$와도 일치한다. 반대로 $\mathrm{diag}(1.1, -0.1)$은 trace가 1이어도 음의 확률을 만들어 상태가 될 수 없다.

Z 측정의 두 효과는 $E_0 = (I + Z)/2$, $E_1 = (I - Z)/2$이며 $p(0) = (1 + r_z)/2$다. 일반 POVM은 효과가 꼭 직교 projector일 필요가 없다. 예를 들어 $E_\pm = (I \pm \eta Z)/2$, $0 \leq \eta \leq 1$이면 $p(+) = (1 + \eta r_z)/2$다. $\eta < 1$은 Z 신호가 약해진 측정의 간단한 모형이다. 효과만으로는 측정 뒤 상태가 완전히 결정되지 않는다. 그 변화를 알려면 측정 연산자 또는 quantum instrument라는 추가 명세가 필요하다.

유도 3과 완전 예제 2: 유한 샷의 불확실성

$R_y(\theta)|0\rangle$에서는 $p(1) = \sin^2(\theta/2)$다. Z 결과를 0일 때 +1, 1일 때 −1로 기록하면 평균은 $f = 1 - 2p(1) = \cos\theta$다. 같은 상태를 독립적으로 다시 준비한 결과 $Z_1, \ldots, Z_S$를 평균하면

$$\widehat{f} = \frac{1}{S}\sum_{s} Z_s, \quad \mathbb{E}\widehat{f} = f, \quad \mathrm{Var}(\widehat{f}) = \frac{1 - f^2}{S}.$$

마지막 식은 각 결과의 제곱이 1이고 독립 결과 사이 공분산이 0이어서 나온다. 드리프트나 재설정 오류로 결과가 상관되면 이 분산식은 그대로 적용할 수 없다.

$\theta = \pi/3$이면 $f = 1/2$, $p(1) = 1/4$다. 1,000 shots에서 표준오차는 $\sqrt{0.75/1000} \simeq 0.0274$, 정규 근사의 95% 폭은 약 ±0.0537이다. 이는 무한 반복에서의 확률적 성질이지 이번 측정의 오차가 반드시 그 안이라는 보증은 아니다. 소표본이나 0·1 근처에서는 이항분포 기반 구간을 쓴다. 관측이 모두 +1이었다고 실제 평균이 정확히 1이라고 선언하지 않는다.

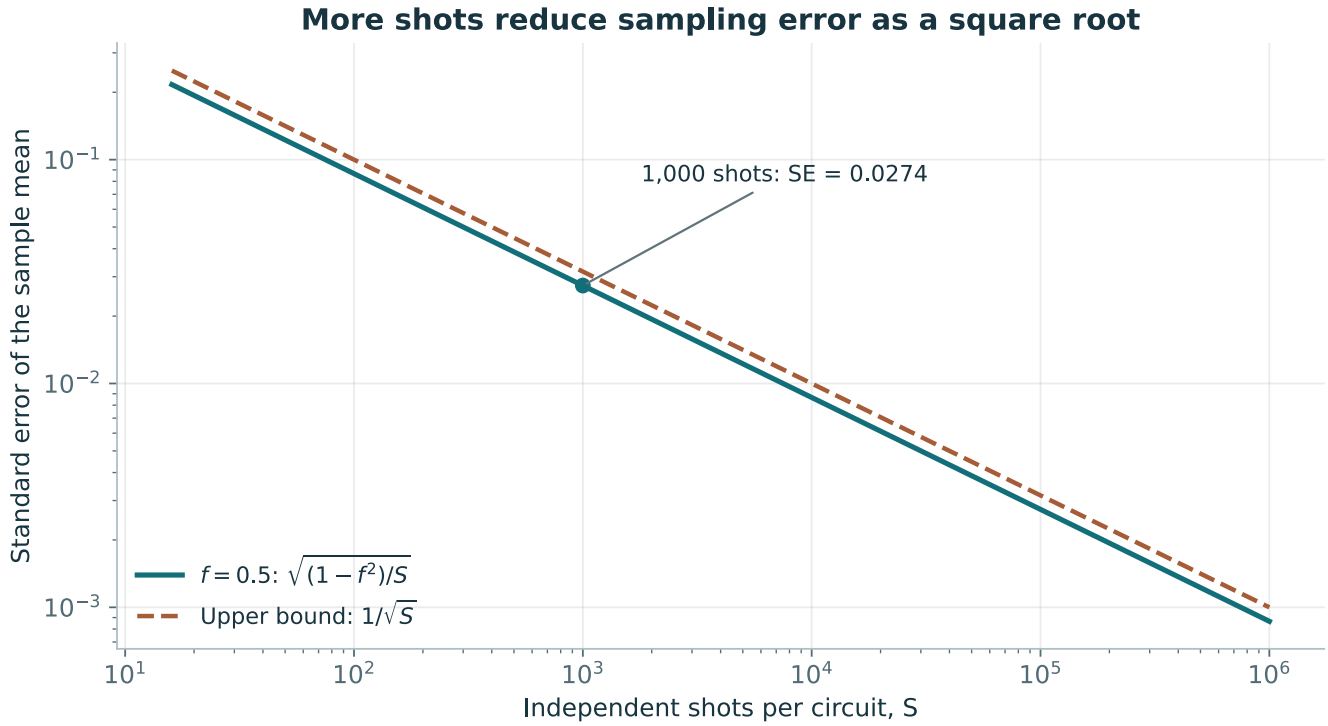


그림 2-1. 독립적인 ±1 측정의 표준오차를 본문 식에서 계산했다. 실선은 평균 0.5, 점선은 분산 상한이다. 교육용 해석 곡선이며 실제 장치 데이터나 systematic bias의 감소를 보여주지 않는다.

만약 측정 장치 때문에 평균이 실제로 0.45가 되었다면 shots를 무한히 늘려도 추정값은 0.45로 수렴한다. 이상적인 0.5와의 차이 0.05는 통계 분산이 아니라 편향이다. 12강의 오류 완화는 이 차이를 별도로 다룬다.

연습문제와 풀이

문제 1. 복소 진폭과 위상

$|\psi\rangle = (|0\rangle + i|1\rangle)/\sqrt{2}$의 Z, X, Y 평균을 계산하라. **힌트:** $\rho = |\psi\rangle\langle\psi|$를 만들고 Bloch 식과 비교한다.

풀이: $\rho = \frac{1}{2}\begin{pmatrix} 1 & -i \\ i & 1 \end{pmatrix}$이므로 $(r_x, r_y, r_z) = (0, 1, 0)$이다. 따라서 Z와 X 평균은 0, Y 평균은 +1이다. Z에서 반반이라는 사실만으로 상대 위상이 없다고 말하면 안 된다. Y 기저에서는 한 결과가 확정되므로 이 위상을 측정 통계로 구별할 수 있다.

문제 2. 게이트 순서

$HZH|0\rangle$와 $ZHH|0\rangle$을 비교하라. **힌트:** 오른쪽 게이트부터 적용하고 $H^2 = I$를 활용한다.

풀이: 첫 회로는 $|0\rangle \to |+\rangle \to |-\rangle \to |1\rangle$다. 둘째 회로는 두 H가 상쇄되어 $Z|0\rangle = |0\rangle$이다. Z 측정 결과는 각각 1과 0으로 확정된다. 같은 게이트들을 사용했다는 사실만으로 같은 연산이 되지 않는다. 회로 그림의 시간 방향과 식의 곱 순서를 모두 써야 오류를 피한다.

문제 3. 올바른 상태와 약한 측정

$\rho = (I + 0.6X + 0.8Z)/2$는 올바른 상태인가? $\eta = 1/2$인 위 POVM에서 + 확률은? **힌트:** Bloch 길이를 먼저 계산한다.

풀이: 길이는 $\sqrt{0.6^2 + 0.8^2} = 1$이므로 고유값은 1과 0이다. 순수 상태이며 올바르다. + 확률은 $[1 + (1/2)0.8]/2 = 0.7$이다. 강한 Z 측정이라면 0.9이므로 측정 효과를 바꾸는 것만으로 결과 분포가 달라진다. 상태가 바뀌었다고 단정할 수 없고 측정 모형부터 확인한다.

문제 4. 샷 증가와 편향

실제 측정 평균 0.45를 400회와 40,000회로 추정한다. 표준오차와 이상 평균 0.5에 대한 편향을 비교하라. **힌트:** 분산에 들어가는 평균은 실제 측정 평균이다.

풀이: $1 - 0.45^2 = 0.7975$이므로 표준오차는 각각 $\sqrt{0.7975/400} \simeq 0.0447$와 0.00447이다. shots를 100배 늘리면 표준오차는 10분의 1이 된다. 반면 이상 평균에 대한 편향은 두 경우 모두 −0.05다. 작은 오차막대는 정확한 이상값을 보증하지 않으며, 오히려 편향된 평균을 더 정밀하게 드러낼 수 있다.

학습 완료 점검

- $|+\rangle$와 $I/2$를 Z로는 구별하지 못하고 X로는 구별하는 이유를 행렬의 비대각 원소로 설명하면 통과다. 실패하면 예제 1로 돌아간다.
- trace 1만으로 상태를 판정하지 않고 양의 준정부호 조건을 확인하면 통과다. 실패하면 Bloch 고유값 유도를 다시 계산한다.
- $p(1) = (1 - \langle Z\rangle)/2$를 직접 유도하고 ±1 출력과 0/1 출력을 구별하면 통과다.
- 표준오차와 편향에 대해 각각 shots 증가의 효과를 말하면 통과다. 둘 다 사라진다고 답하면 예제 2를 반복한다.

원문 읽기

- IBM Quantum Learning, Single systems: Quantum information: 공개 교육 페이지의 quantum states, measurements, unitary operations 설명을 본문의 벡터 계산과 대조한다. 공식 교육 자료이며 연구 결과를 입증하는 실험 보고서는 아니다.
- Watrous, The Theory of Quantum Information 공개 원고: Chapter 2의 states와 measurements 정의를 찾아 ρ와 POVM을 읽는 심화 자료다. 본문 예제만으로 다음 강의를 진행할 수 있으며 원고 전체 정리를 선수 조건으로 요구하지 않는다.
- PennyLane RY API: 행렬의 부호와 각도 관례를 확인한다. 실습의 고정 설치 버전과 현재 문서가 다를 수 있다. 실습 1에서 닫힌 식과 상태벡터 모사를 대조한다.

03. 텐서곱, 얽힘과 양자 회로의 계산 능력

> 독립 집필한 80분 학습 단원 · 2026-10-20 기준. 원강좌 Lecture 2·Lab 1의 공개 개요를 확장한 자체 교육 자료다.

시작하기 전에

2강의 상태벡터, 밀도행렬, Pauli 측정과 trace를 사용한다. 행렬의 고유값과 특잇값이 낯설면 수학 준비 노트를 참조한다. 이 강의의 목표는 두 큐비트 상태를 정확한 기저 순서로 전개하고, 부분계 상태를 직접 구하고, 순수 상태의 얽힘을 Schmidt 계수로 판정하며, 얽힘과 고전 계산 난도를 구별하는 것이다.

양자 학습에서 데이터의 상호작용을 설명할 때 “큐비트들이 서로 연결된다”는 말만으로는 부족하다. 어떤 상태가 만들어지고 어떤 측정에서 고전적 상관과 구별되는지를 계산해야 한다. 반대로 큰 얽힘을 만들었다는 사실만으로 학습이 어려운 고전 문제를 해결했다고 결론 내릴 수 없다.

80분 학습 순서

시간	수행할 활동	남길 결과
0-10분	용어와 기저 순서 확인	텐서곱 벡터 전개
10-25분	Bell 상태·부분 trace 계산	전체와 부분 상태
25-45분	Schmidt 예제와 상관 반례 계산	얽힘 판정의 근거
45-60분	복제 불가능성과 모사 비용 확인	가정과 반례 목록
60-75분	문제 1·2부터 풀고 선택한 문제의 해설만 대조	독립 계산 기록
75-80분	완료 점검을 회상으로 수행	다음 강의 진행 여부

네 문제와 심화 읽기를 모두 완수하려면 별도의 복습 시간을 둔다. 처음부터 빠르게 읽어 80분을 맞추기보다 표에 있는 계산 활동을 남기는 것이 중요하다.

강의 후 **60-90분**에는 남은 문제를 해설 없이 풀고, 유도 하나를 재작성하고, 오답을 수정한다. 원문 전문 독해와 코딩 실습은 별도 시간이다.

핵심 용어

한국어·영어	정의·기호·직관
텐서곱·tensor product	부분계 공간을 결합하는 연산 $\mathcal{H}_A \otimes \mathcal{H}_B$. 두 계의 기저쌍을 새 기저로 만든다.
곱 상태·product state	$\lvert a\rangle \otimes \lvert b\rangle$로 분리되는 순수 상태.

한국어·영어	정의·기호·직관
분리 가능 상태·separable state	$\sum_j p_j \rho_A^{(j)} \otimes \rho_B^{(j)}$로 쓸 수 있는 혼합 상태. 고전적 상관을 포함할 수 있다.
얽힘·entanglement	위 분리 가능 표현이 없는 상태의 성질. 순수 상태에서는 곱으로 분리되지 않음과 같다.
부분 trace·partial trace	다른 부분계를 무시한 통계를 주는 연산 $\rho_A = \mathrm{Tr}_B\, \rho_{AB}$. 행렬 원소 일부를 단순히 지우는 것이 아니다.
Schmidt 분해·Schmidt decomposition	순수 이분 상태를 $\sum_r s_r \lvert u_r\rangle \lvert v_r\rangle$로 쓰는 표현. 양쪽 벡터 집합이 각각 정규직교다.
Schmidt 계수·Schmidt coefficient	$s_r \geq 0$이며 $\sum_r s_r^2 = 1$. 0이 아닌 계수 수가 Schmidt rank다.
국소 연산·local operation	한 부분계에만 작용하는 연산. 여기서 local은 물리적 거리의 모든 의미를 포함하지 않는다.
복제 불가능성·no-cloning	모든 미지의 상태를 동일하게 복제하는 하나의 물리 연산이 존재하지 않는다는 제약.
Clifford·클리퍼드	Pauli 연산자를 켤레변환으로 Pauli 연산자로 보내는 게이트의 부류. H·S·CNOT이 대표적이다.
고전 모사·classical simulation	양자 과정의 특정 출력이나 샘플을 고전 계산으로 얻는 일. 모든 진폭 출력과 샘플 생성은 다른 과제다.
회로 깊이·circuit depth	동시에 실행 가능한 게이트들을 층으로 묶었을 때 필요한 순차 층 수. 게이트 총수와 다르다.

특히 혼합 상태의 “분리 가능”을 하나의 곱 상태와 혼동하지 않는다. 다른 용례는 통합 용어집에서 확인한다.

유도 1: 두 큐비트와 부분계의 상태

기저 순서는 $\lvert 00\rangle, \lvert 01\rangle, \lvert 10\rangle, \lvert 11\rangle$로 고정한다. 첫 큐비트는 왼쪽 비트다. 그러면

$$(a\lvert 0\rangle + b\lvert 1\rangle) \otimes (c\lvert 0\rangle + d\lvert 1\rangle) = ac\lvert 00\rangle + ad\lvert 01\rangle + bc\lvert 10\rangle + bd\lvert 11\rangle.$$

복소수 네 개가 곱의 형태를 만족하지 않으면 단일 큐비트 두 개의 독립 상태로 설명할 수 없다. 첫 큐비트에 H, 첫 큐비트를 control로 CNOT을 적용하면

$$\lvert 00\rangle \xrightarrow{H\otimes I} \frac{\lvert 00\rangle + \lvert 10\rangle}{\sqrt{2}} \xrightarrow{\mathrm{CNOT}_{A\to B}} \lvert \Phi^+\rangle = \frac{\lvert 00\rangle + \lvert 11\rangle}{\sqrt{2}}.$$

이를 곱으로 쓴다고 가정하면 $ac = bd = 1/\sqrt{2}$지만 $ad = bc = 0$이어야 한다. 앞 조건은 네 계수를 모두 0이 아니게 만들므로 뒤 조건과 모순이다. Bell 상태는 얽혔다.

부분 trace를 계산하려면 먼저 규칙을 적는다.

$$\mathrm{Tr}_B\big(\lvert a\rangle\langle a'\rvert \otimes \lvert b\rangle\langle b'\rvert\big) = \lvert a\rangle\langle a'\rvert \langle b'\rvert b\rangle.$$

Bell 밀도행렬은 $(\lvert 00\rangle\langle 00\rvert + \lvert 00\rangle\langle 11\rvert + \lvert 11\rangle\langle 00\rvert + \lvert 11\rangle\langle 11\rvert)/2$다. 가운데 두 항은 B의 $\langle 1\rvert 0\rangle$ 또는 $\langle 0\rvert 1\rangle$ 때문에 0이 된다. 따라서

$$\rho_A = \frac{1}{2}(|0\rangle\langle 0| + |1\rangle\langle 1|) = I/2.$$

전체 순도는 1인데 부분계 순도는 1/2다. 전체가 순수하다는 사실과 각 부분이 순수하다는 사실은 다르다. 부분 trace의 정의는 모든 A 관측량에 대해 $\mathrm{Tr}(\rho_A O_A) = \mathrm{Tr}[\rho_{AB}(O_A \otimes I)]$를 보장한다. 실제로 "B를 보지 않는다"는 실험 의미와 일치한다.

완전 예제 1: 같은 상관이지만 다른 상태

Bell 상태와

$$\rho_{\mathrm{mix}} = \frac{1}{2}|00\rangle\langle 00| + \frac{1}{2}|11\rangle\langle 11|$$

를 비교하자. 두 상태 모두 Z를 측정하면 00·11이 각각 절반이며, 각 부분계는 $I/2$다. 하지만 $X \otimes X$는 00과 11을 교환하므로 $(X \otimes X)|\Phi^+\rangle = |\Phi^+\rangle$이고 Bell의 XX 평균은 1이다. 혼합에서는 $\langle 00|XX|00\rangle = \langle 11|XX|11\rangle = 0$이므로 평균이 0이다. 두 큐비트 모두 H 후 Z 측정을 하면 이 차이를 읽는다.

더 엄밀하게, 모든 분리 가능 상태는 $\langle XX + ZZ\rangle \le 1$을 만족한다. 곱 상태의 Bloch 벡터를 $\mathbf{a}, \mathbf{b}$라 하면 왼쪽은 $a_x b_x + a_z b_z$다. Cauchy-Schwarz 부등식으로 $\sqrt{a_x^2 + a_z^2}\sqrt{b_x^2 + b_z^2} \le 1$이다. 혼합해도 평균의 상계는 유지된다. Bell은 2이므로 이 상계를 위반한다. 따라서 $W = I - XX - ZZ$는 이 예제의 얽힘 witness다. 실제 데이터에서 1을 조금 넘었다면 측정 편향과 통계 오차까지 확인해야 한다. 계산 기저 상관 하나만으로 얽힘을 선언하는 것과는 근거가 다르다.

유도 2와 완전 예제 2: Schmidt 계수로 판정하기

일반 순수 상태를 $|\psi\rangle = \sum_{a,b} C_{ab}|a\rangle|b\rangle$라 쓰자. 계수 행렬 C의 특잇값 분해 $C = UDV^\dagger$에서 $D_{rr} = s_r$라 두면

$$|\psi\rangle = \sum_r s_r |u_r\rangle|v_r\rangle, \quad |u_r\rangle = \sum_a U_{ar}|a\rangle, \quad |v_r\rangle = \sum_b V^*_{br}|b\rangle.$$

복소 켤레가 B 쪽에 들어간다는 점을 확인한다. 직교성으로 부분 trace를 취하면 $\rho_A = \sum_r s_r^2 |u_r\rangle\langle u_r|$다. 따라서 부분계의 고유값은 Schmidt 계수의 제곱이다. 계수가 하나만 있으면 곱 상태이고, 두 개 이상이면 얽힌 순수 상태다.

예를 들어 $|\psi\rangle = (\sqrt{3}|00\rangle + |11\rangle)/2$는 이미 Schmidt 형태다. 계수는 $\sqrt{3}/2, 1/2$이며 부분 상태는 $\mathrm{diag}(3/4, 1/4)$다. 순도는 5/8이고 얽힘 엔트로피는

$$S(\rho_A) = -\sum_r s_r^2 \log_2 s_r^2 = -\frac{3}{4}\log_2\frac{3}{4} - \frac{1}{4}\log_2\frac{1}{4} \simeq 0.811$$

비트다. Bell은 두 계수가 같아 엔트로피가 1이다. 반면 $(|00\rangle + |01\rangle)/\sqrt{2} = |0\rangle|+\rangle$는 계수 행렬의 rank가 1이어서 얽히지 않았다.

중요한 반례가 있다. 위 고전 혼합도 부분 상태가 $I/2$여서 엔트로피 1이다. 그러나 분리 가능하다. 부분 엔트로피를 얽힘의 양으로 직접 읽는 규칙은 여기서 다룬 전체가 순수한 이분 상태에 한정된다. 혼합 상태 전체에 그대로 적용하면 틀린다.

유도 3: 복제 불가능성과 무신호성

모든 상태를 복제하는 하나의 유니터리 U가 있다고 가정하자. 두 입력에 대해 $U|\psi\rangle|0\rangle = |\psi\rangle|\psi\rangle$, $U|\phi\rangle|0\rangle = |\phi\rangle|\phi\rangle$다. 유니터리는 내적을 보존하므로 $c = \langle\psi|\phi\rangle$에 대해 $c = c^2$여야 한다. 서로 다른 비직교 상태는 $0 < |c| < 1$이어서 불가능하다. 예를 들어 0과 +의 내적 $1/\sqrt{2}$는 복제 후 1/2가 되어 내적 보존과 모순이다. 보조 환경까지 포함한 복제 채널도

이 모순을 피하지 못한다. 환경의 최종 상태 내적을 e라 두면 $c = c^2 e$이고 $|e| \le 1$이어야 하므로, $0 < |c| < 1$에서 모순은 유지된다.

CNOT이 $|0\rangle|0\rangle \to |00\rangle$, $|1\rangle|0\rangle \to |11\rangle$을 수행하는 것은 모순이 아니다. 두 입력이 직교하기 때문이다. +를 입력하면 $|+\rangle|+\rangle$ 대신 Bell 상태가 나온다. 알려진 회로를 다시 실행하는 일도 미지 상태를 복제하는 것과 다르다. 따라서 양자 데이터 학습의 표본 수에는 매번 새 상태를 공급할 수 있는지도 적어야 한다.

B에 trace-preserving 연산을 적용해도 결과를 A로 보내지 않으면 A의 상태는 바뀌지 않는다. 상태 변화를 여러 행렬로 나누어 나타내는 Kraus 연산자 K_m가 $\sum_m K_m^\dagger K_m = I$를 만족하면 A 관측량의 평균은

$$\sum_m \mathrm{Tr}[\rho_{AB}(O_A \otimes K_m^\dagger K_m)] = \mathrm{Tr}[\rho_{AB}(O_A \otimes I)]$$

로 유지된다. 특정 B 결과에 조건을 걸면 A의 조건부 상태가 달라질 수 있지만 그 결과를 고전 통신으로 알려야 한다. 얽힘 자체가 초광속 메시지를 제공하지 않는다.

얽힘과 고전 계산 난도 사이의 간격

complex128 진폭은 16바이트이므로 일반 n큐비트 상태벡터는 16×2^n바이트다. 30큐비트는 16GiB, 40큐비트는 16TiB이며 작업 버퍼는 별도다. 그러나 이는 일반 상태를 전부 저장하는 모사 방식의 비용이다. 모든 회로에 필요한 최소 고전 비용의 하한이 아니다.

Clifford 게이트와 계산 기저 초기화·Pauli 측정으로 제한한 stabilizer 회로는 얽힘이 커도 다항 자원으로 모사할 수 있다. 이 반례는 Gottesman의 Heisenberg 표현의 핵심 맥락이다. 비Clifford 게이트가 하나 있다고 바로 어렵다는 역명제도 성립하지 않는다. 깊이, 연결성, 측정 대상, 요구 정밀도와 회로 구조를 같이 봐야 한다. 얽힘이 제한된 상태에서는 tensor network가 유리할 수 있지만 어떤 bipartition의 얽힘이 제한되는지도 중요하다.

QML 보고서에는 “얽힘을 사용했다”와 함께 얽힘이 어느 예측 성분을 바꾸었는지, 같은 효과를 고전 모델이 재현하는지, 무엇을 측정했는지를 기록한다. 단일 큐비트 회전과 얽힘 게이트의 보편성도 임의 연산을 적은 게이트로 합성할 수 있다는 보장은 아니다.

연습문제와 풀이

문제 1. 곱 상태 찾기

$(|00\rangle + |01\rangle + |10\rangle + |11\rangle)/2$의 Schmidt rank와 부분 상태를 구하라. **힌트:** 네 진폭을 2×2 행렬로 놓는다.

풀이: 모든 원소가 1/2인 계수 행렬은 rank 1이다. 상태는 $|+\rangle \otimes |+\rangle$로 분리된다. A 부분 상태는 $|+\rangle\langle+|$이며 순도는 1이다. 계산 기저 결과가 네 가지라고 해서 얽힘이 있는 것은 아니다. 가능한 결과 수와 Schmidt rank는 다른 양이다.

문제 2. 얽힘 검출의 통계

이상 측정으로 $\langle ZZ \rangle = 0.9$, $\langle XX \rangle = 0.7$을 얻었다. 분리 가능 상계와 비교하라. 각 평균에 절대오차 0.1 보장이 있다면 결론은 유지되는가? **힌트:** 가장 불리한 실제 평균을 사용한다.

풀이: 관측합은 1.6으로 상계 1보다 크다. 각각 0.1씩 과대추정했더라도 실제 합은 1.4 이상이므로 여전히 얽힘을 검출한다. 다만 이 오차 보장이 동시에 성립하는 신뢰도와 측정 편향 처리가 전제다. Z 자료만으로는 같은 결론이 나오지 않는다. 분리 가능 혼합도 큰 ZZ 상관을 가질 수 있다.

문제 3. 복제와 재준비

알려진 회로로 Bell 상태를 1,000개 준비하는 일과, 주어진 미지 상태 하나를 1,000개로 복제하는 일의 차이를 설명하라. **힌트:** 입력 자원과 반복 가능한 준비 절차를 구별한다.

풀이: 첫 과정은 매번 새 $|00\rangle$에 알려진 H·CNOT 회로를 적용한다. 소비하는 초기화·게이트 자원을 1,000번 지불하며 원본을 복제하지 않는다. 둘째 과정은 준비 정보를 모르는 단일 상태만으로 새 사본을 얻으려 하므로 일반적으로 no-cloning에 막힌다. 따라서 “shots 1,000회”에는 재준비 접근의 존재가 숨어 있다.

문제 4. 메모리 계산과 과도한 결론

25큐비트 순수 상태벡터와 일반 밀도행렬을 complex128로 저장하는 메모리를 구하라. 이 결과로 모든 25큐비트 회로가 어려운가? **힌트:** 밀도행렬 원소 수는 진폭 수의 제곱이다.

풀이: 상태벡터는 $16 \times 2^{25} = 2^{29}$바이트, 즉 512MiB다. 밀도행렬은 $16 \times 4^{25} = 2^{54}$바이트, 즉 16PiB다. 이 값은 해당 자료구조를 조밀하게 저장하는 비용이며 stabilizer나 낮은 rank 구조까지 강제로 이 방식으로 모사할 필요는 없다. 저장 표현의 지수 증가가 모든 과제의 계산 하한을 증명하지 않는다.

학습 완료 점검

- Bell 상태의 부분 trace에서 사라지는 두 항에 직교 내적을 명시하면 통과다. 실패하면 유도 1로 돌아간다.
- 순수 상태의 Schmidt 계수와 부분 밀도행렬의 고유값 관계를 제곱으로 연결하면 통과다. 혼합 상태 엔트로피를 무조건 얽힘으로 읽으면 예제 2를 반복한다.
- CNOT이 고전 기저 비트를 복사하면서 미지 중첩을 복제하지 못하는 이유를 + 입력으로 보이면 통과다.
- 얽힘이 커도 모사 가능한 회로 부류를 조건과 함께 하나 제시하면 통과다. “모든 양자 회로가 쉽다”로 반대로 확대하지 않는다.

원문 읽기

- IBM Quantum Learning, Multiple systems: Quantum information: tensor products와 entanglement 설명을 읽고 본문의 기저 순서로 다시 쓴다. SDK의 비트열 순서는 별도로 확인한다.
- Watrous 공개 원고: Chapter 1의 tensor product·singular value decomposition과 Chapter 6의 bipartite entanglement는 선택 심화 읽기다. 위 두 큐비트 유도는 이 노트만으로 따라갈 수 있다.
- Wootters and Zurek, A single quantum cannot be cloned (1982): 복제 불가능성의 원 논문. 본문의 내적 증명은 교육용 재구성이다.
- Gottesman, The Heisenberg Representation of Quantum Computers (1998): stabilizer·Clifford 표현의 원문을 읽는 심화 자료다. 본 노트는 일반 모사 알고리즘을 구현하거나 성능을 재측정하지 않았다.

04. 데이터 인코딩과 상태 준비의 숨은 비용

> 독립 집필한 80분 학습 단원 · 2026-10-20 기준. 원강좌 Lecture 3·Lab 2의 주제를 확장한다. 아래 예제와 유도는 자체 교육 자료다.

시작하기 전에

2강의 회전·Born 규칙, 3강의 텐서곱을 사용한다. 내적과 정규화는 수학 준비 노트에서 복습한다. 이 강의 후에는 세 인코딩의 보존 정보를 비교하고, 작은 상태 준비 회로를 설계하고, 인코딩이 만든 커널을 유도하며, 입력 접근 가정이 계산 비용에 미치는 영향을 설명할 수 있어야 한다.

머신러닝에서 전처리는 단순한 청소 단계가 아니다. 양자 인코딩은 데이터의 어떤 차이를 구별할 수 있는지 결정한다. 먼저 인코딩에서 합쳐진 두 점을 찾아야 한다. 나중의 회로를 아무리 복잡하게 만들어도 완전히 같은 입력 상태에 서로 다른 정답을 주지는 못한다.

80분 학습 순서

시간	수행할 활동	남길 결과
0-10분	용어·데이터 단위·분할 규칙 확인	입력 명세
10-25분	세 인코딩과 두 성분 준비 회로 계산	큐비트·각도·정규화
25-45분	커널과 정보 손실 예제 유도	원래 거리와 상태 거리
45-60분	적재 비용·oracle 가정을 비교	비용에 포함한 항목
60-75분	문제 1·2부터 풀고 선택한 문제의 해설만 대조	오답 원인
75-80분	완료 점검을 회상으로 수행	다음 강의 준비

80분에는 전체 외부 읽기와 네 문제의 완전한 독립 풀이를 모두 요구하지 않는다. 본문의 계산을 먼저 끝내고 복습 때 나머지를 해결한다.

강의 후 **60-90분**에는 남은 문제를 해설 없이 풀고, 유도 하나를 재작성하고, 오답을 수정한다. 원문 전문 독해와 코딩 실습은 별도 시간이다.

핵심 용어

한국어·영어	정의·기호·직관
특징 맵·feature map	입력 x를 새 표현 $\phi(x)$나 상태 $\rho(x)$로 보내는 함수.
인코딩·encoding	숫자·비트·물리 신호를 양자 상태 또는 게이트 파라미터로 대응시키는 규칙.

한국어·영어	정의·기호·직관
상태 준비·state preparation	초기 상태에서 목표 $\rho(x)$를 실제로 만드는 연산 과정. 표현의 정의와 구현 비용은 다르다.
기저 인코딩·basis encoding	디지털 비트열 b를 계산 기저 상태 $\|b\rangle$로 나타내는 방법.
각도 인코딩·angle encoding	특징을 회전 게이트의 각도로 쓰는 방법. 주기와 스케일이 모델의 일부다.
진폭 인코딩·amplitude encoding	정규화한 벡터 성분을 상태 진폭으로 넣는 방법. 전체 크기를 별도로 보존해야 한다.
정규화·normalization	여기서는 $x/\|x\|_2$로 단위 길이를 만드는 연산. 통계적 표준화와 구별한다.
충실도·fidelity	순수 상태 사이 $F=\|\langle\phi\|\psi\rangle\|^2$. 본 강의에서는 제곱한 convention을 쓴다.
커널·kernel	여기서는 $K(x,z)=\mathrm{Tr}[\rho(x)\rho(z)]$라는 양의 준정부호 유사도.
앨리어싱·aliasing	서로 다른 입력이 주기성 때문에 같은 표현으로 겹치는 현상.
양자 RAM·qRAM	주소를 중첩으로 주어 메모리 내용에 coherent하게 접근하는 구조의 개념. 고전 배열과 다르다.
오라클·oracle	허용 연산을 하나의 호출로 묶어 추상화한 계산 자원. 호출 내부의 구현 비용은 별도로 적는다.

통합 용어집의 fidelity 정의와 맞춰 읽는다. 문헌에 따라 제곱근 fidelity를 fidelity라고 부르기도 하므로 식을 확인한다.

데이터 분할과 단위를 먼저 고정한다

훈련·검증·테스트를 먼저 나누고, 평균·표준편차·PCA는 훈련셋에서만 추정한다. 그 변환을 다른 집합에도 고정 적용한다. 전체 데이터의 평균을 미리 사용하면 테스트 분포의 정보가 모델 선택으로 들어온다. 양자 회로에 들어가기 전의 고전 전처리도 학습 파이프라인에 포함된다.

단위도 중요하다. 온도 300K를 그대로 300라디안 회전으로 쓰면 가까운 온도가 주기 때문에 예상과 다른 상태 거리를 가질 수 있다. $z_j=(x_j-m_j)/s_j$로 무차원화한 뒤 αz_j를 각도로 쓰는 등의 규칙을 명시한다. α를 검증셋으로 선택하면 하이퍼파라미터 튜닝이며, 테스트 최고 점수로 선택하면 독립 평가가 깨진다.

세 가지 인코딩을 같은 기준으로 비교한다

기저 인코딩은 정밀도까지 디지털 레지스터로 보존한다. 32개 실수를 각각 16비트로 쓰면 단순한 병렬 입력 레지스터는 512큐비트가 필요하다. 부호·고정소수점 규약, 가역 산술과 보조 큐비트는 추가 비용이다. 비트값이 알려져 있으면 1인 위치에 X를 적용해 상태를 만들 수 있다. 그러나 기저 상태의 단순 겹침은 서로 다른 비트열에서 0이므로 숫자 7과 8이 가깝다는 정보를 자동 제공하지 않는다.

각도 인코딩의 한 예는

$$|\phi(x)\rangle=\bigotimes_{j=1}^{d}R_y(\alpha x_j)|0\rangle$$

다. 이 설계는 d큐비트와 d개 회전을 사용한다. 병렬 회전은 깊이를 줄일 수 있지만 특징을 읽고 파라미터를 설정하는 비용은 남는다. 큐비트가 부족하면 데이터를 순차 재업로드할 수 있으며 이 경우 깊이가 증가한다. 6강은 이 선택이 함수 표현에 미치는 영향을 다룬다.

진폭 인코딩은 영벡터를 제외하고

$$|x\rangle = \frac{1}{\|x\|_2}\sum_{j=0}^{d-1} x_j|j\rangle, \qquad n = \lceil \log_2 d \rceil$$

로 정의한다. $d < 2^n$이면 나머지 진폭을 0으로 padding한다. 복소수 입력도 가능하지만 실수 데이터와의 의미 대응을 명시해야 한다. 이 식은 n큐비트로 표현할 수 있다는 선언이며 일반 상태를 n개 게이트로 만들 수 있다는 선언이 아니다.

방식	보존되는 정보·손실	비용 장부
기저	정한 비트 precision과 부호 보존	비트 수·산술·보조 레지스터
각도	주기적 특징 geometry	특징 수·스케일·재업로드 깊이
진폭	방향, norm과 전역 위상은 별도	정규화·분해·상태 재준비

유도 1과 완전 예제 1: 진폭 상태를 실제로 만들기

$x = (3, 4)$의 norm은 5다. $R_y(\theta)|0\rangle = \cos(\theta/2)|0\rangle + \sin(\theta/2)|1\rangle$이므로

$$\cos(\theta/2) = 3/5, \quad \sin(\theta/2) = 4/5, \qquad \theta = 2\,\mathrm{atan2}(4, 3)$$

로 준비할 수 있다. $\mathrm{atan2}$는 사분면을 보존하므로 음의 성분까지 다룰 때 단순 $\arctan(x_1/x_0)$보다 안전하다. 준비 상태의 계산 기저 확률은 0.36과 0.64다. 진폭 0.6·0.8을 한 번 측정해서 그대로 읽는 것은 아니다.

이제 $y = (6, 8)$도 같은 상태를 만든다. 원래 제곱거리는 $(6-3)^2 + (8-4)^2 = 25$인데 상태 fidelity는 1이다. $z = (-3, -4)$도 전체 부호만 달라 같은 물리 상태다. x, z의 원래 제곱거리는 100이지만 fidelity는 다시 1이다. 따라서 norm이나 방향 부호가 정답과 관련되면 이 인코딩만으로는 충분하지 않다.

가령 $(1, 0)$에 label 0, $(-1, 0)$에 label 1이 붙어 있다고 하자. 두 점을 동등한 빈도로 단순 진폭 상태로 넣으면 어떤 고정 측정·학습 회로도 두 label을 구별할 수 없다. 최선의 분류 오류는 1/2다. shots를 늘리거나 더 깊은 후속 회로를 붙여도 동일 입력 상태라는 사실을 바꾸지 못한다. norm 보조 특징은 크기 손실을 해결할 수 있지만 x와 $-x$의 부호 손실까지 자동 해결하지는 않는다.

유도 2와 완전 예제 2: 인코딩이 만드는 geometry

각도 인코딩에서 한 큐비트의 겹침은 삼각함수 덧셈 공식으로

$$\langle 0|R_y(\alpha x_j)^\dagger R_y(\alpha z_j)|0\rangle = \cos\left(\frac{\alpha(x_j - z_j)}{2}\right)$$

다. 텐서곱의 내적은 부분 내적의 곱이므로

$$K(x, z) = |\langle \phi(x)|\phi(z)\rangle|^2 = \prod_{j=1}^{d} \cos^2\left(\frac{\alpha(x_j - z_j)}{2}\right).$$

이 커널은 고전적으로 $O(d)$에 계산된다. “양자 상태로 정의했다”는 것만으로 고전 계산 난도가 생기지 않는다. 순수 상태 projector를 특징으로 보면 $K(x,z)=\mathrm{Tr}[\rho(x)\rho(z)]$이고

$$\|\rho(x)-\rho(z)\|_{\mathrm{HS}}^2=\mathrm{Tr}(\rho(x)^2)+\mathrm{Tr}(\rho(z)^2)-2\,\mathrm{Tr}[\rho(x)\rho(z)]=2(1-K).$$

Hilbert-Schmidt norm은 행렬 성분의 유클리드 길이다. 이 식은 상태공간 거리와 원 데이터 유클리드 거리가 다른 이유를 명확히 보여준다.

$d=2,\alpha=1$에서 $x=(0,0),z=(\pi,0)$이면 K=0이다. 그러나 $w=(2\pi,0)$이면 K=1이다. 원래 x-w 거리는 x-z보다 크지만 상태에서는 w가 x와 겹친다. 또 각 특징 차이가 모두 $\pi/2$면 $K=2^{-d}$다. 이는 이 특정 product map과 입력 차이에 대한 정확한 계산이다. 모든 인코딩이 지수 집중한다는 일반 정리로 확대하지 않는다. 그래도 많은 특징을 곱할 때 신호가 얼마나 작아지는지 먼저 점검하는 좋은 예다.

유도 3: 로그 큐비트 수가 로그 적재 시간이 아닌 이유

일반 정규화 실수 d차원 벡터에는 $d-1$개의 연속 자유도가 있다. 각 고정 크기 게이트가 상수 개의 연속 파라미터에 매끄럽게 의존하는 회로 모형에서는 임의 벡터를 모두 표현하려면 파라미터 수 자체가 d에 비례해야 한다. 이 차원 계산은 구조 없는 일반 상태 준비가 공짜가 될 수 없는 이유다. 가변 큰 다중 큐비트 게이트나 데이터 oracle을 한 번의 연산으로 허용하면 그 내부 비용을 숨긴 것이므로 가정이 바뀐다.

반대로 모든 상태가 어렵다는 결론은 틀린다. 2^n개 성분이 같은 정규화 벡터는 $H^{\otimes n}|0^n\rangle$로 준비한다. n개 H면 충분하다. 희소성, 곱 구조, 알려진 생성 회로 같은 정보는 준비 비용을 낮출 수 있다. 따라서 “일반 벡터”와 “특수한 효율적 준비 회로가 주어진 벡터”를 구별한다.

시뮬레이터의 상태 배열에 숫자를 바로 쓰는 기능은 CPU 메모리에 벡터를 넣는 일이다. 실제 QPU에서는 초기화에서 그 상태를 만드는 연산이 필요하다. 편리한 `AmplitudeEmbedding` 템플릿도 이 물리적 의무를 제거하지 않는다. 분해·정규화·padding·미분 제약을 설치 버전 문서로 확인한다.

qRAM과 oracle의 정확한 역할

디지털 데이터 oracle은 예를 들어 $O_x|j\rangle|0\rangle=|j\rangle|b_j\rangle$로 쓸 수 있다. b_j는 값의 비트 표현이다. 주소를 중첩으로 주면 선형성으로 여러 값에 coherent하게 접근한다. 그러나 이 연산만 썼다고 $\sum_j x_j|j\rangle/\|x\|$가 즉시 만들어지지는 않는다. 진폭을 조절하는 절차·추가 데이터 구조·성공 확률·정규화 정보가 필요할 수 있다.

qRAM은 이런 접근을 구현하려는 메모리 구조다. Giovannetti-Lloyd-Maccone의 원 제안은 중첩 주소 접근의 개념과 구조를 다룬다. 고전 배열을 생성한 것만으로 같은 자원이 제공되지는 않는다. 데이터 초기 적재·업데이트·오류율·제어 비용, 반복 재사용 횟수를 기록한다. 고전 비교에도 원소 질의나 norm 기반 샘플 접근을 줄 것인지 정한다. 이 조건이 14강의 탈양자화 논의를 결정한다.

연습문제와 풀이

문제 1. 큐비트와 입력 크기

1,000차원 벡터를 진폭 인코딩할 최소 큐비트 수와 padding 원소 수를 구하라. 구조가 없다면 상태 준비가 10단계라고 말할 수 있는가? **힌트:** $2^9<1000\le 2^{10}$을 사용한다.

풀이: 최소 10큐비트이며 1,024개 진폭 중 24개를 0으로 채운다. 표현에 필요한 공간과 준비 연산 수는 다르다. 정규화 계산과 일반 회로 분해에는 벡터 성분 정보가 필요하므로 10큐비트라는 이유만으로 10단계 준비를 결론 내릴 수 없다. 효율적 준비 oracle을 가정했다면 그 가정을 명시해야 한다.

문제 2. 사라지는 norm과 부호

$x = (1, 0), y = (-1, 0), z = (2, 0)$의 모든 쌍에 대한 fidelity와 원래 제곱거리를 구하라. **힌트:** 세 상태는 전역 위상까지 같다.

풀이: 모든 fidelity는 1이다. 원래 제곱거리는 x-y가 4, x-z가 1, y-z가 9다. norm을 별도 저장하면 z의 크기 2와 x·y의 크기 1을 구별할 수 있지만 x와 y의 부호는 여전히 잃는다. 원 데이터의 정보 보존 요구를 먼저 쓰고 인코딩을 선택해야 한다.

문제 3. 곱 커널 계산

$d = 3, \alpha = 1$에서 모든 특징 차이가 $\pi/2$다. K와 projector 사이 제곱 Hilbert-Schmidt 거리는? **힌트:** 한 특징의 인자는 1/2다.

풀이: $K = (1/2)^3 = 1/8$이고 제곱거리는 $2(1 - 1/8) = 7/4$다. 원래 데이터 제곱거리는 $3\pi^2/4$라서 수치와 단위가 다르다. 커널 값과 유클리드 거리를 같은 종류의 거리라고 보고 직접 교환하면 안 된다.

문제 4. 스케일 선택과 누수

회전 스케일 후보 50개를 최종 테스트셋 정확도로 골라 최고 결과를 보고했다. 어떤 수정이 필요한가? **힌트:** 양자 회로 밖의 선택도 모델 선택이다.

풀이: 훈련셋에서 전처리 통계와 파라미터를 맞추고, 별도 검증셋 또는 내부 교차검증으로 스케일을 선택한다. 고정된 선택을 독립 테스트셋에서 한 번 평가한다. 이미 50개 선택에 사용한 집합을 새 독립 테스트라고 부를 수 없으므로 가능하면 새 평가 자료를 확보한다. 선택 횟수·고전 기준선의 동일한 튜닝 예산도 보고한다.

학습 완료 점검

- 기저·각도·진폭 인코딩에서 데이터의 어떤 정보가 유지되는지 각 한 문장으로 쓰면 통과다. 실패하면 비교표와 예제 1을 다시 본다.
- product 각도 커널을 한 큐비트 내적에서 시작해 곱으로 유도하면 통과다. 마지막 공식을 외우기만 했다면 유도 2를 반복한다.
- qRAM 값 질의와 진폭 상태 준비가 같은 연산이 아님을 식으로 구별하면 통과다.
- 인코딩에서 합쳐진 서로 다른 label의 두 점을 후속 회로가 왜 구별하지 못하는지 설명하면 통과다. shots 증가로 해결한다고 답하면 정보 손실 반례로 돌아간다.

원문 읽기

- Schuld, Sweke and Meyer, Effect of data encoding… (2021): Section I의 모델 정의와 Section IV.1의 classical pre-processing을 읽는다. Fourier 주파수의 엄밀한 전개는 6강에서 직접 유도한다. 본문의 product 커널과 반례는 자체 계산이다.
- Giovannetti, Lloyd and Maccone, Quantum Random Access Memory (2008): 초록과 메모리 접근 구조를 읽고 주소 레지스터·저장 용량·한 질의 비용을 구별한다. 현대 대규모 장치의 실증 성능으로 읽지 않는다.
- PennyLane AmplitudeEmbedding: normalization, padding, feature differentiation 설명을 확인한다. SDK 실행 버전은 실습 안내를 따른다. 실습 2는 geometry 비교이며 qRAM 구현이 아니다.

05. 양자 k-means를 읽기 전에 거리부터 확인하기

> 독립 집필한 80분 학습 단원 · 2026-10-20 기준. 원강좌 Lecture 3·Lab 2의 공개 주제에서 출발한다. 본문의 projective clustering은 q-means 원 논문의 전체 알고리즘이 아니다.

시작하기 전에

4강의 진폭 인코딩·fidelity·norm 손실을 복습한다. 평균벡터, 고유값과 Rayleigh quotient가 낯설면 수학 준비 노트를 함께 읽는다. 학습 후에는 Lloyd 반복의 감소 성질을 증명하고, SWAP test 확률을 유도하고, fidelity로 유클리드 거리를 대체할 수 없는 반례를 구성하며, 선택한 목적함수에 맞는 중심 갱신과 측정 예산을 설계할 수 있어야 한다.

“양자 k-means”라는 이름 아래에는 서로 다른 입력 모형·거리·출력을 가진 절차들이 있다. 군집 그림이 비슷하다는 이유만으로 동일한 최적화 문제를 풀었다고 가정하지 않는다. 이 강의에서는 먼저 목적함수를 쓰고, 그 함수가 실제 각 단계에서 줄어드는지 확인한다.

80분 학습 순서

시간	수행할 활동	남길 결과
0-10분	용어와 목적함수 구별	입력·거리·출력 명세
10-25분	평균 중심 최적화와 Lloyd 예제 계산	감소 증명
25-45분	SWAP test·projective 중심 유도	두 알고리즘의 차이
45-60분	반례와 샷 오차·할당 격차 계산	안정 조건
60-75분	문제 1·3부터 풀고 네 풀이 대조	계산과 가정 기록
75-80분	완료 점검	다음 강의 진행 판단

완전한 실습 재실행과 원문 읽기는 별도 복습으로 진행한다. 80분 계획은 손계산 활동의 배분이며 단순 낭독 시간이 아니다.

강의 후 **60-90분**에는 남은 문제를 해설 없이 풀고, 유도 하나를 재작성하고, 오답을 수정한다. 원문 전문 독해와 코딩 실습은 별도 시간이다.

핵심 용어

한국어·영어	정의·기호·직관
군집·cluster	선택한 유사도와 목적함수 아래 함께 묶은 데이터 집합. 정답 범주와 같을 필요는 없다.
중심·centroid	군집을 대표하는 변수 μ_a. 어떤 손실을 쓰는지에 따라 최적 갱신이 달라진다.

한국어·영어	정의·기호·직관
Lloyd 반복·Lloyd iteration	최근접 중심 할당과 산술평균 갱신을 번갈아 수행하는 고전 k-means 절차.
목적함수·objective	알고리즘이 줄이려는 수 J. 외부 평가 점수와 구별한다.
국소 최적·local optimum	주변 변경으로 개선하기 어려운 해. 전역 최소라는 뜻은 아니다.
충실도·fidelity	순수 상태 사이 $F = \lvert\langle u \rvert v\rangle\rvert^2$. 내적의 부호와 위상을 잃는다.
SWAP test·스왑 검사	보조 큐비트와 controlled-SWAP으로 두 상태의 겹침을 확률에 기록하는 절차.
계산·역계산·compute-uncompute	한 상태의 준비 후 다른 준비회로의 역연산을 적용하여 겹침을 읽는 절차.
사영 군집·projective clustering	전역 위상이 같은 상태를 동일시하고 projector의 fidelity를 기준으로 군집하는 본문의 교육용 절차.
Rayleigh quotient·레일리 몫	$\langle c \rvert M \rvert c\rangle / \langle c \rvert c\rangle$. 에르미트 M에서 최댓값은 최대 고유값이다.
할당 격차·assignment gap	최선 중심과 두 번째 중심 사이 목적값 차이 Δ. 측정 오차가 순위를 바꿀 여지를 정한다.
동률 규칙·tie-breaking	동일 거리나 동일 고유값에서 선택을 고정하는 규칙. 재현성과 종료 조건의 일부다.

영문 약자와 다른 강의의 사용례는 통합 용어집을 따른다. 아래에서 $1 - F$는 비유사도이며 항상 metric이라고 부르지 않는다.

유도 1: 왜 유클리드 k-means는 평균을 쓰는가

N개 실수 벡터 $x_i \in \mathbb{R}^d$의 할당을 $c_i \in \{1, \dots, k\}$라 두면

$$J(c, \mu) = \sum_{i=1}^{N} \lVert x_i - \mu_{c_i} \rVert_2^2$$

를 최소화하려 한다. 고정된 비어 있지 않은 군집 C의 평균을 $\bar{x} = \lvert C \rvert^{-1} \sum_{i \in C} x_i$라 쓰자.
$x_i - \mu = (x_i - \bar{x}) + (\bar{x} - \mu)$를 제곱해 합하면

$$\sum_{i \in C} \lVert x_i - \mu \rVert^2 = \sum_{i \in C} \lVert x_i - \bar{x} \rVert^2 + \lvert C \rvert \lVert \mu - \bar{x} \rVert^2 .$$

교차항은 $\sum_i (x_i - \bar{x}) = 0$이어서 사라진다. 두 번째 항이 음이 아니므로 평균이 유일한 최적 중심이다. “중심이니까 평균을 쓴다”는 직관이 아니라 제곱 유클리드 손실의 특정한 성질이다.

고정 중심에서는 각 점을 가장 가까운 중심으로 보내면 각 항이 증가하지 않는다. 고정 할당에서는 위 평균 갱신이 합을 증가시키지 않는다. 따라서 정확한 Lloyd 반복의 목적값은 단조 비증가하고 0 아래로 내려가지 않는다. 빈 군집 처리, 동률, 근사 거리, 조기 종료는 별도 명세다. 비어 있는 군집이 없고 변하는 할당에서 동률이 없으며 정확한 갱신을 하면 비정상 반복에서 목적값이 엄격히 줄고, 가능한 할당이 유한하므로 정지한다. 어느 경우든 전역 최소를 찾았다는 보장은 얻지 못한다.

완전 예제 1: 한 번의 Lloyd 반복

실수 데이터 0, 2, 8, 10에 초기 중심 0, 8을 쓰자. 각 점의 제곱거리쌍은 각각 (0,64), (4,36), (64,0), (100,4)다. 따라서 첫 군집은 0·2, 둘째는 8·10이며 목적값은 8이다. 중심을 평균 1과 9로 바꾸면 각 제곱거리는 1, 1, 1, 1이어서 목적값은 4가 된다. 새 할당도 같으므로 다음 갱신은 변하지 않는다.

이 예는 중심 갱신의 근거와 정지 확인을 모두 보여준다. 초기 중심을 바꿔 다른 해를 얻을 수 있는 문제에서는 여러 seed를 비교한다. dense 거리 계산의 단순 비용은 반복 I회에 $O(INkd)$지만 벡터화, minibatch, 근사 탐색 등 더 강한 고전 기준선도 검토해야 한다.

유도 2: SWAP test가 실제로 읽는 양

정규화 상태 $|u\rangle, |v\rangle$와 보조 $|0\rangle$를 준비한다. 보조에 H, 보조가 1일 때 두 레지스터를 교환하는 controlled-SWAP, 다시 H를 적용한다. 최종 상태는

$$\frac{1}{2}|0\rangle(|u\rangle|v\rangle + |v\rangle|u\rangle) + \frac{1}{2}|1\rangle(|u\rangle|v\rangle - |v\rangle|u\rangle).$$

0인 분기의 norm 제곱을 계산하면 두 대각항의 합은 2, 두 교차항의 합은 $2|\langle u|v\rangle|^2$다. 따라서

$$p_0 = \frac{1+F}{2}, \qquad F = |\langle u|v\rangle|^2 = 2p_0 - 1.$$

두 상태 준비와 controlled-SWAP 비용을 모두 포함한다. 준비회로 U_u, U_v와 역회로를 알고 있으면 $U_u^\dagger U_v|0\rangle$의 all-zero 확률도 F다. 이것이 compute-uncompute 방식이다. 보조 큐비트가 없어도 준비·역연산 깊이와 측정 비용이 남는다. 미지 상태만 공급되는 경우에는 역준비회로를 당연히 쓸 수 없다.

반례를 보자. 단위 실수 벡터 $u = (1,0), v = (-1,0)$는 $F = 1$이지만 유클리드 제곱거리는 4다. $2 - 2\sqrt{F} = 0$을 거리로 쓰면 틀린다. 일반적으로

$$\|x - y\|^2 = \|x\|^2 + \|y\|^2 - 2\|x\|\|y\|\,\mathrm{Re}\langle u|v\rangle, \quad u = x/\|x\|,\ v = y/\|y\|$$

이므로 norm과 내적의 실수부가 필요하다. fidelity만으로는 부호·복소 위상을 복구하지 못한다. 제어 가능한 준비 연산을 쓰는 간섭 측정은 가능하지만 이는 추가 접근 가정이다. 물리적 전역 위상을 동일시한 상태만 주어진 경우 원래 벡터 부호를 새로 만들어낼 수는 없다.

유도 3과 완전 예제 2: fidelity 목적함수에 맞는 중심

$D_F(u,c) = 1 - |\langle u|c\rangle|^2$를 쓰려면 목적함수를 새로 정의한다. 고정 군집 C에서 단위 중심 $|c\rangle$에 대한 합은

$$J_C = \sum_{i\in C}(1 - |\langle x_i|c\rangle|^2) = |C| - \langle c|M_C|c\rangle, \quad M_C = \sum_{i\in C}|x_i\rangle\langle x_i|.$$

M의 고유분해를 $M = \sum_r \lambda_r |v_r\rangle\langle v_r|$라 두고 $|c\rangle = \sum_r a_r|v_r\rangle$라 쓰면 평균은 $\sum_r \lambda_r |a_r|^2 \le \lambda_{\max}$다. 따라서 최대 고유값의 단위 고유벡터가 최적 중심이고, 최소 군집 손실은 $|C| - \lambda_{\max}$다. 산술평균을 정규화하는 갱신과는 다른 증명이다.

세 입력이 $|0\rangle, -|0\rangle, |1\rangle$인 군집을 보자. projector 합은 $M = \mathrm{diag}(2,1)$이며 최적 중심은 $|0\rangle$, 손실은 $3 - 2 = 1$이다. 반면 상태벡터의 산술평균을 정규화하면 $|1\rangle$이 되어 손실 2를 낸다. 물리적으로 같은 첫 두 상태에 서로 반대 위상을 골랐다는 이유로 평균이 상쇄된 것이다. projector 갱신은 전역 위상에 영향받지 않는다.

최근접 fidelity 할당과 정확한 최대 고유벡터 갱신을 번갈아 적용하면 이 새 목적값도 증가하지 않는다. 단, 고유값의 중복, 빈 군집, 샷 오차를 명세해야 하고 전역 최적을 보장하지 않는다. 여기서 단조 감소가 보장된다는 말은 원래 유클리드 J가 감소한다는 뜻이 아니다. 실습 2는 이 projective 목적함수를 고전 모사로 계산한다.

샷 오차와 안정적인 할당

S회 독립 Bernoulli 결과로 p_0를 추정하면 $\widehat{F} = 2\hat{p}_0 - 1$이고

$$\mathrm{SE}(\widehat{F}) = 2\sqrt{p_0(1-p_0)/S} \le 1/\sqrt{S}.$$

유한 표본에서 추정 F가 음수가 될 수도 있다. 물리적 F가 음수라는 뜻이 아니며 clipping을 적용하면 추정량의 성질이 달라진다. 처리 방식을 보고한다.

두 중심의 진짜 fidelity가 0.51·0.50이라면 격차는 0.01이다. 100 shots의 표준오차 상한 0.1은 이 차이보다 크다. 두 추정 오차가 각각 $\Delta/2$보다 작으면 순위는 유지되지만, 평균 정확도만 조금 좋아졌다고 항상 안정적인 할당이 되는 것은 아니다. Bernoulli Hoeffding 상계로 한 F의 오차가 ϵ 이상일 확률은 $2e^{-S\epsilon^2/2}$ 이하다. 두 비교의 실패확률을 합쳐 $4e^{-S\Delta^2/8}$라는 보수적 상계를 얻는다. 실패확률 δ 이하를 원하면

$$S \ge \frac{8}{\Delta^2}\log\frac{4}{\delta}$$

가 충분하다. 이 상계는 독립 준비·이상 측정에 대한 보수적 보장이지 필요 샷의 정확한 최소값이 아니다. 많은 점·중심·반복에 동시에 보장하려면 비교 수를 추가로 고려한다.

논문의 질의 복잡도를 전체 군집 실행 시간으로 옮길 때는 입력 적재, 중심 업데이트, 정밀도와 출력 크기를 포함한다. N개 label을 고전적으로 모두 출력하면 최소한 그 출력량만큼의 작업이 남는다. q-means처럼 k개의 고전 중심을 출력하는 과제와 모든 label을 나열하는 과제를 구별한다.

연습문제와 풀이

문제 1. SWAP 결과 해석

$p_0 = 0.8$일 때 fidelity와 가능한 실수 내적을 구하라. **힌트:** 제곱은 부호를 지운다.

풀이: $F = 2(0.8) - 1 = 0.6$이다. 실수 내적이라면 $+\sqrt{0.6}$와 $-\sqrt{0.6}$가 모두 가능하다. 복소 내적이라면 크기만 $\sqrt{0.6}$로 정해지고 위상은 자유롭다. 따라서 norm을 안다고 해도 이 측정 하나만으로 일반 벡터의 유클리드 거리를 유일하게 정할 수 없다.

문제 2. 목적함수에 맞는 중심

단위 상태 $|0\rangle, |0\rangle, |1\rangle, |1\rangle, |1\rangle$의 fidelity 군집 중심과 최소 손실을 구하라. **힌트:** projector를 합한다.

풀이: $M = \mathrm{diag}(2,3)$이고 최대 고유값은 3이다. 따라서 중심은 $|1\rangle$이며 최소 손실은 $5 - 3 = 2$다. 산술평균을 정규화한 벡터는 $(2|0\rangle + 3|1\rangle)/\sqrt{13}$이며 fidelity 합은 $2(4/13) + 3(9/13) = 35/13 < 3$다. 유클리드 평균 규칙을 그대로 적용하면 최적 중심이 아니다.

문제 3. 격차와 오차

두 중심의 F가 0.7과 0.6이다. 각각의 절대 추정오차가 0.04 이하면 순위가 유지되는가? **힌트:** 첫 값을 최대로 낮추고 둘째를 최대로 높인다.

풀이: 첫 추정은 최소 0.66, 둘째는 최대 0.64이므로 순위가 유지된다. 오차 상한이 0.06이면 0.64·0.66으로 역전 가능하다. 일반적으로 $2\epsilon < \Delta$면 충분하다. 모든 비교가 이 조건을 만족한다는 보장은 개별 평균의 표준오차와 별개로 계산해야 한다.

문제 4. 알고리즘 보고서 고치기

"fidelity를 거리로 쓰고 벡터 평균으로 중심을 갱신하니 quantum k-means가 수렴했다"는 문장을 검토하라. **힌트:** 어떤 함수가 줄어드는지 먼저 묻는다.

풀이: $1 - F$ 손실에 산술평균 갱신을 쓰면 위 최적화 증명이 적용되지 않는다. fidelity 목적을 유지하려면 projector 합의 최대 고유벡터를 쓰거나, 실제 갱신이 손실을 줄이는지 별도로 증명·검사해야 한다. 거리 정의, 정규화, 초기화, 빈 군집·동률 규칙, 종료 조건과 shots를 기록한다. 목적값이 안정되었다고 전역 최적·유클리드 k-means와 동등·실용적 양자 우위까지 입증한 것은 아니다.

학습 완료 점검

- 제곱거리 합을 평균 주위 식으로 전개하고 교차항이 사라지는 이유를 설명하면 통과다. 실패하면 유도 1로 돌아간다.
- SWAP test가 내적의 실수부가 아닌 절댓값 제곱을 읽는 이유를 교차항으로 보이면 통과다.
- fidelity 중심이 최대 고유벡터인 이유를 고유기저 전개로 설명하면 통과다. "평균도 비슷하다"로 답하면 예제 2를 다시 계산한다.
- 작은 할당 격차에서 필요한 정밀도가 커지는 이유를 $2\epsilon < \Delta$로 쓰면 통과다.

원문 읽기

- Kerenidis et al., q-means (arXiv v2; NeurIPS 2019): Sections 1.2-1.4에서 k-means·δ-k-means·결과 출력을, Section 2에서 QRAM 접근을, Sections 5.1-5.2에서 오차·시간을 비교한다. 보고된 복잡도는 정밀도·norm·행렬 조건과 데이터 접근 가정을 가진다. 본문 전체 증명을 독립 재현한 것은 아니다.
- Lloyd, Mohseni and Rebentrost (2013): 초기 지도·비지도 양자 학습 제안의 입력과 출력을 읽는 선택 자료다. 제목에 k-means가 등장한다고 본 강의의 projective 구현과 동일시하지 않는다.
- Buhrman et al., Quantum Fingerprinting (2001): 겹침 비교 절차의 원 연구 맥락이다. 위 SWAP test 수식과 군집 예제는 교육용 직접 계산이다.

06. 퍼셉트론에서 양자 신경망과 재업로드로

> 독립 집필한 80분 학습 단원 · 2026-10-20 기준. 원강좌 Lecture 4의 공개 항목을 확장한다. 원 수업의 강의 시간·설명을 재현한 자료가 아니다.

시작하기 전에

2강의 회전과 측정, 4강의 각도 인코딩을 복습한다. 합성함수 미분과 복소 지수 $e^{ix} = \cos x + i \sin x$는 수학 준비 노트에서 확인한다. 이 강의 후에는 회로를 입력의 함수로 전개하고, 중복되거나 관측할 수 없는 파라미터를 찾으며, 재업로드가 허용하는 주파수와 실제로 조절할 수 있는 계수를 구별하고, hybrid 분류기의 손실 미분을 계산할 수 있어야 한다.

"양자 신경망"이라는 이름은 고전 신경망의 모든 성질을 자동으로 가져오지 않는다. 중요한 것은 회로가 어떤 함수 집합을 표현하고 어떤 정보를 측정할 수 있는가다. 게이트 수를 늘리기 전에 손으로 작은 모델을 전개하면 학습이 실패하는 구조적 이유를 찾을 수 있다.

80분 학습 순서

시간	수행할 활동	남길 결과
0-10분	용어와 예측기 정의 확인	회로 출력·확률의 구별
10-25분	단일축·관측 불가 파라미터 계산	중복 자유도 판정
25-45분	Fourier와 재업로드 예제 유도	접근 주파수·계수
45-60분	근사 불가능 반례와 손실 미분 활동	오류 원인·미분식
60-75분	문제 1·3부터 풀고 네 해설 대조	독립 풀이 기록
75-80분	완료 점검	7강 진입 판단

80분은 회상과 계산을 포함한 첫 세션이다. 원문 정리의 전체 증명과 모든 문제의 재풀이에는 별도 복습 시간을 둔다.

강의 후 **60-90분**에는 남은 문제를 해설 없이 풀고, 유도 하나를 재작성하고, 오답을 수정한다. 원문 전문 독해와 코딩 실습은 별도 시간이다.

핵심 용어

한국어·영어	정의·기호·직관
퍼셉트론·perceptron	$w^T x + b$와 threshold 등으로 예측하는 기본 고전 모델.
매개화 양자 회로·PQC	고전 파라미터 θ에 따라 게이트가 변하는 회로 U_θ.
변분 분류기·variational classifier	측정 출력과 손실을 정의하고 고전 최적화기로 회로 파라미터를 학습하는 분류기.

한국어·영어	정의·기호·직관
양자 신경망·QNN	여러 회로 기반 학습 모델을 가리키는 넓은 이름. 특정한 단일 구조를 뜻하지 않는다.
하이브리드 헤드·hybrid head	양자 측정값 뒤에 붙는 고전 함수. logistic 변환과 선형 결합 등이 있다.
표현력·expressive power	모델이 입력의 어떤 함수들을 나타낼 수 있는가. 훈련 성공과 구별한다.
데이터 재업로드·data re-uploading	학습 연산 사이에 같은 고전 입력을 반복 삽입하는 구조. 미지 양자 상태 복제와 다르다.
생성자·generator	$S(x) = e^{-ixH}$에서 인코딩 변화를 정하는 에르미트 H.
주파수 집합·frequency spectrum	출력의 복소 지수 전개에 허용되는 ω들의 집합 Ω.
식별 가능성·identifiability	서로 다른 파라미터가 서로 다른 예측을 만들 수 있는가의 성질.
귀납 편향·inductive bias	데이터에 대한 가정이 모델 구조에 들어가 일부 함수·관계를 선호하는 경향.
교차 엔트로피·cross-entropy	이진 분류에서 $-y\log p-(1-y)\log(1-p)$. label·확률 규약을 맞춰야 한다.

통합 용어집에서 expressivity와 trainability를 함께 확인한다. 상태공간을 넓게 탐색한다는 뜻의 expressibility와 목표 함수를 근사하는 능력도 항상 같은 척도는 아니다.

선형 양자 진화에서 비선형 예측이 나오는 이유

고전 다층 신경망은 선형 변환과 비선형 활성함수를 합성한다. 유니터리 게이트는 상태벡터에 선형으로 작용한다. 따라서 한 양자 게이트를 ReLU와 같은 상태벡터 비선형 함수라고 부르면 잘못이다. 하지만 입력 x가 회전각으로 들어가면 진폭은 $\cos(x/2), \sin(x/2)$이고 측정 확률은 그 절댓값 제곱이다. 따라서 원래 숫자 x에 대한 예측은 비선형일 수 있다. 서로 다른 공간에서 말하는 "선형"을 구별해야 한다.

고정 인코딩 $\rho(x)$ 뒤에 회로를 적용하는 모델은

$$f_\theta(x) = \mathrm{Tr}[OU_\theta\rho(x)U_\theta^\dagger] = \mathrm{Tr}[M_\theta\rho(x)], \quad M_\theta = U_\theta^\dagger O U_\theta$$

다. 상태 행렬의 특징에 대해서는 선형이지만 x에 대해서는 비선형일 수 있다. 이 관찰이 8강의 커널 해석으로 이어진다. 데이터가 여러 층에 다시 들어가면 단일 고정 인코딩 뒤의 측정이라는 형태를 그대로 적용할 수 있는지 다시 확인해야 한다.

유도 1과 완전 예제 1: 파라미터를 늘려도 함수가 늘지 않을 때

$|0\rangle$에 $R_y(x)$를 적용하고 $R_y(\theta_1), R_y(\theta_2)$를 순서대로 적용한 뒤 Z를 읽자. 같은 생성자의 회전은 서로 commute하므로

$$R_y(\theta_2)R_y(\theta_1)R_y(x) = R_y(x+\theta_1+\theta_2), \qquad f = \cos(x+\theta_1+\theta_2).$$

파라미터 두 개 중 합 하나만 예측에 영향을 준다. $(\theta_1, \theta_2) \to (\theta_1 + t, \theta_2 - t)$로 바꾸어도 모든 입력에서 f가 같다. 두 편미분은 모두 $-\sin(x+\theta_1+\theta_2)$이고, 방향 (1,−1)의 방향미분은 0이다. 100개의 같은 축 게이트를 추가해도 유효한 각도는 하나다. 이는 데이터가 부족해서 생긴 추정 문제가 아니라 모델의 비식별성이다.

다른 반례는 $U = R_z(\theta)R_y(x)$다. $R_z^\dagger Z R_z = Z$이므로

$$f = \langle 0|R_y(x)^\dagger Z R_y(x)|0\rangle = \cos x, \qquad \partial_\theta f = 0.$$

Z 회전은 상태의 상대 위상을 바꾸지만 현재 측정은 그 변화를 보지 못한다. 최적화기나 shot 수를 바꿔도 이 파라미터로 예측을 학습할 수 없다. X 측정으로 바꾸면 $f_X = \sin x \cos\theta$가 되어 일부 입력에서 민감도가 생긴다. 단, $x = 0$에서는 여전히 0이다. 파라미터 유용성은 회로·입력·측정의 조합으로 결정된다.

이런 구조적 0은 9강의 무작위 회로에서 기울기 분산이 작아지는 barren plateau와 구별한다. 두 현상 모두 훈련을 어렵게 하지만 원인과 개선책이 다르다.

유도 2: 인코딩 생성자가 주파수를 정한다

입력 x를 한 번 $S(x) = e^{-ixH}$로 넣자. 앞뒤의 입력 독립 게이트를 초기 상태 ρ와 관측량 M에 흡수한다. H의 고유기저에서 $H|a\rangle = \lambda_a|a\rangle$이면

$$f(x) = \mathrm{Tr}[MS(x)\rho S(x)^\dagger] = \sum_{a,b} M_{ba}\rho_{ab} e^{-ix(\lambda_a - \lambda_b)}.$$

따라서 가능한 주파수는 고유값 차이 $\lambda_a - \lambda_b$로 정해진다. 실수 관측값이라는 조건은 반대 주파수 계수의 켤레 관계 $c_{-\omega} = c_\omega^*$를 준다. $H = Y/2$의 고유값은 ±1/2이므로 $\Omega = \{0, \pm 1\}$이고

$$f(x) = a_0 + a_c \cos x + a_s \sin x$$

형태만 가능하다. 입력 독립 회로를 깊게 만들었다는 이유로 $\cos 3x$가 생기지는 않는다. 처음에 $3x$를 회전각으로 쓰면 주파수가 달라지지만 그 스케일도 인코딩 설계의 일부다.

입력을 L번 반복하면 각 진폭의 경로에 고유값 합이 들어가고, bra와 ket의 곱에서 그 합들의 차이가 나온다. 동일 Pauli 회전의 반복에서는 $\Omega \subseteq \{-L, \ldots, L\}$가 된다. 허용 주파수가 늘 수 있다는 뜻이지 각 계수를 마음대로 독립 조절할 수 있다는 뜻은 아니다. 실제 0이 되는 계수, 대칭 제약과 관측량 제한은 따로 확인한다. 이 연결은 Schuld-Sweke-Meyer의 Fourier 분석과 대조할 수 있다.

완전 예제 2: 두 번 재업로드해도 모든 계수가 자유롭지는 않다

$U(x,\theta) = R_y(x)R_z(\theta)R_y(x)$를 생각하자. Bloch 벡터는 초기 (0,0,1)에서 첫 RY로 $(\sin x, 0, \cos x)$, RZ로 $(\cos\theta\sin x, \sin\theta\sin x, \cos x)$가 된다. 마지막 RY 뒤의 z좌표는

$$f(x,\theta) = \cos^2 x - \cos\theta \sin^2 x = \frac{1-\cos\theta}{2} + \frac{1+\cos\theta}{2}\cos 2x.$$

$\theta = 0$이면 $\cos 2x$, $\theta = \pi$이면 상수 1이다. 두 번째 주파수는 생겼지만 이 구조에는 $\sin x, \cos x, \sin 2x$가 없다. 상수항과 $\cos 2x$ 계수의 합도 1로 고정된다. “L=2이므로 모든 2차 Fourier 함수를 표현한다”라는 결론은 이 작은 회로에서 성립하지 않는다.

또 다른 검산법은 x=0을 대입하는 것이다. 모든 θ에 대해 f(0,θ)=1이므로 0에서 다른 값을 갖는 목표 함수를 이 회로 단독으로 완전히 맞출 수 없다. 작은 입력 몇 점을 먼저 검사하면 비싼 훈련 전에 모델의 제약을 발견할 수 있다.

완전 예제 3: 학습 실패가 최적화 문제인지 판정하기

단일 Pauli 인코딩 모델로 $g(x) = \sin 3x$를 $[0, 2\pi]$에서 균등하게 근사한다고 하자. 허용 출력은 $a_0 + a_c \cos x + a_s \sin x$다. 서로 다른 정수 주파수의 직교성 때문에 $\int_0^{2\pi} f(x) \sin 3x \, dx = 0$이다. 따라서 평균 제곱오차는

$$\frac{1}{2\pi}\int_0^{2\pi} (f-g)^2 dx = \frac{1}{2\pi}\int_0^{2\pi} f^2 dx + \frac{1}{2} \geq \frac{1}{2}.$$

f=0을 표현할 수 있는 경우 이 하한에 도달한다. 불가능하다면 최솟값은 더 클 수도 있다. 어떤 최적화기도 이 함수 집합 안에서 오차 0을 만들 수 없다. 반면 몇 개 훈련점만 우연히 맞추는 것은 가능하므로 훈련 성공도 함수 전체의 표현을 보장하지 않는다. 주파수 표현을 바꾸거나 재업로드 구조를 바꾼 뒤에 최적화기 튜닝을 논의해야 한다.

하이브리드 확률과 손실의 정확한 연결

Z 평균 f는 −1부터 1까지의 실수다. 측정 결과 1의 확률 $(1-f)/2$를 직접 쓰는 모델과, 별도 logistic head

$$p_\theta(y=1|x) = \sigma(z), \quad z = a f_\theta(x) + b, \quad \sigma(z) = \frac{1}{1+e^{-z}}$$

를 쓰는 모델은 서로 다르다. a·b도 학습 변수이며 전체 파라미터 수에 포함한다. label은 0/1로 고정한다. 한 사례의 교차 엔트로피는 $\ell = \log(1+e^z) - yz$로 다시 쓸 수 있고

$$\frac{\partial \ell}{\partial z} = p - y, \qquad \partial_\theta \ell = a(p-y)\partial_\theta f$$

다. log의 수치 안정화를 위해 stable softplus 구현을 쓰면 큰 z의 overflow를 피할 수 있다. 확률 clipping을 사용하면 threshold와 미분 처리도 명시한다.

수치 예로 $f = \cos(x+\theta), x=0, \theta=\pi/3, a=2, b=0, y=1$을 쓰자. f=0.5, z=1, p≈0.7311이며 $\partial_\theta f = -\sqrt{3}/2$다. 따라서 손실 미분은 약 0.4658이다. gradient descent로 θ를 조금 줄이면 f와 정답 확률이 올라가 손실이 감소한다. 미분 부호가 예측 변화와 일치하는지 확인하는 유용한 검산이다.

finite-shot 평균 $\widehat{f}$를 sigmoid에 넣으면 일반적으로 $\mathbb{E}\sigma(a\widehat{f}+b) \neq \sigma(af+b)$다. 평균 추정량이 불편이라고 비선형 후처리 결과까지 불편인 것은 아니다. exact expectation 훈련과 장치 훈련의 차이를 평가할 때 이 효과도 고려한다.

표현력, 훈련 가능성과 계산 우위를 분리한다

재업로드의 근사 능력은 회로가 목표 함수를 표현할 수 있다는 질문이다. 그 파라미터를 적은 데이터와 안정적인 미분으로 찾을 수 있는가는 또 다른 질문이다. 찾은 예측을 강한 고전 기준선보다 싸게 계산하는가도 별개다. 단일 큐비트 회로는 매 게이트를 2×2 벡터에 적용해 고전적으로 쉽게 모사할 수 있으므로 복잡한 분류 경계를 만들었다고 지수 계산 우위가 생기지 않는다.

얽힘이 특징 상호작용을 만들 수 있지만 얽힘 수치·함수 근사·테스트 성능은 같은 지표가 아니다. 대칭이나 국소 구조를 넣으면 필요한 자유도를 줄일 수 있으나 정답이 그 구조를 따르지 않으면 underfitting을 만든다. 먼저 회로 출력의 parameter scan을 그리고, 같은 입력 스케일의 고전 Fourier 모델·선형 모델·MLP와 비교한다. 7강은 미분 자원, 9강은 훈련 신호, 10강은 일반화 검증을 이어서 다룬다.

연습문제와 풀이

문제 1. 중복 파라미터

$R_y(\theta_3)R_y(\theta_2)R_y(\theta_1)R_y(x)$의 유효 파라미터 수와 예측을 유지하는 변화를 두 개 제시하라. **힌트:** 합각만 남는다.

풀이: 출력은 $\cos(x+\theta_1+\theta_2+\theta_3)$여서 연속 유효 자유도는 하나다. 변화 (t,−t,0)과 (t,0,−t)는 모두 합을 보존한다. 따라서 세 변수를 독립적으로 최적화해도 새로운 함수 집합을 얻지 못한다. 이런 불필요한 방향은 파라미터 추정과 최적화의 해석을 어렵게 한다.

문제 2. 측정 선택

$R_z(\theta)R_y(x)|0\rangle$에서 Z와 X 평균 및 θ 미분을 비교하라. **힌트:** Bloch 벡터를 회전한다.

풀이: 최종 벡터는 $(\sin x\cos\theta, \sin x\sin\theta, \cos x)$다. Z 평균은 $\cos x$이며 미분 0, X 평균은 $\sin x\cos\theta$이며 미분 $-\sin x\sin\theta$다. X 측정도 x=0이나 θ=0 등에서는 민감도가 0이다. 측정을 바꾸면 구조적 비민감성을 줄일 수 있지만 모든 입력·초기화에서 큰 기울기를 보장하지 않는다.

문제 3. 주파수의 한계

위 두 번 재업로드 예제로 $g(x)=\sin 2x$를 정확히 표현할 수 있는가? **힌트:** 출력의 짝홀성을 비교한다.

풀이: 예제 출력은 상수와 $\cos 2x$의 합이라 x에 대해 짝함수다. 목표는 홀함수이므로 구간 전체에서 같을 수 없다. 예를 들어 x=π/4와 −π/4에서 모델 출력은 같지만 목표는 +1과 −1이다. 주파수 크기 2에 접근한다는 사실만으로 sine·cosine 계수를 모두 자유롭게 만들 수는 없다. 구조나 측정의 변경이 필요하다.

문제 4. 손실 미분과 우위 주장

$f=\cos\theta, a=1, b=0, y=0, \theta=\pi/2$일 때 logistic 손실의 θ 미분을 구하라. 이 학습이 성공하면 양자 우위인가? **힌트:** $a(p-y)\partial_\theta f$를 쓴다.

풀이: f=0이고 p=1/2, $\partial_\theta f=-1$이므로 미분은 −1/2이다. θ를 증가시키면 f와 p가 내려가 y=0의 손실이 감소하므로 부호도 타당하다. 이 예측은 삼각함수 하나로 고전 계산되므로 학습 성공이 양자 우위는 아니다. 모델의 정확성·학습 성능·자원 비교를 서로 다른 주장으로 기록한다.

학습 완료 점검

- 상태벡터에 선형인 게이트가 입력 x에 비선형 함수를 만드는 이유를 회전 진폭으로 설명하면 통과다. 실패하면 첫 본문으로 돌아간다.
- 고유값 차이로 $\{0,\pm1\}$을 얻고 실수 Fourier 형태로 바꾸면 통과다. 주파수와 계수 자유도를 같은 말로 쓰면 유도 2를 반복한다.
- 구조적으로 보이지 않는 파라미터와 단지 작은 기울기를 가진 파라미터를 구별하면 통과다.
- 평균 f, 확률 p, 손실 ℓ와 그 미분을 네 단계로 연결하면 통과다. 0/1 확률과 ±1 평균을 혼동하면 수치 예제를 다시 계산한다.

원문 읽기

- Schuld, Sweke and Meyer, The effect of data encoding… (2021): Section I의 Fourier 전개, II.1-II.3의 주파수·계수 제한, III의 점근적 universality 조건을 읽는다. 허용 주파수와 임의 계수 실현을 분리해 표시한다. 본 노트는 전체 universality 정리를 재증명하지 않았고, 위 작은 회로만 독립 전개했다.
- Pérez-Salinas et al., Data re-uploading for a universal quantum classifier (2020): Sections 2.1-2.2의 반복 업로드·처리 구조와 Figure 1을 읽는다. 단일 큐비트와 고전 보조 처리의 근사 능력을 계산 우위 정리로 읽지 않는다. HTML은 일부 본문이 변환되지 않았으므로 전체 읽기는 연결된 PDF를 사용한다.
- Farhi and Neven, Classification with Quantum Neural Networks on Near Term Processors (2018): 초기 변분 분류기의 입력·측정·손실 정의를 비교하는 선택 원문이다. 실습 3은 작은 모델과 고전 기준선을 동일 분할로 비교하는 교육 실험이다.

07. 양자 회로의 미분과 하이브리드 훈련

> 공개 실라버스에서 출발해 독립 집필한 80분 자율학습 노트다. 원강의 필기나 강사의 설명을 복원하지 않았다. 근거 기준일: 2026-10-20. 아래 유도와 수치는 교육용 계산이며 QPU 실행 결과가 아니다.

이전: 06. QNN과 표현력 · 전체 강의 · 다음: 08. 커널과 SVM

학습의 출발점과 도달점

02강의 기대값, 06강의 매개변수 회로, 미분의 연쇄법칙을 선수 지식으로 삼는다. $\mathrm{Tr}(O\rho)$가 왜 예측값인지 설명하기 어렵다면 수학 준비부터 읽는다. 이 강의를 마치면 두 고유값 생성자의 이동 규칙을 삼각함수로 증명하고, 회로 출력과 손실의 미분을 구별하며, 기울기 표준오차에 필요한 샷을 계산할 수 있어야 한다. 또한 SPSA와 자연 기울기가 무엇을 절약하고 무엇을 추가로 요구하는지 설명한다.

훈련은 입력 준비, 회로 실행, 측정값 집계, 고전 손실 계산, 매개변수 갱신을 반복한다. 함수의 값을 한 번 얻는 비용과 함수를 최적화하는 비용은 다르다. 해를 표현하는 회로가 존재한다는 사실도 그 해에 도달할 수 있다는 뜻은 아니다. 이 구분을 유지하면 미분 공식을 배우면서 양자 역전파가 고전 신경망과 동일한 비용일 것이라는 오해를 피할 수 있다.

80분 학습 순서

시간	실제 수행할 활동
0-5분	기대값과 연쇄법칙을 빈 종이에 각각 한 줄로 쓴다.
5-15분	아래 용어를 읽고 회로 출력, 손실, 기울기를 서로 다른 기호로 표시한다.
15-40분	이동 규칙과 기울기 분산을 직접 유도하고 빠진 독립성 가정을 찾는다.
40-55분	한 큐비트 갱신과 공유 매개변수 반례를 계산기로 확인한다.
55-70분	문제 1-2개를 선택해 독립적으로 풀고 해설의 핵심과 대조한다.
70-75분	원문 읽기의 첫 자료에서 생성자에 관한 조건을 찾아 표시한다.
75-80분	출구 점검에 답하고 오답에 해당하는 문단으로 돌아간다.

80분은 핵심 유도와 선택 문제 1-2개를 다루는 학습 시간이다. 나머지 문제의 독립 풀이, 모든 해설과의 대조, 유도 재작성에는 강의 후 60-90분을 따로 배정한다. 원문 읽기 5분은 지정된 조건을 찾는 안내 독해이며 논문 전문 독해 시간은 포함하지 않는다.

핵심 용어

한국어·영어	이 강의에서의 뜻
매개변수 회로, parametrized quantum circuit	조절 가능한 각도에 따라 유니터리가 바뀌는 회로.
생성자, generator	지수함수 안에서 연속 변환을 만드는 에르미트 연산자.
기울기, gradient	모든 학습 변수에 대한 손실의 편미분 벡터.
매개변수 이동 규칙, parameter-shift rule	특정 스펙트럼에서 미분을 유한한 이동 기대값의 합으로 표현하는 항등식.
유한차분, finite difference	작은 간격의 차이로 미분을 근사하는 수치 방법.
샷 잡음, shot noise	유한한 독립 측정 횟수 때문에 생기는 표본 변동.
불편 추정량, unbiased estimator	반복 평균이 추정 대상과 일치하는 확률변수.
미니배치, mini-batch	한 갱신에 사용하는 훈련 예제의 부분집합.
동시 섭동, simultaneous perturbation	여러 좌표를 무작위로 함께 움직여 방향 정보를 얻는 방법.
양자 자연 기울기, quantum natural gradient	상태 공간 계량을 이용해 갱신 방향을 조정하는 방법.
정규화, regularization	불안정한 역행렬이나 과도한 모델 복잡도를 제한하는 조치.

영어의 analytic gradient는 기대값 함수의 정확한 미분 관계를 뜻한다. 실험에서 측정한 기울기의 통계 오차가 0이라는 뜻은 아니다. 용어를 다시 찾을 때에는 통합 용어집을 사용한다.

예측값에서 손실의 미분까지

입력 x의 밀도행렬을 $\rho(x)$, 학습 변수를 모은 벡터를 θ, 유니터리를 U_θ, 측정 관측량을 O라 하자. N개 훈련 예제의 정답은 y_i, 고전 손실은 ℓ이다.

$$f_\theta(x) = \mathrm{Tr}[O U_\theta \rho(x) U_\theta^\dagger], \qquad \widehat{R}(\theta) = \frac{1}{N}\sum_{i=1}^{N} \ell(f_\theta(x_i), y_i).$$

제곱 손실 $\ell(f,y) = (f-y)^2$에서는 먼저 바깥 함수를 미분하고 안쪽 회로 미분을 곱한다.

$$\partial_j \widehat{R} = \frac{2}{N}\sum_{i} (f_\theta(x_i) - y_i)\, \partial_j f_\theta(x_i).$$

여러 관측량을 읽는 경우에는 각 출력의 손실 미분과 출력의 회로 미분을 더한다. 고전 신경망이 회로 앞뒤에 붙으면 그 부분에도 같은 연쇄법칙을 적용한다. 따라서 소프트웨어의 자동미분은 계산 그래프의 각 부분에 맞는 미분 방법을 연결하는 장치다. 상태벡터 시뮬레이터의 adjoint 미분으로 얻은 빠른 계산 시간을 그대로 QPU 측정 시간으로 보고해서는 안 된다.

유한 샷 출력 $\widehat{f}$를 손실에 넣으면 $\mathbb{E}[(\widehat{f}-y)^2] = (f-y)^2 + \mathrm{Var}(\widehat{f})$다. 출력은 불편해도 제곱 손실 추정은 위로 치우친다. 또한 $\widehat{f}$와 기울기 추정 $\hat{g}$를 곱하면 $\mathbb{E}[\widehat{f}\hat{g}] = fg + \mathrm{Cov}(\widehat{f},\hat{g})$이다. 독립 샷을 사용하면 공분산은 사라지지만, 샷 재사용이 있을 때는 자동으로 0이라 둘 수 없다. 실제 훈련 기록에 무엇을 재사용했는지 남겨야 하는 이유다.

유도 1: 두 고유값에서 이동 규칙을 만든다

한 변수 θ_j가 게이트 $R_P(\theta_j) = e^{-i\theta_j P/2}$ 한 곳에만 나타나고 $P^2 = I$라고 가정한다. 나머지 회로와 입력을 고정한다. I는 항등연산자이고 P의 고유값은 ± 1이다. 지수의 짝수항과 홀수항을 모으면

$$R_P(\theta) = I\cos(\theta/2) - iP\sin(\theta/2).$$

이를 $R_P \rho R_P^\dagger$에 대입한다. 두 번 곱하므로 $\cos^2(\theta/2)$, $\sin^2(\theta/2)$, $\sin(\theta/2)\cos(\theta/2)$ 항이 생긴다. 반각 공식을 쓰면 기대값은 실수 상수 a, b, c에 대해 $f(\theta) = a + b\cos\theta + c\sin\theta$가 된다. 이제 미분과 이동값을 별도로 계산한다.

$$f'(\theta) = -b\sin\theta + c\cos\theta = \frac{f(\theta + \pi/2) - f(\theta - \pi/2)}{2}.$$

작은 간격으로 극한을 근사하지 않았으므로 이 식에는 유한차분의 절단 오차가 없다. 생성자가 G이고 고유값이 $\pm r$인 $e^{-i\theta G}$라면 주파수는 $2r$가 된다. 따라서 이동량은 $\pi/(4r)$, 앞 계수는 r이다. 고유값이 더 많으면 여러 주파수가 생겨 다른 이동 조합이 필요하다. 게이트 이름보다 생성자 스펙트럼을 확인한다. Schuld 등의 미분 논문은 이 접근과 보다 일반적인 경우를 다룬다.

예제와 반례: 같은 기호가 두 게이트에 있으면

한 큐비트 $R_y(\theta)|0\rangle$의 Z 기대값은 $\cos\theta$다. $\theta = \pi/3$, 목표 $y = 0$이면 $f = 1/2$, $f' = -\sqrt{3}/2$, 손실 미분 $2ff' = -\sqrt{3}/2$이다. 학습률 $\eta = 0.1$인 경사하강 갱신은 $\theta_{\text{new}} = \theta - \eta\ell' \approx 1.1338$라디안이다. 목표 기대값이 0인 $\pi/2$ 방향으로 움직인다. 이 계산은 한 단계의 방향을 확인하며 임의 학습률의 전역 수렴을 증명하지 않는다.

반면 $R_y(\theta)R_y(\theta)$에서는 $f = \cos 2\theta$다. 공유된 각도 전체를 $\pm\pi/2$ 이동하면 두 값이 같아 잘못된 미분 0을 얻는다. 해결 방법은 두 각도를 잠시 α, β로 분리하는 것이다. $f(\alpha, \beta) = \cos(\alpha + \beta)$의 각 편미분을 이동 규칙으로 계산한 뒤, $\alpha = \beta = \theta$에서 더하면 $-2\sin 2\theta$를 얻는다. 독립 학습 변수 수와 미분해야 할 게이트 출현 횟수가 다를 수 있음을 이 반례가 보여준다.

유도 2: 측정 잡음이 기울기와 갱신에 전달되는 과정

각 이동 회로를 독립적으로 S번 측정하고 결과가 ± 1이라고 하자. 평균 추정의 분산은 $(1 - f_\pm^2)/S$다. $\hat{g} = (\widehat{f}_+ - \widehat{f}_-)/2$에 분산의 선형결합 공식을 적용하면

$$\mathrm{Var}(\hat{g}) = \frac{2 - f_+^2 - f_-^2}{4S} \le \frac{1}{2S}.$$

각각 500샷이면 표준편차 상한은 약 0.0316이다. 2,000샷으로 늘리면 약 0.0158이 된다. 참 기울기가 0.001이라면 공식은 정확해도 이 정도 측정으로 방향을 확실히 분해하기 어렵다. 갱신 잡음의 분산은 학습률 제곱 η^2를 곱한 값이다. 학습률을 줄이면 흔들림이 줄지만 이동 속도도 낮아진다.

미니배치 손실의 잡음에는 데이터 선택과 샷 선택이 함께 있다. 총분산 법칙으로, 기울기 추정의 분산은 배치에 따른 조건부 평균의 분산과 배치가 주어졌을 때 측정 분산의 평균으로 나뉜다. 배치를 늘려도 장치의 체계적 편향은 없어지지 않으며, 샷을 늘려도 데이터가 부족한 일반화 문제는 없어지지 않는다. 이 둘을 독립 예산으로 조정해야 최적화 실패의 원인을 찾을 수 있다.

두 함수 평가의 SPSA와 상태 기하의 자연 기울기

SPSA에서는 각 성분이 독립적으로 ± 1인 벡터 Δ와 작은 섭동 크기 $c > 0$를 뽑는다. 손실 평가 두 개로 좌표 j의 추정을 만든다.

$$\hat{g}_j^{\mathrm{SPSA}} = \frac{\widehat{R}(\theta + c\Delta) - \widehat{R}(\theta - c\Delta)}{2c\Delta_j}.$$

매끄러운 무잡음 함수를 Taylor 전개하면 선두항은 $\sum_k \partial_k R\,\Delta_k/\Delta_j$다. 독립 대칭 부호의 평균에서 $k \neq j$항은 사라져 참 좌표 미분이 남고, 일반적으로 $O(c^2)$ 편향이 따른다. 한 번의 추정에는 다른 좌표의 기여가 섞인다. 평가 잡음의 분산이 각각 σ^2이면 독립 차분의 분산 기여는 $\sigma^2/(2c^2)$다. 작은 c는 근사 편향을 줄이지만 잡음을 증폭한다. 함수 평가가 두 개라는 사실이 차원에 무관한 수렴 시간이나 정확한 전체 기울기를 보장하지 않는다. Spall의 원 논문을 보충 읽기로 삼는다.

자연 기울기는 다른 문제를 다룬다. 같은 각도 변화가 상태 공간에서 서로 다른 거리를 만들 때, 순수 상태 ψ_θ의 Fubini-Study 계량 g를 사용한다.

$$g_{ij} = \mathrm{Re}[\langle \partial_i\psi|\partial_j\psi\rangle - \langle\partial_i\psi|\psi\rangle\langle\psi|\partial_j\psi\rangle], \quad \Delta\theta = -\eta(g + \lambda I)^{-1}\nabla\widehat{R}.$$

여기서 $\lambda > 0$는 역행렬 안정화 계수다. 회전 하나의 상태에서는 $g_{\theta\theta} = 1/4$이므로 정규화를 무시하면 보통 기울기보다 네 배 큰 좌표 이동이다. 이는 계량의 convention에 의존하며 보편적인 네 배 속도 향상이 아니다. 중복 매개변수는 같은 상태 방향을 가리켜 계량을 특이하게 만들 수 있다. 계량 측정, 샷 잡음, 역행렬 계산이 추가되며 혼합 상태에는 적절한 다른 기하 정의가 필요하다. Stokes 등의 논문은 block-diagonal 근사를 제안한다.

연습문제와 풀이

문제 1. $f(\theta) = \cos\theta$와 $\ell = (f-1)^2$에서 $\theta = \pi/2$의 손실 기울기를 구하라. **힌트:** 출력 미분 뒤에 바깥 제곱의 미분을 곱한다.

풀이. $f = 0$, $f' = -1$이므로 $\ell' = 2(0-1)(-1) = 2$다. 양의 학습률로 각도를 줄이면 $\cos\theta$가 증가해 목표 1에 가까워진다. 출력 미분 -1을 그대로 손실 기울기로 쓰면 갱신 방향을 반대로 고르게 된다.

문제 2. $R_y(\theta)R_y(\theta)$에서 $\theta = \pi/8$의 참 미분과 잘못된 일괄 이동 결과를 구하라. **힌트:** 먼저 $f = \cos 2\theta$로 합친다.

풀이. 참 미분은 $-2\sin(\pi/4) = -\sqrt{2}$다. 일괄 이동은 $\cos(\pi/4 + \pi)$와 $\cos(\pi/4 - \pi)$의 차이여서 0이다. 두 게이트 각도를 분리한 각 편미분은 $-\sqrt{2}/2$이고 합이 참값을 회복한다.

문제 3. 참 출력 기울기 크기 0.02를 표준편차 상한 0.01로 추정하려면 이동 회로당 샷이 최소 얼마인가? **힌트:** 위 분산 상한을 부등식으로 푼다.

풀이. $1/(2S) \le 10^{-4}$이므로 $S \ge 5{,}000$이다. 두 이동 회로에 합계 1만샷이 필요하다. 이는 표준편차에 대한 보수적 설계이며 부호 오류가 전혀 없다는 확률 보장은 아니다. 구체적 신뢰도를 요구하면 별도 꼬리확률 조건을 정해야 한다.

문제 4. SPSA의 섭동 크기를 절반으로 줄이면 평가 잡음 분산 기여와 매끄러운 함수의 선도 편향은 어떻게 변하는가? **힌트:** 각각 c^{-2}, c^2에 의존한다.

풀이. 독립 평가 잡음의 분산이 일정하다면 기울기 분산 기여는 네 배가 된다. $O(c^2)$ 편향의 선도항 크기는 약 1/4이 된다. 따라서 더 작은 이동이 항상 더 좋은 추정은 아니다. 실제 최적값은 함수의 고차 미분과 샷 예산에 달려 있으며 학습률 일정도 함께 조정해야 한다.

학습 완료 점검

- 이동 규칙을 외우지 않고 $a + b\cos\theta + c\sin\theta$에서 재구성한다. 생성자의 조건과 한 게이트 출현 조건까지 말하면 통과다. 실패하면 유도 1과 수학 준비로 돌아간다.
- 샷 증가, 배치 증가, 자연 기울기의 효과를 각각 구별한다. 표본 잡음·데이터 잡음·좌표 기하를 분리하고 추가 비용을 말하면 통과다. 실패하면 유도 2부터 다시 읽는다.

- 공유 각도 반례를 숫자 없이 설명하고 게이트별 미분의 합으로 고친다. 이 답이 되어야 09강의 작은 기울기 문제로 진행한다.

원문 읽기

- Schuld et al., Evaluating analytic gradients on quantum hardware, PRA 2019: 먼저 초록을 읽고 두 번 실행이 충분한 조건을 적는다. 본 노트의 Pauli 생성자 증명과 일반 생성자 논의를 구별한다. 공개 초록과 출판 정보를 재확인했으며 전체 논문 증명을 검증했다고 주장하지 않는다.
- Stokes et al., Quantum Natural Gradient, Quantum 2020: 계량과 block-diagonal 근사의 목적을 확인한다. 상태 거리의 정규화 convention을 비교하는 것이 읽기 과제다. 초록의 방법 설명을 확인했으며 최적화 성능을 재현하지 않았다.
- Spall, Multivariate stochastic approximation…, IEEE TAC 1992: SPSA의 원 출처다. 이 강의의 Taylor 계산은 독립 교육 유도이며 원 논문의 수렴 정리 전체를 대신하지 않는다.

08. 양자 커널, SVM과 학습에 유용한 기하

> 공개 실라버스에서 출발해 독립 집필한 80분 자율학습 노트다. 원강의 자료를 복원하지 않았다. 근거 기준일: 2026-10-20. 손계산 예제는 QPU 실험이나 양자 이점의 증거가 아니다.

이전: 07. 미분과 훈련 · 전체 강의 · 다음: 09. 학습 가능성과 barren plateaus

학습의 출발점과 도달점

04강의 상태 인코딩, 행렬의 고유값, 벡터 내적과 이진 분류를 알고 시작한다. 양의 준정부호가 낯설면 수학 준비를 먼저 읽는다. 목표는 fidelity 커널을 밀도행렬 특징의 선형 내적으로 쓰고 PSD를 증명하는 것, SVM의 쌍대 목적함수를 유도하는 것, finite-shot 행렬의 교정과 시험 비용을 계산하는 것이다. 마지막에는 projected kernel의 정보 손실을 반례로 설명할 수 있어야 한다.

커널 방법에서는 두 데이터의 유사도를 먼저 계산하고 그 유사도를 이용해 고전 최적화를 수행한다. 양자 회로가 등장하는 위치는 보통 특징의 생성과 내적의 추정이다. 최적화가 고전적이라는 사실이 양자 커널의 의미를 없애지는 않지만, 학습이 유용하려면 회로가 만드는 기하가 정답의 구조와 맞아야 한다. 상태 공간이 크다는 이유만으로 가까워야 할 데이터가 가까워지지는 않는다.

80분 학습 순서

시간	실제 수행할 활동
0-5분	내적의 선형성과 PSD의 정의를 적는다.
5-15분	핵심 용어를 읽고 특징 공간, Gram 행렬, 분류 점수를 연결한다.
15-40분	PSD 증명과 SVM 쌍대 유도를 한 줄씩 재현한다.
40-55분	두 점 분류와 비PSD 행렬 교정 예제를 계산한다.
55-70분	문제 1-2개를 선택해 풀고 힌트와 해설의 핵심을 대조한다.
70-75분	원문 읽기에서 고정 인코딩이라는 전제를 찾아 적는다.
75-80분	학습 완료 점검에서 커널의 정확성·유용성·비용을 구별한다.

80분은 핵심 유도와 선택 문제 1-2개를 다루는 학습 시간이다. 나머지 문제의 독립 풀이, 모든 해설과의 대조, 유도 재작성에는 강의 후 60-90분을 따로 배정한다. 원문 읽기 5분은 지정된 조건을 찾는 안내 독해이며 논문 전문 독해 시간은 포함하지 않는다.

핵심 용어

한국어·영어	뜻과 구별할 대상
특징 사상, feature map	입력을 학습에 사용할 벡터나 연산자로 보내는 함수.

한국어·영어	뜻과 구별할 대상
커널, kernel	특징 벡터의 내적을 입력 두 개의 함수로 표현한 것.
Gram 행렬, Gram matrix	훈련점 사이 커널 값으로 만든 행렬.
양의 준정부호, positive semidefinite·PSD	모든 벡터의 이차형식이 음수가 아닌 에르미트 행렬의 성질.
재생핵 Hilbert 공간, RKHS	커널 평가가 내적으로 표현되는 함수 공간.
충실도 커널, fidelity kernel	여기서는 순수 상태 겹침 절댓값의 제곱.
Hilbert-Schmidt 내적	연산자 두 개에 대한 trace 내적. 혼합 상태 fidelity와 구별한다.
마진, margin	결정 경계와 데이터 사이의 부호 있는 여유.
지지 벡터, support vector	최적 쌍대 계수가 0이 아니어서 결정함수에 기여하는 훈련점.
슬랙 변수, slack variable	마진 제약 위반을 허용하고 벌점을 부과하기 위한 변수.
투영 커널, projected kernel	선택한 관측 특징이나 축소 상태를 통해 정의한 커널.
PSD 투영, PSD projection	음의 고유값을 제거하는 등의 방식으로 PSD 행렬을 만드는 후처리.

용어의 한국어 표기는 문헌에 따라 다르다. 영문명과 수학적 정의를 함께 기억하고 통합 용어집으로 교차 확인한다.

유도 1: 양자 상태는 커널의 선형 특징이 된다

입력 x를 n큐비트 순수 상태 $|\phi(x)\rangle = U_\phi(x)|0^n\rangle$로 보낸다. 대응하는 밀도행렬은 $\rho(x) = |\phi(x)\rangle\langle\phi(x)|$다. 다음 커널의 특징 벡터는 상태벡터 자체보다 밀도행렬로 잡는 편이 정확하다.

$$k(x, x') = |\langle\phi(x)|\phi(x')\rangle|^2 = \mathrm{Tr}[\rho(x)\rho(x')].$$

에르미트 행렬 공간에 내적 $\langle A, B\rangle_{\mathrm{HS}} = \mathrm{Tr}(AB)$를 주면 $\rho(x)$는 실수 Hilbert 공간의 한 벡터처럼 작동한다. 차원 $d = 2^n$에서 밀도행렬을 성분으로 펼치면 선형 특징 공간 차원은 최대 d^2이다. 실제 데이터가 차지하는 부분공간은 훨씬 작을 수 있다.

훈련점 $x_1, \ldots, x_N$에 대해 $K_{ij} = k(x_i, x_j)$라 하자. 임의의 실수 계수 벡터 c에 대해 $A = \sum_i c_i \rho(x_i)$는 에르미트이므로 고유값 a_r가 실수다.

$$c^{\mathsf{T}} K c = \mathrm{Tr}(A^2) = \sum_r a_r^2 \geq 0.$$

이것이 PSD의 직접 증명이다. 복소 계수의 경우에는 $c^\dagger K c = \mathrm{Tr}(A^\dagger A)$로 쓰면 된다. 혼합 밀도행렬에도 이 선형 커널은 성립한다. 다만 대각값 $\mathrm{Tr}(\rho^2)$는 purity이므로 일반적으로 1이 아니다. Uhlmann fidelity의 정의와도 구별한다.

RKHS 관점에서는 함수 $f_A(x) = \langle A, \rho(x)\rangle_{\mathrm{HS}}$를 생각한다. 커널 절편 $k(x, \cdot)$과 함수의 내적이 $f_A(x)$를 재생하도록 함수 공간의 내적을 잡는다. 동일한 함수를 나타내는 A가 여럿이면 데이터 특징의 span에 직교하는 부분은 버리고 최소 노름 표현을 택한다. 이런 정규화 아래 representer theorem은 경험 손실과 노름 벌점을 최적화하는 해를 훈련점의 커널 절편 선형결합으로 찾게 한다. 고정 특징 사상의 전체 함수 공간과 특정 변분 ansatz가 실제로 도달하는 관측량 집합은 다를 수 있다. Schuld의 커널 해석은 이 연결을 설명한다.

유도 2: SVM의 볼록성이 어디에서 오는가

라벨 $y_i \in \{-1, +1\}$, 특징 벡터 $\Phi_i = \rho(x_i)$, 가중치 w, 절편 b, 슬랙 $\xi_i \geq 0$, 벌점 $C > 0$를 둔다. soft-margin SVM의 원 문제는

$$\min_{w,b,\xi} \ \frac{1}{2}\|w\|^2 + C\sum_i \xi_i, \qquad y_i(\langle w, \Phi_i\rangle + b) \geq 1 - \xi_i.$$

마진 제약에 승수 $\alpha_i \geq 0$, 슬랙 비음수 제약에 $\beta_i \geq 0$를 붙인다. Lagrangian을 w, b, ξ로 미분하여 0으로 두면 각각 $w = \sum_i \alpha_i y_i \Phi_i$, $\sum_i \alpha_i y_i = 0$, $C - \alpha_i - \beta_i = 0$이다. 따라서 $0 \leq \alpha_i \leq C$이고 대입하면

$$\max_{\alpha} \ \sum_i \alpha_i - \frac{1}{2}\sum_{ij} \alpha_i \alpha_j y_i y_j K_{ij}, \qquad \sum_i \alpha_i y_i = 0.$$

목적함수 Hessian은 $-YKY$이며 $Y = \mathrm{diag}(y_1, \ldots, y_N)$다. K가 PSD이면 YKY도 PSD이므로 쌍대 목적함수는 오목하다. 볼록한 실현 가능 영역에서 전역 최적해를 구할 수 있다는 뜻이다. 데이터 인코딩을 고르는 바깥 최적화나 일반화까지 볼록하다는 뜻은 아니다. PSD가 특이하면 최적 계수의 유일성도 자동으로 보장되지 않는다.

새 입력의 결정 점수는 $s(x) = \sum_i \alpha_i y_i k(x_i, x) + b$이고 예측은 부호다. $0 < \alpha_i < C$인 지지 벡터에서는 상보성으로 마진 등식이 성립하여 $b = y_i - \sum_j \alpha_j y_j K_{ji}$를 계산한다. 경계에 있는 계수만 남는 경우 절편은 KKT 조건에 맞는 구간 등으로 처리한다. 이 계산까지 알아야 라이브러리가 반환한 계수와 예측을 연결할 수 있다.

완성 예제: 한 큐비트로 두 점을 분류한다

$R_y(x)|0\rangle$ 인코딩에서는 반각 내적을 제곱하여 $k(x, x') = \cos^2((x - x')/2)$를 얻는다. 훈련점 $x_1 = 0, x_2 = \pi$, 라벨 $y_1 = +1, y_2 = -1$이면 $K = I_2$다. 등식 제약 때문에 $\alpha_1 = \alpha_2 = a$, 쌍대 목적은 $2a - a^2$이다. 미분 $2 - 2a = 0$에서 $a = 1$이고 $C \geq 1$이면 이 값이 허용된다. 대칭성으로 $b = 0$을 택하면

$$s(x) = k(0, x) - k(\pi, x) = \cos^2(x/2) - \sin^2(x/2) = \cos x.$$

$x = \pi/3$은 점수 1/2로 양성이고 $x = \pi/2$는 점수 0인 경계다. $0 < C < 1$이면 최적 계수는 $a = C$이고 점수의 크기가 줄어든다. 대칭 조건에서 경계의 위치가 같아도 마진과 정규화는 달라진다. 이 예는 완전한 고전 삼각함수 계산으로 풀리므로 양자 속도 향상을 보여주지 않는다.

유도 3과 반례: 샷 추정과 PSD 교정

역회로 $U_\phi(x')^\dagger U_\phi(x)$ 뒤의 모두 0인 확률이 이상적으로 커널 값이다. 각 원소를 독립 Bernoulli 샷 S개로 추정하면 $\mathrm{Var}(\widehat{k}) = k(1-k)/S \leq 1/(4S)$다. 2,500샷의 표준편차 상한은 0.01이다. 행렬 전체가 동시에 정확하다는 조건은 더 강하다. 독립 샷의 Hoeffding 부등식과 union bound를 쓰면, 추정 원소 수 M, 허용 오차 ϵ, 실패확률 δ에 대해 충분조건은

$$S \geq \frac{\log(2M/\delta)}{2\epsilon^2}.$$

대칭성을 이용하면 비대각 쌍은 $M = N(N-1)/2$개다. 고정 회로라도 모든 쌍을 직접 구축하는 비용은 대략 $N^2 S$이고 새 시험점마다 지지 벡터 수만큼 추가 커널 평가가 필요하다. 역회로 잡음은 샷 변동과 별도의 편향이다. Havlíček 등의 실제 장치 시연과 이 교육용 비용식의 실행 수준을 구분한다.

유한 샷에서 행렬을 대칭화해도 PSD가 복구되지는 않는다. 예를 들어 대각 1, 모든 비대각 $r = -0.6$인 3차 행렬의 고유값은 $1 + 2r = -0.2$와 $1 - r = 1.6$ 두 개다. 이는 음의 커널 값을 허용하는 일반 내적 커널의 교육 예다. fidelity 추정만으로는 음의 원소가 나오지 않지만 비PSD 문제 자체는 양의 원소에서도 생길 수 있다. 예를 들어 대각 1,

$K_{12} = K_{13} = 0.9, K_{23} = 0.1$인 대칭 행렬의 행렬식은 -0.468이다.

첫 예에서 고유분해 후 음의 고유값을 0으로 자르면 교정 행렬은 원 행렬에 $0.2\,\mathbf{1}\mathbf{1}^{\mathsf{T}}/3$을 더한 것이다. 대각은 약 1.0667, 비대각은 약 -0.5333이 된다. 대각 1을 다시 원하면 대각 크기로 정규화해야 하며 비대각은 -0.5가 된다. 가장 가까운 PSD 행렬과 대각까지 고정한 가장 가까운 상관행렬은 서로 다른 최적화 문제다. 교정은 측정된 정보를 바꾸므로 교정 전후 성능을 함께 평가하고 시험 정답으로 교정 방법을 고르지 않는다.

투영 특징은 무엇을 보존하고 버리는가

전체 상태 대신 한 큐비트 축소 상태 $\rho_a(x)$를 사용하고 폭 $\gamma > 0$로 다음 커널을 만들 수 있다.

$$k_{\mathrm{proj}}(x, x') = \exp\left[-\gamma \sum_{a} \|\rho_a(x) - \rho_a(x')\|_F^2\right].$$

축소 상태의 Pauli 좌표를 실수 벡터로 모으면 이 식은 그 벡터에 대한 Gaussian 커널이므로 PSD다. $\|\cdot\|_F$는 Frobenius 노름이다. 낮은 차수의 특징을 읽으면 측정과 inductive bias가 달라지지만, 필요한 전역 상관을 버릴 수 있다. Bell 상태 $|\Phi^+\rangle$와 $|\Phi^-\rangle$는 직교하여 전체 fidelity가 0이지만 모든 한 큐비트 축소 상태가 $I/2$로 같다. 따라서 위 projected kernel은 두 상태 사이에도 1이다. 이 특징으로 둘의 위상 라벨을 분류할 수 없다.

Huang 등의 Power of data는 데이터와 커널 기하의 관계를 다룬다. Thanasilp 등의 집중 연구는 특정 인코딩·측정·잡음 조건에서 입력 간 커널 차이가 매우 작아질 수 있음을 분석한다. 커널이 계산하기 어렵다는 성질과 정답을 학습하기 좋은 성질을 각각 검사해야 한다. 전부 다른 상태가 거의 직교하면 훈련 행렬은 단위행렬에 가까워 기억은 쉬워도 새로운 점과 연결할 정보가 적어질 수 있다.

연습문제와 풀이

문제 1. 혼합 상태 두 개의 Hilbert-Schmidt 커널은 왜 PSD이며 대각은 무엇인가? **힌트:** 순수성 대신 에르미트성만 사용한 부분을 찾는다.

풀이. $A = \sum_i c_i \rho_i$가 에르미트이므로 $c^{\mathsf{T}} K c = \mathrm{Tr}(A^2) \geq 0$다. 순수 상태 가정은 필요 없다. 대각은 $\mathrm{Tr}(\rho_i^2)$이며 maximally mixed 상태 I/d에서는 $1/d$이다. 따라서 대각을 강제로 1로 바꾸는 것은 원래 커널을 그대로 측정하는 절차가 아니다.

문제 2. 두 점 예제에서 $C = 1/2$와 $x = \pi/3$의 점수를 구하라. **힌트:** 목적 $2a - a^2$의 최적값을 허용 구간에 제한한다.

풀이. 무제약 최대는 1이지만 $a \leq 1/2$이므로 $a = 1/2$다. 대칭 절편 0에서 $s = (1/2)\cos(\pi/3) = 1/4$이다. 부호는 양성이지만 이전 $C \geq 1$의 점수 1/2보다 작다. 점수 크기를 확률로 직접 해석하지 않는다.

문제 3. 100개 훈련점의 모든 비대각 쌍을 각각 2,500샷으로 평가하면 몇 샷인가? **힌트:** 순서가 다른 동일 쌍을 두 번 세지 않는다.

풀이. 쌍 수는 $100 \cdot 99/2 = 4{,}950$, 총 샷은 12,375,000이다. 순수 상태 대각은 이상적으로 1이라 별도 추정을 생략한 계산이다. calibration, 반복 seed, validation, 시험 커널은 포함하지 않았으므로 전체 프로젝트 비용은 더 커진다.

문제 4. Bell 두 상태를 한 큐비트 projected kernel로 분류하지 못하는 이유를 설명하고 가능한 수정을 제안하라. **힌트:** 차이를 보이는 두 큐비트 관측량을 찾는다.

풀이. 모든 한 큐비트 상태가 같아 특징과 커널 행이 동일해진다. $X \otimes X$ 기대값은 Φ^+에서 +1, Φ^-에서 −1이므로 이 상관을 특징에 추가하면 구별할 수 있다. 관측량을 늘릴 때의 측정 비용과 해당 특징을 알고 있다는 사전정보도 평가에 포함해야 한다.

학습 완료 점검

- PSD 증명과 SVM Hessian의 부호를 연결한다. 두 식을 직접 쓰고 고정 커널의 조건을 말하면 통과다. 실패하면 유도 1·2와 수학 준비를 복습한다.
- 확률 추정 한 번의 오차와 전체 행렬 정확도의 차이를 설명한다. 쌍 개수와 union bound가 등장하면 통과다. 실패하면 유도 3을 다시 읽는다.
- projected kernel의 장점과 Bell 반례를 함께 설명한다. 정보 보존과 고전 계산 난이도를 별도로 물을 수 있어야 09강으로 진행한다.

원문 읽기

- Schuld, Supervised quantum machine learning models are kernel methods, 2021: 초록의 커널 재표현을 읽고 인코딩 고정과 함수 공간 비교의 조건을 적는다. 공개 초록과 수정 이력을 재확인했으며 전체 정리를 재증명한 것은 아니다.
- Havlíček et al., Nature 2019: 실제 QPU 시연의 과제와 범위를 확인할 자료다. 본 강의의 한 큐비트 예제는 그 실험의 재현이 아니다.
- Huang et al., Nature Communications 2021: projected kernel과 데이터의 역할을 읽는다. 기존 노트의 본문 대조를 유지했으며 이번 개정에서는 출판사 접근 제한으로 전문을 다시 확인하지 못했다.
- Thanasilp et al., Exponential concentration in quantum kernel methods, 2024: 공개 초록에서 네 집중 원인과 조건부 결론을 확인했다. 각각을 모든 양자 커널의 불가능성으로 확대하지 않는 것이 독해 과제다.

09. 학습 가능한 회로와 barren plateau의 조건

> 공개 실라버스에서 출발해 독립 집필한 80분 자율학습 노트다. 원강의 설명을 복원하지 않았다. 근거 기준일: 2026-10-20. 독립 교육 유도와 문헌의 조건부 정리를 구별하며 QPU 실험은 수행하지 않았다.

이전: 08. 커널과 SVM · 전체 강의 · 다음: 10. 일반화와 벤치마킹

학습의 출발점과 도달점

07강의 회로 미분과 샷 분산을 이해하고 확률변수의 평균·분산을 복습한다. 필요한 적분은 수학 준비를 참고한다. 이 강의의 목표는 영 기울기 하나와 크기 증가에 따른 기울기 집중을 구별하고, 독립 회전 회로의 전역·국소 비용 분산을 직접 유도하며, 관측된 평평한 훈련 곡선을 진단하는 것이다. 또한 최근의 plateau 회피와 고전 모사 가능성 논의가 어떤 출력과 회로 분포를 대상으로 하는지 읽을 수 있어야 한다.

표현력은 어떤 함수를 회로가 담을 수 있는지 묻는다. 학습 가능성은 제한된 시간과 측정으로 그 함수의 매개변수를 찾을 수 있는지 묻는다. 학습하기 좋은 점이 하나 있다는 사실과 무작위 초기화가 그 점 근처에 도달할 확률도 다르다. 이 세 질문을 구분하지 않으면 회로를 깊게 만들고 훈련이 멈춘 이유를 모두 양자 잡음 탓으로 돌리기 쉽다.

80분 학습 순서

시간	실제 수행할 활동
0-5분	평균 0과 분산 0의 차이를 간단한 확률변수로 설명한다.
5-15분	핵심 용어를 읽고 초기화 분포와 샷 분포를 서로 다른 색으로 표시한다.
15-40분	곱 회로의 두 미분과 분산을 적분으로 유도한다.
40-55분	두 비용의 크기 의존성을 계산하고 GHZ 반례로 국소 정보의 손실을 확인한다.
55-70분	문제 1-2개를 선택해 풀고 틀린 가정을 해설과 대조한다.
70-75분	원문 읽기의 최신 결과에서 평균·정밀도·관측량 조건을 찾는다.
75-80분	출구 점검으로 진단 순서와 회피 방법의 한계를 설명한다.

80분은 핵심 유도와 선택 문제 1-2개를 다루는 학습 시간이다. 나머지 문제의 독립 풀이, 모든 해설과의 대조, 유도 재작성에는 강의 후 60-90분을 따로 배정한다. 원문 읽기 5분은 지정된 조건을 찾는 안내 독해이며 논문 전문 독해 시간은 포함하지 않는다.

핵심 용어

한국어·영어	이 강의에서의 정의
불모 고원, barren plateau	지정된 회로·초기화 분포에서 관련 기울기가 시스템 크기에 따라 지수적으로 집중하는 현상.
초기화 앙상블, initialization ensemble	초기 매개변수나 회로를 뽑는 확률분포.
집중 현상, concentration	확률변수가 작은 범위에 모이는 현상. 무엇을 무작위로 뽑는지 명시해야 한다.
전역 비용, global cost	많은 큐비트에 걸친 연산자나 전체 상태 정보를 사용하는 목적함수.
국소 비용, local cost	적은 수의 큐비트에 작용하는 항들의 합으로 정의한 목적함수.
유니터리 2-design	유니터리 원소와 그 켤레의 2차 모멘트가 Haar 분포와 일치하는 앙상블.
Haar 분포, Haar measure	유니터리 군의 좌우 곱 변환에 불변인 균일 분포.
빛원뿔, causal light cone	특정 게이트가 특정 출력 관측량에 영향을 줄 수 있는 회로 영역.
유니탈 채널, unital channel	항등연산자를 그대로 두는 양자 채널.
비유니탈 채널, non-unital channel	항등연산자를 그대로 두지 않는 양자 채널.
대리 모형, surrogate model	원 회로의 손실이나 예측을 대신 근사하는 고전 모델.
신호 대 잡음비, signal-to-noise ratio	추정하려는 신호 크기와 통계 변동 크기의 상대 비율.

기술 용어를 쓸 때에는 통합 용어집의 정의와 함께 어떤 확률공간을 사용하는지 말한다. 여기서는 같은 기울기에 대해서도 초기화 분산과 측정 분산이라는 두 다른 분산을 다룬다.

유도 1: 분산 감소가 대부분의 초기값을 묶는다

큐비트 수 n, 비용 $C(\theta)$, 좌표 기울기 $g_j = \partial_j C$를 두자. 매개변수 θ를 정해진 초기화 분포에서 뽑는다. 어떤 회로 계열에서 양수 상수 A, $b > 1$에 대해

$$\mathbb{E}_\theta[g_j] = 0, \qquad \mathrm{Var}_\theta(g_j) \le A b^{-n}$$

이면, Chebyshev 부등식에 의해 고정된 $\epsilon > 0$에 대한 확률은

$$\Pr_\theta(|g_j| \ge \epsilon) \le \frac{A b^{-n}}{\epsilon^2}.$$

우변이 작을수록 대부분의 초기값에서 절댓값 기울기가 작다. 그러나 이것은 모든 점의 기울기가 0이라는 진술이 아니다. 평균이 0이라는 사실만으로도 부족하다. 예를 들어 $g = \pm 1$이 같은 확률이면 평균 0이지만 분산은 1이다. 반대로 어떤 최소점 한 곳의 미분이 0인 것은 평범한 정상점의 성질이다. 크기 n을 바꾸어 앙상블 분산을 관찰해야 plateau라는 용어의 의미가 생긴다.

McClean 등의 2018년 연구는 충분히 무작위화된 회로의 상황을 분석한다. 2-design이라는 조건은 복잡한 전체 확률분포를 모두 Haar와 같게 만드는 조건보다 약하지만, 기울기의 2차 모멘트 계산에는 강한 역할을 한다. 얕은 임의 회로를 자동으로 global 2-design이라고 할 수 없고, 초기값 분포를 좁히면 같은 증명을 그대로 사용할 수 없다. 정리를 읽을 때는 회로의 왼쪽·오른쪽 부분 중 어느 부분이 얼마나 무작위화되는지 표시한다.

유도 2: 얽힘 없이도 전역 비용의 기울기가 줄어든다

독립 회전만 있는 상태 $|\psi_\theta\rangle = \bigotimes_{j=1}^{n} R_y(\theta_j)|0\rangle$를 사용한다. 초기 각도 θ_j는 서로 독립이며 $[0, 2\pi]$에서 균일하다. 각 큐비트가 0일 확률을 $q_j = \cos^2(\theta_j/2)$, 투영 연산자를 $P_j = |0\rangle\langle 0|_j$라 두자. 목표가 전부 0인 상태에 가까워지는 것이라면

$$C_G = 1 - \prod_{j=1}^{n} q_j, \qquad C_L = 1 - \frac{1}{n}\sum_{j=1}^{n} q_j$$

라는 두 비용을 생각할 수 있다. 아래첨자 G, L은 각각 전역과 국소다. $dq_1/d\theta_1 = -(\sin\theta_1)/2$이므로

$$\partial_1 C_G = \frac{1}{2}\sin\theta_1 \prod_{j=2}^{n} q_j, \qquad \partial_1 C_L = \frac{\sin\theta_1}{2n}.$$

각도 한 바퀴의 사인 평균은 0이므로 두 미분의 평균은 0이다. 이제 제곱 평균이 분산이 된다. 적분에서 $\mathbb{E}[\sin^2\theta] = 1/2$이다. 또 $\cos^4 u = (3 + 4\cos 2u + \cos 4u)/8$이고 여기서 $u = \theta/2$이므로 $\mathbb{E}[q^2] = 3/8$이다. 초기 각도의 독립성으로 곱의 평균을 평균의 곱으로 바꾼다.

$$\mathrm{Var}(\partial_1 C_G) = \frac{1}{4}\cdot\frac{1}{2}\left(\frac{3}{8}\right)^{n-1} = \frac{1}{8}\left(\frac{3}{8}\right)^{n-1}, \qquad \mathrm{Var}(\partial_1 C_L) = \frac{1}{8n^2}.$$

이는 논문 수치를 가져온 것이 아니라 완전히 지정된 단순 모델의 독립 계산이다. 전역 비용의 곱 구조가 다른 큐비트들의 작은 확률을 모두 곱해 신호를 억제한다. 얽힘이나 깊은 회로가 전혀 없어도 지수 감소가 가능하다. 국소 비용에서는 좌표당 $1/n$ 정규화만 남아 다항 감소한다. 비용 이름을 바꾸는 일이 실제 측정 난이도를 바꿀 수 있는 이유다.

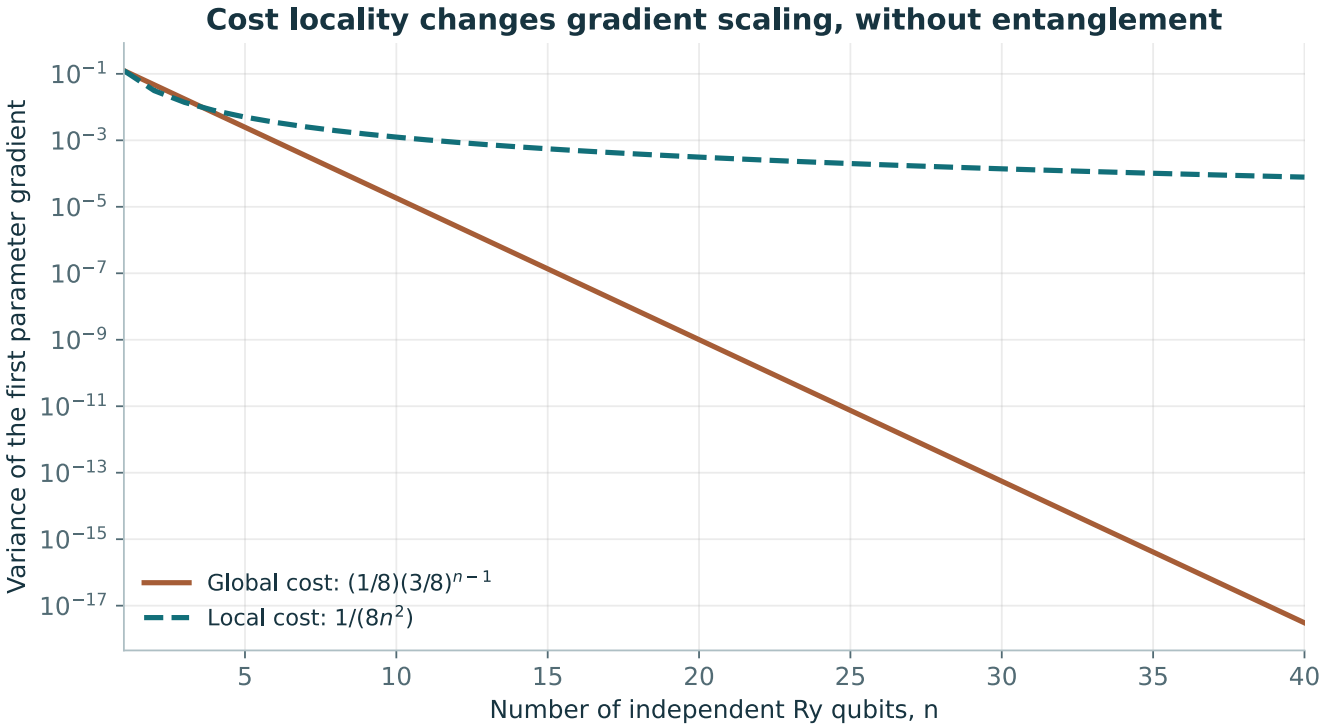


그림 9-1. 위 두 식의 해석값을 큐비트 1-40개에 대해 그렸다. 세로축은 로그다. 균일 독립 각도와 지정한 비용의 교육용 예이며, 일반 QNN의 분산이나 논문의 실제 측정값을 나타내지 않는다.

예제와 반례: 국소 비용으로 바꾸면 충분한가

$n = 10$이면 전역 분산은 약 1.83×10^{-5}, 국소 분산은 0.00125다. 전역의 초기 기울기 표준편차는 약 0.00428이다. 07강의 독립 이동 측정 상한 $1/\sqrt{2S}$를 이 크기 이하로 만들려면 이동 회로당 약 27,300샷이라는 보수적 값이 나온다. 실제 관측량의 분산과 매개변수 위치에 따라 필요한 값은 달라진다. 이 계산은 두 확률공간의 역할을 연결하는 예이며 모든 측정 방식의 하한은 아니다.

이 특별한 목표에서는 $C_L = 0$이면 모든 $q_j = 1$이므로 전역 목표 상태를 얻는다. 그러나 목표가 GHZ 상태의 상대 위상이라면 사정이 다르다. $|\mathrm{GHZ}_{\pm}\rangle = (|0^n\rangle \pm |1^n\rangle)/\sqrt{2}$는 서로 직교하지만 모든 적절한 부분계의 축소 밀도행렬이 같다. 한 큐비트 관측만으로 만든 비용은 두 위상을 구분하지 못한다. 따라서 기울기가 큰 국소 비용이라도 원하는 문제의 정답 정보를 보존하는지 확인해야 한다. 비용을 바꾼 뒤 같은 과제를 풀었다고 말하려면 그 연결을 증명하거나 시험해야 한다.

Cerezo 등의 비용 의존성 연구는 지정된 국소 2-design 구조에서 깊이와 관측량 범위를 함께 다룬다. 국소 관측량의 light cone이 작으면 그 기대값이 참조하는 회로 영역도 작아질 수 있다. 깊이가 커져 cone이 전체 시스템으로 퍼지면 같은 보호 논리가 유지되지 않는다. 얕은 회로의 plateau 회피가 깊은 회로 전체에 관한 정리로 변하지 않는 이유다.

유도 3: 깊이 방향 잡음 수축과 크기 방향 집중을 분리한다

교육용으로 한 큐비트 유니터리 사이에 depolarizing 채널 $\mathcal{D}_p(\rho) = (1-p)\rho + pI/2$를 L번 넣자. $0 \le p \le 1$이고 I는 항등행렬이다. Bloch 벡터가 매번 $1-p$배로 수축하고 이 채널은 유니터리와 교환하므로 traceless 관측량의 기대값과 그 각도 미분은 이상값의 $(1-p)^L$배다. 분산은 $(1-p)^{2L}$배다. 이로써 큐비트 수를 늘리지 않아도 깊이가 증가하면 신호가 사라질 수 있음을 보인다.

다큐비트 회로에서는 관측량의 Pauli 성분, 잡음의 작용 범위, light cone이 함께 들어간다. 위 한 큐비트 등식을 모든 국소 채널의 다큐비트 식으로 바꾸어서는 안 된다. Wang 등의 noise-induced plateau 논문은 국소 Pauli 잡음과 깊이에 관한 조건을 분석한다. 진단에서는 고정 n의 깊이 증가와 고정 깊이의 n 증가를 따로 그린다.

2026년 Mele 등의 논문은 국소 비유니터리 잡음과 무작위 게이트 앙상블을 다룬다. 비유니탈 잡음에서는 마지막 층 부근의 국소 기울기가 남을 수 있지만, 앞쪽 층의 영향은 약해져 기대값 계산에 대한 유효 깊이가 얕아진다. 고정 가산 정밀도의 기대값을 전형적 회로에서 고전적으로 추정하는 결과와 함께 읽어야 한다. 이는 모든 회로, 모든 정밀도, 전체 출력 sampling의 용이성을 증명하는 진술이 아니다.

2025년 perspective는 분석한 plateau 회피 계열 가운데 손실 계산이 작은 부분공간에 머무는 경우를 논한다. 일부 대리 모형은 먼저 양자 데이터를 수집해야 하므로 순수한 무자료 고전 계산과도 구별한다. 읽을 때에는 학습 가능성, 손실의 고전 모사, 유용한 정답, 계산 우위라는 네 질문을 따로 적는다. 어느 하나의 긍정 답이 나머지를 자동으로 해결하지 않는다.

실제 자율학습 진단 활동

종이에 세로축을 기울기 제곱 평균, 가로축을 큐비트 수로 하는 표를 만든다. 위 곱 회로의 $n = 2, 4, 8, 16$ 해석값을 넣고 로그 축에서 비교한다. 심화 실습에서는 초기각을 여러 번 뽑아 표본분산을 계산하고 해석값과 대조한다. seed 수가 작으면 희귀한 큰 기울기의 기여를 놓칠 수 있으므로 반복 수와 오차를 기록한다. 이 단계는 CPU 계산만으로 가능하다.

실제 훈련이 멈추면 먼저 정확한 기대값에서도 멈추는지 본다. 아니면 샷 분해능이나 장치 편향을 의심한다. 정확한 계산에서도 멈추면 학습률, 라벨 연결, 고전 출력 포화, 대칭에 의한 영 미분, ansatz의 표현 부족을 점검한다. 그다음 초기화 분포와 크기를 바꾸어 기울기 분산을 조사한다. 물리적 초기화, 층별 훈련, 국소 목적, 대칭 보존은 검토할 수 있지만 어떤 정보와 가설 공간을 바꾸는지 함께 기록한다. plateau가 없다는 것은 빠른 전역 최적화나 우수한 일반화의 충분조건이 아니다.

연습문제와 풀이

문제 1. 평균 0인 기울기에서 분산이 2^{-n}이면 $|g| \geq 0.1$의 확률 상한은? **힌트:** Chebyshev 식의 분모를 제곱한다.

풀이. 상한은 $100 \cdot 2^{-n}$이며 확률이므로 1과의 최솟값으로 제한한다. $n = 20$이면 약 9.54×10^{-5}다. 이는 평균 0과 지정 분산의 가정 아래 상한이며 실제 확률과 같다는 뜻은 아니다.

문제 2. 곱 회로에서 큐비트 하나를 추가할 때 두 분산의 비율을 구하라. **힌트:** 각각 $n+1$식과 n식의 몫을 계산한다.

풀이. 전역은 $3/8$, 국소는 $n^2/(n+1)^2$다. 전역은 매번 같은 비율로 줄고 국소는 비율이 점점 1에 접근한다. 따라서 고정된 작은 범위의 데이터만 보고 두 scaling을 판정하지 말아야 한다.

문제 3. 각도를 독립적으로 뽑지 않고 모두 같은 무작위 각도로 초기화하면 위 전역 분산 유도가 유지되는가? **힌트:** 곱의 평균을 분리한 줄을 찾는다.

풀이. 유지되지 않는다. $\sin^2\theta\,\cos^{4(n-1)}(\theta/2)$의 하나의 적분을 계산해야 하며 서로 독립인 평균들의 곱으로 나눌 수 없다. 기울기의 형태는 같아도 초기화 분포가 달라지면 분산 결론을 다시 유도해야 한다.

문제 4. 깊은 잡음 회로의 마지막 층 기울기가 크면 무엇을 추가로 확인해야 하는가? **힌트:** 오래된 입력 정보와 출력 접근 방식을 나눈다.

풀이. 앞쪽 층과 입력 정보가 출력에 남아 있는지, 목표 라벨에 관련된 정보인지, 필요한 정밀도의 기대값이 고전적으로도 계산 가능한지 확인한다. 그 뒤 sampling이나 전체 상태 복원이 실제 과제인지 구별한다. 국소 마지막 층의 한 미분이 크다는 관찰만으로 깊은 양자 처리의 유용성이나 우위는 결론 낼 수 없다.

학습 완료 점검

- 두 분산 식을 적분과 독립성으로 재구성한다. $3/8$이 나온 이유까지 설명하면 통과다. 실패하면 유도 2와 수학 준비를 복습한다.
- 평평한 훈련 곡선에 대해 적어도 세 대안을 먼저 검사한다. 단일 정상점과 크기별 앙상블 분산을 구별하면 통과다. 실패하면 진단 활동을 다시 읽는다.

- 국소 목적과 잡음이 기울기를 남겨도 과제와 우위가 남는지 따로 묻는다. GHZ 반례와 2026년 결과의 평균 조건을 함께 말할 수 있어야 10강으로 진행한다.

원문 읽기

- McClean et al., 2018: 공개 초록·출판 정보를 확인했다. 무작위화 조건과 확률적 결론을 표시하는 것이 과제이며, 전체 증명을 독립 검증하지 않았다.
- Cerezo et al., 2021: 국소·전역 비용과 얕은 회로의 관계를 읽는다. 위 곱 회로의 독립 유도와 원 논문의 일반 정리를 구별한다.
- Wang et al., 2021: 잡음 모형과 깊이 가정을 확인할 원 출처다. 기존 노트의 초록 대조 범위를 유지한다.
- Cerezo et al., perspective 2025: 공개 초록과 주장 범위를 재확인했다. 모든 plateau-free 모델의 모사 가능성 정리로 읽지 않는다.
- Mele et al., Nature Physics 2026, 공개본: 공개 초록과 출판사 검색 본문의 평균·정밀도 조건을 대조했다. 논문 전체 증명이나 QPU 실험을 재현한 것은 아니다.

10. 일반화, 통계와 공정한 양자 학습 벤치마크

> 공개 실라버스에서 출발해 독립 집필한 80분 자율학습 노트다. 원강의 평가 지침을 복원하지 않았다. 근거 기준일: 2026-10-20.
> 아래 비교 숫자는 교육용 가상 데이터이며 실제 QML 성능 결과가 아니다.

이전: 09. 학습 가능성 · 전체 강의 · 다음: 11. 하드웨어와 자원

학습의 출발점과 도달점

01강의 학습 과제 정의, 07강의 손실과 측정 잡음, 표본 평균·분산을 알고 시작한다. 확률과 신뢰구간은 수학 준비로 보충한다. 목표는 일반화 차이와 시험 오차를 구별하고, 학습된 모델에 고정 모델의 확률부등식을 잘못 적용하지 않으며, 같은 시험 예제의 paired 비교를 계산하는 것이다. 끝에는 정보 누출 없는 실험 계획을 직접 작성할 수 있어야 한다.

훈련 데이터를 잘 맞히는 모델이 새 입력을 잘 예측한다는 보장은 없다. 양자 회로가 고전적으로 모사하기 어려워도 정답 라벨을 예측하는 과제는 고전 학습기가 쉽게 풀 수 있다. 따라서 모델의 양자성, 통계 성능, 전체 실행 자원을 따로 기록해야 비교 결과를 해석할 수 있다. 정확도 한 숫자의 소수점보다 어떤 데이터와 선택 절차에서 나온 숫자인지가 먼저다.

80분 학습 순서

시간	실제 수행할 활동
0-5분	훈련집합과 시험집합의 역할을 각각 한 문장으로 적는다.
5-15분	핵심 용어를 읽고 데이터·seed·샷의 세 무작위성을 나눈다.
15-40분	고정 모델의 위험 추정, uniform bound, paired 분산을 유도한다.
40-55분	80%와 84%의 비교를 두 discordance 표로 계산한다.
55-70분	문제 1-2개를 선택해 풀고 자기 프로젝트의 split 설계를 점검한다.
70-75분	원문 읽기에서 일반화 정리의 가정과 벤치마크의 실행 수준을 찾는다.
75-80분	출구 점검으로 결과 해석문을 작성한다.

80분은 핵심 유도와 선택 문제 1-2개를 다루는 학습 시간이다. 나머지 문제의 독립 풀이, 모든 해설과의 대조, 유도 재작성에는 강의 후 60-90분을 따로 배정한다. 원문 읽기 5분은 지정된 조건을 찾는 안내 독해이며 논문 전문 독해 시간은 포함하지 않는다.

핵심 용어

한국어·영어	의미
모집단 위험, population risk	목표 데이터 분포에서의 평균 손실.
경험 위험, empirical risk	주어진 표본에서 계산한 평균 손실.

한국어·영어	의미
일반화 차이, generalization gap	모집단 위험에서 훈련 경험 위험을 뺀 값.
독립 동일 분포, i.i.d.	표본들이 서로 독립이고 같은 확률분포에서 나온다는 가정.
검증집합, validation set	모델·학습률·중단 시점 등을 고르는 데이터.
시험집합, test set	고정한 최종 절차를 평가하는 미사용 데이터.
정보 누출, data leakage	평가 시 알 수 없어야 할 정보가 훈련이나 선택에 들어가는 현상.
신뢰구간, confidence interval	반복 표본추출에서 정해진 비율로 참 모수를 덮도록 설계한 구간.
효과 크기, effect size	비교하고자 하는 성능 차이의 양.
대응 비교, paired comparison	같은 예제나 실험 단위에서 얻은 두 결과의 차이를 분석하는 방법.
제거 실험, ablation	특정 구성 요소를 바꾸거나 빼서 기여를 확인하는 비교.
중첩 교차검증, nested cross-validation	안쪽 모델 선택과 바깥 성능 평가를 분리한 교차검증.

신뢰구간을 계산한 뒤 해당 구간에 참값이 들어갈 확률이 95%라고 단순히 해석하지 않는다. 빈도주의 구간의 95%는 절차의 반복 포괄률이다. 필요한 영어 용어는 통합 용어집에서 다시 찾는다.

유도 1: 위험의 정의와 고정 모델의 확률 보장

입력·정답 쌍 $z = (x, y)$의 목표 분포를 P, 훈련집합을 $S = (z_1, \dots, z_N)$, 손실을 $\ell(\theta; z)$라 하자. 기본 정의는

$$R(\theta) = \mathbb{E}_{z\sim P}[\ell(\theta; z)], \qquad \widehat{R}_S(\theta) = \frac{1}{N}\sum_i \ell(\theta; z_i), \qquad \mathrm{gen}_S(\theta) = R(\theta) - \widehat{R}_S(\theta).$$

이 강의의 기본 보장은 같은 분포에서의 새 예제를 대상으로 한다. 미래의 분포가 바뀌거나 한 환자의 여러 측정이 train과 test로 나뉘면 독립 동일 분포 가정이 깨질 수 있다. 그런 과제에서는 환자·시간·분자 계열 같은 실제 독립 단위로 분리하고 목표 분포를 다시 명시한다.

먼저 S를 보기 전에 고정한 θ와 유계 손실 $0 \le \ell \le 1$을 생각한다. 독립 표본 평균에 Hoeffding 부등식을 적용하면

$$\Pr_S\{|R(\theta) - \widehat{R}_S(\theta)| > \epsilon\} \le 2e^{-2N\epsilon^2}.$$

이 확률은 훈련 표본을 다시 뽑는 실험에 대한 것이다. 데이터로 선택한 $\hat{\theta}(S)$를 아무 설명 없이 고정 θ 자리에 대입하면 논리적 공백이 생긴다. 선택 가능한 모델이 미리 고정된 유한 집합 $\mathcal{H}$이고 크기가 H라면 union bound로 모든 모델에 동시에 적용한다.

$$\Pr_S\left\{\sup_{\theta\in\mathcal{H}}|R - \widehat{R}_S| > \epsilon\right\} \le 2He^{-2N\epsilon^2}, \quad \epsilon = \sqrt{\frac{\log(2H/\delta)}{2N}}.$$

실패확률 δ 이내에서 모든 후보의 차이를 함께 제한하므로 데이터가 어느 후보를 골라도 해당 보장이 남는다. 연속 매개변수 회로에는 이 유한 집합 논리를 그대로 적용하지 않고 covering number, 안정성, 함수 복잡도 같은 도구가 필요하다. 이 계산의 목적은 양자 모델의 정확한 상한을 만드는 것이 아니라 선택을 고려해야 한다는 통계 원리를 배우는 것이다.

적은 데이터의 정리가 실제로 제한하는 것

Caro 등의 2022년 논문은 학습 가능한 국소 채널을 사용하는 지정된 QML 모델의 일반화 차이를 다룬다. 독립 학습 채널 수를 T, 채널의 최대 재사용 횟수를 M, 훈련 예제 수를 N이라 할 때, 논문의 유계 손실·채널·고정 구조·표본 조건 아래 핵심 scaling을 요약하면

$$|\mathrm{gen}_S(\hat{\theta})| = \tilde{\mathcal{O}}\left(\sqrt{T/N}\right)$$

이다. 물결표는 로그와 신뢰도 항 등을 생략했다는 뜻이다. $MT \geq 2$인 공유 설정에서는 $\sqrt{T\log(MT)/N}$ 형태가 나타난다. 이것은 참 오차가 그 값과 같다는 예측식도, 훈련이 작은 손실에 도달한다는 보장도 아니다. 상수·관측량·채널 조건을 버린 채 실험의 필요한 데이터 수를 산출해서는 안 된다.

예를 들어 훈련 오류 0.40에 일반화 차이 0.01이면 참 오류는 0.41이다. 작은 gap은 좋은 정확도와 동의어가 아니다. 반대로 훈련 오류가 매우 작은데 시험 오류가 크면 과적합, 분포 차이, 누출 없는 선택 여부를 점검한다. 양자 데이터에서는 라벨된 상태 한 개, 독립 상태 copy, 측정 shot의 단위도 분리한다. 같은 상태를 1만번 준비해 측정해도 새로운 독립 라벨 예제를 1만개 얻은 것은 아니다.

유도 2와 예제: 단일 정확도의 불확실성

최종 모델과 측정 프로토콜을 고정하고 독립 시험 예제 $n_{\mathrm{test}} = 100$개에서 80개를 맞혔다고 하자. 맞음 지시변수 $A_i \in \{0,1\}$는 평균 정확도 p와 분산 $p(1-p)$를 갖는다. 독립 평균의 분산은 이를 표본 수로 나눈 값이다. p를 관측 비율로 대체하면

$$\widehat{p} = 0.80, \quad \widehat{\mathrm{SE}} = \sqrt{\frac{0.80 \cdot 0.20}{100}} = 0.04, \quad \widehat{p} \pm 1.96\widehat{\mathrm{SE}} \approx [0.722, 0.878].$$

이는 정규 근사 구간이다. 표본이 작거나 정확도가 경계에 가까우면 부정확할 수 있다. Wilson 구간은 이항 모수에 대한 score 부등식을 풀어 얻으며, $z = 1.96$, $n = n_{\mathrm{test}}$로 쓰면

$$\frac{\widehat{p} + z^2/(2n) \;\pm\; z\sqrt{\widehat{p}(1-\widehat{p})/n + z^2/(4n^2)}}{1 + z^2/n}.$$

위 숫자에서는 약 $[0.711, 0.867]$이다. 구간 방법을 결과를 보고 유리한 쪽으로 고르지 말고 사전에 정한다. 모델이 샷 수 때문에 무작위 예측을 한다면 어떤 샷 예산과 집계 규칙의 정확도를 평가하는지 명시한다. 여러 측정을 모은 majority vote의 정확도는 단일 샷 정확도와 다른 대상이다.

유도 3과 반례: 80% 대 84%는 같은 숫자로 끝나지 않는다

모델 A가 80%, B가 84%라 하자. 독립 시험집합을 썼다면 독립성 가정 아래 차이의 표준오차는 $\sqrt{0.8 \cdot 0.2/100 + 0.84 \cdot 0.16/100} \approx 0.054$다. 같은 시험집합이라면 독립 분산을 더하는 대신 예제별 차이 $D_i = B_i - A_i$를 사용한다. B만 정답인 개수를 b, A만 정답인 개수를 c라 두면

$$\widehat{\Delta} = \overline{D} = \frac{b-c}{n}, \qquad \widehat{\mathrm{SE}}_{\mathrm{paired}} \approx \sqrt{\frac{(b+c)/n - \widehat{\Delta}^2}{n}}.$$

이는 경험적 이차 모멘트를 넣은 큰 표본 근사다. 불편 표본분산을 쓰면 작은 표본 보정도 들어간다. 차이 0.04가 같아도 $b+c$, 즉 두 모델이 서로 다르게 맞힌 예제 수에 따라 불확실성이 달라진다.

가상 비교	둘 다 정답	B만 정답 b	A만 정답 c	둘 다 오답
경우 1	80	4	0	16
경우 2	72	12	8	8

경우 1의 paired 표준오차는 약 0.0196, 경우 2는 약 0.0445다. 첫 경우조차 불일치 표본이 네 개뿐이다. 같은 정확도라는 귀무가설의 McNemar exact 비교에서는 불일치 네 개의 방향이 대칭 이항분포를 따른다는 가정하에 양측 p값이 $2(1/2)^4 = 0.125$이다. 작은 불일치 수에서 정규 근사를 기계적으로 적용하면 과신할 수 있음을 보여준다. p값은 우위가 참일 확률이 아니며, 실용적으로 필요한 효과 크기도 별도로 정해야 한다.

셀프 스터디용 실험 설계

먼저 평가 단위를 적고 데이터를 train, validation, test로 분리한다. 표준화·PCA·특징 선택의 매개변수는 train에서만 맞춘다. validation에서 회로 깊이, 인코딩, 학습률, 중단 규칙, PSD 교정 방법을 고정한다. test를 열고 결과가 마음에 들지 않아 다시 설계하면 그 test는 다음부터 validation 역할을 한 것으로 취급하고 새로운 최종 평가가 필요하다. 작은 데이터에서는 nested 교차검증으로 선택과 평가를 분리할 수 있다.

고전 기준선에는 logistic regression, RBF SVM, 적절한 신경망처럼 과제에 맞는 모델을 넣고 각자 적절한 튜닝 예산을 준다. 매개변수 수만 같게 맞추면 공정해지는 것이 아니다. 입력 정보, 전처리, 정규화, 총 검색 횟수, 실행 장비와 시간 예산을 함께 기록한다. 얽힘 제거, 고정 무작위 특징, 고전 Fourier 특징 등의 ablation은 이득을 만든 구조를 확인하는 데 유용하다.

Bowles 등의 2024년 연구는 고전 시뮬레이션으로 12개 양자 모델과 6종 이진 과제에서 만든 160개 데이터셋을 비교했다. 그 설정에서는 기본 고전 기준선이 전반적으로 더 강했고 얽힘을 제거해도 좋은 경우가 있었다. 이는 모든 QML의 불가능성 정리가 아니라 작은 학습 과제의 설계가 결론을 크게 바꾼다는 사례다. 본 노트는 해당 실험을 재실행하지 않았다.

동일 데이터 split을 공유한 여러 seed는 독립 모집단 표본이 아니다. seed 간 변동은 최적화 안정성을 알려주지만 시험집합의 대표성을 늘려주지 않는다. 샷 반복은 측정 변동을 보여주고, 다른 split은 데이터 변동을 보여준다. 각 수준을 섞어 표준오차를 인위적으로 줄이지 않는다. 불균형 데이터에서는 balanced accuracy와 precision-recall, calibration을 함께 검토한다. 시간·샷·에너지 측정은 11강으로 연결한다.

연습문제와 풀이

문제 1. 훈련 오류 0.40, 일반화 차이 0.01인 모델의 참 오류를 구하고 품질을 판정하라. **힌트:** 차이의 정의부터 쓴다.

풀이. $R = \widehat{R} + \mathrm{gen} = 0.41$이다. gap이 작아도 오류 자체는 41%다. 과제의 라벨 비율과 기준선에 따라 유용성을 판단해야 하며 gap만 보고 좋은 모델이라 할 수 없다.

문제 2. 로그를 무시한 $\sqrt{T/N}$ 상한에서 채널 수가 네 배면 같은 수준을 유지하는 표본 수는? **힌트:** 비율 T/N을 고정한다.

풀이. N도 네 배다. 이는 상한의 선도 scaling을 유지하는 계산이며 실제 필요한 예제 수를 정확히 예측하지 않는다. 재사용 횟수나 구조까지 바뀌면 생략한 조건도 다시 확인해야 한다.

문제 3. PCA를 전체 데이터에 맞춘 뒤 train/test를 나누면 정답을 사용하지 않았으니 괜찮은가? **힌트:** 평가 입력 분포에 관한 정보도 누출이다.

풀이. 일반적인 새 입력 평가에서는 적절하지 않다. 시험 입력의 공분산과 방향을 미리 사용해 전처리를 선택했기 때문이다. 먼저 split을 고정하고 train에서 PCA를 맞춘 뒤 동일 변환을 validation/test에 적용한다. 전체 비라벨 입력을 미리 허용하는 transductive 과제라면 그 접근 조건을 명시하고 양쪽 모델에 동일하게 제공해야 한다.

문제 4. B가 A보다 네 개 더 맞혔다는 정보만으로 paired 검정을 계산할 수 있는가? **힌트:** 차이와 불일치 합을 구분한다.

풀이. 없다. $b - c = 4$는 알지만 $b + c$를 모른다. 위 두 표는 같은 정확도 차이지만 다른 paired 분산을 만든다. 예제별 두 예측을 보존해야 하고, 불일치가 적으면 exact 방법을 사용한다. 가장 좋은 seed만 골랐다면 선택 편향도 별도로 해결해야 한다.

학습 완료 점검

- 고정 모델의 bound를 학습된 모델에 그대로 대입할 수 없는 이유를 설명한다. 데이터 의존성과 동시 보장을 언급하면 통과다. 실패하면 유도 1과 수학 준비를 복습한다.
- 같은 80%·84%라도 두 paired 결과가 다를 수 있음을 표로 재현한다. 불일치 방향과 합을 구별하면 통과다. 실패하면 유도 3으로 돌아간다.
- train·validation·test, seed·샷·split 각각의 역할을 적는다. 모든 선택이 시험 전 고정되고 전체 비용이 보고되면 11강으로 진행한다.

원문 읽기

- Caro et al., Generalization in quantum machine learning from few training data, 2022: Theorem 2의 채널 수·재사용·확률 조건을 읽는다. 기존 노트의 본문 대조를 유지했으며 이번 개정에서는 출판사 접근 제한으로 전문을 재확인하지 못했다. 정리 전체를 독립 재증명하지 않았다.
- Bowles, Ahmed, Schuld, Better than classical?, 2024: 공개 초록에서 12개 모델·160개 데이터셋·고전 시뮬레이션 범위를 재확인했다. 결과를 보편적 불가능성으로 확대하지 않는 것이 독해 과제다.
- Huang et al., Power of data in quantum machine learning, 2021: 계산하기 어려운 양자 함수와 데이터로 배우기 어려운 함수의 차이를 읽는다. 기존 본문 대조를 유지하며 여기서 실험 재현을 보고하지 않는다.

11. 하드웨어, 컴파일과 전체 학습 자원 계산

> 공개 실라버스에서 출발해 독립 집필한 80분 자율학습 노트다. 원강의 장치 설명을 복원하지 않았다. 근거 기준일: 2026-10-20. 모든 수치 예제는 가상 비용 계산이며 특정 제품 사양이나 실제 QPU 벤치마크가 아니다.

이전: 10. 일반화와 벤치마킹 · 전체 강의 · 다음: 12. 잡음과 오류 완화

학습의 출발점과 도달점

03강의 게이트와 회로, 07강의 이동 미분, 10강의 공정한 비교를 선수 지식으로 삼는다. 단위와 지수 계산은 수학 준비를 참고한다. 목표는 원 실라버스의 여덟 하드웨어 범주를 물리 원리와 제어 방식으로 구별하고, 추상 회로를 실행 회로로 바꿀 때의 자원을 세며, 훈련 전체 샷·시간·메모리·에너지의 계산 경계를 설명하는 것이다.

큐비트 수는 중요한 사양이지만 모델의 실행 가능성을 혼자 결정하지 않는다. 상태 준비, native gate, 연결성, 초기화·판독, 고전 제어와 calibration이 함께 작동해야 한다. 논문 그림의 회로를 계산했다고 곧 실제 장치에 같은 비용으로 올릴 수 있는 것도 아니다. 이 강의에서는 특정 업체 순위를 외우는 대신 어떤 물리적 조건이 내 회로 비용을 바꾸는지 배우게 된다.

80분 학습 순서

시간	실제 수행할 활동
0-5분	물리 큐비트·논리 큐비트·시뮬레이터 인덱스를 구별한다.
5-15분	용어와 여덟 범주 표를 읽고 상태·제어·측정을 연결한다.
15-40분	라우팅, 샷 수, 메모리 계산을 직접 유도한다.
40-55분	가상 훈련 시간과 에너지를 계산하고 CPU/GPU/TPU/QPU 역할을 배정한다.
55-70분	문제 1-2개를 선택해 풀고 자기 프로젝트 자원 장부의 항목을 정한다.
70-75분	원문 읽기에서 metric에 포함된 고전 처리 범위를 찾는다.
75-80분	출구 점검으로 실행 수준과 비용 경계를 설명한다.

80분은 핵심 유도와 선택 문제 1-2개를 다루는 학습 시간이다. 나머지 문제의 독립 풀이, 모든 해설과의 대조, 유도 재작성에는 강의 후 60-90분을 따로 배정한다. 원문 읽기 5분은 지정된 조건을 찾는 안내 독해이며 논문 전문 독해 시간은 포함하지 않는다.

핵심 용어

한국어·영어	정의
물리 큐비트, physical qubit	실제 물리 계에서 조작하는 양자 정보 단위.

한국어·영어	정의
논리 큐비트, logical qubit	오류정정 코드의 보호된 부분공간에 저장하는 정보 단위.
모달리티, qubit modality	큐비트를 구현하는 물리 계와 제어 방식의 종류.
고유 게이트, native gate	장치가 직접 제공하는 기본 연산.
연결성, connectivity	직접 상호작용을 실행할 수 있는 큐비트 관계.
배치·라우팅, placement and routing	논리 큐비트를 물리 위치에 대응시키고 이동 연산을 정하는 과정.
회로 깊이, circuit depth	정한 병렬 실행 규칙 아래 필요한 순차 연산 층 수.
처리량, throughput	단위 시간에 완료하는 샷·회로·층 등의 수. 단위가 필요하다.
지연시간, latency	하나의 요청부터 결과 수신까지의 시간.
보정, calibration	제어·판독 모형과 매개변수를 측정해 맞추는 절차.
전력, power	에너지 사용률. 와트는 초당 줄이다.
에너지, energy	일정 시간 동안 사용한 전력의 적분. kWh로 보고할 수 있다.

통합 용어집과 함께 영어 명칭을 기억한다. 특히 샷/초와 게이트/초, 컴파일 시간과 큐 대기시간은 다른 단위와 대상을 측정한다.

원 실라버스의 여덟 범주를 물리적으로 구별한다

원강좌 Hardware 1 공개 개요에는 superconducting, trapped-ion, photonic, neutral-atom, silicon-spin, NV-center, topological, emerging가 나온다. 마지막 emerging는 단일 구현 방식이 아니라 새로운 접근을 묶은 범주다. 아래 표는 그 목록을 설명하기 위한 독립 교육 비교이며 최신 장치 성능 순위가 아니다.

범주	정보를 담고 제어하는 방식	QML 회로에서 확인할 질문
초전도, superconducting	Josephson 비선형성을 가진 회로의 에너지 준위를 쓰고 전기적 펄스로 제어한다.	연결 그래프에 맞춘 2큐비트 게이트·주파수 충돌·판독과 초기화 비용은?
포획 이온, trapped-ion	전기장에 잡은 이온의 내부 준위를 쓰며 빛이나 마이크로파와 집단 운동 등을 제어에 이용한다.	사용 가능한 상호작용·운동 모드·동시 게이트·이온 이동 조건은?
광자, photonic	경로·편광·시간 모드 등으로 정보를 담고 광학 소자와 광검출을 이용한다.	광원·손실·검출·feed-forward·조건부 성공 확률을 포함했는가?
중성원자, neutral-atom	광학적으로 가둔 원자의 내부 상태를 쓰며 Rydberg 여기 등의 상호작용을 이용한다.	원자 배치·이동·손실·상호작용 범위가 회로에 어떤 제약을 주는가?
실리콘 스핀, silicon-spin	실리콘의 양자점이나 불순물에 있는 전자·핵 스핀을 쓰고 전기·자기적 제어를 결합한다.	교환 상호작용·주소 지정·제어 배선·판독이 어떤 원시 연산을 주는가?
NV 센터, NV-center	다이아몬드 질소-공공 결함의 전자 스핀과 주변 핵 스핀 등을 쓰며 광학 접근을 결합한다.	국소 레지스터 내부 연산과 원격 광학 연결 비용을 구별했는가?

범주	정보를 담고 제어하는 방식	QML 회로에서 확인할 질문
위상적 접근, topological	비국소적 부호화와 비가환 애니온의 braiding·fusion 등으로 보호된 연산을 만들려는 접근이다.	원하는 위상적 자유도·연산·판독이 실제로 입증된 범위는 어디까지인가?
새로운 접근, emerging	예를 들어 조화진동자 모드에 정보를 부호화하는 bosonic 방식처럼 다른 저장·보호 전략을 포괄한다.	새 범주의 물리 계와 코드, 제공 연산을 구체적으로 정의했는가?

위상적 접근의 이론적 보호 원리는 이상적인 모형의 조건에 의존한다. 제안된 큐비트가 곧 임의 QML을 실행할 검증된 범용 장치라는 뜻은 아니다. bosonic 부호화는 초전도 공진기나 다른 플랫폼에서도 구현할 수 있으므로 위 범주들은 완전히 배타적인 분류가 아니다. 물리 계, 정보 부호화, 계산 모델이라는 서로 다른 축을 섞지 않아야 한다. 디지털 게이트 모델과 analog Hamiltonian 진화, annealing 역시 같은 API를 가진 장치라고 가정할 수 없다.

원리의 출발점은 Nakamura의 초전도 실험, Cirac-Zoller의 이온 제안, KLM의 광자 제안, Jaksch의 원자 게이트, 실리콘 양자점 실험, Jelezko의 NV 스핀 실험, Kitaev의 애니온 모형, Ofek의 bosonic 부호화 실험이다. 역사적 원 논문은 작동 원리 자료이며 2026년 제품 사양의 근거가 아니다.

CPU·GPU·TPU·QPU의 역할은 어떻게 나뉘는가

CPU는 데이터 전처리, 분할, 컴파일, 작업 제출, 최적화 제어와 결과 집계에 적합한 범용 처리 장치다. GPU는 다수의 산술 연산을 병렬 수행하여 고전 신경망, 큰 배치 선형대수, 상태벡터 시뮬레이션 등에 쓰인다. TPU는 행렬·텐서 연산에 맞춘 고전 가속기 계열이다. Jouppi 등의 TPU 논문은 이런 설계의 원 출처이며 과거 세대의 구체적 성능비를 현재 장치에 옮기지 않는다.

QPU는 준비된 상태에 물리 연산을 적용하고 측정 표본을 반환하는 역할을 맡는다. 고전 데이터 파일 전체를 그대로 양자 중첩으로 무료 적재하는 메모리가 아니다. 하이브리드 QML에서는 CPU가 회로 매개변수를 전송하고 QPU 표본을 받아 손실과 다음 갱신을 계산한다. GPU·TPU가 주변 고전 신경망을 담당할 수도 있다. 큐비트 수를 GPU 메모리 크기나 FLOPS와 직접 환산하는 공통 공식은 없다. 동일한 문제·출력 오차·총 시간·에너지에서 비교해야 한다.

유도 1: 추상 게이트와 실행 게이트를 구분한다

선형 연결 $0-1-2$에서 CNOT을 native gate로 가정하자. 먼 큐비트 0에서 2로 CNOT을 수행하려고 0과 1을 SWAP한 뒤 인접 CNOT을 실행하고 원위치로 되돌린다. SWAP 하나를 CNOT 세 개로 분해하면 2큐비트 연산 수 G_{2q}는

$$G_{2q} = 3 + 1 + 3 = 7$$

이다. 이는 간단한 구현 예이며 최적 컴파일의 하한이 아니다. 출력의 물리 위치를 다시 대응시키거나 이웃 게이트와 합치면 비용을 줄일 수 있다. native 연산이 CZ나 다른 상호작용이면 분해도 달라진다. 따라서 폭, 깊이, 2큐비트 수, 측정 설정, 배치 seed를 컴파일 전후에 기록한다.

독립 확률 오류만 있는 교육 모형에서 게이트 g의 오류율을 p_g라 하면 모든 게이트가 오류 없이 끝날 확률은 $\prod_g (1-p_g)$다. 모두 같은 작은 p이고 게이트 수가 G이면 로그를 전개해

$$\log p_{\text{no error}} = G\log(1-p) \approx -Gp, \qquad p_{\text{no error}} \approx e^{-Gp}.$$

실제 coherent 오류·상관 오류·측정량에 영향을 주지 않는 오류까지 이 식으로 설명할 수는 없다. gate fidelity를 곱한 숫자를 분류 정확도로 읽으면 안 된다. 이 식은 작은 오류라도 연산을 많이 쓰면 누적될 수 있다는 비용 감각을 위한 것이다.

유도 2와 완성 예제: 훈련 한 번의 샷과 시간

한 갱신에서 미분할 게이트 출현 수를 P, 배치 예제 수를 B, 동시에 측정할 수 없는 관측량 그룹 수를 G_m, 그룹당 샷을 S라 하자. 각 출현의 두 항 이동 미분을 독립 평가하고 재사용이 없으면

$$N_{\text{shots}}^{\text{grad}} = 2PBG_mS.$$

공유 매개변수가 여러 게이트에 있으면 P는 독립 학습 변수 수와 다를 수 있다. forward 손실, 계량 추정, validation, 검색 실패, 오류 완화는 위 식 밖의 비용이다. 제출을 묶어 통신을 줄여도 총 샷이 자동으로 줄어드는 것은 아니다.

가상 조건 $P = 12, B = 20, G_m = 3, S = 1{,}000$에서는 144만샷이다. 실효 처리량을 가상의 초당 2,000샷으로 두면 720초, 즉 12분이다. 100회 갱신은 순수 샷 처리만 20시간이다. 표준오차를 절반으로 줄이려면 독립 샷을 네 배로 늘려 같은 조건에서 갱신당 576만샷이 된다. validation이나 재시작을 추가하면 프로젝트 총비용을 다시 합해야 한다.

전체 경과 시간은 적어도 준비·컴파일·큐 대기·실행·고전 처리·calibration으로 나눠 기록한다. 병렬 실행이 있으면 단순 합과 실제 wall-clock이 다르므로 중첩 구간도 적는다. 훈련 후 예측 요청 하나의 지연시간과 많은 예측을 묶은 처리량은 또 다르다. Wack 등의 CLOPS 연구는 고전·양자 처리를 함께 고려하는 속도 평가를 제안한다.

유도 3과 반례: 시뮬레이터 메모리는 무엇을 뜻하는가

n큐비트 상태벡터에는 2^n개 복소 진폭이 있고 complex128 하나는 16바이트다. 작업 배열을 제외한 원시 저장량은

$$M_{\text{statevector}} = 16 \cdot 2^n \text{ bytes}.$$

따라서 30큐비트는 2^{34}바이트인 16GiB, 40큐비트는 2^{44}바이트인 16TiB다. 밀도행렬을 그대로 저장하면 4^n개의 복소 성분이 필요하다. CPU와 GPU 어느 쪽이든 이 배열 표현을 쓰면 저장해야 할 성분 수는 같다. 분산 장치, 통신, 임시 버퍼는 추가 비용이다.

이 메모리는 모든 고전 계산법의 하한이 아니다. Clifford 회로는 stabilizer 표현으로, 낮은 얽힘은 tensor network로, 작은 출력 light cone은 제한된 부분 계산으로 다룰 수 있다. 예를 들어 독립 회전 n개로 만든 곱 상태는 두 성분짜리 상태 n개만 저장하면 되며 전체 2^n 배열이 필요 없다. 따라서 큰 상태벡터를 직접 못 저장한다는 사실로 같은 예측 과제가 고전적으로 불가능하다고 결론 내리지 않는다.

에너지 장부와 벤치마크의 해석

전력 $P(t)$를 시간에 적분하면 에너지 $E = \int P(t)dt$다. QPU 비교의 경계에는 냉각, 레이저, 진공, 전자 제어, 고전 호스트, 통신을 어디까지 포함하는지 적는다. 공유 시설의 상시 전력은 작업당 배분 규칙과 가동률에 따라 달라진다. 칩에 전달한 펄스 에너지와 시설 전체 전력은 같은 지표가 아니다. 큐 대기 중 모든 시설 전력을 한 작업에 돌리는 방식 역시 별도의 배분 가정이다.

교육용 시설 평균 전력을 25kW, 실행을 12분으로 두면 $E = 25 \times (12/60) = 5$kWh다. 호스트만 0.5kW라면 같은 시간 0.1kWh다. 경계를 다르게 잡은 이 둘을 양자 대 고전 에너지 우위로 비교하면 안 된다. 서로 같은 목표 오차와 작업을 달성한 전체 경계를 맞춰야 한다. 에너지를 측정할 수 없다면 측정값이라고 쓰지 않고 가정한 전력·시간의 추정 범위를 보고한다.

Quantum volume은 정해진 무작위 회로 품질을 보는 지표이며 특정 QML 정확도를 보장하지 않는다. application benchmark에는 실제 과제와 가까운 회로·오차·시간을 함께 둔다. 2026년 CLOPS 하드웨어 고려 지표 프리프린트는 물리 층과 품질 조건을 연결한 속도 정의를 제안한다. 기존 CLOPS 숫자와 프로토콜 확인 없이 직접 비교하지 않는다. 처리량 제안 자체가 QML 학습 우위의 실험 결과도 아니다.

연습문제와 풀이

문제 1. 가상 훈련에서 P가 두 배, S가 네 배면 갱신당 샷은? **힌트:** 독립 비용 인자를 곱한다.

풀이. $2 \times 4 = 8$배로 1,152만샷이다. 같은 실효 처리량에서는 96분이다. 처리량이나 회로 길이가 바뀌면 시간 비례도 다시 확인한다. 각도를 공유하더라도 게이트 출현별 미분이 필요한 상황에서는 변수 수만으로 P를 줄일 수 없다.

문제 2. 상태벡터 큐비트가 세 개 늘 때 메모리와 밀도행렬 메모리는 각각 몇 배인가? **힌트:** 2^n과 4^n을 비교한다.

풀이. 각각 8배와 64배다. 이는 지정 배열 표현에 관한 결과다. 곱 상태나 Clifford 구조를 이용하는 다른 표현의 비용까지 같은 배수라고 주장하지 않는다.

문제 3. 1시간 20kW를 쓰는 공유 시설에서 두 작업이 절반씩 동일하게 점유했다면 작업당 에너지는? **힌트:** 배분 규칙이 문제에 주어져 있다.

풀이. 총 20kWh이며 동일 점유로 배분하면 각 10kWh다. 실제 시설에서는 상시·증분 전력과 가동률이 다르므로 이 규칙을 그대로 적용할 수 있다고 가정하지 않는다. 전력계 경계와 배분 기준을 보고해야 결과를 재계산할 수 있다.

문제 4. 컴파일한 1만 논리 게이트와 QPU에서 실행한 1만 물리 게이트를 동등한 실행 증거로 비교할 수 있는가? **힌트:** 연산 단위와 관측된 결과를 나눈다.

풀이. 비교할 수 없다. 전자는 논리 연산 변환·자원 평가이고 후자는 잡음 있는 물리 실행이다. 내결함성 논리 실행이라면 코드 거리, 물리 큐비트, syndrome·디코딩·보조 상태 준비가 추가된다. 동일 목표 알고리즘에 대해 해당 비용과 결과 오차를 맞춘 뒤 비교한다.

학습 완료 점검

- 여덟 범주에서 저장·제어 원리를 설명하고 emerging가 열린 범주임을 말한다. 업체 이름 없이 설명하면 통과다. 실패하면 모달리티 표와 용어집을 복습한다.
- 144만샷·12분·16GiB를 단위까지 다시 계산한다. 무엇을 제외한 수치인지 말하면 통과다. 실패하면 유도 2·3으로 돌아간다.
- 에너지 비교의 시설 경계와 목표 품질을 정의한다. 컴파일·시뮬레이션·물리 QPU·논리 추정을 구분해야 12강으로 진행한다.

원문 읽기

- 원강좌 Hardware 1: 공개 목록의 여덟 범주와 CPU·GPU·TPU·QPU, 에너지 주제를 재확인했다. 세부 설명은 본 노트의 독립 보충이다.
- Nakamura et al., 1999, Cirac-Zoller, 1995, Jaksch et al., 2000, Loss-DiVincenzo, 1998, Kitaev, 2003: 제목·초록 또는 출판 정보를 확인한 원 연구다. 실험·제안·이론 모형의 차이를 표시하는 선택 읽기이며 전문 검증을 보고하지 않는다.
- KLM의 광자 계산 제안, Ofek의 공진기 부호화 실험: 공개 초록 또는 저자 연구실의 논문 본문 일부를 확인했다. NV와 실리콘의 링크는 물리 원리의 추가 원 출처이며 특정 성능 수치는 인용하지 않는다.
- Jouppi et al., TPU, 2017: 고전 텐서 가속기의 설계 목적을 읽는다. 과거 성능표를 현재 제품 비교로 옮기지 않는다.
- Wack et al., 2021, Wack, 2026 프리프린트: 공개 초록에서 metric의 범위와 고전 처리 포함을 확인했다. 처리량 지표와 실제 응용 성공을 구별하는 것이 읽기 과제다.

12. 잡음, 오류 완화와 학습 결과의 신뢰성

> 공개 실라버스에서 출발해 독립 집필한 80분 자율학습 노트다. 원강의 실습을 복원하지 않았다. 근거 기준일: 2026-10-20. 아래 채널·통계 예제는 교육용이며 실제 장치의 calibration이나 QPU 실행 결과가 아니다.

이전: 11. 하드웨어와 자원 · 전체 강의 · 다음: 13. 양자 데이터와 classical shadows

학습의 출발점과 도달점

02강의 밀도행렬·Bloch 벡터, 07강의 샷 분산, 11강의 자원 계산을 복습한다. trace와 분산은 수학 준비를 참고한다. 목표는 Kraus 연산자의 조건으로 채널을 검증하고, 서로 다른 잡음이 상태에 미치는 영향을 계산하며, 판독 보정과 ZNE의 편향·분산을 고정 총샷에서 비교하는 것이다. 완화와 오류정정의 정보 처리 목적도 구별할 수 있어야 한다.

샷 수를 늘리면 표본 변동은 줄어들지만 상태 준비와 게이트·판독의 체계적 편향은 남는다. 반대로 보정한 평균이 참값에 가까워져도 분산이 커지면 제한 예산의 최종 정확도는 나빠질 수 있다. QML에서는 기대값 오차와 분류 정확도 변화가 같지 않으므로 두 지표를 따로 평가한다. 학습이 장치 잡음에 적응했어도 시험 시 장치 상태가 바뀌면 그 적응이 유지되지 않을 수 있다.

80분 학습 순서

시간	실제 수행할 활동
0-5분	샷 변동과 체계적 편향을 각각 한 예로 설명한다.
5-15분	용어와 CPTP 정의를 읽고 Kraus 완비 조건을 확인한다.
15-40분	amplitude damping, 판독 역산, ZNE 분산을 직접 유도한다.
40-55분	고정 총샷의 MSE 비교와 최적 샷 배분 예제를 계산한다.
55-70분	문제 1-2개를 선택해 풀고 완화 실험 비교표의 핵심을 적는다.
70-75분	원문 읽기에서 ZNE 가정과 완화 하한의 worst-case 조건을 찾는다.
75-80분	출구 점검으로 채널 convention과 비용 경계를 설명한다.

80분은 핵심 유도와 선택 문제 1-2개를 다루는 학습 시간이다. 나머지 문제의 독립 풀이, 모든 해설과의 대조, 유도 재작성에는 강의 후 60-90분을 따로 배정한다. 원문 읽기 5분은 지정된 조건을 찾는 안내 독해이며 논문 전문 독해 시간은 포함하지 않는다.

핵심 용어

한국어·영어	뜻
양자 채널, quantum channel	밀도행렬에 작용하는 완전양의 trace-preserving 선형 사상.

한국어·영어	뜻
완전양성, complete positivity	임의 보조계의 항등사상과 결합해도 양의 연산자를 양의 연산자로 보내는 성질.
Kraus 표현, Kraus representation	채널을 연산자들의 합으로 나타내는 방식. 표현은 유일하지 않다.
탈분극, depolarization	여기서는 상태를 최대혼합 상태 쪽으로 수축하는 잡음.
위상 소실, dephasing	선택한 기저의 비대각 성분이 감소하는 과정.
진폭 감쇠, amplitude damping	여기서는 들뜬 상태가 바닥 상태로 이완하는 채널.
판독 오류, readout error	실제 측정 결과와 기록된 고전 비트가 달라지는 오류.
편향, bias	추정량의 평균과 목표값의 차이.
평균제곱오차, mean squared error·MSE	목표값과 추정값 차이 제곱의 평균.
영잡음 외삽, zero-noise extrapolation·ZNE	여러 잡음 강도의 관측값으로 잡음 0의 값을 추정하는 방법.
준확률, quasiprobability	음의 계수를 허용하는 선형결합 가중치.
오류 syndrome	부호화된 논리 정보를 직접 읽지 않고 오류에 관한 정보를 얻는 검사 결과.

통합 용어집의 유니탈·비유니탈 채널도 함께 확인한다. 동일한 depolarizing라는 이름을 써도 매개변수 정의는 문헌마다 달라질 수 있다.

유도 1: 채널을 물리적 사상으로 검증한다

밀도행렬 ρ와 선형 연산자 K_a들에 대해 채널을 다음처럼 쓰자. a는 Kraus 항의 지표이고 I는 항등연산자다.

$$\mathcal{E}(\rho) = \sum_a K_a \rho K_a^\dagger, \qquad \sum_a K_a^\dagger K_a = I.$$

각 $K_a \rho K_a^\dagger$는 양의 연산자이므로 합도 양이다. 보조계를 붙여도 Kraus 연산자를 $K_a \otimes I$로 바꾸면 같은 논리가 성립하므로 완전양성이다. trace의 순환성을 쓰면 $\mathrm{Tr}\,\mathcal{E}(\rho) = \mathrm{Tr}[\rho \sum_a K_a^\dagger K_a] = \mathrm{Tr}\,\rho$다. 따라서 완비 조건이 확률 정규화를 보존한다. 한 번의 측정 결과에 조건을 건 부분 연산은 trace가 줄어들 수 있으며, 모든 결과를 합한 채널과 구별한다.

한 큐비트의 Pauli 행렬을 X, Y, Z, 잡음률을 p라 두고 이 강의의 탈분극 convention을

$$\mathcal{D}_p(\rho) = (1-p)\rho + pI/2, \quad 0 \le p \le 1$$

로 정한다. Kraus 연산자로 $K_0 = \sqrt{1-3p/4}\, I$, $K_{1,2,3} = \sqrt{p/4}\,(X, Y, Z)$를 택할 수 있다. $X\rho X + Y\rho Y + Z\rho Z = 2I - \rho$를 대입하면 위 식을 회복한다. Pauli 오류가 확률 q로 일어난다는 다른 convention과는 $q = 3p/4$ 관계다. 숫자만 비교하지 말아야 한다.

위상 플립 채널은 $\mathcal{Z}_q(\rho) = (1-q)\rho + qZ\rho Z$이고 Kraus는 $\sqrt{1-q}I, \sqrt{q}Z$다. 대각은 보존되고 비대각은 $1-2q$배가 된다. $q = 1/2$이면 완전 dephasing이며 $q = 1$이면 단순한 Z 유니터리여서 잡음 크기의 단조 척도로 읽으면 안 된다. 단조 소실 예제로는 $0 \le q \le 1/2$를 사용한다. bit flip은 Z를 X로 바꾸며 계산 기저의 점유 확률도 바뀐다.

완성 예제: 진폭 감쇠는 최대혼합 상태도 움직인다

감쇠 확률 $0 \le \gamma \le 1$의 amplitude damping을

$$K_0 = \begin{pmatrix} 1 & 0 \\ 0 & \sqrt{1-\gamma} \end{pmatrix}, \qquad K_1 = \begin{pmatrix} 0 & \sqrt{\gamma} \\ 0 & 0 \end{pmatrix}$$

로 정의한다. 먼저 $K_0^\dagger K_0 + K_1^\dagger K_1 = \mathrm{diag}(1, 1-\gamma) + \mathrm{diag}(0, \gamma) = I$이므로 trace 보존을 확인한다. 일반 상태의 성분을 곱하면

$$\rho = \begin{pmatrix} a & b \\ b^* & 1-a \end{pmatrix} \longmapsto \begin{pmatrix} a + \gamma(1-a) & \sqrt{1-\gamma}\, b \\ \sqrt{1-\gamma}\, b^* & (1-\gamma)(1-a) \end{pmatrix}.$$

들뜬 상태 확률은 $1-\gamma$배로 줄고 비대각은 그 제곱근 배로 줄어든다. Bloch 좌표 x, y, z로 쓰면 $(x', y') = \sqrt{1-\gamma}\,(x, y)$, $z' = (1-\gamma) z + \gamma$다. 예를 들어 $\gamma = 0.2$, 초기 최대혼합 상태 $I/2$는 $\mathrm{diag}(0.6, 0.4)$가 된다. 따라서 이 채널은 비유니탈이다. 탈분극과 위상 플립은 최대혼합 상태를 보존한다. coherent 과회전은 또 다르다. 단일 Kraus 유니터리로 기술되며 순수성을 줄이지 않으면서 기대값을 잘못 돌릴 수 있다.

한 큐비트 유니터리 사이에 같은 탈분극이 L번 작용하면 traceless 관측량 신호는 $(1-p)^L$배다. $p = 0.01, L = 100$이면 약 0.366배다. 이 등식은 채널의 유니터리 공변성과 단순한 삽입 조건에 의존한다. 다큐비트 국소 잡음에는 관측량의 전파와 상관 구조가 추가된다. 비유니탈 잡음에서 기울기가 남을 수 있다는 최신 논의는 09강의 회로 앙상블·관측량 조건과 함께 읽는다.

유도 2: 판독 보정은 역문제다

실제 비트가 뒤집혀 기록될 대칭 확률을 $e < 1/2$, 실제 0 확률을 p_0, 기록된 0 확률을 q_0라 하자. 정확하고 시간에 따라 고정된 오류 모형을 우선 가정한다.

$$\begin{pmatrix} q_0 \\ q_1 \end{pmatrix} = \begin{pmatrix} 1-e & e \\ e & 1-e \end{pmatrix} \begin{pmatrix} p_0 \\ p_1 \end{pmatrix}, \qquad p_0 = \frac{q_0 - e}{1 - 2e}.$$

첫 행에서 $q_0 = (1-e)p_0 + e(1-p_0) = e + (1-2e)p_0$를 얻고 역산한 식이다. $e = 0.1, q_0 = 0.66$이면 $p_0 = 0.70$이다. Z 기대값은 기록값 $2q_0 - 1 = 0.32$에서 보정값 0.40으로 바뀐다. e가 정확하다면 추정량의 평균도 올바르게 복구된다.

그러나 기울기가 $1/(1-2e)$인 선형 변환이므로 분산은

$$\mathrm{Var}(\widehat{p}_0) = \frac{q_0(1-q_0)}{S(1-2e)^2} = 1.5625\,\mathrm{Var}(\hat{q}_0)$$

로 커진다. $e \to 1/2$이면 보정 행렬의 행렬식이 0으로 가고 역문제가 불안정해진다. 샷을 무한히 늘려도 $e = 1/2$에서 잃은 비트 정보는 이 역산으로 복구할 수 없다.

실제로는 e도 calibration 샷으로 추정한다. 독립 추정이라는 가정하에 delta 방법으로 그 추가 분산의 선도항은 $[(2q_0-1)/(1-2e)^2]^2\,\mathrm{Var}(\hat{e})$다. calibration과 본 실험의 drift가 있으면 체계적 편향도 남는다. 역산 확률이 0보다 작거나 1보다 크면 유한 표본·잘못된 모형을 점검한다. 범위로 잘라내는 후처리는 편향을 바꾸므로 사용 여부를 기록한다. 다큐비트 독립 판독 모형은 저렴하지만 상관 오류가 강할 때 정확하지 않을 수 있다.

유도 3: ZNE의 편향 감소와 고정 예산 분산

잡음 강도를 λ, 관측량의 장치 평균을 $\mu(\lambda)$라 하자. $\mu(0)$이 목표다. 같은 이상적 계산을 유지하면서 잡음만 정확히 배율 조절할 수 있고, 약한 잡음에서 매끄럽게 전개된다고 가정한다.

$$\mu(\lambda) = \mu(0) + a\lambda + b\lambda^2 + O(\lambda^3).$$

두 배 강도까지 측정해 $2\widehat{\mu}(\lambda) - \widehat{\mu}(2\lambda)$를 만들면 상수 계수 합은 1, 일차항 계수는 $2 - 2 = 0$이다. 따라서 평균은 $\mu(0) - 2b\lambda^2 + O(\lambda^3)$이고 선형 편향이 제거된다. Temme 등과 Li-Benjamin은 잡음을 증폭해 외삽하는 접근을 정립한 원 연구다.

각 평균을 독립적으로 S샷 평가하고 결과가 ± 1이면 분산 상한은 $4/S + 1/S = 5/S$다. 총샷은 $N = 2S$이므로 고정 총예산 표현은 $10/N$이다. 같은 N샷을 원시 평균 한 개에 쓰면 분산 상한은 $1/N$이다. 회로당 샷을 같게 놓고 총비용이 같다고 말하면 이 차이를 놓친다.

각 점의 개별 결과 분산을 σ_1^2, σ_2^2, 배분 샷을 $n_1 + n_2 = N$이라 하면 ZNE 분산은 $4\sigma_1^2/n_1 + \sigma_2^2/n_2$다. Lagrange 승수로 미분하거나 Cauchy-Schwarz를 쓰면 최적 비율은 $n_1 : n_2 = 2\sigma_1 : \sigma_2$다. 두 분산을 모두 1의 상한으로 설계하면 2:1 배분과 상한 $9/N$을 얻는다. 실제 최적 배분을 알려면 먼저 분산을 추정하는 비용도 필요하다.

고정 예산 예제와 외삽의 실패 조건

교육용으로 이상값이 0.78이고 두 잡음 강도 평균이 각각 0.72, 0.66인 정확한 선형 모형을 가정한다. ZNE 평균은 $2(0.72) - 0.66 = 0.78$이다. 원시 평균의 편향은 −0.06이다. 평균제곱오차는 모든 추정량에 대해

$$\mathbb{E}[(\widehat{\mu} - \mu(0))^2] = \mathrm{Var}(\widehat{\mu}) + \mathrm{Bias}(\widehat{\mu})^2$$

로 나뉜다. 원시값에 총 N샷을 쓰면 MSE는 $0.4816/N + 0.0036$이다. 독립 ZNE에 절반씩 배분하면 실제 분산은 $4.9816/N$이고 가정한 선형 모형에서 편향은 0이다. $N = 1{,}000$에서는 원시 MSE 약 0.00408, ZNE 약 0.00498로 완화가 불리하다. $N = 10{,}000$에서는 각각 약 0.00365와 0.000498로 순서가 바뀐다. 보정이 잘된 평균만 보여주지 말고 고정 비용의 MSE를 비교해야 한다는 완성 예다.

실제 게이트 folding은 이상적 연산을 유지하도록 항등 연산을 늘리지만 잡음까지 정확히 배율만 바뀐다는 보장은 없다. coherent 오류, drift, 다른 시간 규모, 회로 재컴파일이 외삽 모형을 깨뜨릴 수 있다. 높은 차수의 외삽은 더 많은 점과 큰 양·음 계수를 요구해 분산을 더 키울 수 있다. 기대값 범위 밖 결과도 선형 추정에서는 나올 수 있으므로 불확실성과 모형을 점검한다. 관측 후 유리한 외삽 차수만 고르면 선택 편향이 생긴다.

오류 상쇄와 오류정정은 다른 정보를 다룬다

Probabilistic error cancellation은 이상 연산을 구현 가능한 잡음 연산들의 준확률 선형결합으로 쓴다. 계수 절댓값 합을 Γ라 하면 부호와 가중치를 포함한 표본의 크기가 커져 전형적인 샷 오버헤드가 Γ^2와 연결된다. 채널을 충분히 정확히 알고 적절한 연산 집합을 구현해야 한다. 음의 확률로 실험을 실행하는 것이 아니라 양의 확률로 선택한 실험의 결과에 부호를 붙여 평균한다.

오류정정은 논리 상태를 여러 물리 자유도에 부호화하고 syndrome을 읽어 연산 중 오류 영향을 줄이는 접근이다. 논리 진폭을 그대로 복사하거나 직접 측정해서 정답을 알아내는 과정이 아니다. Steane의 원 논문은 부호화에 의한 보호의 기초를 제시한다. 완화는 주로 특정 기대값 추정의 편향을 줄이고 오류정정은 정보 저장·연산의 보호를 목표로 한다. 두 방법은 결합할 수 있지만 자원 단위가 다르다.

Quek 등의 2024년 한계 연구는 큰 회로 부류에서 이상 관측량 복원에 필요한 worst-case 표본 수가 매우 커질 수 있음을 보인다. 이를 모든 소규모 구조적 실험이 실패한다는 결론으로 확대하지 않는다. 이상 simulator, noisy simulator, 원시 QPU, 완화 QPU를 분리하고 calibration·추가 회로·샷·모델 선택을 합한 비용을 보고한다. 본 강의의 계산은 CPU 손계산이며

QPU 접근을 요구하지 않는다.

연습문제와 풀이

문제 1. 위상 플립 $q = 1/2$가 $|+\rangle$에 작용한 상태와 Z, X 기대값을 구하라. **힌트:** 비대각 성분이 0이 된다.

풀이. 초기 밀도행렬은 모든 성분이 1/2이고 채널 뒤에는 $I/2$다. 따라서 두 기대값 모두 0이다. 초기 Z도 0이었으므로 그 관측량만 보면 잡음을 발견하지 못한다. 잡음 효과는 어떤 관측량을 보는지에 의존한다.

문제 2. 진폭 감쇠 $\gamma = 0.3$가 $|1\rangle$에 작용하면 바닥 상태 확률과 Z 기대값은? **힌트:** 들뜬 상태 확률은 $1 - \gamma$다.

풀이. 출력은 $0.3|0\rangle\langle 0| + 0.7|1\rangle\langle 1|$다. 바닥 확률 0.3, Z 기대값 $0.3 - 0.7 = -0.4$다. 탈분극과 달리 장시간 목표가 바닥 상태라는 방향성을 가진다.

문제 3. 판독 오류가 정확히 $e = 0.2$라면 보정 분산 증폭은 얼마인가? **힌트:** 역기울기의 제곱을 계산한다.

풀이. $1/(1-2e)^2 = 1/0.6^2 \approx 2.778$이다. 같은 분산을 얻으려면 원시 추정 대비 약 2.778배의 본 실험 샷이 필요하다. calibration 오류가 없고 다른 조건이 같다는 가정이며 실제 총비용에는 calibration 샷도 더한다.

문제 4. 총 9,000샷의 ZNE에서 두 점의 표본 분산을 같은 1로 설계하면 최적 배분과 분산 상한은? **힌트:** 계수 절댓값이 2와 1이다.

풀이. 2:1로 6,000샷과 3,000샷을 준다. 상한은 $4/6000 + 1/3000 = 0.001$이다. 균등 배분이면 $5/4500 \approx 0.001111$다. 이것은 분산을 줄이는 배분일 뿐 남은 이차 이상 편향이나 잘못된 잡음 배율을 제거하지 않는다.

학습 완료 점검

- Kraus 완비 조건과 amplitude damping의 비유니탈성을 직접 계산한다. 단순한 이름 대신 행렬로 설명하면 통과다. 실패하면 유도 1과 수학 준비를 복습한다.
- 원시값·판독 보정·ZNE의 편향과 분산을 같은 총샷에서 비교한다. 5/S와 10/N의 관계를 설명하면 통과다. 실패하면 유도 2·3을 다시 읽는다.
- 기대값 보정과 논리 상태 보호를 구별하고 calibration drift의 영향을 말한다. 결과·샷·모형·실행 수준을 함께 기록할 수 있어야 13강으로 진행한다.

원문 읽기

- IBM Quantum, Noise and errors, Build noise models: 공개 공식 설명에서 Kraus·채널 명칭을 확인했다. 본 노트는 명시한 convention으로 직접 계산하며 특정 SDK 버전의 실행 결과를 보고하지 않는다.
- Temme, Bravyi, Gambetta, PRL 2017, Li-Benjamin, PRX 2017: 공개 초록의 외삽·준확률 접근을 확인했다. 독립 교육 유도와 원 논문의 일반 방법을 구별하며 실험을 재현하지 않았다.
- Quek et al., Nature Physics 2024: 공개 초록·출판사 검색 본문에서 worst-case 표본 한계를 확인했다. 어떤 출력과 회로 부류에 대한 진술인지 표시하는 것이 읽기 과제다.
- Steane, 1996: 공개 초록과 출판 정보를 확인한 오류정정 원 연구다. 부호화와 syndrome에 관한 심화 읽기이며 오류정정 회로를 여기서 실행한 것은 아니다.

13. 양자 데이터와 classical shadows: 무엇을 측정해야 배울 수 있는가

> 독립 집필한 확장 강의. 원 CMU 실라버스 밖의 보완 내용이며 원 강의의 녹취·복원이 아니다. 근거 기준일: 2026-10-20. 아래 유도·수치 예제는 별도 표시가 없으면 자체 구성한 교육용 계산이다.

앞 강의: 12. 잡음과 오류 완화 · 다음 강의: 14. 우위와 탈양자화

선수 지식과 학습 목표

2강의 Born 규칙, 3강의 밀도행렬과 텐서곱, 11강의 샷 오차를 먼저 확인한다. 계산이 막히면 수학 보충의 trace·기댓값·분산을 복습한다. 이 강의의 목표는 미지 상태를 모두 복원하지 않고도 여러 물리량을 예측하는 방법을 이해하는 것이다. 수강 뒤에는 한 큐비트 측정 채널을 직접 역산하고, 무게가 다른 Pauli 문자열의 표본 비용을 계산하며, 양자 메모리가 허용된 학습과 즉시 측정하는 학습의 자원을 구분해야 한다.

학습 대상은 고전 파일에 저장된 숫자 벡터가 아니라, 동일한 준비 절차로 반복 생성되는 미지 상태 ρ다. n큐비트에서 ρ는 2^n차원 밀도행렬이며, $\rho \succeq 0$, $\operatorname{Tr}\rho = 1$을 만족한다. 목표는 주어진 Hermitian 관측량 $O_1, \dots, O_M$의 평균 $\mu_i = \operatorname{Tr}(O_i\rho)$를 가산 오차 ϵ 이내에서 함께 예측하는 것이다. 어떤 측정을 허용하는지가 문제 정의의 일부다.

80분 학습 순서

시간	직접 할 활동
0-8분	용어를 읽고 '복사본'과 '복제', '상태'와 '측정 기록'의 차이를 한 문장씩 쓴다
8-28분	Bloch 표현에서 측정 채널과 역채널을 손으로 유도한다
28-46분	한 큐비트·Bell 상태 예제를 계산하고 직접 측정과 비용을 비교한다
46-58분	표본 보장의 증명 윤곽과 메모리 접근 차이를 읽고 숨은 가정을 표시한다
58-75분	핵심 문제 1-2를 독립 시도하고 해설로 오답을 대조한다
75-80분	출구 점검으로 locality와 실패 확률을 설명한다

해설 읽기는 문제를 시도한 뒤에 한다. 80분은 안내된 핵심 학습 시간이다. 남은 문제 3·4와 원문 심화 읽기는 별도 60-90분 복습에 배정한다. 미완료 항목을 이해 완료로 표시하지 않는다.

핵심 용어

한국어·영어	정확한 뜻과 직관
양자 데이터, quantum data	미지 상태·채널에 대한 물리적 접근이다. 비트열로 측정하면 일부 정보는 소실된다
상태 복사본, state copy	같은 준비 절차가 주는 독립적인 ρ 한 개다. 미지 상태를 임의 복제하는 연산을 뜻하지 않는다
상태 단층촬영, state tomography	상태를 지정한 오차 척도에서 복원하는 과제다. 특정 기대값 몇 개의 예측보다 강한 요구다
측정 채널, measurement channel	무작위 기저 선택과 결과를 평균한 선형 사상 $\mathcal{M}$이다
고전 스냅샷, classical snapshot	측정 결과에 역채널을 적용한 행렬 $\hat{\rho}$다. 개별 스냅샷은 물리적 상태일 필요가 없다
고전 그림자, classical shadow	스냅샷을 재구성할 수 있게 저장한 기저·결과의 묶음이다. 전체 밀도 행렬을 저장하지 않아도 된다
불편 추정량, unbiased estimator	$\mathbb{E}\hat{\mu} = \mu$인 추정량이다. 한 번의 값이 참값과 가깝다는 뜻은 아니다
Pauli 무게, Pauli weight	문자열에서 항등행렬이 아닌 인자의 수 k다. 전체 큐비트 수와 구별한다
Shadow norm	측정 방식에 따라 관측량 추정의 최악 분산을 제어하는 크기다. 관측량 개수만으로 비용을 정하지 못하게 하는 항이다
평균들의 중앙값, median of means	표본을 여러 독립 묶음으로 나누고 각 평균의 중앙값을 택한다. 드문 큰 오차에 견디도록 실패 확률을 줄인다
공동 측정, collective measurement	여러 상태 복사본을 양자적으로 함께 처리하는 측정이다. 각 복사본을 먼저 비트열로 바꾸는 방법과 자원이 다르다

용어의 연결은 용어집에서 다시 찾을 수 있다. ‘고전’이라는 이름은 처리 결과가 고전 기록이라는 뜻이다. 자료를 얻는 실험까지 고전 장치라는 뜻은 아니다.

측정 채널을 역산하는 첫 번째 유도

한 큐비트 상태를 Bloch 벡터 $r = (r_x, r_y, r_z)$로 쓰면 $\rho = (I + r_x X + r_y Y + r_z Z)/2$다. I는 항등행렬이고 X, Y, Z는 Pauli 행렬이다. 각 샷에서 $a \in \{X, Y, Z\}$를 균등하게 고르고, 그 축의 측정 결과 $s \in \{+1, -1\}$를 기록한다. 결과에 대응하는 투영자는 $\Pi_{a,s} = (I + sa)/2$이고 조건부 확률은 $p(s \mid a) = (1 + s r_a)/2$다.

첫 단계로 한 축을 고정하고 투영자의 평균을 낸다. $\mathbb{E}[s \mid a] = r_a$이므로 $\sum_s p(s \mid a)\Pi_{a,s} = (I + r_a a)/2$다. 두 번째 단계로 세 축에 대해 평균하면

$$\mathcal{M}(\rho) = \frac{1}{3}\sum_{a=X,Y,Z}\sum_{s} p(s \mid a)\Pi_{a,s} = \frac{1}{2}\left(I + \frac{r_x X + r_y Y + r_z Z}{3}\right) = \frac{\rho + I}{3}.$$

마지막 등식은 trace가 1인 입력에 대한 표현이다. 임의 행렬 A로 확장하면 $\mathcal{M}(A) = (A + \mathrm{Tr}(A) I)/3$이며, 역은 $\mathcal{M}^{-1}(B) = 3B - \mathrm{Tr}(B) I$다. 따라서 한 샷 스냅샷은

$$\hat{\rho} = 3\Pi_{a,s} - I = \frac{I + 3sa}{2}, \qquad \mathbb{E}\hat{\rho} = \rho.$$

측정은 정보를 축소하지만 실험 전체의 평균은 알려진 선형 사상이다. 그 축소를 고전 계산으로 역보정하여 불편성을 얻는다. $\hat{\rho}$의 고유값은 2와 −1이므로 물리적 상태가 아니다. 이것은 오류가 아니라 통계 추정량의 성질이다. 모든 스냅샷을 다시 QPU의 상태로 준비할 수 있다고 해석하면 안 된다.

다중 큐비트 추정량과 분산의 두 번째 유도

각 큐비트의 기저를 독립적으로 고르면 역채널도 텐서곱으로 작용한다. 한 샷에 기록한 기저와 결과를 (a_j, s_j), $j = 1, \dots, n$이라 하면 $\hat{\rho} = \bigotimes_j (3\Pi_{a_j,s_j} - I)$다. 상태 자체는 얽혀 있어도 이 표현이 성립한다. 필요한 것은 측정 기저 앙상블의 곱 구조이며, 측정 결과들이 독립이라는 가정은 하지 않는다.

Pauli 문자열 P가 지지집합 S에서만 비항등이고 $k = |S|$라 하자. $\mathrm{Tr}[P\hat{\rho}]$를 계산하면 모든 관련 기저가 맞은 샷에서만 값이 남는다.

$$\hat{\mu}_P = 3^k \, \mathbf{1}\{a_j = P_j \text{ for all } j \in S\} \prod_{j \in S} s_j.$$

기저가 모두 맞을 확률은 3^{-k}다. 그 조건에서 결과 곱의 평균은 $\mu_P = \mathrm{Tr}(P\rho)$이므로 $\mathbb{E}\hat{\mu}_P = \mu_P$다. 또한 결과 곱의 제곱은 1이므로

$$\mathbb{E}\hat{\mu}_P^2 = 3^k, \qquad \mathrm{Var}(\hat{\mu}_P) = 3^k - \mu_P^2, \qquad \mathrm{Var}(\overline{\mu}_P) = \frac{3^k - \mu_P^2}{N}.$$

마지막 식은 N개 독립 동일분포 샷의 산술평균이다. 평균값을 알고 싶어 측정하므로 실제로 μ_P^2를 미리 아는 것은 아니다. 설계할 때는 $3^k/N$을 상한으로 쓸 수 있다. 이 계산은 단일 Pauli 문자열에 대한 정확한 결과다. 임의의 k국소 관측량을 여러 문자열의 합으로 쓰면 공분산도 고려해야 하므로 동일한 식을 무조건 적용하지 않는다.

일반 Hermitian 관측량의 제곱 shadow norm은, 고정한 측정 앙상블에서 $\|O\|_{\mathrm{sh}}^2 = \sup_\sigma \mathbb{E}_\sigma[(\mathrm{Tr}(O\hat{\rho}))^2]$라는 최악의 두 번째 모멘트로 정의할 수 있다. 최댓값은 가능한 밀도행렬 σ 전체에서 취한다. 그러므로 각 상태의 분산은 이 값 이하이며, 앞 Pauli 문자열에서는 3^k가 된다. 관측량의 크기만이 아니라 어떤 기저로 측정하는지도 이 정의에 포함된다.

완전 예제 1: 한 관측량만 원할 때

$\rho = |0\rangle\langle 0|$이고 목표가 Z 평균이면 참값은 1이다. Z를 고르는 확률 1/3에서 $s = 1$, 추정값은 3이다. 다른 기저에서는 추정값이 0이다. 따라서 평균은 $(1/3)3 = 1$, 두 번째 모멘트는 $(1/3)9 = 3$, 분산은 2다. $N = 200$이면 표준오차는 $\sqrt{2/200} = 0.1$이다.

그런데 처음부터 Z만 직접 측정하면 매번 +1이므로 이상적인 이 상태에서 분산은 0이다. Shadows가 각 질문을 가장 싸게 답하는 보편적인 방법은 아니다. 측정 뒤에 여러 국소 질문을 재사용할 수 있는 유연성을 위해 샷을 나누어 쓴다. 실제 상태 준비·측정 잡음이 있으면 직접 측정도 분산과 편향이 생기므로 이 수치는 이상적 비교의 경계 사례다.

완전 예제 2: Bell 상태의 국소와 상관 정보

$|\Phi^+\rangle = (|00\rangle + |11\rangle)/\sqrt{2}$에서는 $\langle Z_1 \rangle = 0$, $\langle Z_1 Z_2 \rangle = 1$이다. 첫 번째 추정량의 분산은 3, 두 번째는 9−1=8이다. 동일한 표준오차 0.1을 목표로 단순 평균을 설계하면 각각 300샷과 800샷이다. 이것은 표준오차 기준이며 실패 확률을 보장하는 신뢰구간과 동일하지 않다.

상관 관측에서는 두 기저가 모두 Z일 확률이 1/9이고, 그때 결과 곱은 언제나 +1이므로 추정값 9를 기록한다. 두 개별 결과는 무작위여도 곱은 고정된다. 기저의 독립성과 결과의 독립성을 혼동하지 말아야 하는 이유다. X_1X_2도 +1이지만 Y_1Y_2는 −1이다. 부호를 없애고 절댓값 상관만 비교하면 서로 다른 상태를 잘못 합칠 수 있다.

많은 질문의 표본 보장: 증명 윤곽

한 질문의 추정량 분산 상한을 v라 하자. r샷 묶음의 평균에 Chebyshev 부등식을 적용하면 $\Pr(|\bar{\mu}-\mu|>\epsilon)\le v/(r\epsilon^2)$다. $r\ge 8v/\epsilon^2$로 잡으면 한 묶음의 실패 확률은 1/8 이하다. 독립 묶음 B개의 중앙값이 실패하려면 절반 이상이 동시에 실패해야 하므로 그 확률은 B에 지수적으로 감소한다. M개 질문에 union bound를 적용하려면 질문당 실패를 δ/M 이내로 낮추면 된다.

따라서 $B=O(\log(M/\delta))$, 총 샷은 $N=rB=O(v\log(M/\delta)/\epsilon^2)$다. 이것이 shadows의 다중 예측 보장을 이해하는 기본 경로다. 원 논문은 더 일반적인 shadow norm으로 이를 정식화한다. 노트의 간단한 분산 증명을 모든 측정 앙상블의 최적 상수나 하한 증명으로 읽지는 않는다. 특히 M의 로그만 보고 지수 비용이 사라졌다고 판단하면 $v\sim 3^k$를 빠뜨린 것이다.

측정 뒤에 질문을 선택할 수 있다는 설명에도 통계적 범위가 있다. 위 동시 보장은 지정한 관측량 집합을 제어한다. 기록을 수없이 탐색한 뒤 가장 극단적인 추정값만 골라 같은 오차막대를 붙이면 선택 편향이 생길 수 있다. 검증용 독립 샷을 남기거나, 선택할 수 있는 전체 후보 집합에 대한 동시 보장을 적용해야 한다. 측정 재사용의 유연성이 무제한의 자료 탐색을 무료로 허용한다는 뜻은 아니다. 이 차이는 과학적 발견에 shadows를 사용할 때 특히 중요하다.

기록, 메모리, 실험 인터페이스

로컬 Pauli 기록은 샷마다 n개 기저와 n개 결과이므로 고전 저장량은 $O(Nn)$이다. 행렬 $\hat{\rho}$를 $2^n\times 2^n$ 배열로 만들 필요가 없다. 한 무게 k 문자열은 샷별로 관련 위치만 확인하여 $O(Nk)$ 시간에 계산할 수 있다. 질문 M개를 순진하게 처리하면 $O(MNk)$가 되므로 측정 수의 로그 의존성과 고전 계산 시간의 로그 의존성은 다른 주장이다.

양자 메모리에 여러 복사본을 보관하고 공동 측정하는 학습기는 즉시 측정하는 학습기보다 강한 접근을 가질 수 있다. Huang 등의 2022년 연구는 이런 접근 차이에서 특정 표본 우위를 다룬다. 이 결과를 고전 이미지 분류의 보편적 속도 우위로 옮길 수 없다. 동일 준비 상태 가정, 독립성, 기저 무작위화와 readout 보정도 실제 분석의 전제다. 드리프트가 있으면 날짜별 평균을 확인하고, 상관 샷을 독립 샷으로 세지 않아야 한다. 미지 상태가 이미 손상된 뒤 얻은 기록에 이상적 역채널을 적용하면 불편성은 더 이상 자동으로 성립하지 않는다.

연습문제와 풀이

1. **스냅샷 검산.** $\rho=I/2$에서 $\langle X\rangle$ 추정량의 가능한 값과 확률, 평균·분산을 구하라. **힌트:** X 기저가 맞은 뒤에도 결과 부호는 균등하다. **풀이:** +3과 −3은 각각 1/6, 0은 2/3의 확률이다. 평균은 0, 두 번째 모멘트는 $9/6+9/6=3$이므로 분산은 3이다. N샷 평균의 분산은 $3/N$이다. 상태가 최대혼합이어도 모든 추정값이 0인 것은 아니다.

2. **비국소성 비용.** 참 평균이 0인 무게 2와 무게 6 문자열을 표준오차 0.05로 추정할 때 필요한 단순 평균 샷을 비교하라. **힌트:** 표준오차 제곱을 분산/N으로 놓는다. **풀이:** 무게 2에서는 $N\ge 9/0.0025=3600$, 무게 6에서는 $N\ge 729/0.0025=291600$이다. 비율은 81이다. 전체 장치의 큐비트 수는 이 계산에 직접 들어가지 않지만, 예측 대상의 무게가 비용을 지배한다.

3. **비선형량의 함정.** 두 독립 스냅샷으로 순도 $\mathrm{Tr}(\rho^2)$의 불편 추정량을 제안하고, 같은 스냅샷을 두 번 쓰는 방식이 실패함을 보여라. **힌트:** 독립성 아래 곱의 평균을 분리한다. **풀이:** $i\neq j$에서 $\mathbb{E}\,\mathrm{Tr}(\hat{\rho}_i\hat{\rho}_j)=\mathrm{Tr}[(\mathbb{E}\hat{\rho}_i)(\mathbb{E}\hat{\rho}_j)]=\mathrm{Tr}(\rho^2)$다. 한 큐비트 동일 스냅샷의 고유값은 2, −1이므로 $\mathrm{Tr}(\hat{\rho}_i^2)=5$가 매번 나온다. 순도는 1 이하여서 명백히 편향됐다. 서로 다른 쌍을 평균하는 U-statistic을 쓸 수 있지만 분산과 계산 비용은 별도 분석한다.

4. **실험 설계 판단.** 100큐비트 상태에서 하나의 알려진 $Z^{\otimes 100}$만 추정하려 한다. 무작위 로컬 shadows를 반드시 택해야 하는가? **힌트:** 모든 샷에서 목표 기저를 측정하는 대안을 계산한다. **풀이:** 아니다. 직접 Z기저로 측정한 결과 곱은 ±1이고 분산은 최대 1이다. 반면 무작위 방식의 분산 상한은 3^{100}이다. 추후 여러 종류의 관측량을 물을 필요가 없다면 직접 측정이 자연스럽다. 이 비교는 shadows 전체의 실패가 아니라 측정 설계와 질문의 적합성에 대한 결론이다.

학습 완료 점검

- 역채널이 물리적 채널일 필요가 없는 이유를 '고전 후처리'와 음의 고유값으로 설명한다. 막히면 첫 유도에서 trace를 직접 계산한다.
- $\log M$과 3^k가 동시에 나타나는 이유를 구분한다. 문제 2의 비율을 재현하지 못하면 분산 유도를 다시 푼다.
- 원 논문의 표본 우위를 설명할 때 상태 복사본, 양자 메모리, 허용 측정을 빠짐없이 적는다. 단순히 '양자 데이터니까 우위'라고 쓰면 통과하지 못한다.

원문 읽기

- Huang, Kueng, Preskill, Predicting many properties of a quantum system from very few measurements, Nature Physics (2020). 공개 본문의 **Procedure**, **Rigorous performance guarantees**, Predicting expectation values of global observables (non-example)와 Supplementary **1 B, Example 2**를 확인했다. 읽기 질문은 '우리의 3^k 결과가 일반 국소 관측량의 어떤 특수 경우인가'다.
- Huang 외, Quantum advantage in learning from experiments, Science (2022). 초록·문제 설정을 읽고 즉시 측정과 공동 처리의 차이를 표로 적는다. 본 노트는 장치 실험을 독립 재현하지 않았다.
- Liu 외, Quantum learning advantage on a scalable photonic platform, Science (2025). 광학 과정과 큐비트 상태의 차이를 먼저 적고 18강의 사례 분석으로 넘어간다.

14. 양자 우위와 탈양자화: 같은 입력으로 같은 답을 구하는가

> 독립 집필한 확장 강의. 원 CMU 실라버스 밖의 보완 내용이며 원 강의의 녹취·복원이 아니다. 근거 기준일: 2026-10-20. 계산 예제와 간단한 증명은 학습을 위한 자체 구성이다.

앞 강의: 13. 양자 데이터와 shadows · 다음 강의: 15. 생성형 양자 모델

선수 지식과 학습 목표

4강의 데이터 부호화, 8강의 내적과 커널, 10강의 평가 조건을 복습한다. 복소 내적·조건수·확률 표기가 낯설면 수학 보충을 함께 읽는다. 목표는 '양자 우위'를 한 단어로 판정하는 것이 아니라, 비교 명제를 정확하게 쓰는 것이다. 수강 뒤에는 접근 모델을 명시하고, 길이제곱 샘플링으로 내적의 불편 추정량을 유도하며, 부분 알고리즘의 개선이 전체 비용 개선으로 이어지는 조건을 계산해야 한다.

성능 비교의 기본 단위는 $(\mathcal{P}, \mathcal{A}, \epsilon, \delta, \mathcal{R})$라는 묶음으로 생각할 수 있다. $\mathcal{P}$는 문제군, $\mathcal{A}$는 입력 접근 방식, ϵ은 허용 오차, δ는 실패 확률, $\mathcal{R}$은 비교할 시간·메모리·표본 같은 자원이다. 이는 교육용 표기다. 이 다섯 항목 중 하나라도 다르면 같은 알고리즘 문제에 대한 우위인지 다시 확인해야 한다.

80분 학습 순서

시간	직접 할 활동
0-8분	우위의 자원을 세 종류로 나누고 접근 모델 용어를 정의한다
8-28분	Sample-and-query 내적 추정과 Heisenberg 부분공간 모사를 유도한다
28-46분	상대 부호·전체 실행 시간의 완전 예제를 계산한다
46-58분	Tang 원문의 입력 자료구조와 노트의 단순 추정량을 구분한다
58-75분	핵심 문제 1-2를 독립 시도하고 추정량 계산을 대조한다
75-80분	출력·입력 비용을 포함한 비교 명제를 제출한다

80분은 안내된 핵심 학습 시간이다. 남은 문제 3·4와 원문 심화 읽기는 별도 60-90분 복습에 배정한다. 문제는 먼저 독립적으로 시도한 뒤 해설을 읽는다.

핵심 용어

한국어·영어	정의와 직관
계산 우위, computational advantage	같은 과제를 더 적은 계산 자원으로 푸는 조건부 비교다. 단순 정확도 차이와 다르다
표본 복잡도, sample complexity	목표 오차와 성공 확률에 필요한 독립 자료 수다. 자료 하나의 생성 시간은 별도다

한국어·영어	정의와 직관
쿼리 복잡도, query complexity	정해진 oracle을 호출한 횟수다. 한 호출의 실제 구현 비용을 무료로 볼 수 있는 추상 모델이다
오라클, oracle	지정된 입출력 기능을 제공하는 접근 장치다. '데이터가 있다'보다 강하고 구체적인 가정이다
진폭 접근, amplitude access	벡터 x를 정규화한 상태 $\|x\rangle$를 준비하는 접근이다. 원소 목록 전체를 반환하지 않는다
길이제곱 샘플링, length-squared sampling	i를 $\|x_i\|^2/\|x\|_2^2$에 비례해 고르는 고전 접근이다
샘플 및 조회 접근, sample-and-query access	길이제곱 샘플, 원소 조회, 노름 정보를 제공하는 기능 묶음이다. 구체적인 정밀도·구축 비용도 필요하다
탈양자화, dequantization	양자 알고리즘의 일부 효과를 유사한 자료 접근을 가진 고전 알고리즘으로 재현하는 연구다
통계적 쿼리, statistical query	분포에 대한 함수의 기대값을 허용 오차로 받는 학습 모델이다. Sample-and-query와 약자 SQ만 같다
고전 대리모델, classical surrogate	원 양자 모델의 출력·학습을 고전 계산으로 근사하는 모델이다. 양자 사전 측정을 사용했는지 표시해야 한다
점근 복잡도, asymptotic complexity	문제 크기가 커질 때의 자원 증가율이다. 유한 크기의 상수·통신 지연까지 자동 설명하지 않는다

용어는 용어집과 대조한다. 논문에 SQ라고만 쓰여 있으면 풀어 쓴 명칭부터 찾는다. 서로 다른 SQ 접근을 동일시하면 하한과 알고리즘의 가정이 바뀐다.

입력 접근은 어떻게 달라지는가

$x \in \mathbb{C}^d$, $x \neq 0$라 하자. 원소 조회는 인덱스 i를 주면 x_i를 정해진 정밀도로 반환한다. 진폭 준비는 $|0\rangle \mapsto |x\rangle = \sum_i x_i|i\rangle/\|x\|_2$를 구현한다. 상태 복사본만 받는 경우, 준비 유니터리와 역연산까지 호출할 수 있는 경우도 서로 다르다. 고전 샘플링은 $p_i = |x_i|^2/\|x\|_2^2$에서 인덱스를 하나 뽑는다.

목록으로 주어진 조밀한 벡터를 읽어 자료구조를 구축하는 데에는 전체 입력 크기에 따른 비용이 든다. 이후 업데이트와 샘플링이 빠를 수 있지만 구축을 공짜라고 두면 최초 실행의 비용을 누락한다. 같은 벡터로 많은 질의를 반복한다면 구축 비용을 분담할 수 있으므로 반대로 모든 호출에서 새로 구축한다고 세는 것도 부정확하다. 입력의 재사용 횟수를 비교의 일부로 적어야 한다.

고전 알고리즘에게 원소 조회와 정확한 노름까지 제공하면서 양자 쪽에는 미지 상태 복사본만 준다면 고전 접근이 더 많은 정보를 가질 수 있다. 양자 알고리즘에게 coherent 준비와 역연산을 주면서 고전 쪽에는 임의 순서 원소 조회만 주면 반대 비대칭이 생길 수 있다. 접근 모델의 공정성은 기능을 나란히 쓰고 과제와 연결해서 평가한다.

첫 번째 유도: 샘플링으로 내적을 추정한다

두 벡터 $x, y \in \mathbb{C}^d$의 내적 $s = x^\dagger y = \sum_i \overline{x_i} y_i$를 추정하자. x의 길이제곱 샘플링, x_i, y_i 조회, $\|x\|_2$를 사용할 수 있다고 가정한다. $x_i = 0$인 위치는 샘플되지 않으며 내적 기여도 0이다. 뽑힌 $I \sim p$에 대해

$$Z = \frac{\overline{x_I} y_I}{p_I} = \|x\|_2^2 \frac{y_I}{x_I}$$

를 계산한다. 첫 단계로 평균을 취하면 $\mathbb{E} Z = \sum_{i : x_i \neq 0} p_i \overline{x_i} y_i / p_i = s$이므로 불편 추정량이다. 두 번째 단계로 제곱 크기를 계산하면

$$\mathbb{E}|Z|^2 = \sum_{i : x_i \neq 0} \frac{|x_i|^2 |y_i|^2}{p_i} = \|x\|_2^2 \sum_{i : x_i \neq 0} |y_i|^2 \leq \|x\|_2^2 \|y\|_2^2 .$$

독립 N회 평균 $\bar{Z}$의 평균제곱 오차는 $\mathbb{E}|\bar{Z} - s|^2 \leq \|x\|_2^2 \|y\|_2^2 / N$이다. 두 노름이 1이라면 차원 d가 이 표본 상한에 직접 나타나지 않는다. 다만 접근 기능을 구현하는 비용, 유한 정밀도 나눗셈, 실패 확률 감소를 위한 반복은 별도다. s가 매우 작을 때 상대오차까지 요구하면 가산오차 보장만으로는 충분하지 않다.

이 유도는 탈양자화가 왜 가능한지 보여주는 작은 예제이며 Tang 추천 알고리즘 전체의 증명이 아니다. Tang의 원 결과는 저랭크 근사와 자료구조·추천 출력의 문제 조건을 더 포함한다. ‘양자 내적 서브루틴이 있으므로 지수 우위’라는 설명을 읽었을 때 고전 확률 추정과 접근 비용을 함께 검토하게 만드는 것이 학습 목적이다.

완전 예제 1: 확률만으로 상대 부호를 잃는다

$x = (3, 4)$, $z = (3, -4)$는 모두 노름 5이고 계산 기저 측정 확률은 $(9/25, 16/25)$다. 따라서 이 비트열 분포만 반복 관측해서 둘을 구별할 수 없다. 그러나 상태에 Hadamard를 적용하고 측정하면 $|x\rangle$의 0 확률은 $(3+4)^2/50 = 49/50$, $|z\rangle$에서는 $(3-4)^2/50 = 1/50$이다. 간섭이 상대 부호를 읽는 추가 기능을 제공한다.

이 예제로 고전 원소 조회까지 불가능하다고 결론낼 수는 없다. 조회는 두 번째 성분을 읽으면 바로 부호를 안다. ‘고전 샘플 분포’, ‘Sample-and-query’, ‘양자 상태’가 같은 입력이 아니라는 사실을 보여준다. 동일 확률 분포를 가진 상태도 모든 양자 측정에서 같지는 않다.

두 번째 유도: 작은 관측량 공간에서 고전 모사가 가능하다

변분 손실을 $f_\theta = \mathrm{Tr}[\rho U_\theta^\dagger O U_\theta]$로 쓰자. ρ는 초기 상태, O는 측정 관측량이다. Hermitian 기저 $B_1, \dots, B_D$의 선형공간이 회로의 각 게이트에 의한 conjugation 아래 닫혀 있다고 가정한다. 또한 O가 그 공간 안에 있고, 각 변환의 계수 갱신과 초기 기대값을 효율적으로 계산하거나 사전 측정할 수 있다고 가정한다.

그러면 $U_\theta^\dagger O U_\theta = \sum_{a=1}^{D} c_a(\theta) B_a$로 나타난다. 기저별 초기 기대값 $m_a = \mathrm{Tr}(\rho B_a)$를 한 번 얻으면 $f_\theta = \sum_a c_a(\theta) m_a$다. 게이트를 차례로 적용하면서 D개 계수를 갱신하면 전체 2^n차원 상태벡터를 저장할 필요가 없다. 다만 D가 다항식이라는 사실만으로 충분하지 않고 기저 표현·계수 갱신·기대값 획득의 비용도 작아야 한다.

예를 들어 한 큐비트 $R_y(\theta)$와 $O = Z$에서는 $R_y^\dagger Z R_y = \cos\theta Z - \sin\theta X$다. 따라서 $f_\theta = m_Z \cos\theta - m_X \sin\theta$를 고전적으로 계산한다. 초기 상태가 복잡한 양자 자료라면 m_X, m_Z의 측정은 여전히 필요할 수 있다. 이 경우 ‘고전 훈련’과 ‘양자 자료를 사용하지 않는 알고리즘’을 구별해야 한다. 더 큰 회로의 관측량 공간이 지수적으로 커지면 이 방식의 효율성은 사라진다.

완전 예제 2: 서브루틴 개선과 전체 시간

교육용 파이프라인에서 고전 핵심 계산이 질의당 10^6시간 단위, 양자 핵심 계산이 10^3단위라고 하자. 양자 자료구조 구축은 10^8단위이고, 고전 방식은 원래 저장된 입력을 그대로 사용한다고 가정한다. 같은 입력으로 K번 질의하면 $T_C = 10^6 K$, $T_Q = 10^8 + 10^3 K$다. 양자 쪽이 작으려면 $999000 K > 10^8$, 즉 정수 $K \geq 101$이 필요하다.

첫 질의는 양자 쪽이 훨씬 느리지만 입력을 충분히 재사용하면 비교가 달라진다. 매 질의 입력이 완전히 바뀌어 구축을 다시 해야 하면 $T_Q = K(10^8 + 10^3)$이 되어 이 예제의 개선은 사라진다. 숫자는 실제 장치 예측이 아니며, 구축·반복·캐싱을 명시하면 논쟁적인 우위 문장이 계산 가능한 질문으로 바뀐다는 예다.

하한과 벤치마크를 읽을 때의 논리

고전 알고리즘의 한 종류가 느리다는 증거는 모든 고전 알고리즘이 느리다는 하한보다 약하다. 특정 gradient 방식 또는 statistical-query 모델에 대한 하한에는 그 모델 이름을 붙여야 한다. 반대로 탈양자화가 알려진 한 문제를 해결했다고 모든 양자 학습이 고전적으로 모사된다는 결론도 나오지 않는다. 과제의 구조·입력·정밀도 의존성을 함께 추적한다.

출력을 모두 쓰는 비용도 간단한 하한을 준다. d개의 계수를 고전 메모리에 명시적으로 반환하라는 과제는 적어도 d개 항목을 기록해야 한다. 해 상태 한 개나 확률 표본 하나를 반환하는 알고리즘과 같은 출력이 아니다. 원소 조회만 가능한 길이 d 비트열이 전부 0인지 정확히 판정하는 결정론적 최악의 경우도 모든 위치를 읽어야 한다. 읽지 않은 한 위치를 1로 바꾸면 관측 이력이 같아져 정확성을 보장하지 못하기 때문이다. 이 단순 논증을 모든 근사·무작위 학습 문제의 하한으로 확대하면 안 된다.

벤치마크에서는 선형 모델·RBF 커널·문제에 적합한 강한 고전 모델을 비교하고 튜닝 예산을 기록한다. 양자 특징 없이 같은 차원의 삼각함수 특징을 쓰거나 얽힘 게이트를 제거한 ablation도 원인을 구분하는 데 유용하다. 작은 데이터의 정확도 차이는 반복·신뢰구간·분할 민감도를 필요로 하며 점근 우위를 대신하지 않는다. Cerezo 등의 2025년 Perspective는 알려진 학습 가능한 구조와 고전 모사성의 관계를 논의하지만, barren plateau가 없으면 항상 고전 모사가 된다는 보편 정리는 아니다.

연습문제와 풀이

1. **추정량 계산.** $x = (3, 4)$, $y = (1, 0)$에서 위 내적 추정량의 가능한 값·평균·분산을 구하라. **힌트:** $p = (9/25, 16/25)$다. **풀이:** $I = 1$이면 $Z = 25/3$, $I = 2$이면 0이다. 평균은 $(9/25)(25/3) = 3$, 두 번째 모멘트는 25이므로 분산은 16이다. 참 내적 3과 일치하지만 한 표본은 크게 흔들린다. N개 평균의 분산은 $16/N$이다.

2. **상대오차 비용.** 정규화된 두 벡터의 내적이 10^{-4}이고 상대오차 10%를 원한다. 분산 상한 1만 쓴다면 평균제곱 오차 기준 샘플 상한의 규모는? **힌트:** 필요한 가산오차를 먼저 구한다. **풀이:** 가산오차는 10^{-5}, 그 제곱은 10^{-10}이다. $1/N \le 10^{-10}$을 만족하려면 $N \ge 10^{10}$이다. 이는 보수적인 충분조건이며 최적 하한이 아니다. 차원에 독립적인 식도 정밀도에서는 비쌀 수 있다.

3. **Surrogate의 범위.** 모든 θ에 대해 $U_\theta^\dagger O U_\theta = c_1 B_1 + c_2 B_2$이며 m_1, m_2를 양자 실험으로 얻었다. 이후 훈련을 '완전히 고전 자료만 사용'이라고 써도 되는가? **힌트:** 자료 획득과 최적화를 나눈다. **풀이:** 훈련 갱신은 고전 계산이지만 입력 특징은 양자 측정으로 획득했다. '양자 사전 측정과 고전 최적화'라고 적는다. 두 기대값의 추정 오차가 e_1, e_2이면 예측 오차는 $|c_1| e_1 + |c_2| e_2$ 이하이므로 재사용 시 계수 크기도 확인한다.

4. **우위 문장 수정.** '60개 논리 큐비트가 수백만 고전 비트보다 작으므로 모든 데이터 처리에서 빠르다'를 정확한 주장으로 바꾸라. **힌트:** 메모리, 시간, 문제군과 출력은 다른 항목이다. **풀이:** '지정된 스트리밍 과제와 입력 분포·오차 조건에서, 논리 메모리 규모가 비교 고전 모델보다 작다는 이론적 결과'처럼 범위를 정한다. 시간 우위는 총 호출 수·회로 구현·입출력·고전 기준선에 대한 별도 분석이 필요하다. 논리 큐비트의 물리적 구현 비용도 60이라는 숫자에 포함되지 않는다.

학습 완료 점검

- 내적 추정량의 평균과 두 번째 모멘트를 식 없이 설명한 뒤 다시 유도한다. 평균만 맞추고 분산을 생략하면 문제 1을 반복한다.
- 우위 주장에 입력 접근·오차·실패 확률·자원·출력을 모두 적는다. 빈칸은 임의로 채우지 말고 '원문 확인 필요'로 남긴다.
- 다항 시간 고전 모사 가능성, 유한 크기의 실용 속도, 양자 자료 획득 필요성을 각각 다른 문장으로 설명한다.

원문 읽기

- Tang, A quantum-inspired classical algorithm for recommendation systems, STOC (2019). 공개 본문 **2.2 Sampling**, **3 Data Structure**, **4.1 Vector Sampling**의 제목과 설정을 확인했다. 우리의 단순 내적 추정과 추천용 저랭크 알고리즘이 어디서 달라지는지 적는다.
- Cotler, Huang, McClean, Revisiting dequantization and quantum advantage in learning tasks (2021). 입력 접근의 강도를 비교하는 보충 읽기다. 서로 다른 접근 모델에서 얻은 하한을 옮길 수 있는지 질문한다.
- Cerezo 외, Does provable absence of barren plateaus imply classical simulability?, Nature Communications (2025), Perspective. 논리적 가능성과 알려진 사례의 관계를 구분한다.
- Bowles, Ahmed, Schuld, Better than classical? The subtle art of benchmarking quantum machine learning models, 2024. 작은 분류 비교의 통제 조건을 점검한다. 논문의 대규모 benchmark를 이번 노트에서 재실행하지 않았다.

15. 생성형 양자 모델: 샘플을 만들고 분포를 검증한다

> 독립 집필한 확장 강의. 원 CMU 실라버스 밖의 보완 내용이며 원 강의의 녹취·복원이 아니다. 근거 기준일: 2026-10-20. 분포·회로·수치는 자체 구성한 교육 예제이며 논문 실험의 재현이 아니다.

앞 강의: 14. 우위와 탈양자화 · 다음 강의: 16. 대칭과 과학 학습

선수 지식과 학습 목표

3강의 얽힘, 7강의 parameter shift, 10강의 검증 분할을 복습한다. 확률·독립 표본·기댓값은 수학 보충을 참조한다. 수강 뒤에는 Born machine의 분포를 회로에서 계산하고, MMD를 확률표 없이 추정하며, 국소 통계만 맞는 모델의 실패를 반례로 설명할 수 있어야 한다. 샘플링 난도와 학습 난도를 별도의 연구 질문으로 쓰는 것도 목표다.

분류기는 x에서 라벨 y를 예측하지만, 생성기는 미지 목표분포 $p(x)$에 가까운 모델분포 $q_\theta(x)$에서 새 표본을 낸다. θ는 학습 매개변수다. p를 정확히 아는 것이 아니라 훈련 표본만 가진다는 점이 중요하다. 학습 자료의 복사, 새로운 조합의 생성, 드문 사건의 빈도 추정은 서로 다른 성능 항목이다. 검증용 표본은 훈련과 커널 선택 과정에 쓰지 않는다.

80분 학습 순서

시간	직접 할 활동
0-8분	암묵적 모델과 우도 계산의 차이를 용어로 정리한다
8-28분	Born 분포, MMD의 특징공간 표현과 표본 추정식을 유도한다
28-46분	두 큐비트 생성기와 패리티 반례를 완전히 계산한다
46-58분	기울기 측정·유한 샷의 로그 함정·최근 생성 우위의 범위를 읽는다
58-75분	핵심 문제 1-2를 독립 시도하고 분포·MMD 계산을 대조한다
75-80분	학습·샘플링·확률평가의 차이를 출구 점검한다

80분은 안내된 핵심 학습 시간이다. 남은 문제 3·4와 원문 심화 읽기는 별도 60-90분 복습에 배정한다. 문제는 먼저 독립적으로 시도한 뒤 해설을 읽는다.

핵심 용어

한국어·영어	정의와 직관
생성 모델, generative model	목표 자료의 확률분포를 근사하여 새 표본을 만드는 모델이다
Born machine	상태 진폭의 제곱을 모델 확률로 쓰는 생성기다. 정규화가 상태의 정규화에서 자동으로 따른다
암묵적 모델, implicit model	표본 생성은 가능하지만 각 $q_\theta(x)$의 효율적인 계산이 일반적으로 주어지지 않는 모델이다

한국어·영어	정의와 직관
최대우도, maximum likelihood	관측 자료의 $\sum_i \log q_\theta(x_i)$를 최대화하는 학습 기준이다
지원집합, support	확률이 양수인 사건들의 집합이다. 목표 지원집합을 놓치면 로그 손실이 발산할 수 있다
최대평균차이, maximum mean discrepancy·MMD	커널 특징공간의 평균 두 개 사이 거리다. 독립 표본의 커널 값으로 추정할 수 있다
양의 준정부호 커널, positive semidefinite kernel	임의 표본의 Gram 행렬이 양의 준정부호인 대칭 함수다. 어떤 특징 내적으로 해석할 수 있다
특성 커널, characteristic kernel	그 커널의 평균 특징이 같으면 분포도 같은 커널이다. 표현상의 식별성과 유한 표본 검출력은 다르다
주변분포, marginal distribution	일부 변수만 남기고 나머지를 합한 분포다. 저차 주변분포가 같아도 결합분포는 다를 수 있다
패리티, parity	비트 합의 짝·홀 성질이다. $\prod_j (-1)^{x_j}$로 측정하는 전역 상관이다
모드 붕괴, mode collapse	목표분포의 여러 부분 중 일부만 생성하는 실패다. 낮은 한 지표가 이를 항상 잡지는 못한다

용어집의 커널·편향·분산과 연결해서 읽는다. 생성 모델에서 '학습 가능하다'는 표현을 쓰려면 자료 접근, 학습 시간, 목표 거리와 성공 확률을 함께 지정해야 한다.

첫 번째 유도: 회로에서 분포까지

n큐비트 회로 U_θ를 $|0^n\rangle$에 적용하고 계산 기저로 측정하면

$$q_\theta(x) = |\langle x|U_\theta|0^n\rangle|^2, \qquad x \in \{0,1\}^n, \qquad \sum_x q_\theta(x) = 1.$$

마지막 등식은 U_θ의 유니터리성에서 나온다. 양자 장치가 주는 기본 출력은 x라는 표본이다. 상태벡터 시뮬레이터가 돌려주는 2^n개 정확한 확률은 실제 QPU 접근보다 강한 정보다. 모델 설계·손실·평가에서 어떤 정보를 사용했는지 표시해야 한다.

두 큐비트에서 첫 큐비트에 $R_y(2\theta)$, 이어서 첫째를 제어로 CNOT을 적용하자. 첫 단계는 $(\cos\theta|0\rangle + \sin\theta|1\rangle)|0\rangle$, 두 번째 단계는

$$|\psi_\theta\rangle = \cos\theta|00\rangle + \sin\theta|11\rangle.$$

따라서 $q_\theta(00) = \cos^2\theta$, $q_\theta(11) = \sin^2\theta$, 나머지는 0이다. 목표가 $p(00) = 3/4$, $p(11) = 1/4$이면 $\theta = \pi/6$이다. 한 비트 주변분포만 맞춘 독립 생성기는 01과 10도 만들기 때문에 같은 목표를 재현하지 못한다. 다만 고전적으로 동전을 하나 뽑아 두 비트에 복사하면 이 분포를 쉽게 생성한다. 얽힘의 표현 역할과 고전 계산 난도는 같은 결론이 아니다.

측정 비트열을 학습하는 과제와 양자 상태를 학습하는 과제도 다르다. 예를 들어 $(|00\rangle + |11\rangle)/\sqrt{2}$와 $(|00\rangle - |11\rangle)/\sqrt{2}$는 계산 기저 분포가 같다. 따라서 이 기저의 생성 표본만으로는 상대 위상을 구별할 수 없다. 목표가 비트열 생성이면 같은 분포가 정답일 수 있지만, 다른 기저에서의 상관이나 후속 양자 연산까지 재현해야 한다면 추가 측정 정보가 필요하다. 학습 목표를 먼저 정하지 않으면 확률분포의 충실성을 상태 충실도로 오해하게 된다. 생성기의 평가 대상이 고전 분포인지 밀도행렬인지 명시하자.

두 번째 유도: 특징 평균의 차이에서 MMD까지

커널이 $k(x,y)=\langle \phi(x),\phi(y)\rangle$라는 특징 내적으로 주어졌다고 하자. ϕ는 고정된 특징 사상이며 이 강의에서는 실수 커널을 쓴다. 두 분포의 특징 평균을 $\mu_p=\mathbb{E}_p\phi(X)$, $\mu_q=\mathbb{E}_q\phi(Y)$라 하면

$$\mathrm{MMD}^2(p,q)=\|\mu_p-\mu_q\|^2=\mathbb{E}k(X,X')+\mathbb{E}k(Y,Y')-2\mathbb{E}k(X,Y).$$

같은 분포에서 따로 뽑은 $X,X'\sim p$, $Y,Y'\sim q$는 모두 독립이다. 내적을 전개하고 독립성으로 평균을 분리하면 위 식을 얻는다. 표본 $x_1,\dots,x_m$, $y_1,\dots,y_l$만 있어도 다음 불편 추정량을 계산할 수 있다.

$$\widehat{\mathrm{MMD}^2}_u=\frac{\sum_{i\neq j}k(x_i,x_j)}{m(m-1)}+\frac{\sum_{i\neq j}k(y_i,y_j)}{l(l-1)}-\frac{2\sum_{i,j}k(x_i,y_j)}{ml}.$$

대각항을 제외하는 이유는 같은 표본을 두 번 쓰면 독립 표본의 기대값과 달라지기 때문이다. $m,l\geq 2$가 필요하고 순진한 계산량은 $O(m^2+l^2+ml)$다. 모집단 MMD 제곱은 음수가 아니지만 이 불편 추정량은 유한 표본에서 음수가 될 수 있다. 음수라는 이유만으로 코드 오류라고 판단하거나 무조건 0으로 잘라 통계 처리를 바꾸지 않는다. 대각항을 포함한 비음수 추정량도 가능하지만 유한 표본 편향이 있다.

커널은 어떤 차이를 보고 싶은지 정한다. $k(x,y)=\mathbf{1}\{x=y\}$이면 $\mathrm{MMD}^2=\sum_x[p(x)-q(x)]^2$다. 유한 비트열 공간에서는 서로 다른 모든 분포를 구분하지만, 큰 공간에서 동일 비트열끼리 만나는 사건이 드물면 표본 검출력이 약할 수 있다. ‘모집단에서 구분 가능’과 ‘적은 샷으로 구분 가능’을 구별한다.

완전 예제 1: 손실과 한 번의 갱신

위 두 큐비트 회로에서 $\theta=\pi/4$이면 $q(00)=q(11)=1/2$다. 지시함수 커널을 쓰면 MMD 제곱은 $(3/4-1/2)^2+(1/4-1/2)^2=1/8$이다. $a=\cos^2\theta$라 두면 손실은 $L=2(a-3/4)^2$이고 $da/d\theta=-\sin 2\theta$이므로

$$\frac{dL}{d\theta}=-4(\cos^2\theta-3/4)\sin 2\theta.$$

$\theta=\pi/4$에서는 기울기가 1이다. 학습률 0.1의 gradient descent는 θ를 약 0.6854로 줄인다. 이는 목표 $\pi/6\approx 0.5236$ 쪽 이동이다. 이 계산은 정확한 확률을 썼다. 실제 샷 기반 갱신은 손실·기울기 모두 통계 오차를 가지므로 매 스텝 손실 감소가 보장되지는 않는다. 훈련 기록의 일시적 상승을 모두 학습 실패라고 볼 수 없다.

세 번째 유도: 표본으로 기울기를 측정한다

회로에서 학습변수 φ가 한 번만 $e^{-i\varphi P/2}$, $P^2=I$에 나타난다고 하자. 다른 매개변수는 고정한다. 각 출력 확률의 도함수는 $\partial_\varphi q=(q_+-q_-)/2$이며 $q_\pm$는 $\varphi\pm\pi/2$ 회로의 분포다. 대칭 커널에서 q끼리의 기대값을 미분하면 두 자리에 같은 도함수가 생겨 2배가 된다. 따라서

$$\partial_\varphi L=\mathbb{E}_{q_+,q}k-\mathbb{E}_{q_-,q}k-\mathbb{E}_{p,q_+}k+\mathbb{E}_{p,q_-}k.$$

각 항은 서로 독립인 표본 쌍의 커널 평균으로 추정한다. 동일 샘플을 부주의하게 두 자리에 재사용하면 편향이 생길 수 있다. 매개변수가 여러 게이트에서 공유되면 각 게이트의 미분 기여를 합하거나 적절한 일반화 규칙이 필요하다. 앞 예제는 $R_y(2\theta)$이므로 θ에 대한 이동량과 계수는 $\varphi=2\theta$의 연쇄법칙으로 바뀐다. 기호만 바꾸어 동일한 이동식을 복사하면 틀린다.

완전 예제 2: 모든 저차 통계가 맞는 잘못된 분포

세 비트 짝수 집합 $\{000, 011, 101, 110\}$의 균등분포를 p, 홀수 집합 $\{001, 010, 100, 111\}$의 균등분포를 q라 하자. 각 첫 비트는 두 번 0, 두 번 1이므로 평균이 같고, 첫 두 비트는 00·01·10·11이 각각 한 번 나온다. 다른 두 비트 조합도 대칭으로 같다. 모든 한 비트·두 비트 주변분포가 일치한다.

그러나 $z_j = (-1)^{x_j}$라 두면 $\mathbb{E}_p[z_1 z_2 z_3] = 1$, $\mathbb{E}_q[z_1 z_2 z_3] = -1$이다. 두 분포의 지원집합은 완전히 분리되어 total variation distance $\frac{1}{2}\sum_x |p(x) - q(x)|$는 1이다. 특징이 z_j와 $z_i z_j$까지만 포함된 커널은 특징 평균이 같아 MMD가 0이어도 완전히 틀린 분포를 허용한다. 전역 특징 $z_1 z_2 z_3$ 하나를 추가하면 차이가 드러난다. 어떤 상관을 학습시키고 검증할지 문제 구조에 맞춰 정해야 한다.

유한 샷의 로그와 최신 결과의 범위

최대우도에서는 $-\log q_\theta(x)$가 필요하다. 참확률이 양수라도 N샷에서 한 번도 안 보일 확률은 $(1 - q_\theta(x))^N$이다. $q = 0.001$, $N = 1000$이면 약 0.368이다. 빈도 0을 참확률 0으로 간주하면 로그 손실이 무한대가 된다. 작은 상수를 더하면 수치 문제는 막지만 편향·정밀도·지수적으로 큰 지원집합 문제는 남는다. 확률표를 정확히 제공한 simulator 훈련과 실제 QPU에서 가능한 훈련을 분리해야 한다.

생성 단계가 고전적으로 어렵더라도 매개변수를 자료에서 효율적으로 배울 수 있는지는 별도다. 반대로 훈련을 고전적으로 수행한다고 생성도 고전적으로 쉬운 것은 아니다. Huang 등의 2025년 프리프린트는 구조화한 문제에서 이 두 단계를 분리한다. 보고된 새 실험은 68물리 큐비트의 깊은 회로를 816 shallow 큐비트 표현에 대응시킨다. 34,304 shallow 큐비트 결과는 기존 67물리 큐비트 샘플링 결과의 대응과 학습 모사에 근거한 추론이다. 816 shallow 규모 자체를 beyond-classical로 기대하지 않는다는 저자의 제한도 유지한다. 이 수치는 실제 816·34,304물리 큐비트 장치가 아니다.

Quantum GAN은 판별기와 생성기의 대결을 쓰는 별도 설계이며, 판별기가 양자 상태에 접근하는지 비트열만 보는지에 따라 과제가 달라진다. Quantum diffusion 같은 이름도 자료 종류·출력 규모·우도 접근·실행 수준을 확인해야 평가할 수 있다. 최신 명칭을 나열하는 대신, 작은 프로젝트에서는 독립 검증 MMD, 패리티·주변분포, 다양성, 샷 수 민감도를 함께 보고한다.

연습문제와 풀이

1. **주변분포 반례.** 목표 $p(00) = 3/4, p(11) = 1/4$와 같은 한 비트 주변분포를 가진 독립 생성기의 네 확률과 목표에서 벗어난 질량을 구하라. **힌트:** 두 비트 모두 0 확률이 3/4다. **풀이:** 독립 모델은 00에 9/16, 01·10에 각각 3/16, 11에 1/16을 준다. 목표에 없는 비트열의 질량은 6/16=3/8이다. 한 비트 통계가 모두 맞아도 상관을 놓친다.

2. **유한 표본 MMD.** 지시함수 커널에서 목표 표본 $(0, 1)$, 모델 표본 $(0, 1)$의 불편 MMD 제곱을 구하라. **힌트:** 같은 분포 내부에서는 대각항을 빼고 교차항은 모두 센다. **풀이:** 내부의 서로 다른 두 쌍 커널은 모두 0이다. 교차 네 쌍 중 두 쌍이 같으므로 교차 평균은 1/2다. 추정값은 $0 + 0 - 2(1/2) = -1$이다. 모집단 거리가 음수라는 뜻이 아니라 불편 추정량의 유한 표본 변동이다. 대각항 포함 추정량은 이 표본에서 0이다.

3. **커널과 패리티.** 세 비트에서 $k(x, y) = z_1(x)z_1(y) + z_2(x)z_2(y) + z_3(x)z_3(y)$는 양의 준정부호인가? 짝·홀 분포를 구별하는가? **힌트:** 3차원 특징 내적이다. **풀이:** 특징을 (z_1, z_2, z_3)로 두면 내적이므로 양의 준정부호다. 두 분포의 각 특징 평균이 0이므로 MMD는 0이며 구별하지 못한다. $z_1 z_2 z_3$ 특징을 추가하면 평균 차이 2의 제곱인 4가 더해진다.

4. **'샘플 없음'의 의미.** 참확률 0.01인 사건을 100샷에서 관측하지 못할 확률을 구하고, 관측 0회만으로 모델 지원집합에서 제외해도 되는지 판단하라. **힌트:** 독립 시행에서 실패가 연속될 확률이다. **풀이:** $0.99^{100} \approx 0.366$이다. 약 36.6%의 확률로 놓치므로 참확률 0이라 단정할 수 없다. 로그 손실 평가에는 확률 추정의 신뢰도와 smoothing 규칙을 명시하고, 희귀 사건을 평가하려면 표본 설계를 바꿔야 한다.

학습 완료 점검

- Born 정규화와 확률 평가 비용을 구분한다. 전체 확률표가 무료라고 말하면 첫 유도로 돌아간다.
- MMD의 세 기대값을 독립 표본으로 재구성하고, 불편 추정값의 음수가 가능한 이유를 설명한다. 문제 2를 다시 계산한다.
- '국소 지표 성공→분포 학습 성공'이라는 추론을 패리티 예제로 반박한다. 샘플링·학습·검증을 각각 한 문장으로 정의한다.

원문 읽기

- Liu, Wang, Differentiable Learning of Quantum Circuit Born Machine, Physical Review A (2018). 공개 본문 **II Model and Learning algorithm**, **II.1 Quantum Circuit Architecture Design**와 MMD·미분식을 확인한다. 본문의 회전 규약을 노트의 $R_y(2\theta)$와 비교한다.
- Rudolph 외, Trainability barriers and opportunities in quantum generative modeling, npj Quantum Information (2024). 손실의 locality와 고차 상관의 관계를 읽고 패리티 반례와 연결한다.
- Huang 외, Generative quantum advantage for classical and quantum problems, 2025 프리프린트. 공개 본문 **Fig. 2** 설명과 **Appendix C.3**의 실험 설정을 확인했다. 물리 큐비트·shallow 표현·추론 결과를 각각 적는다.
- Lloyd, Weedbrook, Quantum generative adversarial learning, Physical Review Letters (2018). 판별기가 받는 입력 종류를 확인하는 선택 읽기다.

16. 대칭을 넣은 학습과 과학 자료: 무엇을 같게 보고 무엇을 보존하는가

> 독립 집필한 확장 강의. 원 CMU 실라버스 밖의 보완 내용이며 원 강의의 녹취·복원이 아니다. 근거 기준일: 2026-10-20. 아래 대칭 증명·두 스핀 계산은 자체 구성한 학습 예제다.

앞 강의: 15. 생성형 양자 모델 · 다음 강의: 17. 내결함성 QML

선수 지식과 학습 목표

3강의 텐서곱, 6강의 회로 표현력, 14강의 구조와 고전 모사성을 복습한다. 교환자·고유값은 수학 보충을 참조한다. 이 강의 뒤에는 불변성과 등변성의 차이를 정의하고, 회로·부호화·관측량 조건으로 불변성을 증명하며, 잘못된 대칭 제약이 정답을 배제하는 반례를 제시할 수 있어야 한다. 추가로 neural quantum state의 변분 에너지를 직접 유도하고 '양자 자료를 배우는 고전 ML'의 계산 장치를 구분한다.

물리 지식을 학습기에 넣는 첫 단계는 대칭 이름을 붙이는 것이 아니라 정답의 변환 법칙을 정하는 것이다. 분자를 회전해도 에너지는 같지만 힘 벡터는 함께 회전한다. 입자 이름을 바꿔도 총에너지는 같을 수 있지만, 특정 위치 센서의 측정값은 같지 않을 수 있다. 대칭이 맞으면 불필요한 자유도를 줄이고, 틀리면 아무리 학습해도 정답을 표현하지 못한다.

80분 학습 순서

시간	직접 할 활동
0-8분	군·표현·불변·등변을 에너지와 힘 예제로 구분한다
8-28분	기대값 불변성, twirling, 대칭 부문 보존을 증명한다
28-46분	교환 대칭 예제와 두 스핀 VMC 에너지를 계산한다
46-58분	잘못된 대칭 반례와 실제 과학 학습의 입력·출력을 분석한다
58-75분	핵심 문제 1-2를 독립 시도하고 대칭 조건을 대조한다
75-80분	원하는 정답을 대칭 제약이 허용하는지 출구 점검한다

80분은 안내된 핵심 학습 시간이다. 남은 문제 3·4와 원문 심화 읽기는 별도 60-90분 복습에 배정한다. 문제는 먼저 독립적으로 시도한 뒤 해설을 읽는다.

핵심 용어

한국어·영어	정의와 직관
군, group	합성·항등·역변환이 정의되고 결합법칙을 만족하는 변환 집합이다. 회전·순열이 예다

한국어·영어	정의와 직관
군 표현, group representation	군 원소 g를 $V_g V_h = V_{gh}$를 만족하는 행렬로 나타낸다. 양자 상태에서는 유니터리 표현을 쓴다
불변성, invariance	$f(gx) = f(x)$다. 입력을 변환해도 출력이 같다
등변성, equivariance	$f(gx) = D_g f(x)$다. 출력도 지정된 표현 D_g에 따라 변한다
교환자, commutator	$[A, B] = AB - BA$다. 0이면 두 연산의 순서를 바꿀 수 있다
군 평균, twirling	연산자를 군의 모든 변환에 대해 평균하여 대칭인 부분을 남기는 연산이다
대칭 부문, symmetry sector	보존량의 같은 고유값 또는 같은 표현 성질을 가진 부분공간이다. 회로가 이를 보존하면 다른 부문으로 못 간다
귀납 편향, inductive bias	학습기가 선호하거나 허용하는 함수 구조다. 대칭 제약은 정답에 대한 사전 가정이다
신경망 양자 상태, neural quantum state	고전 신경망의 출력으로 파동함수 $\psi_\theta(s)$를 나타내는 표현이다
변분 Monte Carlo, variational Monte Carlo·VMC	$\lvert\psi_\theta\rvert^2$에 따라 표본을 뽑아 변분 에너지를 추정·최적화하는 고전 확률 계산이다
국소 에너지, local energy	$E_{\mathrm{loc}}(s) = (H\psi)(s)/\psi(s)$다. 한 구성에서 계산하지만 모든 항이 공간적으로 국소라는 뜻은 아니다

용어집의 '국소'는 회로 locality, 관측량 지지집합, local energy에서 서로 다른 맥락을 가질 수 있다. 이름이 같다고 같은 계산량 보장을 적용하지 않는다.

첫 번째 유도: 기대값 예측기의 불변성

입력 x의 부호화 상태를 $\rho(x)$, 군 원소 g의 유니터리를 V_g라 하자. 먼저 부호화가 $\rho(gx) = V_g \rho(x) V_g^\dagger$를 만족한다고 가정한다. 회로 U_θ와 Hermitian 관측량 O가 모든 g에 대해 $[U_\theta, V_g] = 0$, $[O, V_g] = 0$이면

$$\begin{aligned} f_\theta(gx) &= \mathrm{Tr}[O U_\theta V_g \rho(x) V_g^\dagger U_\theta^\dagger] \\ &= \mathrm{Tr}[V_g^\dagger O V_g U_\theta \rho(x) U_\theta^\dagger] \\ &= \mathrm{Tr}[O U_\theta \rho(x) U_\theta^\dagger] = f_\theta(x). \end{aligned}$$

첫 변형은 회로와 V_g의 교환 및 trace의 순환성, 마지막은 관측량의 대칭에서 나온다. 이는 충분조건이며 필요한 유일한 설계는 아니다. 회로 일부가 대칭이어도 부호화가 이 변환 법칙을 만족하지 않으면 증명 첫 줄이 성립하지 않는다. 전처리·큐비트 배치·측정·마지막 고전 출력층을 함께 확인해야 한다.

벡터 출력 f_a에는 관측량 묶음 O_a를 사용한다. 같은 회로 조건 아래 $V_g^\dagger O_a V_g = \sum_b D_{gab} O_b$라면 위 계산에서 마지막 줄이 $f_a(gx) = \sum_b D_{gab} f_b(x)$가 된다. 힘처럼 회전해야 하는 출력에는 이런 등변 조건이 적합하다. 스칼라 불변 출력을 여러 개 나열한다고 자동으로 벡터 등변성이 생기지는 않는다.

두 번째 유도: twirling은 어떤 정보를 지우는가

유한군 G에서 $|G|$는 원소 수다. 임의 관측량을

$$\overline{O} = \frac{1}{|G|}\sum_{g\in G} V_g^\dagger O V_g$$

로 평균한다. 임의 $h \in G$에 대해 $V_h^\dagger \overline{O} V_h$를 계산하면 합 안의 항은 $V_{gh}^\dagger O V_{gh}$가 된다. $g \mapsto gh$는 군 원소의 순서를 바꾸기만 하므로 전체 평균은 $\overline{O}$ 그대로다. 따라서 $\overline{O}$는 군과 교환한다. 이미 불변인 관측량은 평균해도 그대로이므로 twirling을 두 번 해도 한 번과 같다.

두 큐비트를 교환하는 SWAP S와 항등으로 된 군에서는 $\overline{O} = (O + SOS)/2$다. $O = Z_1$이면 $(Z_1 + Z_2)/2$, $O = Z_1 - Z_2$이면 0이다. 평균은 순서 편향을 지우지만 방향 정보도 지운다. 유한군의 크기가 크면 정확한 평균 비용이 커질 수 있다. 군 원소를 무작위로 샘플링해 평균을 근사하면 추가 분산이 생긴다. 연속군의 평균에는 적절한 정규화 Haar 측도가 필요하며 여기의 유한 합을 그대로 쓰지 않는다.

완전 예제 1: 교환 대칭이 맞을 때와 틀릴 때

입력을 $R_y(x_1)\otimes R_y(x_2)|00\rangle$로 부호화하고 회로 없이 $O = (Z_1 + Z_2)/2$를 측정하면 $f(x_1, x_2) = (\cos x_1 + \cos x_2)/2$다. $(0, \pi)$와 $(\pi, 0)$에서 모두 0이다. $Z_1 + Z_2$, X_1X_2를 생성자로 사용한 유니터리는 SWAP과 교환하므로 같은 대칭의 학습 가능한 확장이 가능하다.

그러나 라벨이 $y = x_1 - x_2$이면 두 입력의 정답은 $-\pi$, $+\pi$다. 불변 모델은 같은 값 c를 내야 한다. 두 표본의 평균 제곱오차는 $[(c-\pi)^2 + (c+\pi)^2]/2 = c^2 + \pi^2$이므로 최소도 π^2다. 최적화 실패가 아니라 가설공간의 제약이다. 이 라벨에는 순열 시 부호를 바꾸는 등변 출력이나 두 센서의 다른 역할을 명시한 입력이 필요하다.

보존되는 부문은 초기 상태에서 시작한다

Hermitian 보존량 Q와 회로가 $[U_\theta, Q] = 0$을 만족한다고 하자. $Q|\psi_0\rangle = q|\psi_0\rangle$이면 $QU_\theta|\psi_0\rangle = U_\theta Q|\psi_0\rangle = qU_\theta|\psi_0\rangle$다. 따라서 회로는 고유값 q 부문을 벗어나지 않는다. 잡음이 보존법칙을 깨면 실제 장치는 다른 부문으로 새는 leakage를 보일 수 있으므로 이상적 증명과 측정 검사를 나눈다.

예를 들어 $Q = Z_1Z_2$, $H = -Q$에서 바닥 에너지는 −1이고 짝수 패리티 부문에 있다. $|01\rangle$은 $q = -1$ 부문이므로 모든 Q보존 회로에서 에너지가 +1이다. 대칭 회로를 선택한 사실만으로 올바른 바닥 상태를 찾는 것은 아니다. 원하는 입자 수·스핀·패리티 부문을 먼저 골라야 한다. 해밀토니안의 대칭과 실제 학습 라벨의 대칭도 구별한다. 외부장·경계·자발적 대칭 깨짐을 생략하면 잘못된 가정을 넣을 수 있다.

세 번째 유도: 신경망 파동함수에서 변분 에너지까지

Neural quantum state에서는 고전 신경망이 기저 구성 s의 복소 진폭 $\psi_\theta(s)$를 계산한다. 정규화 상수 $Z_\theta = \sum_s |\psi_\theta(s)|^2$가 직접 계산하기 어려워도, 그에 비례한 분포 $p_\theta(s) = |\psi_\theta(s)|^2/Z_\theta$에서 샘플링할 수 있다고 가정한다. Hermitian 해밀토니안 H의 에너지는

$$E_\theta = \frac{\sum_{s,s'}\psi_\theta(s)^* H_{ss'}\psi_\theta(s')}{Z_\theta} = \sum_s p_\theta(s)\underbrace{\sum_{s'} H_{ss'}\frac{\psi_\theta(s')}{\psi_\theta(s)}}_{E_{\mathrm{loc}}(s)}.$$

분모가 0인 구성은 샘플링하지 않는 지원집합에서 식을 사용한다. 복소 파동함수에서는 개별 국소 에너지가 복소수일 수 있지만 전체 기대값은 실수다. Hermitian성에 맞춰 실수 부분의 표본 평균을 쓰고 허수 잔차를 수치 점검할 수 있다. 희소 H이면 연결된 s'만 합해 계산을 줄이지만 진폭비 계산과 샘플링 혼합이 어려울 수 있다.

변분 원리도 직접 확인할 수 있다. 정규화 상태를 H의 고유상태 $|E_a\rangle$로 $|\psi\rangle = \sum_a c_a |E_a\rangle$라 쓰면 $E = \sum_a |c_a|^2 E_a \geq E_0$이다. 이는 정확한 기대값의 하한이다. 유한 샘플 추정값이 우연히 E_0보다 작을 수 있으므로 한 번의 낮은 숫자를 변분 원리의 위반이나 더 좋은 상태로 해석하지 않는다. 정확한 고유상태에서는 지원집합 위 $E_{\mathrm{loc}}(s) = E_a$여서 분산이 0이라는 점도 유용한 진단이다.

완전 예제 2: 두 스핀 VMC를 손으로 계산한다

$H = -Z_1 Z_2 - h(X_1 + X_2)$, $h > 0$로 두고 실수 진폭을 $\psi(00) = \psi(11) = 1$, $\psi(01) = \psi(10) = a > 0$로 정하자. 정규화 상수는 $2(1 + a^2)$다. 같은 비트 구성에서는 $E_{\mathrm{loc}} = -1 - 2ha$, 다른 비트에서는 $E_{\mathrm{loc}} = 1 - 2h/a$다. X_1, X_2가 각각 한 비트를 뒤집으므로 이 진폭비를 얻는다.

같은 비트의 총확률은 $1/(1 + a^2)$, 다른 비트는 $a^2/(1 + a^2)$이므로

$$E(a) = \frac{-1 - 2ha + a^2(1 - 2h/a)}{1 + a^2} = \frac{a^2 - 1 - 4ha}{1 + a^2}.$$

$h = 1/2, a = 1/2$에서는 $E = -1.4$다. 비교를 위해 교환 대칭 기저 $(|00\rangle + |11\rangle)/\sqrt{2}$, $(|01\rangle + |10\rangle)/\sqrt{2}$에서 H는 $\begin{pmatrix} -1 & -2h \\ -2h & 1 \end{pmatrix}$이고 고유값은 $\pm\sqrt{1 + 4h^2}$다. 나머지 두 직교 조합의 에너지는 ±1이므로 $h = 1/2$의 전체 바닥 에너지는 $-\sqrt{2} \approx -1.4142$다. 변분 값 −1.4는 그보다 높아 원리와 일치한다.

실제 Monte Carlo에서는 독립 표본이 아닐 수 있다. 정상성·적절한 혼합과 유한 자기상관 합을 가정하면 평균 분산을 독립 표본보다 키우는 인자 $1 + 2\sum_{t \geq 1} \rho_t$를 생각할 수 있다. 여기서 ρ_t는 시차 t 자기상관이다. 10만 번 Markov chain을 갱신했다고 독립 표본 10만 개를 얻은 것은 아니다. burn-in·여러 체인·유효 표본 수를 점검해야 한다.

최근 연구를 이 기초 위에서 읽는다

Permutation-equivariant QNN 연구의 보장은 특정 표현·회로·측정 조건에 대한 것이다. 대칭 회로 전체에 동일하게 적용하지 않는다. Horizontal quantum gates 연구는 엄격한 교환 조건의 표현 제약을 다루므로, 위의 충분조건이 유일한 설계법이 아니라는 사실과 연결해 읽는다. 구조 축소가 학습과 일반화에 유리해도 고전 모사 역시 쉬워질 수 있어 14강의 비교가 필요하다.

양자 상을 분류하는 QCNN은 물리 상태에 접근하는 과제이며 작은 고전 이미지 분류와 다르다. 반대로 attention 기반 quantum-state foundation model은 고전 신경망이 여러 해밀토니안의 파동함수를 공유 표현으로 배우는 방향이다. '양자'는 대상이 양자 상태라는 뜻일 수도 있다. 모든 물질계에 일반화했다는 결론은 데이터 범위와 검증을 넘어선다. 장치·자료·예측 대상의 세 질문을 먼저 적으면 서로 다른 연구를 한 순위로 오해하지 않는다.

과학 자료의 분할도 물리적 문제와 맞춰야 한다. 같은 해밀토니안에서 나온 인접 구성들을 무작위로 나누면 새로운 해밀토니안에 대한 일반화보다 쉬운 검증이 될 수 있다. 계의 크기·결합상수·온도·경계 조건 중 무엇을 보지 않은 영역으로 남겼는지 적는다. 대칭을 보존한 자료 증강이 훈련 자료와 동일한 물리 상황을 검증 집합에 복제하지 않는지도 확인한다. 학습곡선은 회로 매개변수 수뿐 아니라 독립적인 물리 계와 상태의 수를 함께 표시해야 해석할 수 있다.

연습문제와 풀이

1. **등변 출력.** $O = Z_1 - Z_2$는 SWAP에서 어떻게 변하며, 어떤 라벨에 적합한가? **힌트:** $SZ_1S = Z_2$다. **풀이:** $SOS = Z_2 - Z_1 = -O$다. 회로가 SWAP과 교환하고 부호화가 공변이면 출력도 교환 시 부호가 바뀐다. 두 동일 역할 센서의 차이나 반대칭 라벨에 적합하다. 총에너지 같은 불변 라벨에는 이 출력만으로 일반적으로 충분하지 않다.

2. **Twirl 검산.** $O = 2Z_1 + X_1X_2$를 두 큐비트 교환군으로 평균하라. **힌트:** 두 번째 항은 교환 후 같다. **풀이:** $SOS = 2Z_2 + X_1X_2$이므로 $\overline{O} = Z_1 + Z_2 + X_1X_2$다. 다시 교환해도 같고 두 번 평균해도 같다. 계수 2를 모두 없애는 것이 아니라 두 위치에 동일하게 나눈다.

3. **VMC 계산.** 위 두 스핀 모델에서 $h = 1/2, a = 1$의 국소 에너지 두 종류와 평균을 구하라. **힌트:** 네 구성의 확률이 모두 1/4다. **풀이:** 같은 비트에서는 −2, 다른 비트에서는 0이다. 각 종류의 총확률이 1/2여서 평균은 −1이다. 정확한 바닥 에너지 $-\sqrt{2}$보다 높다. 국소 에너지가 상수가 아니므로 이 상태는 에너지 고유상태가 아니며 표본 분산도 0이 아니다.

4. **잘못된 부문.** $H = -Z_1Z_2$, 초기 $|01\rangle$, 모든 회로가 $Q = Z_1Z_2$를 보존한다. 학습률을 바꾸면 바닥 에너지에 도달할 수 있는가? **힌트:** 고유값 보존 증명을 적용한다. **풀이:** 초기 Q고유값은 −1이고 회로 뒤에도 −1이다. 따라서 에너지는 항상 +1이다. 바닥 에너지 −1은 $Q = +1$ 부문이므로 학습률·샷 수를 늘려도 해결되지 않는다. 초기 부문이나 허용 회로를 목적에 맞춰 바꿔야 한다.

학습 완료 점검

- 부호화·회로·관측량의 세 조건을 모두 써서 불변성을 증명한다. 하나를 빠뜨리면 첫 유도를 다시 전개한다.
- 맞는 대칭과 틀린 대칭의 예를 각각 제시하고 표현 불가능성과 최적화 실패를 구분한다.
- VMC 식에서 정규화 상수가 샘플링 확률에 들어가는 위치를 설명한다. 문제 3을 못 풀면 local energy의 진폭비부터 다시 계산한다.

원문 읽기

- Theoretical guarantees for permutation-equivariant quantum neural networks, npj Quantum Information (2024). 원문의 구체적 아키텍처와 보장 조건을 확인하는 읽기다. 모든 대칭 회로로 일반화하지 않는다.
- Wiersema 외, Geometric quantum machine learning with horizontal quantum gates, Physical Review Research (2025). 공개 본문 **II Background**, **II.3 Equivariant Quantum Gates**, **II.4 Horizontal Quantum Gates**, **III Starting from a symmetry: Homogeneous spaces**의 구분을 확인했다. 엄격한 교환 조건이 어떤 방향을 배제하는지 찾는다.
- Carleo, Troyer, Solving the quantum many-body problem with artificial neural networks, Science (2017). Neural quantum state와 VMC의 출발점으로 읽는다. 위 두 스핀 계산은 원문 수치 재현이 아니다.
- Zaklama, Guerci, Fu, Attention-Based Foundation Model for Quantum States, v2 2026-06-17 프리프린트. 입력 해밀토니안 범위·훈련 자료·보지 않은 계의 평가를 분리해 적는다.

17. 내결함성 QML: 선형대수의 입력·조건수·출력 비용을 계산한다

> 독립 집필한 확장 강의. 원 CMU 실라버스 밖의 보완 내용이며 원 강의의 녹취·복원이 아니다. 근거 기준일: 2026-10-20. 작은 행렬과 오류 예산은 교육용 자체 계산이다.

앞 강의: 16. 대칭과 과학 학습 · 다음 강의: 18. 2025-2026 프런티어

선수 지식과 학습 목표

4강의 진폭 부호화, 11강의 자원, 14강의 접근 모델을 먼저 읽는다. 고유값·특잇값·조건수는 수학 보충을 사용한다. 목표는 HHL·QSVT·amplitude estimation의 이름을 외우는 데 있지 않다. 수강 뒤에는 block encoding의 수학적 정의를 쓰고, 역행렬의 작은 고유값이 왜 비용과 오차를 키우는지 설명하며, 해 상태와 고전 계수 목록을 구분해야 한다. 논리 자원 추정에서 어떤 입력과 출력 항목이 빠졌는지도 판단해야 한다.

내결함성 계산은 오류정정으로 논리 오류를 충분히 낮춘 긴 계산을 뜻한다. 짧은 변분 회로에서 실행하기 어려운 선형계 풀이·coherent 추정·특잇값 변환을 검토할 수 있게 하지만, 자료 부호화와 읽기의 비용은 여전히 남는다. 이 강의는 특정 미래 장치의 속도를 예측하지 않고 알고리즘을 읽는 최소 수학과 비용 회계를 다룬다.

80분 학습 순서

시간	직접 할 활동
0-8분	논리·물리 큐비트와 block encoding 용어를 구분한다
8-28분	Ridge 회귀·block encoding·역수 필터의 수학을 전개한다
28-46분	대각 선형계와 진폭 추정의 완전 예제를 계산한다
46-58분	조건수 민감도·오류 예산·외부 상태 입력을 분석한다
58-75분	핵심 문제 1-2를 독립 시도하고 조건수·블록을 검산한다
75-80분	총 비용을 서술하고 출구 점검한다

80분은 안내된 핵심 학습 시간이다. 남은 문제 3·4와 원문 심화 읽기는 별도 60-90분 복습에 배정한다. 문제는 먼저 독립적으로 시도한 뒤 해설을 읽는다.

핵심 용어

한국어·영어	정의와 직관
물리 큐비트, physical qubit	장치에서 실제로 제어·측정하는 구성 요소다

한국어·영어	정의와 직관
논리 큐비트, logical qubit	오류정정 코드의 부호공간에 보호된 정보 단위다. 여러 물리 자원이 필요하다
내결함성, fault tolerance	국소 오류가 제어할 수 없는 논리 실패로 퍼지는 것을 억제하며 계산하는 원리다
조건수, condition number	가역 행렬에서 $\kappa(A)=\sigma_{\max}/\sigma_{\min}$다. 작은 입력 오차에 대한 해의 민감도와 알고리즘 비용에 관련된다
블록 부호화, block encoding	행렬을 더 큰 유니터리의 선택한 부분 블록으로 나타내는 접근이다
특잇값 변환, quantum singular value transformation·QSVT	부호화된 행렬의 특잇값에 허용된 다항식 변환을 구현하는 틀이다
해 상태, solution state	$A^{-1}b$의 방향을 정규화하여 진폭으로 담은 상태다. 전체 노름·모든 계수의 고전 출력과 다르다
진폭 추정, amplitude estimation	coherent 준비와 역연산 등을 이용해 성공확률을 추정하는 양자 절차다
사후선택, postselection	특정 측정 결과를 얻은 실행만 남기는 조건부 절차다. 성공확률에 따른 반복 비용이 든다
비 Clifford 자원, non-Clifford resource	Clifford 연산만으로 표현되지 않는 연산을 구현하는 자원이다. 많은 코드에서 T 게이트·magic state 공급이 주요 비용이다
양자 업로딩, quantum uploading	외부 미지 상태를 보호 메모리로 옮겨 부호화하는 절차다. 손실된 원 정보를 임의 복원하는 기능은 아니다

용어의 연관은 용어집에 정리한다. ‘논리 큐비트 수’에 물리 큐비트 환산이나 실행 시간이 이미 포함됐다고 가정하지 않는다.

첫 번째 유도: 회귀 문제를 선형계로 쓴다

$X\in\mathbb{R}^{m\times d}$는 행마다 한 표본, 열마다 한 특징인 자료행렬이고 $y\in\mathbb{R}^m$는 목표값이다. $\lambda>0$인 ridge 손실 $J(\beta)=\|X\beta-y\|_2^2+\lambda\|\beta\|_2^2$를 미분하면 $\nabla J=2X^\top(X\beta-y)+2\lambda\beta$다. 이를 0으로 놓으면

$$A\beta=b,\qquad A=X^\top X+\lambda I,\quad b=X^\top y.$$

A는 양의 정부호다. X의 가장 큰·작은 특잇값을 $\sigma_{\max},\sigma_{\min}$라 하면 $\kappa(A)=(\sigma_{\max}^2+\lambda)/(\sigma_{\min}^2+\lambda)$다. 열 방향에서 랭크가 부족하면 $\sigma_{\min}=0$으로 본다. λ는 수치 조건을 개선하지만 통계적 편향과 모델 목적도 바꾸므로 단순히 속도를 위해 무한히 키울 수 없다.

고전 알고리즘은 역행렬을 명시적으로 만들 필요가 없다. QR·SVD·반복법·preconditioning·저랭크 근사를 허용해야 한다. 정규방정식은 $\lambda=0$에서 조건수를 제곱시킬 수 있어 X 자체를 다루는 표현이 나을 수 있다. 양자 알고리즘도 어떤 행렬을 실제로 부호화하는지 명시해야 공정한 비교가 된다.

두 번째 유도: block encoding과 역수 필터

보조 큐비트 a개를 포함한 유니터리 U가 A의 $(\alpha,a,\varepsilon_{\mathrm{BE}})$-block encoding이라는 말은

$$\|A-\alpha(\langle 0^a|\otimes I)U(|0^a\rangle\otimes I)\|\le\varepsilon_{\mathrm{BE}}$$

라는 뜻이다. 노름은 연산자 노름, $\alpha > 0$는 정규화 계수다. 정확한 부호화에서는 $\varepsilon_{\mathrm{BE}} = 0$이다. U를 적용한 뒤 보조 레지스터를 0으로 사후선택하면 주 레지스터에 $A|b\rangle/\alpha$가 남으며, 성공확률은 그 벡터의 노름 제곱이다. 블록을 사용할 수 있다는 정의와 그 U를 실제 구현하는 방법은 다른 문제다.

Hermitian A가 $\|A\| \le 1$이면 형식적으로

$$U_A = \begin{pmatrix} A & \sqrt{I - A^2} \\ \sqrt{I - A^2} & -A \end{pmatrix}$$

는 한 보조 큐비트의 정확한 block encoding이다. 대각 블록의 제곱합은 $A^2 + (I - A^2) = I$, 비대각은 $A\sqrt{I - A^2} - \sqrt{I - A^2}A = 0$이므로 $U_A^2 = I$다. 마지막 교환은 같은 A의 함수라는 데서 나온다. 이 수학적 존재식이 조밀한 대형 $\sqrt{I - A^2}$를 빠르게 구현한다는 알고리즘을 주는 것은 아니다. 실제 sparse access·QROM·상태 준비에 맞는 구성 비용이 필요하다.

QSVT는 적절한 block encoding과 위상 회전을 반복하여 특잇값의 다항식 P를 구현한다. 모든 다항식이 자유롭게 가능한 것은 아니며, 유니터리 블록의 크기 제한·parity·오차 조건을 만족해야 한다. 양의 정부호 A를 정규화해 고유값이 $[1/\kappa, 1]$에 있다고 하자. 역수 필터는 이 구간에서 $P(t) \approx c/t$, $c \le 1/\kappa$를 근사한다. $1/t$ 자체는 작은 t에서 1보다 커져 유니터리 블록의 확률 진폭으로 그대로 넣을 수 없으므로 축소 계수가 필요하다.

$c = 1/\kappa$이면 성공 분기의 벡터는 $A^{-1}|b\rangle/\kappa$이고 정규화한 결과는 원하는 해 상태다. 다항식 차수·κ·정밀도·성공확률이 비용에 들어간다. 최신 선형계 알고리즘은 성공확률과 조건수 처리를 결합해 개선할 수 있으므로, 이 간단한 사후선택 계산을 모든 QSVT solver의 최적 복잡도로 제시하지 않는다.

완전 예제 1: 두 계수의 역행렬과 읽기

$A = \mathrm{diag}(1, 1/10)$, 고전 $b = (1, 1)^{\top}$라 하자. $\kappa = 10$, 고전 해는 $x = (1, 10)^{\top}$다. 정규화 입력 $|b\rangle = (|0\rangle + |1\rangle)/\sqrt{2}$에 축소 역수 $A^{-1}/10$을 적용하면 비정규화 벡터 $(|0\rangle + 10|1\rangle)/(10\sqrt{2})$다. 성공확률은 $101/200 = 0.505$, 성공 뒤 상태는

$$|x\rangle = \frac{|0\rangle + 10|1\rangle}{\sqrt{101}}.$$

계산 기저 측정은 1을 100/101 확률로 반환하며 숫자 10을 직접 주지 않는다. 전체 노름은 정규화에서 사라진다. 입력 b를 2배로 해도 같은 해 상태를 얻는다. 계수 목록·부호·전체 크기를 원하면 추가 추정이 필요하다. 반면 목표가 $\langle x|Z|x\rangle = -99/101$ 같은 소수의 기대값이면 상태 출력이 목적에 맞을 수 있다.

같은 A에서 입력이 $|0\rangle$이면 축소 역수의 성공확률은 1/100이다. 단순 반복의 평균 횟수는 100이며 coherent amplitude amplification을 허용하면 제곱근 규모로 줄일 수 있다. 그 기능에는 준비 유니터리의 역과 성공 분기를 표시하는 연산이 필요하다. 단순 샷 표본만 받아서는 같은 연산을 수행할 수 없다.

세 번째 유도: 작은 고유값은 오차도 증폭한다

A 대신 $A + \Delta A$를 구현했다고 하자. $\delta_A = \|\Delta A\|/\|A\|$, $\kappa\delta_A < 1$을 가정하면 $\|A^{-1}\Delta A\| < 1$이고 $(A + \Delta A)^{-1} = (I + A^{-1}\Delta A)^{-1}A^{-1}$이고 Neumann 급수로 역의 노름을 제어한다. 같은 우변에서 $(A + \Delta A)(x + \Delta x) = Ax$이므로 $\Delta x = -(A + \Delta A)^{-1}\Delta A x$다. 따라서

$$\frac{\|\Delta x\|}{\|x\|} \le \frac{\|A^{-1}\|\|\Delta A\|}{1 - \|A^{-1}\|\|\Delta A\|} = \frac{\kappa\delta_A}{1 - \kappa\delta_A}, \quad \delta_A = \frac{\|\Delta A\|}{\|A\|}.$$

이는 최악의 충분 상한이고 실제 오차가 항상 여기에 도달한다는 뜻은 아니다. $\kappa = 100$, $\delta_A = 10^{-4}$이면 상한은 약 0.0101이다. '입력 행렬을 0.01% 정확도로 구현했다'는 말이 해도 같은 상대정확도라는 보장은 아니다. Block encoding·다항식 근사·통계 추정의 오차 예산을 분리해야 한다.

완전 예제 2: 진폭 추정의 제곱 개선은 어떤 자원인가

준비 유니터리 $\mathcal{A}$가 성공 분기 진폭 $\sqrt{p}$를 만들고, 성공 표시와 $\mathcal{A}^\dagger$도 사용할 수 있다고 하자. $p = \sin^2\vartheta$로 놓으면 두 반사의 곱이 성공·실패의 2차원 공간에서 각 2ϑ의 회전으로 작용한다. 위상 추정은 M규모의 coherent 호출로 각도를 $O(1/M)$ 오차에서 추정한다. $|d(\sin^2\vartheta)/d\vartheta| \le 1$이므로 확률 가산오차도 $O(1/M)$다.

독립 Bernoulli 샘플은 Hoeffding 부등식으로 $N \ge \log(2/\delta)/(2\epsilon^2)$이면 오차 ϵ, 실패확률 δ를 보장한다. $\epsilon = 10^{-3}, \delta = 0.05$면 약 184만 샘플이라는 충분조건이다. 이상적 amplitude estimation은 상수 성공확률에서 $1/\epsilon$규모 쿼리를 쓰지만 상수·성공확률 증폭과 긴 회로 비용이 추가된다. '약 천 쿼리'라는 규모를 '천 번의 짧은 측정'으로 바꾸어 비교하면 안 된다. 이는 정확한 총실행 시간 예측이 아니다.

논리 자원과 외부 양자 입력

자원 표에는 논리 큐비트뿐 아니라 비 Clifford 수·깊이, magic-state 공급, 오류정정 주기, 디코딩·측정 지연, 물리 큐비트와 총시간을 기록한다. 오류 위치가 G개이고 각 위치의 논리 실패 확률 상한이 p_L이면 union bound는 $P(\text{하나 이상 실패}) \le G p_L$를 준다. 독립성은 필요하지 않지만 각 확률 상한을 정당화하는 fault model은 필요하다. $G = 10^8$, 허용 실패 0.01이면 $p_L \le 10^{-10}$이라는 보수적 예산이 나온다. 특정 코드가 이 값을 달성한다는 실험 보고가 아니다.

외부 센서의 미지 상태는 처음부터 코드 안에 있지 않다. 계산기 내부의 보호만으로 입력 인터페이스 잡음이 없어지지는 않는다. 2026년 noisy-learning 이론은 이 차이를 과제로 정식화한다. Quantum uploading 프리프린트는 상태를 즉시 보호 메모리에 부호화해 이후의 반복 노출을 줄이는 방향을 제안한다. 입력의 일회성 잡음까지 항상 제거한다는 뜻은 아니며, 해당 학습 과제·잡음 조건·즉시 부호화하지 않는 기준선에 대한 결과다. 실제 내결함성 천문 장치 실험과 구분해 18강에서 읽는다.

오차 예산은 확률과 크기를 나누어 쓴다. Block encoding 근사·다항식 근사·최종 기대값 추정의 가산 오차 상한이 각각 주어졌다면, 필요한 안정성 조건 아래 삼각부등식으로 전체 목표에 배분한다. 논리 실패 사건의 확률은 그 오차 크기와 다른 항목이며 실패 확률 예산으로 기록한다. 장치 실패 1%와 예측값 오차 0.01은 같은 숫자여도 같은 단위가 아니다. 전처리기의 구축·자료 갱신 비용도 추가한다. 양자 선형계의 조건수를 줄이는 방법을 사용했다면 고전 기준선에도 해당 전처리 또는 그에 맞는 강한 대안을 허용해야 한다. 구현의 이점은 전체 파이프라인에서 같은 정답을 얻을 때 평가한다.

연습문제와 풀이

1. **회귀 조건수.** X의 특잇값이 10과 1일 때 $X^\top X$ 및 $X^\top X + 9I$의 조건수를 구하라. **힌트:** 특잇값을 제곱한 뒤 같은 값을 더한다. **풀이:** 정규방정식의 고유값은 100과 1이어서 조건수 100이다. Ridge 행렬은 109와 10이므로 10.9다. 수치 조건은 개선되지만 $\lambda = 9$는 회귀 해 자체를 바꾸므로 같은 통계 모델의 단순 가속과 구별한다.

2. **정확한 block encoding.** 스칼라 $A = 3/5$의 한 보조 큐비트 유니터리를 쓰고 성공확률을 구하라. **힌트:** $\sqrt{1-A^2} = 4/5$다. **풀이:** $U = \begin{pmatrix} 3/5 & 4/5 \\ 4/5 & -3/5 \end{pmatrix}$이며 행의 노름은 1, 내적은 0이다. $|0\rangle$ 입력에서 보조 결과 0의 확률은 9/25다. 원하는 블록이 존재해도 매번 성공하는 것은 아니다.

3. **출력 불충분성.** 위 선형계에서 우변을 $b' = (2,2)^\top$로 바꾸면 해 상태와 고전 해는 어떻게 되는가? **힌트:** 선형성과 정규화를 구분한다. **풀이:** 고전 해는 $(2,20)^\top$로 두 배지만 정규화 상태는 여전히 $(|0\rangle + 10|1\rangle)/\sqrt{101}$다. 상태만으로 전체 배율을 알 수 없다. 계수 목록 출력 과제라면 노름 추정·tomography 등 목적에 맞는 추가 비용을 계산해야 한다.

4. **오류 예산.** 총 논리 오류 위치가 5×10^9, 허용 실패가 0.02라면 균등 p_L 상한은? 서로 독립이어야 하는가? **힌트:** union bound에 넣는다. **풀이:** $p_L \leq 0.02/(5 \times 10^9) = 4 \times 10^{-12}$다. Union bound는 독립성을 요구하지 않는다. 다만 상관 오류가 실제 코드의 위치별 상한 가정을 깨는지는 별도 검토해야 한다. 이 값만으로 필요한 물리 큐비트 수는 정할 수 없다.

학습 완료 점검

- Block encoding 정의의 α, 보조 큐비트, 오차를 모두 설명한다. 존재식과 효율적 구현을 혼동하면 두 번째 유도로 돌아간다.
- 선형계 우위 주장에 조건수·정밀도·행렬 접근·입력 상태·출력 목적을 적는다. 하나라도 불명확하면 정량 우위 판단을 유보한다.
- 진폭 추정의 $1/\epsilon$ 쿼리가 coherent 역연산을 필요로 함을 설명하고 물리·논리 자원을 분리한다.

원문 읽기

- Harrow, Hassidim, Lloyd, Quantum algorithm for linear systems of equations, Physical Review Letters (2009). 해의 고전 목록 대신 기대값을 추정하는 출력 목적과 입력 가정을 확인한다.
- Gilyén 외, Quantum singular value transformation and beyond, STOC (2019). 공개 본문 **1 Introduction**, **3.1 Quantum signal processing**, **3.2 Singular value transformation**을 확인했다. 다항식의 boundedness·parity 조건을 찾아 적는다. 전체 구성 증명은 심화 읽기다.
- Brassard 외, Quantum Amplitude Amplification and Estimation, **2 Quantum amplitude amplification**, **4 Quantum amplitude estimation**, 특히 **Theorem 12**를 확인한다. 상수 성공확률과 쿼리 단위가 무엇인지 읽는다.
- Kannan, Putterman, Cotler, Fault-tolerant quantum processing of physical experiments, v2 2026-09-06 프리프린트. **II.1 Surface-Code State Injection**, **II.2 Uploading and noisy quantum learning theory**, **III Speedups for Noisy Experiments**를 확인했다. 입력 일회성 잡음이 남는 조건을 표시한다.

18. 2025-2026 프런티어: 논문의 주장을 검증 가능한 학습 문제로 바꾼다

> 독립 집필한 확장 강의. 원 CMU 실라버스 밖의 보완 내용이며 원 강의의 녹취·복원이 아니다. 검색·대조 기준일: 2026-10-20. 이 날짜까지 확인한 선택적 사례이며 전체 최신 논문 목록이 아니다. 아래 손계산·연구 계획은 노트의 교육용 재구성이다.

앞 강의: 17. 내결함성 QML · 다음 단계: 종합 프로젝트

선수 지식과 학습 목표

10강의 공정 비교, 13강의 측정 접근, 14강의 우위 명제, 17강의 자원을 복습한다. 통계 식은 수학 보충, 연구 용어는 용어집에서 찾는다. 수강 뒤에는 최신 논문 한 편에서 문제·입력·오차·기준선·증거를 추출하고, 확인하지 못한 가정을 빈칸으로 남기며, 기존 결과를 확장해 볼 작은 반증 가능한 실험을 설계해야 한다.

이 강의는 최신 제목을 외우는 시간보다 원문을 읽는 시간을 확보한다. 논문의 ‘advantage’는 시간·메모리·표본·정확도 중 무엇을 말하는가? 실제 장치를 실행했는가, 논리 자원을 추정했는가? 증명의 문제군과 실험 자료가 같은가? 이 세 질문을 먼저 쓰면 서로 다른 연구를 한 줄 순위로 오해하지 않는다. 이론을 이해하려면 정리의 모든 가정을 읽어야 하며, 초록·소개만 확인한 항목은 그 수준을 명시한다.

80분 학습 순서

시간	직접 할 활동
0-8분	용어와 사례표를 읽고 증거 종류를 분류한다
8-28분	자원 비율·잡음 감쇠·역보정 분산을 직접 유도한다
28-46분	자원 절충과 잡음 수치의 완전 예제를 계산한다
46-58분	완료된 원문 읽기 양식을 검토하고 다른 논문의 빈 양식을 채운다
58-75분	핵심 문제 1-2를 독립 시도하고 잡음·자원 계산을 대조한다
75-80분	한 문장의 조건부 결론과 미확인 항목을 제출한다

전체 보충 증명은 80분 밖의 심화 읽기다. 수업 중 확인할 범위를 주 정리의 문장·입력 정의·대표 그림으로 좁히고, 추가 독해가 필요한 항목을 완료한 것처럼 표시하지 않는다.

80분은 안내된 핵심 학습 시간이다. 남은 문제 3·4와 원문 심화 읽기는 별도 60-90분 복습에 배정한다. 문제는 먼저 독립적으로 시도한 뒤 해설을 읽는다.

핵심 용어

한국어·영어	정의와 읽는 방법
프리프린트, preprint	동료평가 출판 전후 공개하는 저자 원고다. 버전·개정일을 함께 고정한다
최종 출판본, version of record	출판사가 확정한 학술 기록 버전이다. 최초 온라인 공개일과 다를 수 있다
문제군, problem family	크기를 바꾸어 정의하는 문제들의 집합이다. 단일 실자료 성능과 점근 정리의 범위를 나눈다
하한, lower bound	정해진 모델의 모든 허용 알고리즘이 적어도 필요한 자원이다. 테스트한 기준선 몇 개의 비용과 다르다
상한, upper bound	제시한 알고리즘이 충분히 사용하는 자원이다. 최적 비용과 같다고 보장하지 않는다
가설 검정, hypothesis testing	관측 자료로 경쟁하는 분포·과정 가설을 정해진 오류 확률 아래 구별하는 과제다
양자 통계적 쿼리, quantum statistical query·QSQ	양자 예제 상태에 대한 관측량 기대값을 허용 오차로 받는 학습 접근이다
논리 자원 추정, logical resource estimate	오류정정된 연산 단위의 회로·메모리·비용을 계산한 결과다. 실제 물리 장치 실행은 별도다
추론·외삽, inference·extrapolation	직접 측정하지 않은 규모를 대응식·모델·fit으로 추정하는 일이다. 근거와 가정이 필요하다
개방 문제, open problem	현재 결과가 해결하지 못한 구체적 수학·실험 질문이다. '더 큰 장치'만으로는 충분한 정의가 아니다
재현, reproduction	주어진 자료·코드·조건으로 특정 결과를 다시 계산하는 일이다. 논문을 읽고 설명하는 것과 구별한다

'논문 보고'는 저자가 주장한 결과, '노트 계산'은 이 강의의 독립적인 작은 계산, '후속 제안'은 미실행 연구 계획이라는 뜻으로 사용한다. 이 세 표현을 연구 노트에 함께 남긴다.

최신 사례를 범위와 함께 읽는다

원 연구와 상태	문제·실행 수준	결론을 읽을 범위
Liu 외, photonic learning, Science 389, 1332-1335 (2025); 최초 2025-02-11	실제 광학 장치의 다중 모드 변위 과정 학습	100모드 재구성과 별도 가설 검정의 기준선·보장 차이를 구분한다. 모드는 큐비트 수가 아니다
Lewis·Gilboa·McClean, shallow neural networks, 온라인 2025-12-31, VOR 2026-02-04	QSQ에서 periodic neuron을 배우는 이론	분포·접근 조건과 고전 gradient·correlational SQ 하한의 적용 모델을 명시한다

원 연구와 상태	문제·실행 수준	결론을 읽을 범위
Zhao 외, massive classical data, 최초 2026-04-08, v2 2026-10-01 프리프린트	스트리밍 oracle sketching 정리·실자료 수치·논리 자원	메모리 크기와 제한된 메모리의 표본·시간 절충이다. 실제 QPU의 범용 속도 실측이 아니다
Cotler·Gong·Kannan, noisy learning, 온라인 2026-05-29, VOR 2026-07-23	외부 미지 계에 잡음으로 접근하는 학습 이론	일부 이상적 우위의 소실과 남는 구조적 가능성을 구분한다
Kannan·Putterman·Cotler, quantum uploading, 최초 2026-05-03, v2 2026-09-06 프리프린트	미지 상태의 보호 부호화 정리·천문 영상 수치 예시	즉시 부호화하지 않는 비교 전략과의 조건부 차이다. 내결함성 천문 장치 실측은 아니다

광학 논문의 **Process reconstruction**, **Provable, scalable quantum advantage**, Fig. 2·3은 특히 나누어 읽는다. 100모드 재구성의 11.8 orders 개선은 낮은 모드 수 자료의 fit에서 외삽한 vacuum·heterodyne 기준선과의 비교다. 저자는 이 재구성만으로 provable advantage를 주장하지 않는다고 명시한다. 별도 가설 검정에서는 측정 후에 질문의 방향을 공개하여 사전 지식의 차이를 통제하고 entanglement-free 전략 하한과 비교한다. 거대한 수치 하나를 모든 과제의 실험적 시간 우위로 바꾸면 안 된다.

Shallow-network 연구는 일반 실자료 전체를 분류하는 알고리즘이 아니라 특정 periodic neuron과 충분한 분포 구조의 학습이다. 양자 예제 상태·QSQ 접근을 데이터 파일 입력으로 자동 대체할 수 없다. 고전 하한 역시 명시한 알고리즘 계열에 대한 것이므로 '모든 고전 알고리즘보다 빠르다'는 문장으로 넓히지 않는다. Massive-data 연구의 60 미만 논리 큐비트와 실자료 수치도 물리 장치의 실행 기록과 분리한다. 본 노트는 해당 대형 코드를 독립 재현하지 않았다.

생성형 최신 결과는 15강의 68물리 큐비트·816 shallow 표현과 34,304 shallow 규모 추론의 구분을 유지한다. 양자 상태를 고전 attention 모델로 학습하는 방향은 16강에서 다뤘다. 이 구분들은 주장의 가치를 줄이려는 절차가 아니라 무엇을 실제로 달성했는지 정확히 이해하는 학술 독해다.

첫 번째 유도: 우위는 세 비율로 나눈다

동일 문제·입력 조건·오차·성공확률에서 고전과 양자 알고리즘의 메모리를 M_C, M_Q, 표본 수를 N_C, N_Q, 시간을 T_C, T_Q라 하자. 교육용 비교 비율을

$$R_M = M_C/M_Q, \qquad R_N = N_C/N_Q, \qquad R_T = T_C/T_Q$$

로 정의한다. 비율이 1보다 크면 해당 자원에서 양자 쪽이 작다. 메모리는 고전 비트·정해진 정밀도 레지스터·논리 큐비트 중 단위를 명시해야 한다. 단순히 서로 나누었다고 실제 물리 크기 비율이 되는 것은 아니다. 같은 표본 수라도 한 표본을 준비하는 비용이 다르면 시간 비율은 달라진다.

전체 시간을 $T_Q = T_{\mathrm{setup}} + N_Q t_Q + T_{\mathrm{post}}$로 쓰면, N_Q만 작다는 사실에서 전체 속도가 따라오지 않는 이유가 드러난다. t_Q는 한 자료의 coherent 처리·측정 비용, T_{post}는 고전 후처리다. 입력을 매번 구축하면 setup을 반복 항으로 옮긴다. 이 회계식은 위 다섯 논문의 정리가 아니라 누락된 항을 찾는 방법이다.

완전 예제 1: 메모리는 적고 시간은 더 든다

고전 방식의 작업 메모리가 10^9비트이고 양자 방식이 30논리 큐비트라 하자. 알고리즘 단위의 크기 차이는 보고할 수 있지만 30논리 큐비트의 실제 장치 크기를 모르면 물리 메모리 비율은 정할 수 없다. 양쪽이 동일 목표에서 각각 $N_C = 10^6$, $N_Q = 10^4$자료를 사용한다면 표본 비율은 100이다.

한 자료 처리 시간이 고전 1마이크로초, 양자 1밀리초라면 핵심 처리 총시간은 각각 1초와 10초다. 여기에 양자 setup 2초를 넣으면 시간 비율은 $1/12$다. 표본 이점과 시간 불이점이 동시에 성립한다. 자료 생성이 한 개당 1초 걸리는 희귀 물리 실험이라면 상황이 뒤집힐 수 있다. 실제 목적의 비용 구조를 적어야 의미 있는 비교가 된다.

두 번째 유도: 국소 잡음이 고차 신호를 줄인다

교육용 채널을 $\mathcal{D}_p(\rho) = (1-p)\rho + pI/2$, $0 \le p < 1$로 정한다. p 규약은 논문마다 다를 수 있다. Traceless Pauli 행렬 Q에 대해 $\mathcal{D}_p^*(Q) = (1-p)Q$이고 항등행렬은 보존된다. 무게 w인 문자열 P에는 비항등 인자가 w개 있으므로

$$\mathrm{Tr}[P\mathcal{D}_p^{\otimes n}(\rho)] = \alpha\mu, \qquad \alpha = (1-p)^w, \quad \mu = \mathrm{Tr}(P\rho).$$

Heisenberg 관점에서 채널을 관측량에 옮기고 텐서곱별 감쇠를 곱한 결과다. 임의의 깊은 회로에서는 관측량 지지집합이 변하고 상관 잡음이 생길 수 있으므로 '모든 회로에서 항상 같은 감쇠'라고 쓰지 않는다.

세 번째 유도와 완전 예제 2: 역보정의 분산

잡음 뒤 Pauli 측정값 $Y \in \{-1, 1\}$의 평균은 $\alpha\mu$, 분산은 $1 - \alpha^2\mu^2$다. α를 정확히 안다고 가정하여 $\hat{\mu} = \overline{Y}/\alpha$로 보정하면 불편하지만

$$\mathrm{Var}(\hat{\mu}) = \frac{\alpha^{-2} - \mu^2}{N} \le \frac{\alpha^{-2}}{N}.$$

무잡음 측정 분산은 $(1-\mu^2)/N$다. 따라서 샷 비용의 정확한 비율은 상태에 의존하고 $\mu = 0$일 때 α^{-2}가 된다. α도 추정해야 하면 보정 계수 불확실성과 편향이 추가된다.

$p = 0.01, w = 100$에서는 $\alpha = 0.99^{100} \approx 0.3660$, $\alpha^{-2} \approx 7.46$이다. $\mu = 0$의 표준오차를 0.05로 맞추려면 무잡음 400샷에 비해 보정은 적어도 약 2986샷이라는 분산 기준 계산을 얻는다. $w = 10$이면 계수는 약 1.22다. 동일 잡음률이라도 관측량의 차수가 중요하다. 이는 전체 noisy-learning 정리나 실제 오류 완화 성능의 재현이 아니다.

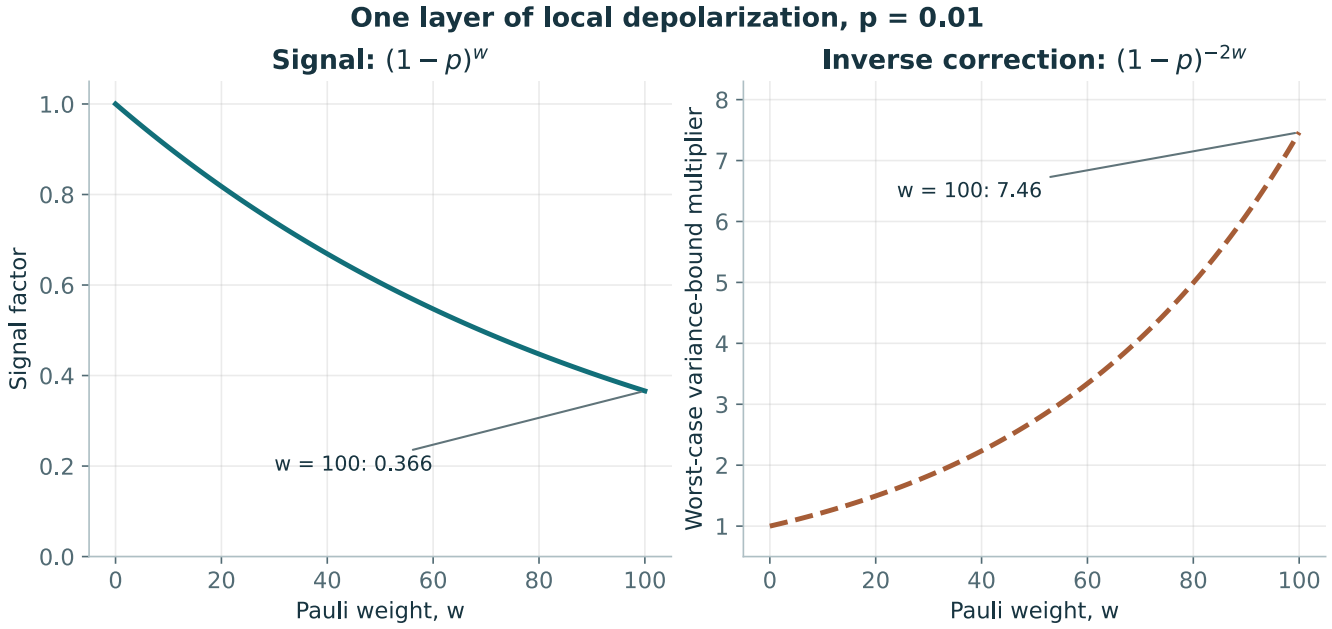


그림 18-1. 본문의 단일 층·큐비트별 독립 채널을 해석적으로 계산한 곡선이다. 오른쪽은 단순 역보정의 분산 상한 계수이며 실제 샷 비율은 원 상태 평균과 보정 계수의 추정 오차에도 의존한다. 실제 장치 데이터가 아니다.

원문 읽기 양식과 완료 예시

빈 양식을 복사해 논문 한 편에 적용한다. (1) 제목·버전·날짜, (2) 자료 한 개의 물리적 의미, (3) 준비·역연산·메모리·측정의 허용 기능, (4) 목표 거리·오차·실패확률, (5) 고전 또는 비부호화 기준선의 허용 자원, (6) 정리·그림 위치, (7) 실제 실행 수준, (8) 입증하지 않은 범위, (9) 후속 실험을 적는다. 이 아홉 항목은 원문 문장을 옮기는 요약보다 문제를 재구성하는 데 목적이 있다.

확인하지 못한 정리의 상수·범위는 '미확인'으로 남긴다. 예를 들어 초록의 exponential을 보고 임의의 2^n을 비용식에 넣지 않는다. Big-O의 변수, 숨은 상수의 독립성, 고정한 잡음률, ϵ과 δ의 의미를 본문에서 찾는다. 정리의 상한과 실험의 finite-size 결과가 직접 비교 가능한지도 확인한다. 빈칸은 무지가 아니라 다음 독해의 정확한 목표다.

완료 예시는 uploading 원고의 **Theorem 2, informal**이다. 버전은 v2 2026-09-06, 자료는 외부 n큐비트 미지 상태, 목표는 k국소 Pauli 추정이다. 비교는 물리 상태에 brickwork 무작위 전처리를 하는 raw 방식과 즉시 부호화한 shallow-shadows 방식이다. 원문은 상수 잡음 λ, 주입 잡음 $\lambda < \eta < c\lambda$에서 $N_{\mathrm{raw}}/N_{\mathrm{inj}} \geq \exp(\Omega(\lambda k))$라는 비형식 정리를 제시한다. 정밀도·실패확률과 상수의 완전한 범위는 보충 정리 확인 항목으로 남긴다. 실제 장치 실행 결과로 분류하지 않는다.

이 예시에서 노트가 도출하는 후속 질문은 '유한 k에서 주입 준비 시간까지 넣어도 총시간이 줄어드는가'다. 위 비율은 표본 비교이므로 총시간 답을 주지 않는다. 작은 계산 계획은 raw·uploaded의 같은 목표 오차를 고정하고 표본 수, 전처리 깊이, 입력 준비 시간, 논리 비용을 따로 바꾸는 것이다. 실패 조건은 주입 비용 때문에 총시간 차이가 사라지거나 추정 오차가 목표를 넘는 경우다. 이러한 계획은 아직 실행하지 않은 제안이며 원 논문의 새로운 결론이 아니다.

연습문제와 풀이

1. **감쇠 계산.** $p = 0.02, w = 20, \mu = 0$에서 역보정의 분산 계수와 표준오차 0.1에 필요한 샷을 구하라. **힌트:** $\alpha^{-2} = 0.98^{-40}$다. **풀이:** 계수는 약 2.244이고 $\mathrm{Var} \leq 2.244/N$이다. 표준오차 0.1에는 $N \geq 224.4$, 정수 225샷을 쓴다. 무잡음의 100샷보다 늘어난다. 이는 분산 기준이며 신뢰구간 보장을 따로 요구하면 추가 설계가 필요하다.

2. **단위 점검.** 100모드 광학 실험과 100물리 큐비트 장치의 크기가 같다고 써도 되는가? **힌트:** 기저 공간과 실험 자원을 비교한다. **풀이:** 아니다. 광학 모드는 연속변수 자유도이고 큐비트는 2차원 정보 단위다. 모드의 에너지·squeezing·손실·시간 다중화 자원을 적어야 비교할 수 있다. 숫자 100만으로 정보 용량·하드웨어 규모·계산 우위를 동일시하지 않는다.

3. **미확인 가정.** 논문 초록에서 표본 우위만 확인했고 정리의 오차 척도를 못 찾았다. 기존 노트의 MSE를 대신 넣어도 되는가? **힌트:** 문제 정의가 같아지는지 생각한다. **풀이:** 안 된다. MSE·가산 기대값 오차·분포 거리·검정 오류는 다른 목표다. '오차 척도 미확인, 정리·보충자료 확인 필요'라고 적고 정량 우위 계산을 보류한다. 같은 문제로 바꾸어 비교하려면 두 척도 사이의 정당한 변환을 증명해야 한다.

4. **후속 실험 설계.** 표본 수는 100배 줄지만 한 표본 처리 시간이 1000배 커진다. 어떤 결과를 보고하고 어떤 조건에서 실용 이점이 남는가? **힌트:** 자료 획득 시간도 넣는다. **풀이:** 처리만 비교하면 총시간은 10배 증가한다. 두 방식을 각각 $N_C(t_{\mathrm{data}} + t_C)$, $(N_C/100)(t_{\mathrm{data}} + 1000t_C)$로 쓰면 양자 쪽이 작을 조건은 $99t_{\mathrm{data}} > 900t_C$다. 자료 생성이 충분히 느리면 표본 절약이 총시간을 줄일 수 있다. 추가 setup 비용이 있으면 그 조건도 포함한다.

학습 완료 점검

- 원문 한 편을 아홉 항목 양식으로 작성하고 미확인 가정을 분명히 남긴다. 초록의 문구만 복사한 답은 완료가 아니다.
- 광학 재구성의 fit 외삽과 가설 검정의 하한 비교를 구분한다. 구분하지 못하면 Fig. 2·3과 관련 단락을 다시 읽는다.
- 표본 우위·시간 우위·물리 자원 우위를 각각 따로 판단하고 후속 실험의 실패 조건을 쓴다. 종합 프로젝트는 이 판단을 작은 재현 가능한 실험으로 이어간다.

원문 읽기

- Photonic learning 공개 본문: **Process reconstruction**, **Provable, scalable quantum advantage**, Fig. 2·3을 확인했다. 경험적 외삽과 하한의 적용 과제가 같은지 비교한다.
- Shallow neural networks 출판본: Introduction의 quantum example·QSQ와 고전 하한 모델을 확인한다. 무제한 고전 알고리즘으로 적용 범위를 넓히지 않는다.
- Massive classical data v2: 버전·초록의 메모리 주장과 실자료·논리 큐비트의 실행 수준을 확인했다. 완전 정리의 가정은 본문·보충자료로 이어서 읽는 과제다.
- Noisy quantum learning theory: 최초 공개·VOR 날짜와 입력 인터페이스 문제를 확인했다. 정리마다 noise·메모리 조건이 다른지 추적한다.
- Quantum uploading v2 공개 본문: **II Quantum Uploading**, **III.1 Classical shadow tomography**, **Theorem 2**, 보충 **S5**가 완료 예시의 읽기 위치다. 비형식 정리와 완전한 기술 가정을 구분한다.

자율학습 워크북: 정의에서 독립 계산과 논문 검토까지

> 독립 학습 시리즈 2.0의 기록 양식 · 근거 기준일 2026-10-20. 아래 빈칸은 독자가 채운다. 완성 예시는 교육용 해석 계산이며 실제 QPU나 원강좌 수강 기록이 아니다.

이 워크북은 답을 옮기는 공책보다, 무엇을 혼자 설명할 수 있는지 확인하는 기록이다. 강의마다 다음 양식을 복사하거나 인쇄해 사용한다. 정답을 본 경우에는 보았다고 표시한다. 힌트 이용은 실패가 아니라 다음 복습 때 무엇을 다시 풀어야 하는지 알려 주는 정보다. 공부 시간은 실제 기록을 쓰며 학습 안내의 제안 시간과 혼동하지 않는다.

수학 보충편의 준비 문제 8개로 출발점을 확인하고, 모르는 말은 한영 용어집에서 찾는다. 80분 첫 세션에는 선택한 문제 1-2개를, 이후 60-90분 복습에는 네 문제와 유도 재작성을 배정한다. 아래 권장 기준은 검증된 평가 시험이나 공식 수강 요건이 아니다.

1. 전체 진도 기록

표의 빈칸에는 날짜와 한두 단어의 결과를 쓴다. 강의 번호는 이 독립 시리즈의 번호다. 강의별 기록이 충분하지 않으면 읽었다는 표시만으로 완료 처리하지 않는다.

강의	첫 세션 날짜·실제 분	용어 5개 회상	유도 1개 재작성	네 문제 중 독립 풀이 수	오답 재풀이 날짜	완료 점검
01	___	___	___	___/4	___	___
02	___	___	___	___/4	___	___
03	___	___	___	___/4	___	___
04	___	___	___	___/4	___	___
05	___	___	___	___/4	___	___
06	___	___	___	___/4	___	___
07	___	___	___	___/4	___	___
08	___	___	___	___/4	___	___
09	___	___	___	___/4	___	___
10	___	___	___	___/4	___	___
11	___	___	___	___/4	___	___
12	___	___	___	___/4	___	___
13	___	___	___	___/4	___	___
14	___	___	___	___/4	___	___
15	___	___	___	___/4	___	___

강의	첫 세션 날짜·실제 분	용어 5개 회상	유도 1개 재작성	네 문제 중 독립 풀이 수	오답 재풀이 날짜	완료 점검
16	___	___	___	___/4	___	___
17	___	___	___	___/4	___	___
18	___	___	___	___/4	___	___

첫 준비도 문제: 독립 풀이 ___/8, 막힌 준비 절 ___, 오답 수정 날짜 ___. 여섯 문제 이상을 해설 없이 설명하고 나머지를 재계산하는 것을 권장 출발점으로 삼는다. 총점이 같아도 켤레 내적이 막힌 경우와 복잡도 문장이 막힌 경우에는 돌아갈 절이 다르다.

2. 강의 한 회 기록 양식

강의 번호·제목: ___
학습일·자료 판본: ___
사전 준비 실제 시간: ___분
첫 세션 실제 시간: ___분
복습 실제 시간: ___분
오늘 설명하려는 질문 한 문장: ___

용어 다섯 개

용어를 찾기 전에 자신의 정의를 쓰고, 확인 뒤 수정한다. 번역어만 맞히지 않고 식과 구별점을 남긴다. 영어 용어가 한 문장에 세 개 이상 낯설다면 학습 안내의 용어 공부법을 먼저 적용한다.

한국어·영어·약자	내 말로 쓴 정의	기호·식 또는 짧은 예	닮았지만 다른 용어	확인 후 고친 부분
1. ___	___	___	___	___
2. ___	___	___	___	___
3. ___	___	___	___	___
4. ___	___	___	___	___
5. ___	___	___	___	___

유도 하나를 다시 쓰기

유도할 결론: ___
입력·출력과 각 기호의 뜻·차원: ___
필요 가정: ___
사용한 정의 또는 앞 강의 식: ___

단계	내가 쓴 식·행렬곱·확률 계산	다음 줄로 넘어가는 근거
출발	___	정의·초기 조건 ___
중간 1	___	항등식·선형성·정규화 등 ___

단계	내가 쓴 식·행렬곱·확률 계산	다음 줄로 넘어가는 근거
중간 2	___	독립성·직교성·최적화 등 ___
중간 3	___	생략한 연산이 없는가 ___
결론	___	원래 질문에 대한 해석 ___

표의 줄 수는 필요한 만큼 늘린다. “정리로부터”라고만 쓰기보다 어떤 정리의 어느 조건이 충족되는지 쓴다. 반각 공식이나 공분산 항이 사라지는 이유를 설명하지 못하면 그 단계를 빈칸으로 남기고 돌아갈 절을 적는다.

계산을 검산한 방법: 단위·극한·특수값·별도 행렬 계산 중 ___
가정을 하나 빼면 깨지는 단계: ___
막혔을 때 돌아갈 정확한 절 또는 강의: ___

숫자를 바꾼 예제와 반례

본문 예제의 조건: ___
바꿀 숫자·입력·측정·가정 한 가지: ___
계산 전에 예상한 변화: ___
직접 얻은 계산값과 단위: ___
예상과 다르면 원인: ___

흔한 주장 한 문장: ___
그 주장이 깨지는 반례: ___
반례에서 유지되는 정의와 빠지는 가정: ___
반례를 반영해 고친 정확한 문장: ___

예를 들어 “얽힘이 있으면 고전 계산이 어렵다”에는 Clifford 회로의 조건을, “정규화해도 원래 거리가 유지된다”에는 x와 $-x$를 사용할 수 있다. 반례의 이름만 쓰지 않고 실제 값이나 가능한 측정 통계를 남긴다.

네 문제와 힌트 이용 기록

문제	첫 시도의 식·결론	힌트·풀이를 보기 전 해결했는가	확인한 힌트·해설 범위	오답 원인	답을 덮고 다시 푼 결과·날짜
1	___	예/아니오	___	___	___
2	___	예/아니오	___	___	___
3	___	예/아니오	___	___	___
4	___	예/아니오	___	___	___

오답 원인은 정의, 기호·단위, 계산 기술, 가정 누락, 문제 자체의 해석 중 무엇인지 구체적으로 쓴다. 독립 풀이 수를 세고, 최소 세 문제를 독립적으로 설명하며 남은 문제도 수정·재풀이하는 것을 권장한다. 풀이를 본 직후 그대로 베껴 쓴 것은 독립 해결 수에 넣지 않는다.

원문·판본과 다음 행동

기록 항목	내가 확인한 내용
제목·저자·연도·URL	___
판본·확인 날짜	arXiv v___ / 출판본 ___ / 날짜 ___
실제 읽은 위치	초록 / Section ___ / 정리 ___ / Figure ___
원문에서 확인한 정의·주장	___
본문 노트와 다른 규약	___
읽지 않은 증명·미확인 실험	___
다음 복습의 질문 하나	___

완료 점검 답: ___
조건부 진행 또는 복습 결정: ___
다음 행동과 자료 위치: ___
다음날 용어·유도 회상 결과: ___

3. 완성 예시: 07강의 공유 파라미터 미분

이 예시는 기록 깊이의 기준을 보여준다. 아래 숫자는 이상적 한 큐비트 식에서 계산했다. 물리 장치·유한 샷 측정의 보고가 아니다. 07강의 전체 용어와 문제를 대신하지도 않는다.

질문: 같은 θ가 두 게이트에 나타나면 왜 전체 각도를 ±π/2 이동하는 규칙이 실패하는가?

정의: parameter-shift rule은 특정 생성자 스펙트럼에서 기대값 미분을 이동 기대값들의 조합으로 쓰는 항등식이다. parameter sharing은 하나의 학습 변수가 여러 게이트에 들어가는 일이다. analytic derivative는 정확한 함수 관계이며 finite-shot estimator의 오차가 0이라는 뜻이 아니다. chain rule은 각 출현 위치의 기여를 더하도록 한다. identifiability는 서로 다른 파라미터가 예측에서 구별되는지에 관한 성질이며 공유 여부와 같은 개념은 아니다.

상태·관측·가정: 초기 상태는 $|0\rangle$, 회로는 $R_y(\theta)R_y(\theta)$, 관측량은 Z다. 회전은 $R_y(t)=e^{-itY/2}$이고 각도 단위는 rad다. 게이트와 관측은 이상적이며 기대값은 정확하게 계산한다. 회로 출력과 제곱 손실을 다른 기호로 둔다.

유도:

$$R_y(\theta)R_y(\theta)=R_y(2\theta),\qquad f(\theta)=\cos 2\theta,\qquad f'(\theta)=-2\sin 2\theta.$$

두 게이트가 같은 축을 사용하므로 합각으로 묶었다. $\theta=\pi/8$이면 $f=\sqrt{2}/2$, $f'=-\sqrt{2}$다. 그러나 공유 변수 전체를 이동하면

$$f(\theta+\pi/2)=\cos(2\theta+\pi)=-\cos 2\theta,\qquad f(\theta-\pi/2)=\cos(2\theta-\pi)=-\cos 2\theta$$

이므로 차분이 0이다. 0은 진짜 미분 −√2와 다르다. 한 게이트의 생성자 조건을 전체 공유 파라미터에 그대로 적용한 오류다.

해결하려면 $g(\alpha,\beta)=\cos(\alpha+\beta)$로 두 출현을 분리한다. 각 변수는 게이트 하나에만 나타나므로

$$\frac{\partial g}{\partial \alpha}=\frac{g(\alpha+\pi/2,\beta)-g(\alpha-\pi/2,\beta)}{2},\qquad \frac{\partial g}{\partial \beta}=\frac{g(\alpha,\beta+\pi/2)-g(\alpha,\beta-\pi/2)}{2}.$$

$\alpha = \beta = \pi/8$에서 각 + 이동값은 $-\sqrt{2}/2$, 각 − 이동값은 $+\sqrt{2}/2$다. 두 편미분은 각각 $-\sqrt{2}/2$이고, $d\alpha/d\theta = d\beta/d\theta = 1$이므로

$$f'(\theta) = \frac{\partial g}{\partial \alpha} + \frac{\partial g}{\partial \beta} = -\sqrt{2}.$$

원래 해석 미분과 일치한다. 목표 y=0에 대한 $\ell = (f-y)^2$라면 $\ell' = 2(f-y)f' = -2$다. 출력 미분 −√2를 그대로 손실 기울기로 사용하는 것도 또 다른 오류다.

숫자 변경: θ=0에서는 진짜 미분도 0이므로 잘못된 규칙과 우연히 일치한다. 따라서 특수값 하나의 일치만으로 구현을 검증할 수 없다. θ=π/8처럼 영점이 아닌 값을 추가한다. θ=π/4라면 f=0, 출력 미분 −2이지만 y=0의 제곱 손실 미분은 0이다. 출력과 손실의 미분을 구별하는 추가 검산이다.

자원 메모: 게이트별 이동식에는 네 평가 항이 나타난다. 이 예제에서는 두 게이트가 commute하여 일부 이동회로가 같은 함수로 단순화될 수 있다. 일반 공유 회로에서 항상 두 설정만 필요하다고 결론 내리지 않는다. 같은 finite-shot 추정값을 재사용한다면 미분 합의 분산에서 공분산을 포함해야 한다.

원문 읽기 범위: Schuld et al., Evaluating analytic gradients on quantum hardware의 생성자·이동 규칙 조건을 추가 확인한다. 위 공유 회로와 수치는 자체 교육 예제이며 논문 전체 실험을 재현한 결과가 아니다.

완료 기준: 전체 이동이 왜 0인지, 게이트별 합이 왜 −√2인지, 손실 미분이 왜 −2인지 세 계산을 답 없이 다시 만들면 이 예제를 이해한 것으로 기록한다. 막히면 06강의 합각·비식별성, 수학 P7의 chain rule, 07강의 공유 변수 문단으로 돌아간다.

4. 실습 한 회 기록 양식

먼저 실습 안내의 실행 조건을 확인한다. 실행 성공과 학습 목표 달성은 별도로 기록한다. 명령은 사용한 실제 명령을 쓰고, 출력 전체를 무조건 공개 배포물로 복사하지 않는다.

기록 항목	내용
Lab 번호·질문	___
연결한 강의·식	___
실행 날짜·코드 판본	___
Python·NumPy·SDK 버전	___
실행 수준	고전 exact 모사 / finite-shot 모사 / 실제 QPU / 기타 ___
seed·데이터 생성·분할	___
설정	qubits ___ / layers ___ / parameter occurrences ___ / shots ___
실행 전 해석·수치 예상	___
실제 명령·주요 산출물	___
관측값·단위·오차막대의 정의	___
예상과의 차이·원인	___
추가 측정·보정·준비 비용	___

기록 항목	내용
조건 한 가지를 바꾼 재실행	___
결과로 말할 수 있는 것	___
아직 말할 수 없는 것	___

실습	꼭 확인할 비교	내 결과 요약
Lab 1	해석식·게이트 모사·유한 샷의 차이	___
Lab 2	원 벡터 거리·진폭 fidelity·중심 갱신	___
Lab 3	동일 분할의 고전 기준선·커널·VQC	___
Lab 4	깊이·잡음·관측량에 따른 신호	___
Lab 5	완화 전후 bias·variance·MSE·샷 비용	___

Lab 5의 calibration을 고정했다면 그 조건에서의 분산이라고 표시한다. Lab 3의 seed 사이 표준편차를 곧바로 95% 신뢰구간이라고 표시하지 않는다. exact 모사에서 짧게 실행된 시간을 물리 장치의 학습 시간이라고 기록하지 않는다. 비교가 기대와 다르면 먼저 데이터·식·실행 수준이 같은지 확인한다.

5. 논문 한 편의 여덟 질문: 빈 양식

아래 양식을 논문마다 작성한다. 동일 논문도 arXiv 판본·출판본에서 조건이나 수치가 다르면 따로 기록한다. 원문을 읽은 범위를 직접 표시하고, 확인하지 못한 칸은 추측 대신 “미확인”으로 남긴다.

제목·저자·URL: ___
판본·최초 공개일·수정일·출판 상태: ___
내가 읽은 위치·확인 날짜: ___

1. **입력과 접근은 무엇인가?** 고전 숫자, 양자 상태·채널, oracle, qRAM, 개별·집단 측정 중 허용되는 접근과 초기 준비·재준비 비용을 적는다.
   기록: ___
2. **출력과 목표 정확도는 무엇인가?** 고전 벡터·상태·label·기댓값·샘플 중 출력 형태, 가산·상대·분포 오차와 성공 확률을 적는다.
   기록: ___
3. **정리나 방법의 핵심 가정은 무엇인가?** 데이터 구조·조건수·대칭·국소성·잡음·회로 앙상블·메모리 제한을 원문의 위치와 함께 적는다.
   기록: ___
4. **비교 대상은 같은 과제를 푸는가?** 고전 알고리즘의 입력 접근·출력·오차·튜닝 예산을 맞췄는지, 빠진 강한 기준선이 있는지 적는다.
   기록: ___
5. **어떤 자원이 줄어드는가?** 시간·표본·샷·메모리·통신 중 대상과 숨긴 정밀도·준비·출력·보정 비용을 적는다.
   기록: ___
6. **증거는 무엇인가?** 정리·고전 모사·컴파일·논리 자원 추정·실제 QPU 실험을 구별하고, 핵심 식·정리·도표 번호와 보고 수치를 적는다.

기록: ___

7. **내가 확인하거나 재현한 범위는 어디까지인가?** 서지 확인, 작은 수식 검산, 저자 코드 실행, 독립 구현, 장치 재실행을 구별하고 미수행 부분을 적는다.
   기록: ___
8. **무엇이 아직 미입증이며 다음에는 무엇을 검증할 것인가?** 논문의 결과를 넘어서는 주장을 하나 제한하고, 가정 하나를 바꾼 후속 실험·계산과 실패 기준을 적는다.
   기록: ___

한 문장으로 정리한 실제 결과: ___
저자의 보고와 내 해석을 구별한 문장: ___
이 노트의 어느 강의와 연결되는가: ___

6. 프로젝트 종료 때 남길 자료

프로젝트 세 제안 중 하나를 골라 질문, 가정, 비교 기준, 실행 계획을 먼저 기록한다. 결과가 좋은 쪽으로 나온 뒤 지표와 종료 조건을 바꾸었다면 변경 사실을 남긴다. 실패 사례도 왜 가설을 지지하지 않는지 해석한다.

제출할 결과	내 파일·문서와 확인 내용
질문·가정·입출력·오차의 한 장 명세	___
실행 환경·코드 판본·seed·명령	___
비교표·불확실성·전체 비용	___
직접 검산한 식과 반례	___
실패 분석·미재현·미입증 범위	___
논문 읽기 양식 두 편	___
다음 독자가 반복할 절차	___

이름 붙인 용어를 스스로 정의하고, 계산 과정을 재구성하고, 반례로 주장 범위를 좁힐 수 있으면 학술적인 읽기로 이어진다. 모르는 부분은 기록해 다음 학습 대상으로 남긴다.

실습: 양자 모델을 만들고, 비용과 한계를 함께 측정하기

근거·실행 기준일: **2026-10-20**. 이 실습은 공개된 CMU 17-620 Quantum Machine Learning 강의 안내에서 주제를 참고해 이 아카이브용으로 새로 작성했다. 원 수업의 노트북·과제·해설을 확보하거나 복제한 자료가 아니다. 원 수업의 Lab 번호와 아래 번호가 일대일로 대응하지는 않는다.

목표는 작은 양자 모델을 직접 계산하면서, 데이터 인코딩이 보존하는 정보, 고전 비교 기준, 측정 비용, 잡음 보정의 편향과 분산을 함께 이해하는 것이다. **기록된 모든 실행은 CPU상의 고전 시뮬레이션 또는 선형대수 계산이다. 물리 QPU 실행은 없으며 양자 우위도 측정하지 않았다.** Lab 4의 시간은 가정에 따른 산술 계산이고 Lab 5의 잡음은 명시적으로 만든 모형이다.

설치와 실행

권장 재현 환경은 **Python 3.12.14, NumPy 2.3.5**다. 기본 실습에는 NumPy만 필요하다. 패키지 설치 뒤 실행에는 인터넷, API key, 클라우드 계정이 필요하지 않다. 아래 명령은 이 강의 시리즈 폴더에서 실행한다.

```
python3.12 -m venv .venv
. .venv/bin/activate
python -m pip install -r labs/requirements.txt
python labs/qml_labs.py --lab all --output labs/results/my-results.json
```

한 개만 실행하려면 `--lab 1`부터 `--lab 5`까지 선택한다. `--output`을 생략하면 JSON을 표준 출력에 표시한다. 보존된 기준 결과는 reference-results.json이다. 이 파일에는 버전, seed, 데이터 조건, 학습 설정, 수치 결과, 실행 수준이 들어 있다. 내 결과는 다른 파일명으로 저장해 기준 결과와 비교한다. 기본 스크립트는 Python 3.9.6 / NumPy 2.0.2에서도 실행을 확인했지만, 고정 requirements는 권장 환경용이다. 부동소수점의 마지막 자릿수는 BLAS·플랫폼에 따라 달라질 수 있다.

실습	준비 지식	권장 시간	얻어야 할 결과
1. 회로·기댓값·미분	복소 벡터, 행렬 곱, 미분	60-90분	Bell 상관과 parameter shift의 수치 검증
2. 인코딩·군집화	내적, 노름, 고유벡터	90-120분	정규화·전역 위상으로 사라지는 정보 확인
3. 커널·VQC·고전 비교	ridge 회귀, train/test 분리	120-180분	고정 조건에서 반복 seed 성능표
4. 하드웨어 비용 장부	이항분포, 회로 실행	60-90분	회로 수·샷 수·대기시간 가정의 분리
5. 잡음·측정 보정·ZNE	분산, 선형 방정식	120-180분	편향 감소와 분산 증가의 동시 측정

실습 중 `assert`는 단순히 출력이 이전 실행과 같은지만 검사하지 않는다. 해석식과 게이트 행렬, 독립적인 실행 수 열거, Richardson 모멘트 조건 등 서로 다른 표현으로 같은 관계를 확인한다. 기본 Python 실행을 사용하고 `python -O`로 검사를 비활성화하지 않는다.

Lab 1. Bell 상태와 미분 가능한 회로

질문: 측정 결과의 상관을 보았다는 것과 양자 코히런스를 확인했다는 것은 어떻게 다른가? 회로를 두 번 이동시켜 미분을 구할 수 있는 이유는 무엇인가?

```
python labs/qml_labs.py --lab 1
```

기저 순서는 `|q0 q1⟩ = |00⟩, |01⟩, |10⟩, |11⟩` 이며 q0가 최상위 비트다. `H(0)` 와 `CNOT(0,1)` 로

$$|\Phi^+\rangle = (|00\rangle + |11\rangle)/\sqrt{2}$$

를 만든다. 이상적인 Z 측정 확률은 `(1/2,0,0,1/2)` 다. 기준 실행의 4,096회 독립 샷은 `(2110,0,0,1986)` 이다. 정확한 기댓값은 `⟨Z0⟩=0` , `⟨Z0Z1⟩=1` , `⟨X0X1⟩=1` 이다. 대각 혼합상태 `ϱ=(|00⟩⟨00|+|11⟩⟨11|)/2` 도 같은 Z 분포를 내지만 `⟨X0X1⟩=0` 이다. 따라서 Z counts만으로 얽힘을 인증했다고 쓰면 안 된다. 여기서는 상태벡터와 혼합상태의 정확한 계산으로 차이를 확인했으며, 유한 샷 얽힘 witness의 통계적 인증은 수행하지 않았다.

다음에는 단일 큐비트 `Ry(θ)|0⟩` 에서 `f(θ)=⟨Z⟩=cos θ` 를 계산한다. `Ry(θ)=exp(-iθY/2)` 의 생성자 고유값은 ±1/2이므로

$$f'(\theta) = \frac{f(\theta + \pi/2) - f(\theta - \pi/2)}{2} = -\sin\theta.$$

`θ=0.73 rad` 에서 해석 미분 `-0.6668696350` , parameter shift `-0.6668696350` , 중앙 유한차분 `-0.6668696351` 이 일치한다. 이동한 두 회로에 각 4,096샷을 쓰면 seed 101의 추정값은 `-0.6774902344` , 알려진 모형에서 계산한 표준오차는 약 `0.0082331` 이다. 한 번의 무작위 추정값은 정확한 미분과 일치할 필요가 없다.

직접 할 일: θ를 0, π/2, π로 바꾸고 확률·기댓값·분산의 관계를 기록한다. 샷 수를 네 배로 늘렸을 때 표준오차가 약 절반인지 반복 실험한다. 생성자의 스펙트럼이나 한 파라미터의 다중 게이트 공유가 바뀌어도 이 단순한 두 회로 공식을 그대로 적용할 수 있는지 조사한다.

Lab 2. 인코딩은 어떤 정보를 없애는가

질문: 고전 벡터를 양자상태로 옮겼을 때 원래의 거리와 군집 구조가 보존되는가?

```
python labs/qml_labs.py --lab 2
```

두 인코딩을 구분한다.

- 진폭 인코딩은 실수 2차원 벡터 v를 `|v⟩=v/||v||` 인 한 큐비트 상태로 바꾼다. 영벡터는 허용하지 않는다. 일반 d차원 데이터에는 2의 거듭제곱 차원으로 padding과 정규화가 필요하며 상태 준비 비용은 이 작은 계산에 포함되지 않는다.
- 각도 인코딩은 두 숫자를 `Ry(x0)|0⟩ ⊗ Ry(x1)|0⟩` 에 넣는다. 두 큐비트가 필요하며 각도는 rad 단위다. 2π 주기의 물리적 동일성과 스케일 선택이 데이터의 의미에 영향을 준다.

진폭 상태의 fidelity `K(v,w)=|⟨v|w⟩|²` 는 원 벡터의 노름을 없애고 전역 부호도 구분하지 못한다. v와 −v의 fidelity는 1이지만 정규화한 고전 벡터의 제곱 유클리드 거리는 4다. v와 10v도 같은 상태다. 표준 정규화 절차를 작은 기술적 단계로만 생각하면 문제의 목표 자체를 바꿀 수 있다.

코드는 같은 8개 정규화 벡터에 두 가지 Lloyd 반복을 적용한다. 유클리드 k-means는 산술평균 centroid를 사용한다. 여기서 새로 구현한 **projective fidelity clustering**은 `Σ_i[1-|⟨x_i|c⟩|²]` 를 줄이며, 각 군집의 `Σ_i |x_i⟩⟨x_i|` 의 최대 고유값 고유벡터를 단위 centroid로 선택한다. 이는 Rayleigh quotient의 해다. 목적함수가 다른 알고리즘이므로 유클리드 k-

means를 양자적으로 가속했다고 부르지 않는다. `1-K` 역시 일반적인 거리의 삼각부등식을 자동으로 만족하는 metric이라고 가정하지 않는다.

기준 실행의 projective 군집은 `(0,0,0,0,1,1,1,1)`이고 최종 목적함수는 `0.0792079`다. 유클리드 군집은 `(0,0,1,1,1,1,0,0)`이며 목적함수는 `4.0396040`이다. **서로 다른 목적함수의 숫자 크기로 어느 군집화가 더 좋다고 비교하면 안 된다.** 초기 centroid를 고정했으므로 전역 최적해를 보장하지도 않는다.

각도 인코딩의 fidelity는

$$K(x,y)=\prod_{j=0}^{1}\cos^2((x_j-y_j)/2)$$

이며, 코드가 게이트 행렬 내적과 이 식을 따로 계산해 확인한다. 예제 쌍에서 `0.2985717802`로 일치한다.

직접 할 일: 부호가 의미 있는 데이터와 의미 없는 데이터를 각각 만든다. 노름이 목표값을 결정하는 데이터도 만든다. 어떤 인코딩에서 예측 불가능한 충돌이 생기는지 보이고, 노름·부호를 별도 고전 feature로 보존하는 방법을 제안한다. 상태를 만드는 전체 게이트 수를 모른 채 "n개의 실수를 $\log_2 n$ 큐비트에 넣으므로 효율적"이라고 결론 내리지 않는다.

Lab 3. 같은 데이터에서 커널, VQC, 고전 기준 비교

질문: 비선형 분류에 도움이 되는 양자 표현을 찾았다는 것과 고전 계산보다 유리하다는 주장은 어떻게 구별되는가?

```
python labs/qml_labs.py --lab 3
```

합성 데이터는 독립 균등분포 `x~U([-1.4,1.4]²)`이며 정답은 `y=sign(x0x1)∈{-1,+1}`이다. seed `(11,23,37,41,53)`마다 새로 뽑은 240개를 앞 80개 학습, 뒤 160개 시험으로 분리한다. 입력 정규화나 feature 선택을 시험 데이터에 맞추지 않는다. ridge λ=0.1, VQC 600회·학습률 0.08은 사전에 정한 교육용 값이고 튜닝 결과가 아니다. 현실 데이터에 대한 일반화 검증은 아니다.

비교 모델은 선형 ridge, 고전 삼각함수 feature ridge, 위 각도 fidelity kernel ridge, 고전 RBF kernel ridge, 두 파라미터 VQC다. kernel ridge는 `α=(K+λI)⁻¹y`를 선형 방정식으로 풀며 prediction은 `K(test,train)α`다. SVM을 구현한 것은 아니다. Gram 행렬의 대칭성·단위 대각·양의 준정부호를 확인한다. 유한 샷 kernel의 음수 고유값과 보정은 이 실습 밖의 확장 문제다.

VQC는 `Ry(x0),Ry(x1) → Ry(θ0),Ry(θ1) → CNOT(0,1) → ⟨Z1⟩`이다. 고전 gain·bias를 포함한 출력은 `g fθ(x)+b`, 학습 손실은 평균제곱오차다. θ의 미분은 parameter shift로 계산하고 g,b는 고전 미분으로 갱신한다. 시험 정답은 학습·조기 종료·파라미터 선택에 사용하지 않는다.

이 회로는 정확히

$$f_\theta(x)=\cos(x_0+\theta_0)\cos(x_1+\theta_1)$$

이므로 빠른 고전 식으로 학습한다. 별도의 게이트 행렬 계산을 각 seed의 시험 데이터 10개와 대조한다. 또한 `cos x0 cos x1`, `cos x0 sin x1`, `sin x0 cos x1`, `sin x0 sin x1`의 선형결합으로 정확히 전개되므로 같은 feature를 쓰는 강한 고전 기준도 함께 넣었다. 이 실습의 fidelity kernel도 단순한 두 변수 삼각함수 곱이다. **얽히는 회로를 쓴다는 사실만으로 고전적으로 어려운 모델이 되지 않는다.**

기준 실행의 시험 정확도는 다음과 같다. ±는 다섯 seed 사이의 표본 표준편차이며 신뢰구간이나 우월성 유의성 검정이 아니다. 모든 행은 같은 seed에서 같은 분할을 사용했다.

모델	시험 정확도 평균 ± seed 표준편차
선형 ridge	0.58625 ± 0.09222
고전 삼각함수 feature ridge	0.88500 ± 0.05441
각도 fidelity kernel ridge	0.87375 ± 0.05104
고전 RBF kernel ridge	0.91875 ± 0.03395
VQC + 고전 gain,bias	0.91875 ± 0.04122

"VQC가 선형 모델보다 잘했다"는 이 합성 데이터의 결과는 맞지만, 고전 RBF와 평균 정확도가 같고 모든 계산을 고전 CPU로 수행했다. 하이퍼파라미터·모델 용량·최적화 방법도 완전히 같은 자원으로 맞춘 비교가 아니다. 시간 우위, 표본 복잡도 우위, 하드웨어 내잡음성은 측정하지 않았다.

직접 할 일: 검증 분할을 새로 두고 모든 모델의 λ·RBF 폭·VQC 초기화를 같은 탐색 예산으로 고른 뒤 마지막 시험을 한 번 수행한다. 클래스 균형, balanced accuracy, 학습곡선, 데이터 분포 이동도 보고한다. 양자 모델에만 feature를 유리하게 고르거나 고전 기준을 선형 모델 하나로 제한하지 않는다.

Lab 4. 샷과 대기시간까지 포함한 하드웨어 실험 설계

질문: 작은 VQC의 파라미터 수를 알 때 실제로 요청할 회로·샷 수는 얼마나 되는가?

```
python labs/qml_labs.py --lab 4
```

기본 비용 예제는 Lab 3을 그대로 실행한 기록이 아니라 **별도의 가상 workload**다. 파라미터 P=6, batch B=12, 학습 T=25회, 비가환 측정 group G=2, 회로 설정별 S=2048샷이다. 모든 파라미터를 독립적인 두 회로 shift로 미분하고, 각 예제에 forward 회로 하나를 추가한다고 가정하면

$$N_{\text{settings}} = TB(1+2P)G = 7800, \qquad N_{\text{shots}} = SN_{\text{settings}} = 15,974,400.$$

공유 파라미터의 다중 등장, 회로 캐싱, stochastic gradient, 샷 재사용, adjoint 방식에 따라 다른 식이 필요하다. 측정 group 수는 observable의 통근 관계와 측정 계획에서 결정해야 한다. 코드에서는 인덱스 조합을 실제로 열거해 같은 수를 확인한다.

회로 설정 300개/job, 샷당 50μs, job당 queue 30초와 고정 overhead 0.2초를 **임의로 가정**하면 26 jobs, 샷 실행 798.72초, 직렬 queue 합 780초, overhead 5.2초, 총 1583.92초다. 이는 실제 제공자 측정·견적·예측이 아니다. job의 병렬 처리·재시도, calibration, routing, reset·측정 구성, 데이터 전송·상태 준비 비용에 따라 달라진다. 샷당 시간도 한 회로 길이에 대한 예시일 뿐이다.

같은 파일은 80개 학습 데이터의 이상적 대각을 생략하고 대칭을 재사용하는 kernel 비용도 센다. 학습 비대각 3,160쌍과 test-train 12,800쌍, 합계 15,960회 overlap 설정이다. noisy diagonal을 실제 측정해야 한다면 별도로 추가해야 한다. kernel 구축비와 VQC 학습비를 예측 하나의 비용으로 혼동하지 않는다.

마지막으로 `⟨Z⟩=cos(0.73)`를 128,512,2048,8192샷으로 각각 1,000번 이항 샘플링한다. 이론 표준오차 `sqrt((1-⟨Z⟩²)/S)`와 경험 RMSE를 비교하면 샷 64배가 표준오차 8배 감소에 해당한다.

실제 QPU로 확장할 때는 qpu_submission_template.json을 새 결과 파일에 복사해 채운다. provider/backend, SDK/plugin 버전, calibration 시각, physical qubit mapping, native gate 수, transpiled depth, job ID, counts, queue/QPU/wall 시간, 비용과 보정 전후 불확실성을 기록한다. `null`은 아직 측정하지 않았다는 뜻이다. **이 템플릿은 제출**

코드를 포함하지 않으며 현재 실습은 인증정보를 읽거나 클라우드 작업을 제출하지 않는다. 실제 실행 조건과 예산을 결정한 뒤 해당 제공자의 공식 문서로 제출 코드를 작성해야 한다.

Lab 5. 측정 보정과 ZNE가 편향·분산에 미치는 영향

질문: 오차 완화로 평균값을 개선해도 더 많은 샷이 필요한 이유는 무엇인가?

```
python labs/qml_labs.py --lab 5
```

여기서는 회로의 물리 채널을 시뮬레이션하는 대신, 이상값 `E0=cos(0.73)=0.7451744`와 명시적 스칼라 모형 `E(s)=E0 exp(-0.12s)`를 둔다. noise scale `s=(1,2,3)`에서 이항분포로 ±1 측정값을 만든다. **gate folding, 펄스 늘이기, 실제 장치의 noise scaling을 구현한 것은 아니다.**

먼저 true state 0과 1을 각 20,000샷 준비했다고 가정한 대칭 측정 오류 8% 모형에서 assignment 행렬 A를 추정한다. 행은 observed bit, 열은 true bit이며 `pobs=A ptrue`다. 역행렬 해와 기댓값의 affine correction을 대조한다. 보정은 관측 확률의 통계 변동도 확대하며, A가 특이행렬에 가까울수록 불안정해진다. 결과를 확률 범위나 [−1,1]로 임의 clipping하지 않는다. clipping하면 편향·분산 추정 자체가 달라진다.

ZNE는 세 scale의 보정된 추정치를 `3E(1)-3E(2)+E(3)`으로 합친다. 계수의 합은 1이고 s, s^2에 대한 가중합은 0이므로 noise expansion의 첫 두 항을 소거한다. 지수함수에는 더 높은 차수 항이 남는다. 정확한 무샷 결과에서도 ZNE 값은 `0.7440969`, 이상값 대비 편향 `-0.0010775`로 0이 아니다.

각 scale에 과학 측정 4,000샷을 쓰고 1,000회 실험을 반복했다. calibration은 한 번 뽑아 모든 반복이 공유한다. 따라서 아래 표준편차와 코드의 이론 표준오차는 **그 calibration에 조건부**이며 calibration uncertainty를 전파하지 않았다. 반복마다 calibration까지 다시 하는 bootstrap은 확장 과제다. 1,000회 반복은 분포를 교육용으로 추정하기 위한 계산이며, 한 번의 실제 실험 비용과 구분한다.

추정기	평균	이상값 대비 bias	표본 표준편차	RMSE
scale 1 raw, 4,000샷	0.55517	−0.19001	0.01277	0.19044
scale 1 readout 보정, 4,000샷	0.65361	−0.09157	0.01512	0.09281
readout 보정 + ZNE, 3×4,000샷	0.73655	−0.00862	0.06837	0.06888
readout 보정만, scale 1에 12,000샷	0.65369	−0.09149	0.00907	0.09194

마지막 행은 ZNE와 같은 총 과학 샷 12,000개를 사용하는 예산 비교다. 두 방법 모두 calibration 40,000샷은 별도이며 같다. ZNE의 분산은 독립 추정치라면 $\Sigma\, c_i^2\, \mathrm{Var}(E_i)$ 다. 계수 제곱합은 19이지만 scale별 분산이 서로 달라 정확한 증폭률이 항상 19인 것은 아니다. 이 모형에서는 ZNE가 예산을 맞춘 RMSE도 줄였으나, 작은 noise나 적은 샷에서는 분산 증가 때문에 더 나빠질 수 있다. 오차 완화는 오차 정정이나 내결함성의 증명이 아니다.

직접 할 일: noise rate를 0.01부터 0.30까지, 총 과학 샷을 300부터 30,000까지 바꾸어 같은 예산의 RMSE를 비교한다. calibration을 매 반복 다시 추정해 전체 불확실성을 포함한다. 서로 다른 scale 사이에 noise drift를 넣고 선형·이차 외삽 중 어느 쪽이 실패하는지 본다. 원하는 결론이 나오는 scale만 사후 선택하지 않는다.

선택 실습: PennyLane과 독립 대조

원 수업의 SDK 입문 주제를 따라가되, 위 NumPy 구현을 독립 기준으로 삼는다. **Python 3.12.14 / PennyLane 0.45.1 / NumPy 2.3.5**로 다음 선택 실습도 실제 실행했다.

```
python -m pip install -r labs/requirements-pennylane.txt
python labs/pennylane_compare.py --output labs/results/my-pennylane-results.json
```

`default.qubit`, `shots=None`에서 Bell 상태, parameter-shift 자동미분, `AmplitudeEmbedding(normalize=True)`, 각도 feature overlap, VQC 기댓값을 독립 NumPy·해석식과 비교한다. 이 SDK의 정확한 상태벡터도 물리 하드웨어가 아니다. 보존 결과는 pennylane-results.json, 당시의 전체 설치 버전은 sdk-lock.txt다. 고정 requirements는 실습 재현을 위한 기록이며 이후 최신 지원 버전이라는 주장은 아니다.

SDK 코드의 사용법은 PennyLane QNode 공식 문서, parameter-shift 공식 문서를 확인했다. 수식의 출처를 SDK 동작과 혼동하지 않도록 미분 자체는 Schuld et al., 2019, ZNE의 원리는 Temme et al., 2017을 함께 읽는다. 이 코드가 해당 논문의 실험을 재현하는 것은 아니다.

제출·검토 기준

실습마다 질문, 수학적 가정, 실행 명령, 버전, seed, 실제 결과, 비교 기준, 한계를 1-2페이지로 정리한다. 기대한 결과와 다른 값이 나왔다면 숨기거나 seed를 바꾸기보다 어떤 조건이 달랐는지 기록한다. 무작위 결과의 한 표본과 기댓값을 구분하고, 정확도 우위와 시간·샷·데이터·구현 비용 우위를 각각 평가한다. 후속 캡스톤 세 프로젝트에서 비교 설계를 확장할 수 있다.

작성·검증: Codex 보조로 독립 작성한 교육용 코드다. 실제 실행과 해석 항등식 대조 범위는 위와 같으며, 원 강좌 담당자의 검토·승인·과제 정답을 의미하지 않는다. 시리즈 전체의 책임 편집·사람 검토 상태는 상위 안내를 따른다.

캡스톤: 양자 머신러닝의 성능 주장에 필요한 증거 만들기

이 문서는 원 수업의 과제 복제가 아니라, 독립 실습을 확장하도록 새로 설계한 세 프로젝트다. 각 프로젝트는 2-4주 규모이며 하나를 골라 완결해도 된다. **양자 우위가 없는 결과, 오차 완화가 실패한 결과도 설계와 분석이 정확하면 높은 점수를 받을 수 있다.** QPU 계정·유료 실행은 필수 조건이 아니다. 물리 장치를 사용하지 않으면 보고서의 실행 수준을 고전 시뮬레이션으로 표시한다.

공통 제출물은 문제 정의 1페이지, 식·가정과 비교 계획, 실행 가능한 코드·고정 환경, 재현 명령, seed별 원시 수치, 최종 보고서 6-10페이지다. 공개 가능한 합성·오픈 데이터만 포함한다. 모델 선택에 사용하지 않은 최종 시험 집합을 보존하고, 실행 전 정한 설정과 결과를 보고 변경한 설정을 구별한다. 비공개 계정·credential·장치 토큰·내부 경로는 제출하지 않는다.

프로젝트 A. 데이터 인코딩이 만드는 정보 손실과 분류 성능

핵심 질문: 진폭·각도·재업로드 인코딩의 성능 차이는 어떤 정보가 남는지, 어떤 고전 feature와 같은지로 설명할 수 있는가?

Lab 2·3을 출발점으로 데이터 세 종류를 만든다. 첫 번째는 `label=sign(x0x1)`인 방향 과제다. 두 번째는 방향을 유지하고 노름만 달리해 label을 정하는 방사형 과제다. 세 번째는 전역 부호로 label이 바뀌는 과제다. 각 데이터에서 진폭 encoding, 각도 encoding, `angle → trainable rotation → angle` 형태의 두 번 data re-uploading을 비교한다. 데이터 크기는 train 40/80/160, validation 80, final test 400 이상으로 하고 최소 5개 seed를 사용한다. 수치는 제안 범위이며 계산 예산에 맞게 실행 전에 수정해도 된다.

비교 기준에는 선형, RBF kernel, 원 feature의 적절한 다항식·삼각함수 모델을 포함한다. 모든 모델의 하이퍼파라미터 선택에 같은 validation 데이터와 명시한 탐색 예산을 준다. 정확도뿐 아니라 balanced accuracy, 파라미터 수, kernel 계산 수, 샷 가정, 학습·시험 데이터 크기를 보고한다. 실행 시간은 환경과 반복 횟수·warm-up을 함께 기록하며 작은 NumPy 최적화 차이를 양자 계산 속도로 해석하지 않는다.

최종 산출물에는 “같은 양자상태인데 다른 정답을 갖는 입력 쌍”을 최소 하나 제시한다. 충돌이 있는 인코딩에서 classifier를 아무리 복잡하게 해도 회복할 수 없는 정보가 무엇인지 논증한다. 노름을 별도 고전 입력으로 주는 hybrid 모델을 추가하고 정보가 복구되는지 측정한다.

평가 항목	배점	충족 조건
정보 손실에 대한 수학적 설명	25	전역 위상·정규화·주기성을 구별하고 충돌 예제 증명
비교 설계와 데이터 분리	25	같은 분할, 검증 기반 선택, 시험 누수 없음
구현과 수치 검증	20	상태 정규화·kernel PSD·독립 해석식 대조
반복 결과와 비용 보고	20	seed 분포, 표본 크기, 자원 정의, 강한 고전 기준
해석과 재현성	10	입증·미입증 범위, 명령·환경·코드 일치

해설 힌트: 진폭 encoding에서는 $|v\rangle$와 $|-v\rangle$의 density matrix가 같다. 동일한 density matrix에 대한 모든 POVM의 분포도 같으므로, 부호로 label이 바뀌는 대칭 균형 데이터에서 이 encoding만 사용하는 모델은 두 label을 구별할 수 없다. 이는 optimizer 실패가 아니다. 각도 encoding의 원래 fidelity kernel은 삼각함수 feature의 고전 내적으로 펼칠 수 있다. re-uploading이 늘린 Fourier 성분과 같은 고전 feature 기준을 비교해야 “표현력이 증가했다”는 해석이 구체적이다. Lab 3의 기준 실행에서 고전 RBF와 VQC의 평균 정확도는 모두 0.91875였지만, 그 값은 새 데이터·튜닝의 목표 점수가 아니다.

프로젝트 B. 유한 샷 kernel과 VQC의 동일 예산 비교

핵심 질문: 데이터·회로·측정 예산을 고정하면 kernel과 VQC 중 어디에 자원이 쓰이며 성능이 어떻게 변하는가?

같은 합성 분류 문제에서 `Ntrain=(20,40,80)`과 샷 예산 $(10^4, 10^5, 10^6)$의 작은 격자를 먼저 정한다. Lab 4의 회로 장부를 확장해 kernel 구축, VQC forward·gradient·시험 예측, calibration, hyperparameter 탐색을 따로 센다. 모든 비용을 하나로 숨기지 말고 무엇이 총 예산에 포함되는지 명시한다. kernel은 대칭 pair를 재사용하고, noisy diagonal을 측정할지 이상값으로 고정할지 미리 결정한다. VQC는 총 회로 수가 예산을 넘으면 batch·iteration·샷을 어떻게 줄일지 정한다.

Lab 3의 exact kernel을 성공확률로 사용해 각 원소를 유한 샷 이항 샘플링한다. 그 결과를 대칭화하고 고유값을 조사한다. PSD projection을 쓰는 경우 음수 고유값을 0으로 자르는 것이 원래 추정기와 학습 문제를 어떻게 바꾸는지 기록한다. projection 뒤의 대각 재정규화 여부도 명시한다. VQC도 ±1 outcome의 유한 샷으로 forward와 parameter shift를 추정한다. 같은 데이터 seed 안에서 shot seed를 최소 10개 바꿔 데이터 표본 불확실성과 측정 불확실성을 분리한다.

오프라인 계산만으로 완결할 수 있다. QPU를 추가한다면 결과 템플릿의 실제 값을 기록하고 컴파일 자원과 물리 결과를 따로 보인다. 제출 스크립트는 기본 실행에서 클라우드 요청을 보내지 않게 분리한다. queue는 timestamp에서 측정한 값만 결과로 쓰고, 가정값은 시나리오 분석에만 쓴다.

평가 항목	배점	충족 조건
동일 예산의 명확한 정의	25	학습·추론·튜닝·calibration 비용 포함 여부 명시
유한 샷 kernel 처리	20	sampling, 대칭, PSD와 projection 영향 구별
VQC 측정·최적화 구현	20	독립 shift sampling, 총 요청 횟수 정확
실험 설계·오차 분석	20	여러 데이터/shot seed와 동일 분할, 편향 포함
재현성과 실행 수준 표시	15	재실행 코드와 실제 QPU·가정 시간의 분리

해설 힌트: 이상적인 pure-state kernel의 diagonal은 1이지만 finite-shot overlap 구현이나 실제 noisy channel에서 diagonal을 무조건 1로 놓으면 다른 추정 문제를 풀게 된다. train pair 수는 off-diagonal만 재사용할 때 `N(N-1)/2`, test 비용은 `Ntest N`이다. VQC의 두 회로 parameter shift 비용은 독립 파라미터당·샘플당·측정 group당 두 설정이며 반복 학습비가 붙는다. Gram matrix 원소별 unbiased sampling도 PSD를 보장하지 않는다. PSD 보정은 유효한 학습 규칙일 수 있으나 quantum advantage의 증거는 아니다. 단일 회로의 작은 표준오차가 전체 Gram matrix나 gradient의 안정성을 자동으로 보장하지 않는다.

프로젝트 C. 오차 완화가 이득이 되는 영역과 실패하는 영역

핵심 질문: 같은 총 샷에서 readout mitigation과 ZNE가 언제 RMSE를 줄이고 언제 늘리는가?

Lab 5의 스칼라 모형으로 시작해 noise rate `(0.01,0.04,0.12,0.24)`, 총 과학 샷 `(300,3000,30000)`, calibration 샷 `(1000,10000,40000)`을 조사한다. 이 숫자는 사전 계획이며 예산에 맞는 더 작은 격자로 줄여도 된다. scale `(1,2)`의 선형 ZNE와 `(1,2,3)`의 이차 ZNE, readout 보정만, raw를 비교한다. 각 셀에서 calibration·science를 모두 새로 뽑는 500회 이상 Monte Carlo를 수행한다. raw와 보정 추정기의 RMSE·bias·variance를 같은 이상값에 대해 계산한다.

이차 외삽의 샷 배분을 동일 배분과 `|ci| sqrt(Var_i per shot)`에 비례하는 배분으로 비교한다. oracle 분산을 썼는지 pilot 샷으로 추정했는지, pilot 비용을 포함했는지 구별한다. 이상값을 기준으로 scale을 사후 선택하는 절차를 실용적인 방법이라고 소개하지 않는다.

다음으로 `E(s)=E0 exp(−λs)+δs²` 같은 단순 모형 변경이나 scale 사이의 readout drift를 넣는다. 모형이 깨질 때 보정이 좋아 보이는 평균값과 실제 RMSE가 어떻게 어긋나는지 보여 준다. 선택적으로 density matrix에 depolarizing·amplitude damping 채널을 적용한 작은 회로로 확장하되, noise scaling을 실제로 어떻게 구현했는지 명시한다. 고전 density-matrix 실험은 물리 하드웨어 결과로 표시하지 않는다.

평가 항목	배점	충족 조건
추정기·noise 가정의 정확성	20	assignment 방향, 외삽 계수, 독립성 가정 명시
총 예산 비교	20	calibration·pilot·science 비용 일관성
편향·분산·RMSE 분석	25	무작위 calibration 포함, 반복 수·불확실성 보고
실패 영역과 모형 변화	20	저잡음·적은 샷·drift 등 반례 포함
재현성과 주장 경계	15	물리 scaling·QEC 미입증을 정확히 구별

해설 힌트: Lab 5의 quadratic Richardson 계수 `(3,−3,1)`은 `Σci=1`, `Σci si=0`, `Σci si²=0`을 만족한다. 독립 추정치일 때 분산은 `Σci²vi`이므로 noise가 작아 이미 편향이 작은 조건에서는 추가 분산 때문에 ZNE가 더 나빠질 수 있다. 동일 분산을 가정하면 계수 제곱합은 19다. 고정 총 샷 S에서 `vi=vi/Si` 라면 Lagrange multiplier로 `Si∝|ci|sqrt(vi)`가 나온다. Lab 5의 calibration을 고정한 반복은 전체 calibration uncertainty를 포함하지 않았으므로 본 프로젝트에서는 이를 고쳐야 한다. 보정 확률을 잘라내는 postprocessing을 썼다면 그로 생긴 bias까지 RMSE에 포함한다.

최종 구두 검토 질문

1. 결과의 어느 부분이 실제 실행이고 어느 부분이 가정·해석인가?
2. 고전 모델을 더 강하게 바꿔도 결론이 유지되는가?
3. 인코딩·상태 준비·kernel 구축·측정·보정 비용 중 빠진 것은 무엇인가?
4. 같은 결과를 얻기 위해 필요한 데이터와 총 샷이 얼마인가?
5. 어떤 반례나 분포 이동에서 내 결론이 깨지는가?
6. 다른 사람이 새 환경에서 같은 명령으로 표와 그림을 만들 수 있는가?

프로젝트의 성공 기준은 유리한 정확도 한 줄을 얻는 것이 아니라, 선택한 모델이 무엇을 계산했고 어떤 조건에서 유용했는지 다른 사람이 확인할 수 있게 만드는 것이다.

출처와 확인 범위

근거 기준일: 2026-10-20. 원 강좌 주제는 공식 홈페이지·공개 세션 개요에서 확인했다. 과학 내용은 원 논문·저자 원고·공식 SDK 문서를 우선했다. 아래 목록은 길잡이이며 강의별 원문 링크와 설명이 함께 참고문헌을 구성한다. 원문·도표·강의 자료를 통째로 재배포하지 않는다.

원 강좌

- Daniel Justice, CMU 17-620: Quantum Machine Learning, Fall 2026 Mini-2. 홈페이지와 12개 세션의 공개 개요를 확인했다. 웹 검색 도구의 일부 접근 실패를 공개 HTML 직접 열람으로 보완했다. 확인일 2026-10-20, 페이지 갱신 표시 2026-10-19. 비공개 Canvas 과제·영상·성적 기준은 확보하지 않았다.
- 강좌 소개 LinkedIn 게시물. 원 강좌를 찾는 출발점이며 과학적 우위를 입증하는 근거로 사용하지 않았다.

기초·모델·미분

문헌	읽을 이유·확인 범위
IBM Quantum Learning: Basics of Quantum Information	상태·측정·유니터리의 공식 교육 자료. 작은 예제는 별도로 유도
Lloyd, Mohseni, Rebentrost, quantum supervised/unsupervised learning (2013)	초기 군집 제안. oracle과 출력 가정 확인용
Kerenidis et al., q-means, NeurIPS 2019	qRAM·정밀도·조건수·군집 조건. 초록의 복잡도와 서지 확인
Pérez-Salinas et al., Data re-uploading, Quantum 2020	재업로드·근사 능력. 초록 확인, 전체 정리 재증명 없음
Schuld, Sweke, Meyer, data encoding, PRA 2021	Fourier 관점. 초록·공개 본문 검색 대조, 작은 회로 직접 전개
Schuld et al., analytic gradients, PRA 2019	Parameter shift. 초록·본문 검색 대조, 특수 경우 직접 계산
Stokes et al., Quantum Natural Gradient, Quantum 2020	상태공간 계량. 정의 확인, 수렴 성능 독립 재현 없음

커널·학습 가능성·평가

문헌	읽을 이유·확인 범위
Havlíček et al., feature spaces, Nature 2019	실제 장치 proof of concept. 초록·출판 서지 대조
Huang et al., Power of data, Nature Communications 2021	데이터·projected kernel·고전 비교. 본문 식과 discussion 확인
Thanasilp et al., kernel concentration, Nature Communications 2024	커널 집중의 조건. 초록·공개 본문 검색 확인
McClean et al., barren plateaus, Nature Communications 2018	무작위 회로의 기울기 분산. 초록 확인, 노트의 product 예제는 자체 유도
Caro et al., generalization, Nature Communications 2022	조건부 일반화 gap. 본문 framework·정리·discussion 확인

문헌	읽을 이유·확인 범위
Bowles, Ahmed, Schuld, benchmarking (2024)	고전 기준선·튜닝의 역할. 초록 확인, 대규모 benchmark 재실행 없음
Cerezo et al., absence of plateaus and simulability, Nature Communications 2025	Perspective의 본문·예외 확인. 보편 불가능성 정리가 아님
Mele et al., non-unital noise and plateaus, Nature Physics 2026	본문 Theorems 1, 5, 8·Proposition 3 확인. 국소 관측량·앙상블·정확도 조건 유지

양자 데이터·생성·내결함성

문헌	읽을 이유·확인 범위
Huang, Kueng, Preskill, classical shadows, Nature Physics 2020	원 방법·서지 확인. 로컬 Pauli 예제는 직접 유도
Huang et al., learning from experiments, Science 2022	양자 데이터 접근·표본 우위. 초록·서지 확인, 장치 결과 독립 재현 없음
Tang, quantum-inspired recommendation, STOC 2019	Sample-and-query 접근과 탈양자화. 입력 가정 구별
Liu and Wang, differentiable Born machine, PRA 2018	샘플 기반 생성 학습. 수식의 작은 예는 자체 구성
Harrow, Hassidim, Lloyd, linear systems, PRL 2009	해 상태·조건수·출력 비용. 전체 자원 추정 재현 없음
Gilyén et al., QSVT, STOC 2019	Block encoding과 다항식 변환의 원문
Temme, Bravyi, Gambetta, error mitigation, PRL 2017	완화의 원 연구. 실습의 ZNE·분산은 별도 toy 계산
Quek et al., mitigation limitations, Nature Physics 2024	Worst-case 하한. 모든 현실 회로의 동일 비용을 뜻하지 않음

최신 선택 문헌

문헌·상태	이번 노트의 확인과 한계
Liu et al., photonic learning, Science 2025	최초 2025-02-11, 온라인 2025-09-25. 초록·논문 서지·공개 본문의 핵심 비교 조건 대조. 장치 재실행 없음
Lewis, Gilboa, McClean, shallow networks, Nature Communications 2026	온라인 2025-12-31. 본문의 QSQ 접근·gradient/ correlational SQ 하한·미해결 범위 확인
Zhao et al., massive classical data, arXiv v2	최초 2026-04-08, v2 2026-10-01, 프리프린트. 초록·문제 설정·주정리 서술·실자료 및 자원 설명 대조. 전체 169쪽 증명·공식 코드 독립 재현 없음
Cotler, Gong, Kannan, Noisy quantum learning theory, Nature Communications 2026	온라인·VOR 날짜 구별. 잡음 인터페이스·허용 메모리·측정 설정의 조건 대조. 모든 학습의 불가능성으로 확대하지 않음
Kannan, Putterman, Cotler, fault-tolerant experiments, arXiv v2	최초 2026-05-03, v2 2026-09-06, 프리프린트. 즉시 부호화와 비교 기준·수치 사례 확인. 실제 내결함성 센서 실험이 아님

위 최신 연구를 포함했다고 해서 기준일의 모든 QML 논문을 검토한 것은 아니다. 저자의 보고, 노트의 해설, 후속 프로젝트 제안을 구별한다. 논문의 전체 증명이나 원 데이터를 독립 검증했다고 주장하지 않는다.

2.0 개정에서 추가 확인한 13-18강의 문헌

아래는 위 표의 기존 확인 범위를 보존하면서 추가한 독해 기록이다. '본문 확인'은 명시한 절·식·그림의 대조를 뜻하며 논문 전체 증명의 검증이나 장치·대규모 계산의 독립 재현을 뜻하지 않는다. 본문의 작은 회로, 분산, 패리티, 두 스핀 VMC와 block encoding 예제는 노트가 별도로 유도한 교육 자료다.

1차 문헌·연결 강의	2.0에서 확인한 위치와 한계
Huang, Kueng, Preskill, classical shadows 공개본, 13강	**Procedure**, **Rigorous performance guarantees**, **Predicting expectation values of global observables (non-example)**와 Supplementary **1 B, Example 2**를 대조했다. 측정 앙상블·shadow norm·관측량 locality가 표본 비용을 함께 정한다. 전체 정보이론적 하한 증명을 재검증하지 않았다.
Tang, quantum-inspired recommendation 공개본, 14강	**2.2 Sampling**, **3 Data Structure**, **4.1 Vector Sampling**의 접근·구축 조건을 확인했다. 노트의 내적 불편 추정은 자체 교육 유도이며 추천 알고리즘 전체의 증명·실행을 대신하지 않는다.
Cotler, Huang, McClean, Revisiting dequantization and quantum advantage in learning tasks, 14강	초록·서지에서 sample-and-query 접근과 양자 상태 복사본 입력의 비대칭을 확인했다. 학습 과제별 접근 모델을 구분하는 자료이며 모든 탈양자화 결과의 부정으로 사용하지 않는다.
Liu, Wang, Differentiable Learning of Quantum Circuit Born Machine 공개본, 15강	**II Model and Learning algorithm**, **II.1 Quantum Circuit Architecture Design**의 Born 분포·표본 기반 손실·회전 규약을 확인했다. 노트의 두 큐비트 생성기와 MMD 표본 계산은 원 실험의 재현이 아니다.
Rudolph et al., Trainability barriers and opportunities in quantum generative modeling, npj Quantum Information 10, 116 (2024), 15강	초록·공개 본문 검색의 **Framework**, **Trainability analysis on loss functions**, **Discussion**에서 explicit·implicit 손실과 고차 상관의 식별 문제를 대조했다. 훈련 표본·측정 예산·손실 구조에 따른 조건부 결과이며 일반화 성공이나 모든 생성기의 불가능성을 보장하지 않는다.
Huang et al., Generative quantum advantage for classical and quantum problems 공개본, 2025-09-10 v1 프리프린트, 15강	**Fig. 2** 설명과 **Appendix C.3**의 실험 설정을 확인했다. 새 68물리 큐비트 실험·816 shallow 큐비트 표현, 기존 결과에 근거한 34,304 shallow 규모의 추론을 구분했다. 816 규모 자체에 대한 저자의 beyond-classical 제한을 유지하며 대형 학습·샘플링을 독립 재현하지 않았다.
Schatzki et al., Theoretical guarantees for permutation-equivariant quantum neural networks, npj Quantum Information 10, 12 (2024), 16강	초록·공개 본문 검색의 **Definitions 2-3**, **Lemma 1**, **Theorem 1**, **Methods: Building S_n-equivariant operators**를 대조했다. 특정 생성자·측정·블록별 무작위화 조건을 모든 대칭 회로로 확대하지 않는다. 그래프 분류 수치 실험은 재실행하지 않았다.
Wiersema et al., Geometric quantum machine learning with horizontal quantum gates 공개본, Physical Review Research 7, 013148 (2025), 16강	**II.3 Equivariant Quantum Gates**, **II.4 Horizontal Quantum Gates**, **III Starting from a symmetry: Homogeneous spaces**를 확인했다. 엄격한 교환 조건과 다른 설계의 구분을 읽었으며 원 논문의 최적화 성능·전체 기하학적 구성을 재현하지 않았다.

1차 문헌·연결 강의	2.0에서 확인한 위치와 한계
Carleo, Troyer, Solving the Quantum Many-Body Problem with Artificial Neural Networks, Science 355, 602 (2017), 16강	서지·초록에서 신경망 파동함수의 변분 표현과 지정된 스핀계 적용을 확인했다. 노트의 VMC 식·두 스핀 손계산은 자체 유도이며 원문의 수치 정밀도·동역학 결과를 재현하지 않았다.
Zaklama, Guerci, Fu, Attention-Based Foundation Model for Quantum States, v2 2026-06-17 프리프린트, 16강	v2 날짜·초록의 입력 구성과 해밀토니안 매개변수·계 크기 사이의 상태 예측 목적을 확인했다. 전체 훈련·자료·모든 물질계에 대한 일반화를 검증하지 않았다. 고전 신경망으로 양자 상태를 표현하는 연구를 QPU 학습 결과와 구분한다.
Gilyén et al., QSVT 공개본, STOC (2019), 17강	**1 Introduction**, **3.1 Quantum signal processing**, **3.2 Singular value transformation**의 구성과 공개 본문의 다항식 boundedness·parity 설명을 확인했다. 노트의 작은 block encoding은 직접 검산했으나 전체 QSVT 구성 증명·최적 선형계 복잡도·논리 자원 추정을 재현하지 않았다.
Brassard et al., Quantum Amplitude Amplification and Estimation 공개본, 17강	**2 Quantum amplitude amplification**, **4 Quantum amplitude estimation**, **Theorem 12**의 coherent 준비·역연산, 쿼리 단위와 상수 성공확률 조건을 확인했다. 쿼리 개선을 짧은 샷 수나 실제 장치 총시간의 동일한 개선으로 바꾸어 적지 않는다.
Liu et al., photonic learning 공개본, 18강	**Process reconstruction**, **Provable, scalable quantum advantage**, **Fig. 2·3**를 구분했다. 100모드 재구성의 11.8 orders 비교는 작은 모드 수 fit에서 외삽한 기준선이며, 별도 가설 검정의 entanglement-free 하한 비교와 같은 증거가 아니다. 원문 측정 자료·장치를 재현하지 않았다.
Kannan, Putterman, Cotler, quantum uploading v2 공개본, 17-18강	**II.1 Surface-Code State Injection**, **II.2 Uploading and noisy quantum learning theory**, **III.1 Classical shadow tomography**, 비형식 **Theorem 2**와 보충 **S5**의 위치·범위를 확인했다. 18강의 완료 양식은 즉시 부호화·raw 비교와 잡음 조건을 적고, 완전한 정밀도·실패확률·상수 범위는 추가 확인 항목으로 남겼다. 기술 증명 전체와 천문 영상 수치 예시는 독립 재현하지 않았다.

최근 논문 독해에서는 서지·초록 확인, 지정 본문 대조, 노트의 독립 손계산, 실제 실험 재현을 서로 다른 수준으로 기록했다. 최신 사례의 미확인 기술 가정은 18강 읽기 양식에 남기며, 노트에 익숙한 오차 척도나 비용식을 원 정리의 가정 대신 채워 넣지 않는다.

소프트웨어·그림·재현 자료

PennyLane 공식 문서와 해당 AmplitudeEmbedding·RY 규약을 확인했다. 실제 실행 버전과 고정 의존성은 실습 안내·결과 JSON을 따른다. API의 현재 문서와 설치 버전은 다를 수 있다.

코드·합성 데이터·손계산은 이 노트용 교육 예제다. 수식은 MathJax로 조판했고 교육용 그래프 3개는 본문의 해석식을 NumPy·Matplotlib로 계산했다. 물리 장치 사진·논문 도표를 가져오지 않았다. 생성 코드와 식·조건·버전 기록은 `artifacts/build_figures.py`와 `artifacts/figure-manifest.json`에 보존한다. 본문 글꼴은 Google Fonts 배포 Nanum Gothic의 OFL 허용 범위에서 별도 이름으로 subset하여 내장했고 라이선스를 배포본에 포함했다.